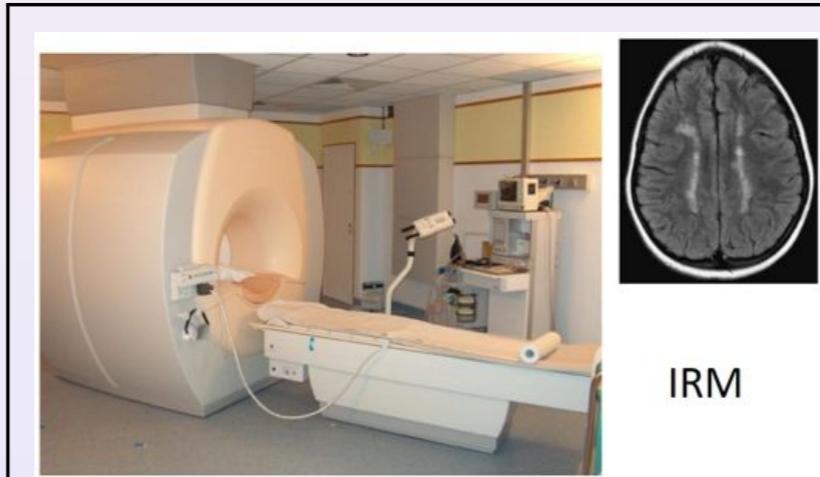
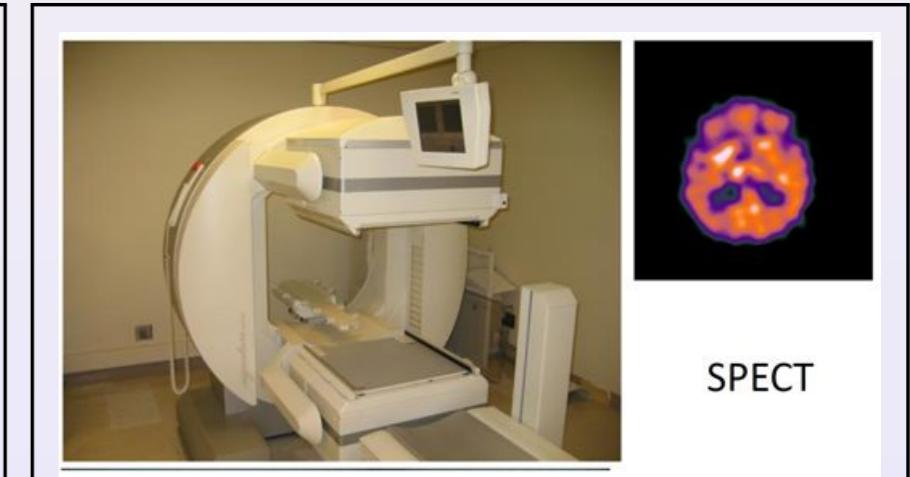




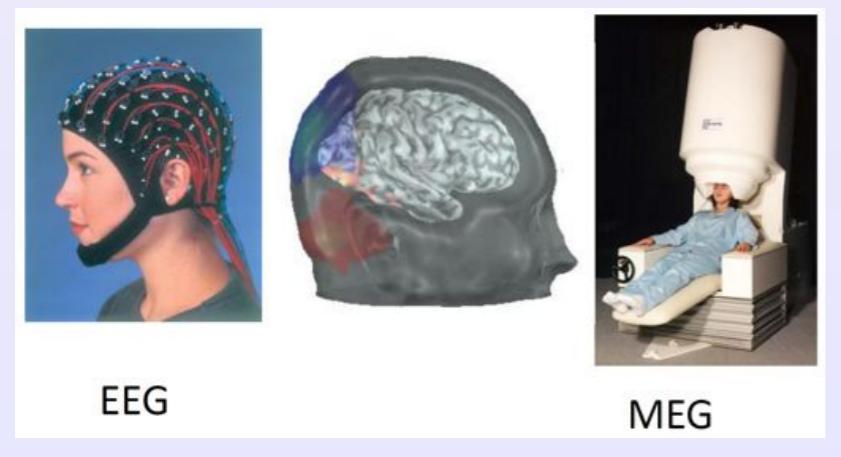
TEP



IRM



SPECT



EEG

MEG

# IMN-530

Reconstruction et analyses d'images médicales

-

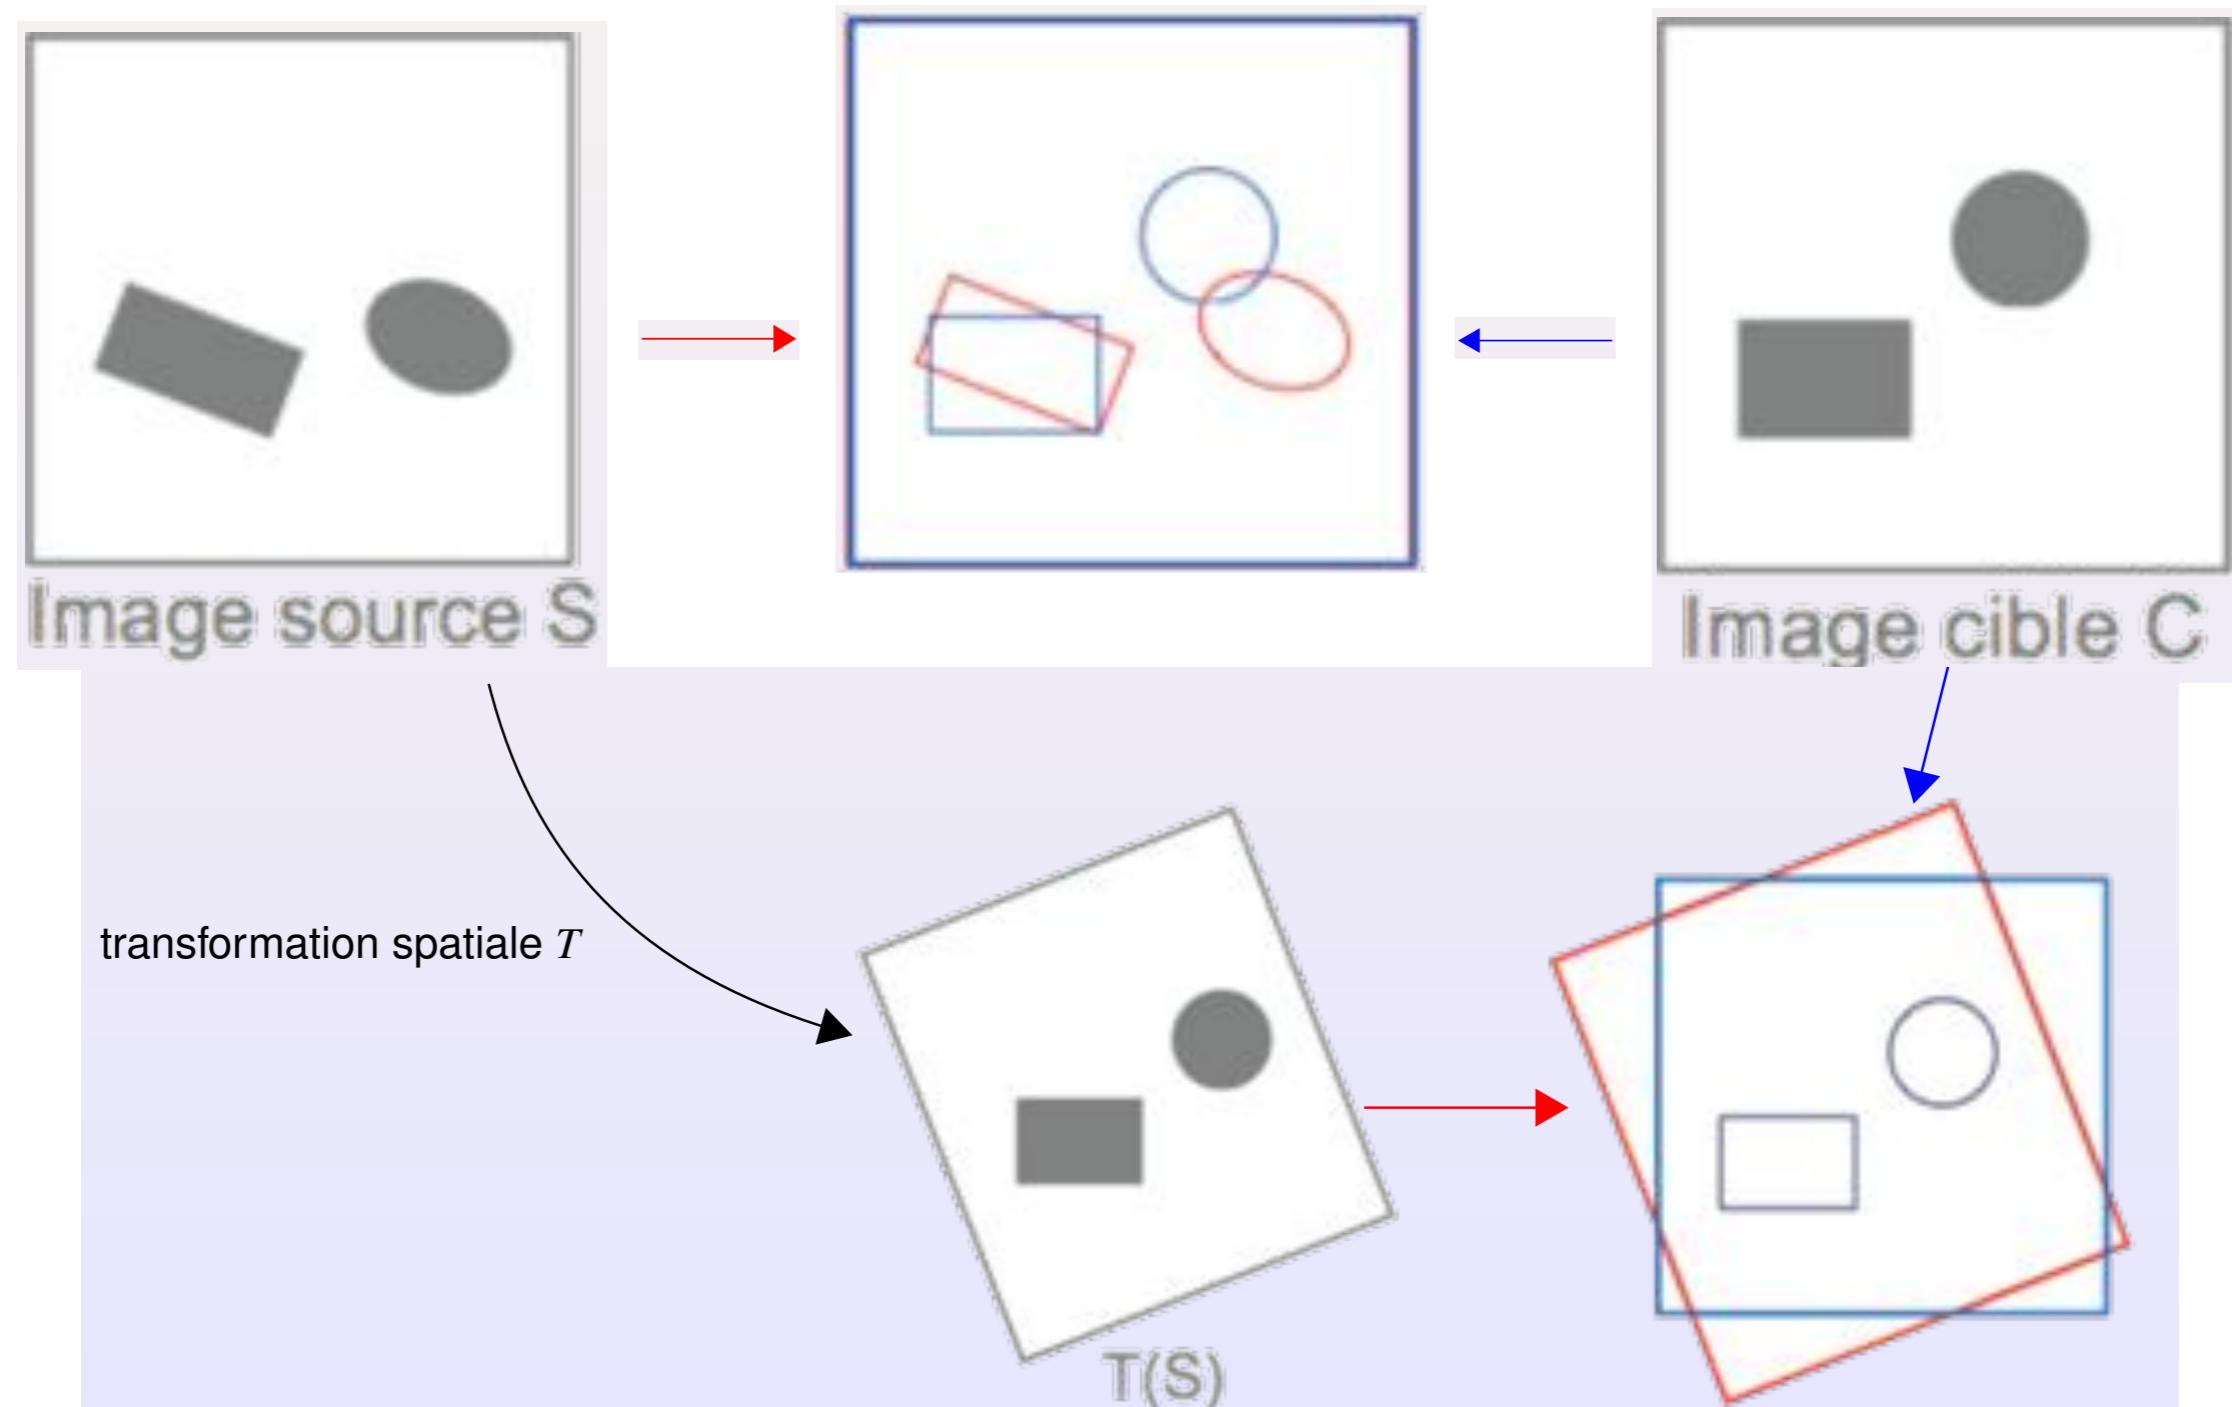
RECALAGE

# Recalage

- Mise en correspondance de deux images (supposées représenter le même objet)
- Quoi?
- Pourquoi?
- Comment?
- Exemples
- Excellentes lectures pour en savoir plus:  
*Roche et al, Rapport de recherche INRIA 1998*  
*Malandain HDR 2006*  
*Bernier MSc 2011*

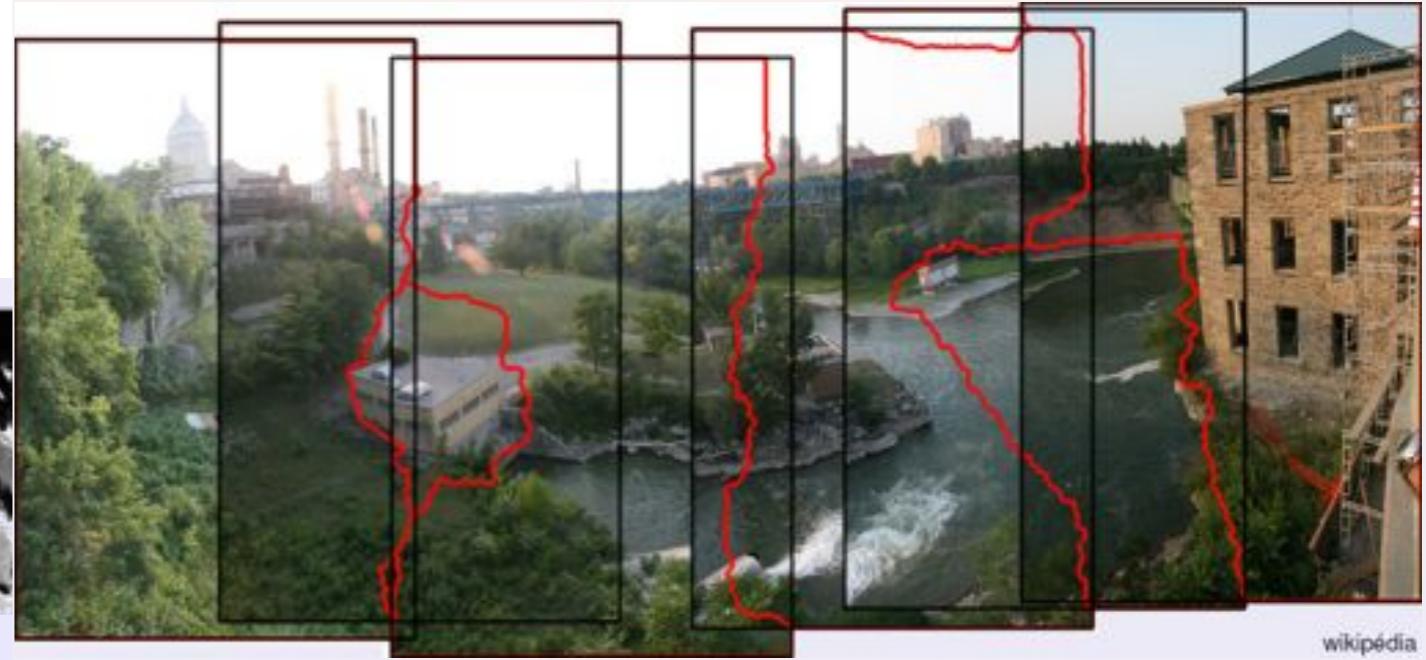
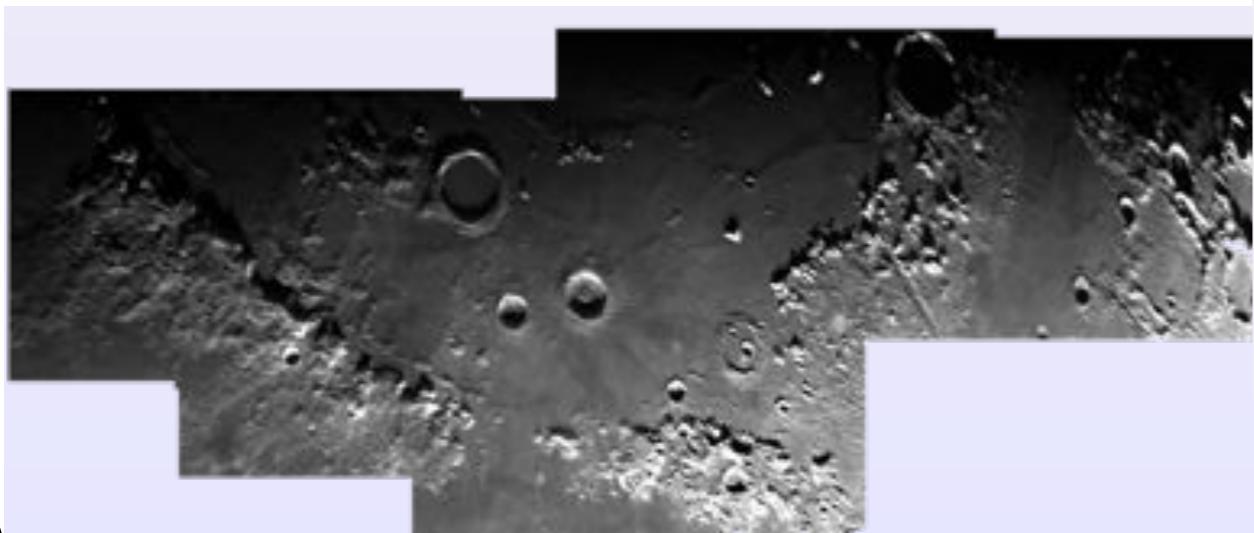
# Recalage - quoi?

- Deux images S et C : cherche  $T$  tel que  $T(S)$  ressemble à C



# Recalage : applications

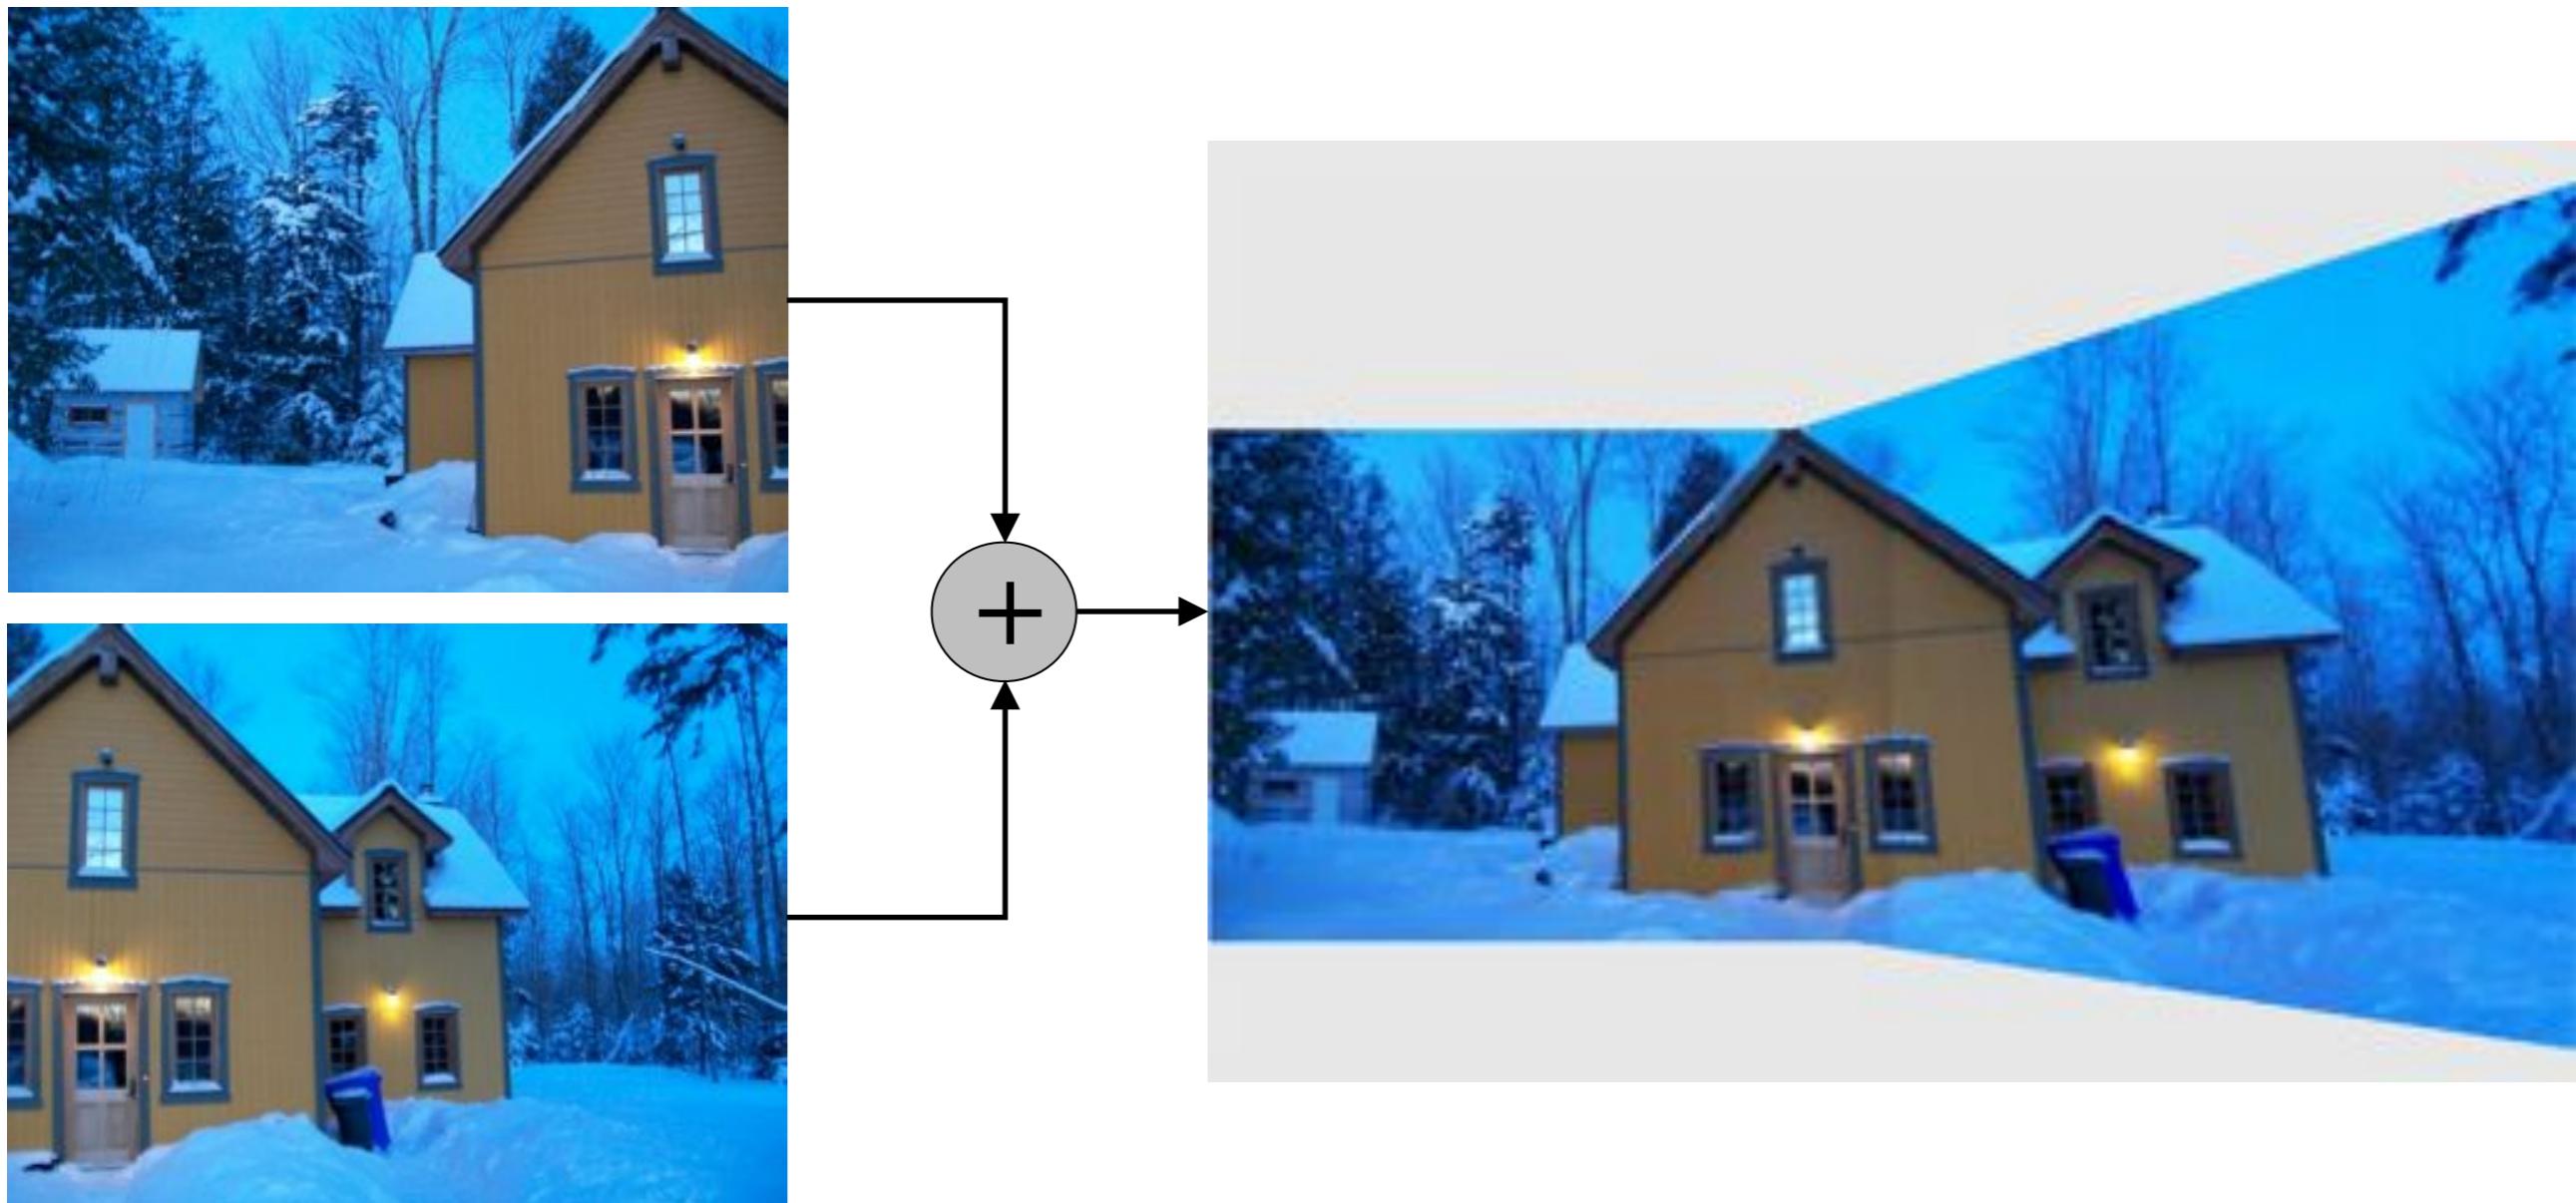
- Outil **fondamental** en analyse d'images médicales, mais pas uniquement
- Où ailleurs en imagerie?
- Crédit d'images panoramiques
- Mosaïques
- Astronomie



wikipédia

# Systèmes par mosaïque

Ce type d'approche consiste à **construire les images panoramiques** à partir d'une **série d'images** prises avec le même système optique. On peut, par exemple, utiliser une caméra en rotation autour de son centre optique.



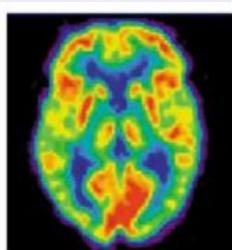
# Systèmes par mosaïque

Évidemment, un nombre arbitraire d'images peut être utilisé...

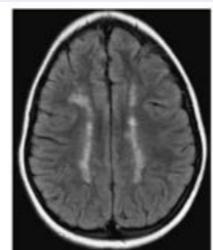


[Microsoft research, 2007] [Mode panoramique du iPhone est un autre bel exemple]

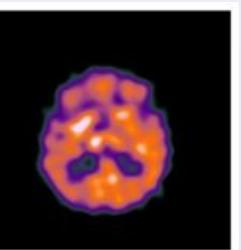
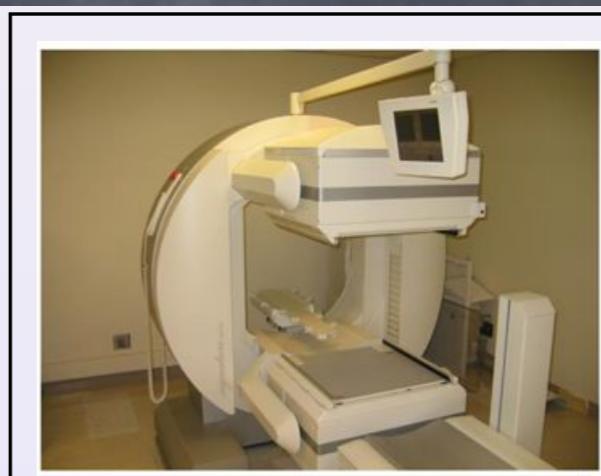
# Exemples en imagerie médicale



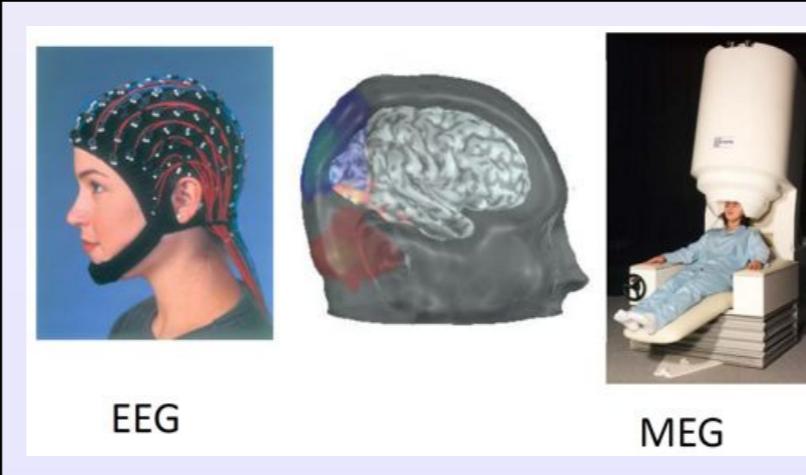
TEP



IRM



SPECT



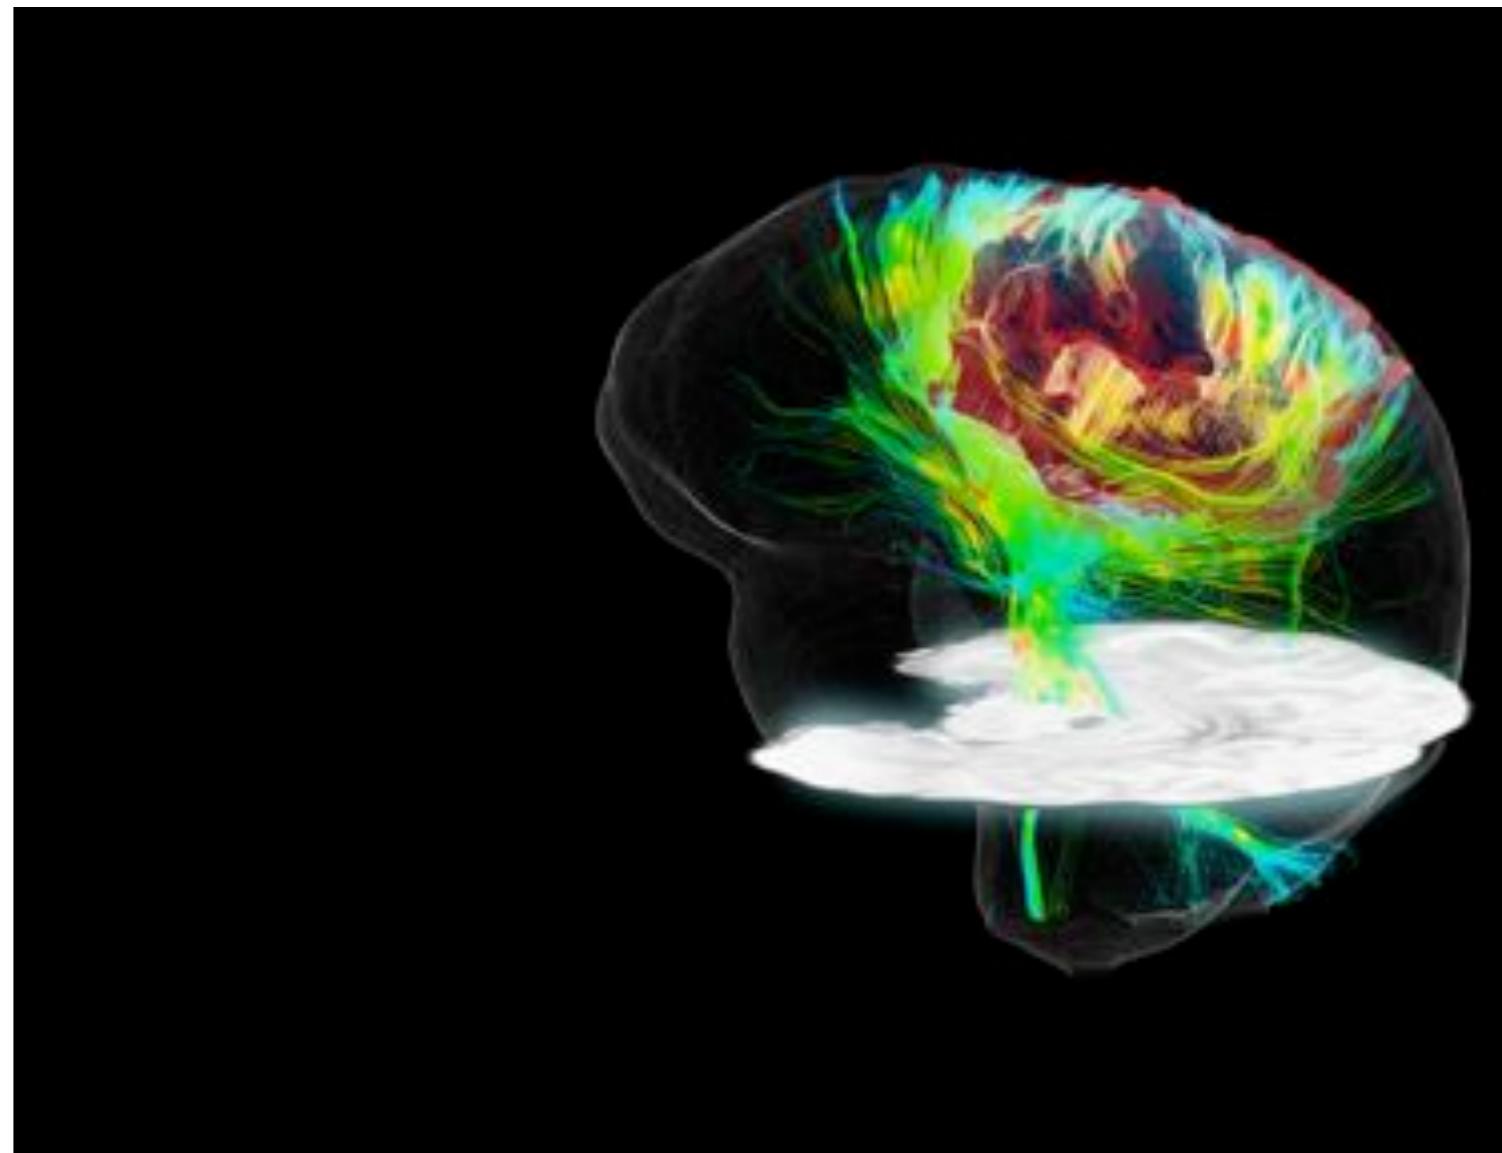
EEG



MEG

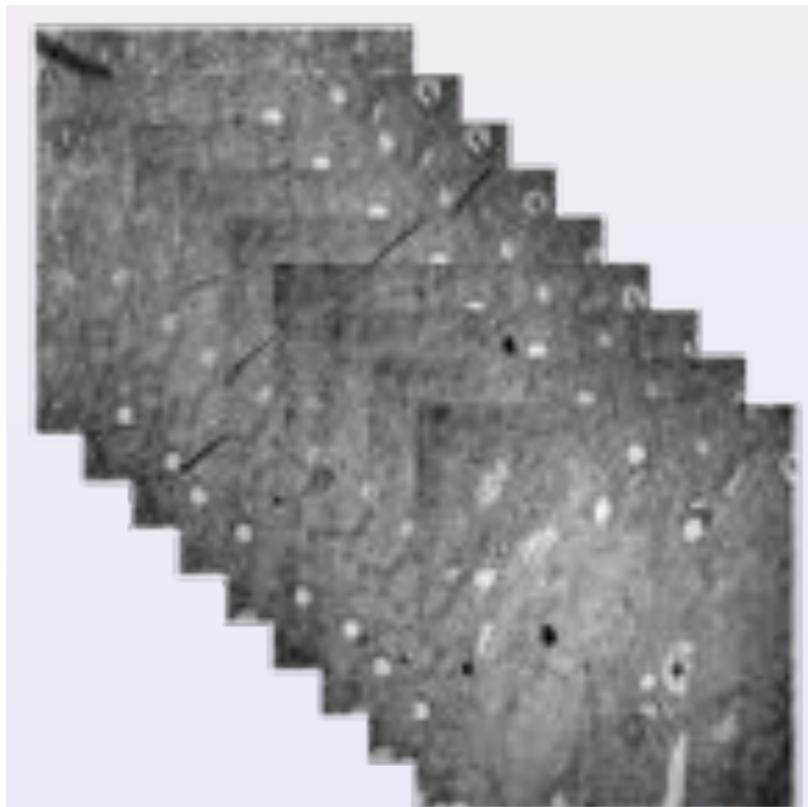
# Illustration : la chirurgie assistée par imagerie

- Examens “statiques” - recherche d’une lésion / tumeur (IRM et ou TDM)
- Examens “dynamiques”
  - imagerie TEP
  - imagerie fonctionnelle
- IRM pré-opératoire (la veille de l’examen)
  - Imagerie de diffusion, fonctionnelle, angiographie
  - Imagerie anatomique avec et sans rehaussement gadolinium (vaisseaux sanguins)
- Voir votre TP3/projet.
- Voir PDF annexe sur la chirurgie de l’épilepsie



# Recalage en imagerie médicale

- Reconstruction d'un volume 3D
  - À partir d'une série de coupes 2D contiguës (microscopie, épaisseur de coupe 60 nm environ)



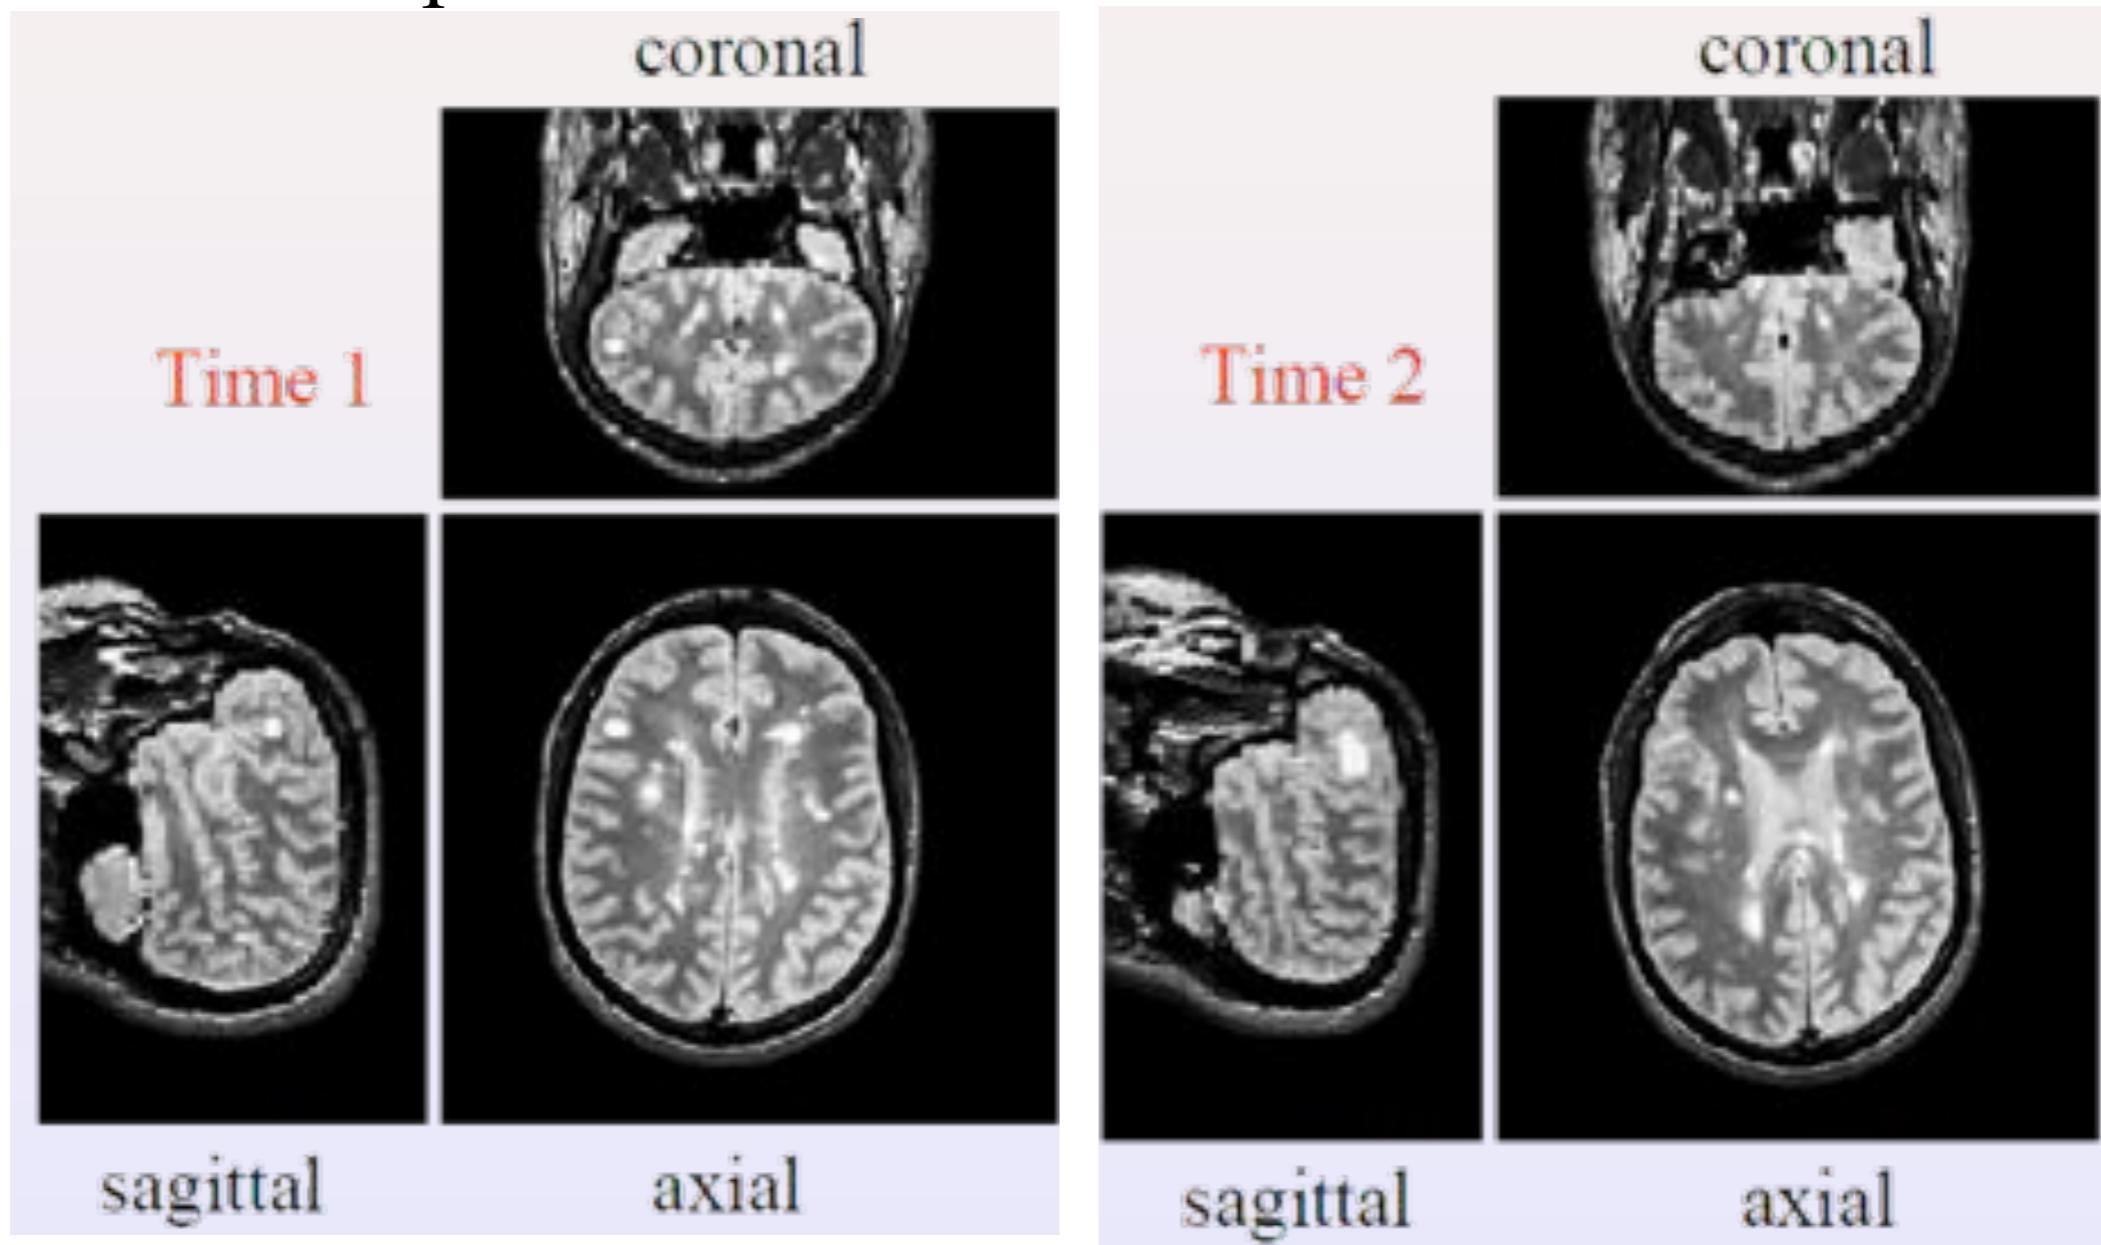
*Series of successive 2D slices*



*Orthogonal views of the reconstructed volume using affine transformations*

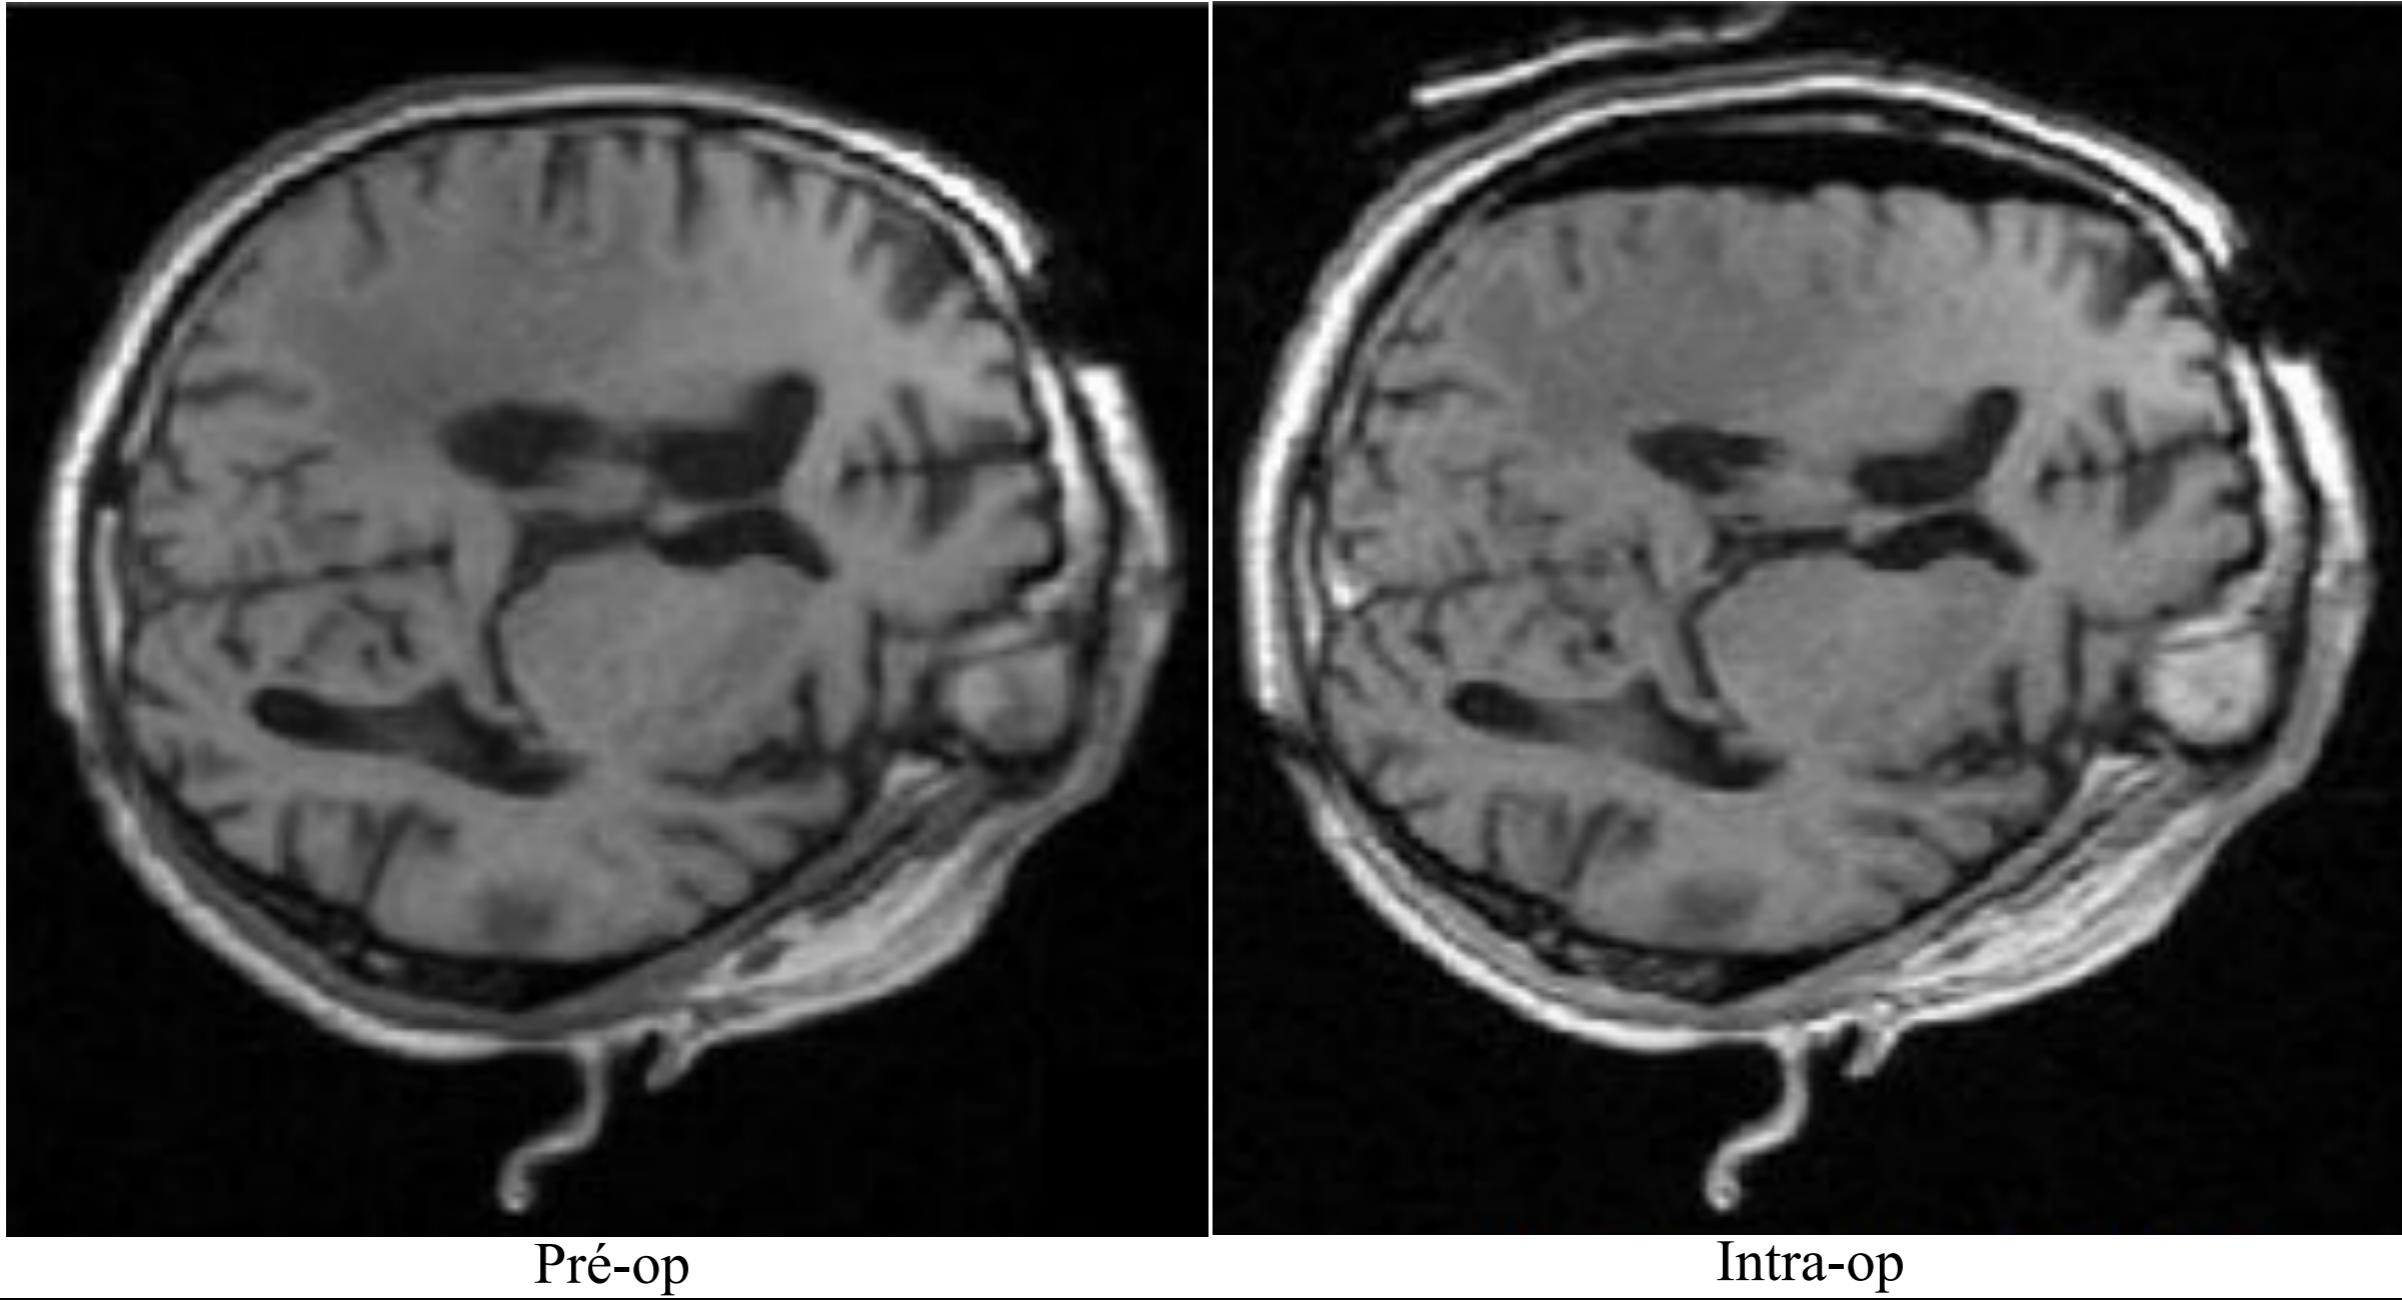
# Recalage en imagerie médicale

- Évolution temporelle



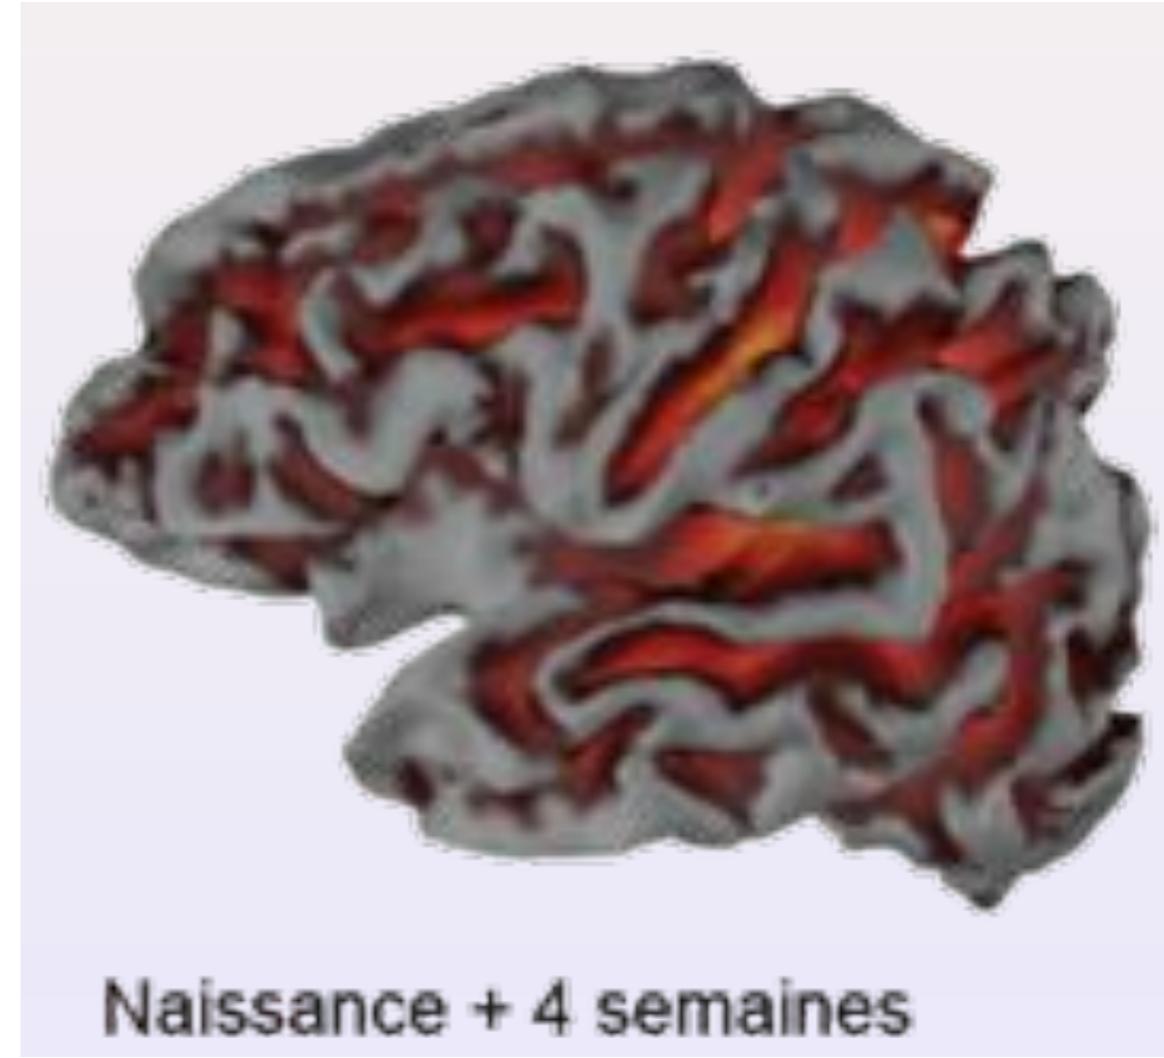
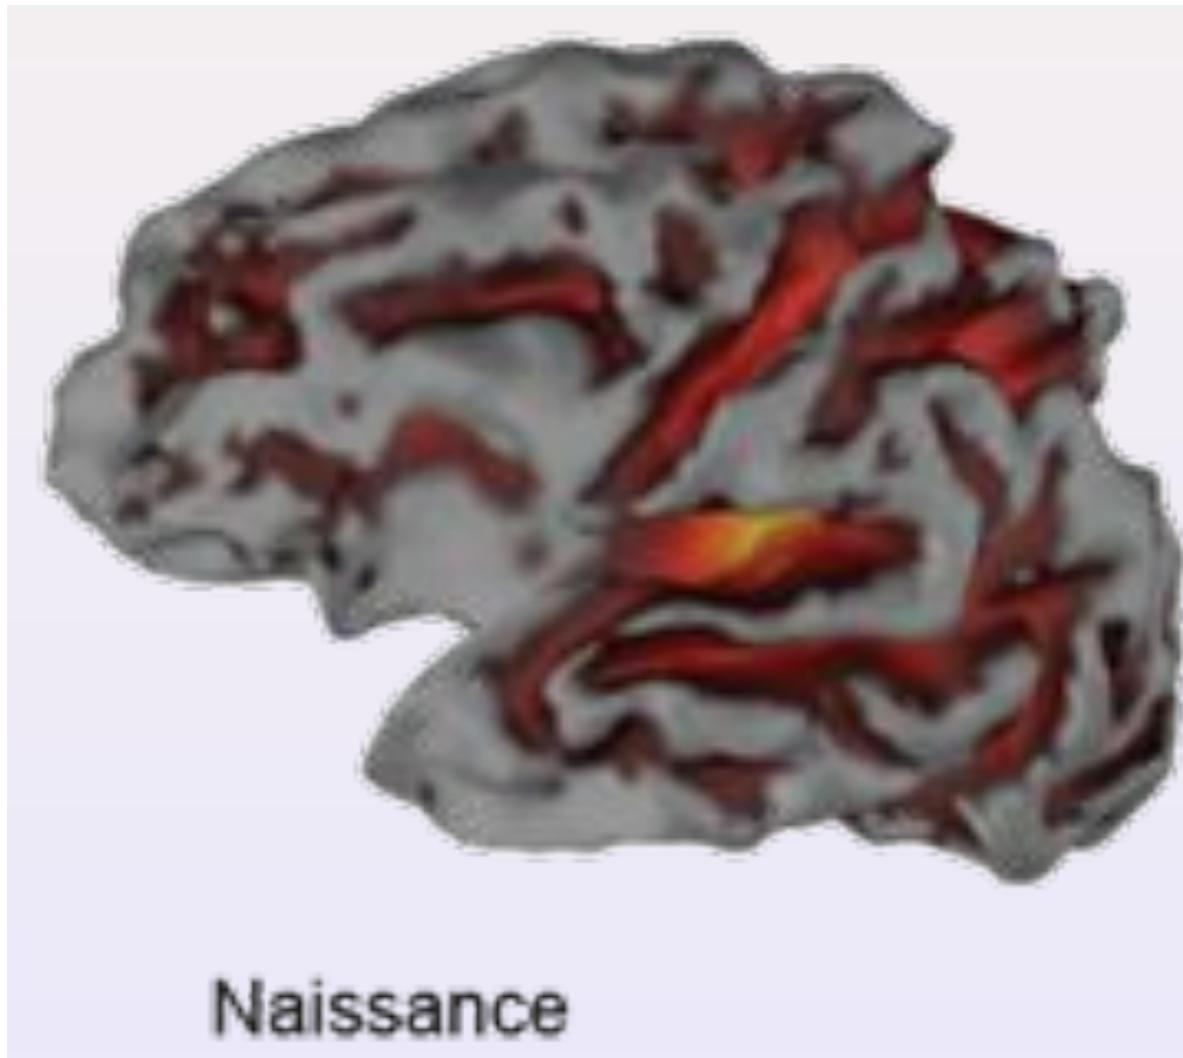
# Recalage en imagerie médicale

- Évolution temporelle (*brain-shift*)



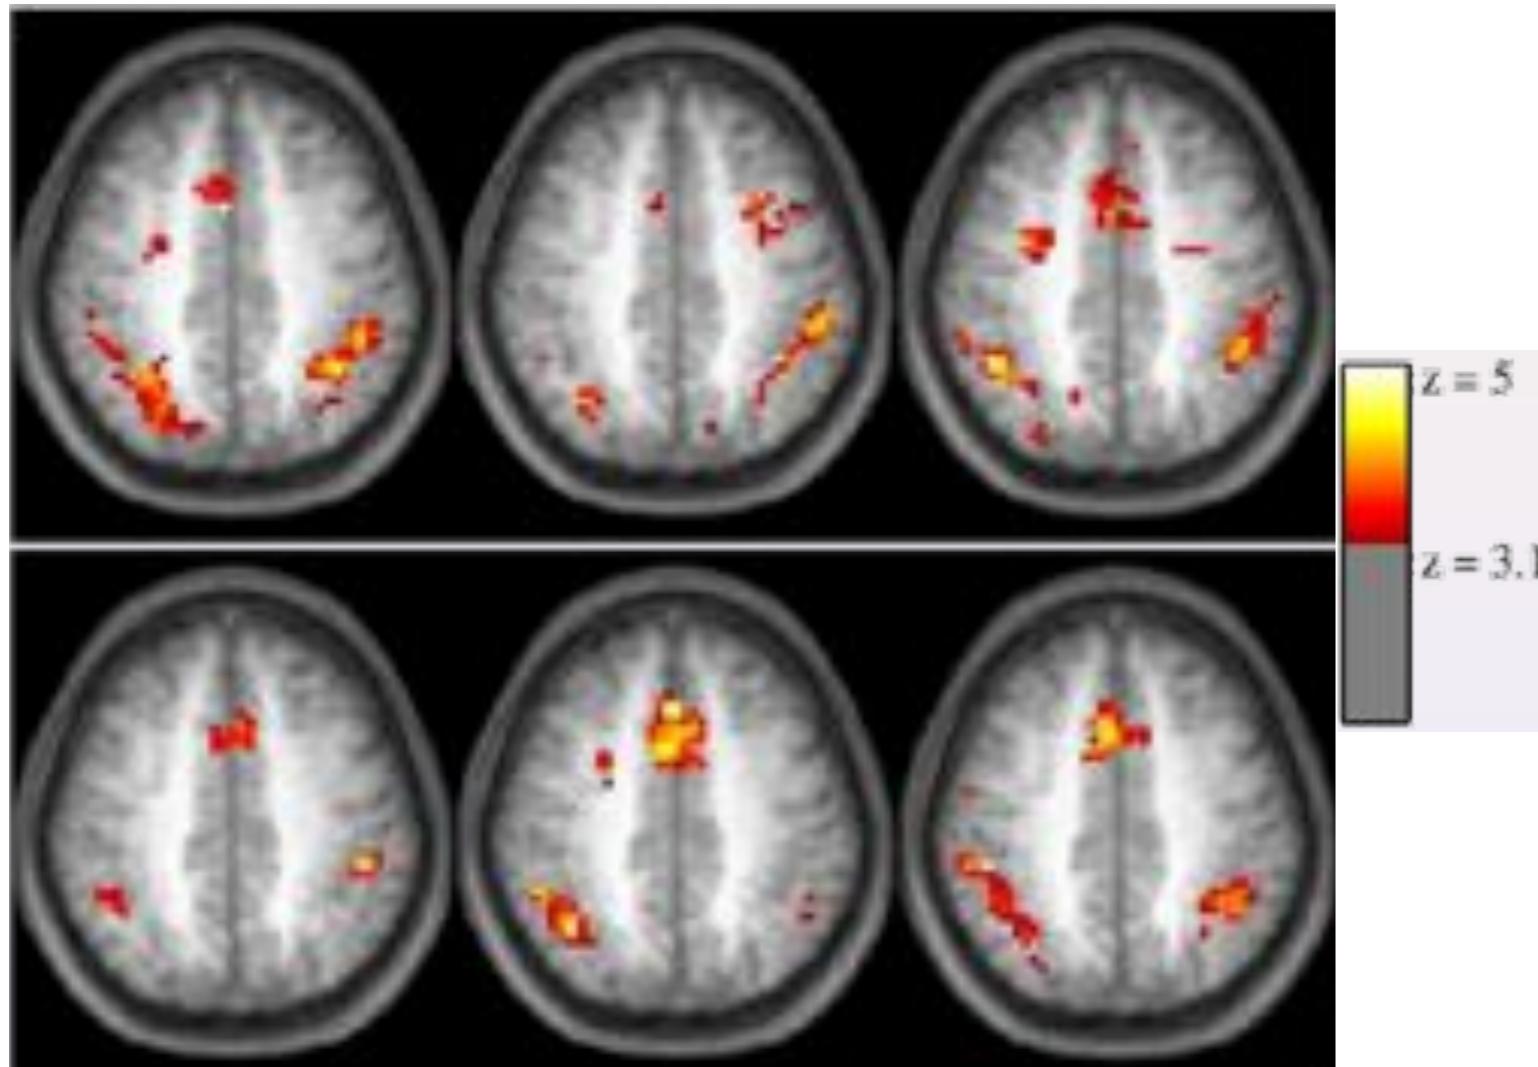
# Recalage en imagerie médicale

- Évolution temporelle, développement cérébral



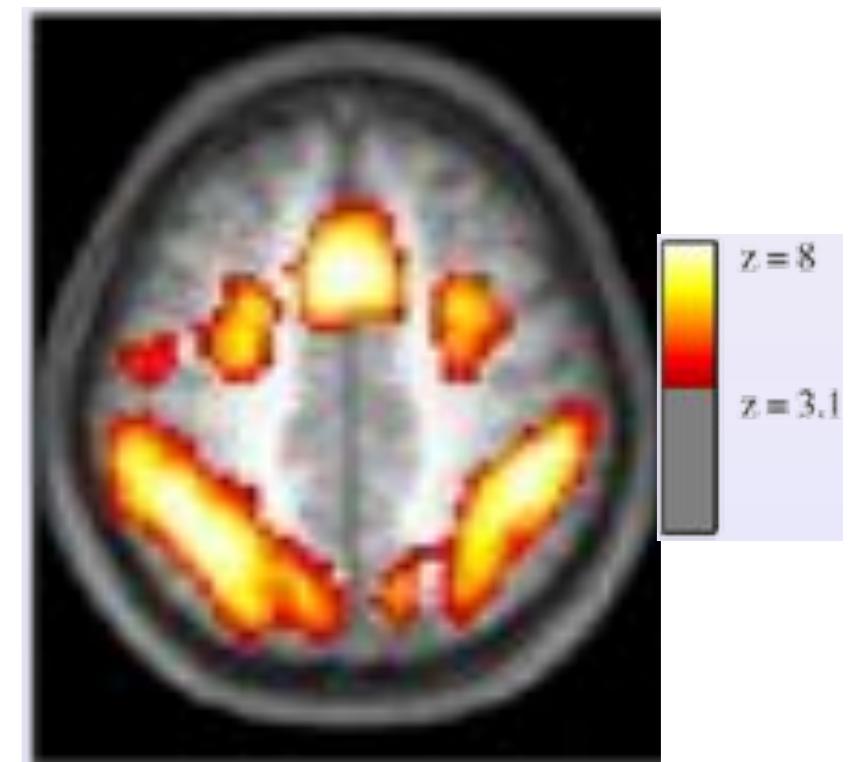
# Recalage en imagerie médicale

- Comparaison entre différents sujets



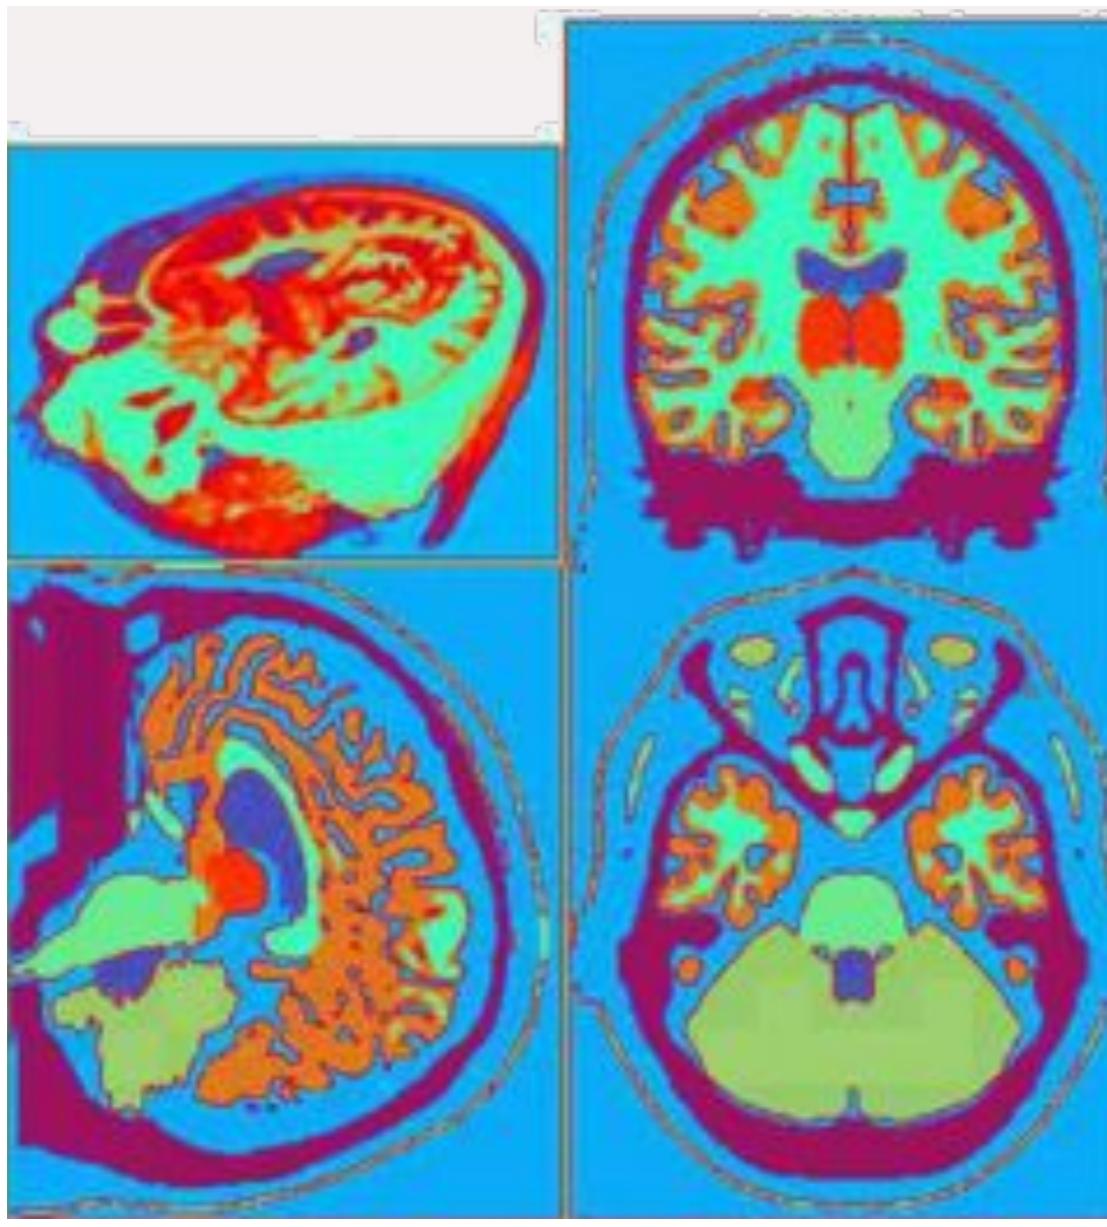
Individu

Moyenne du groupe



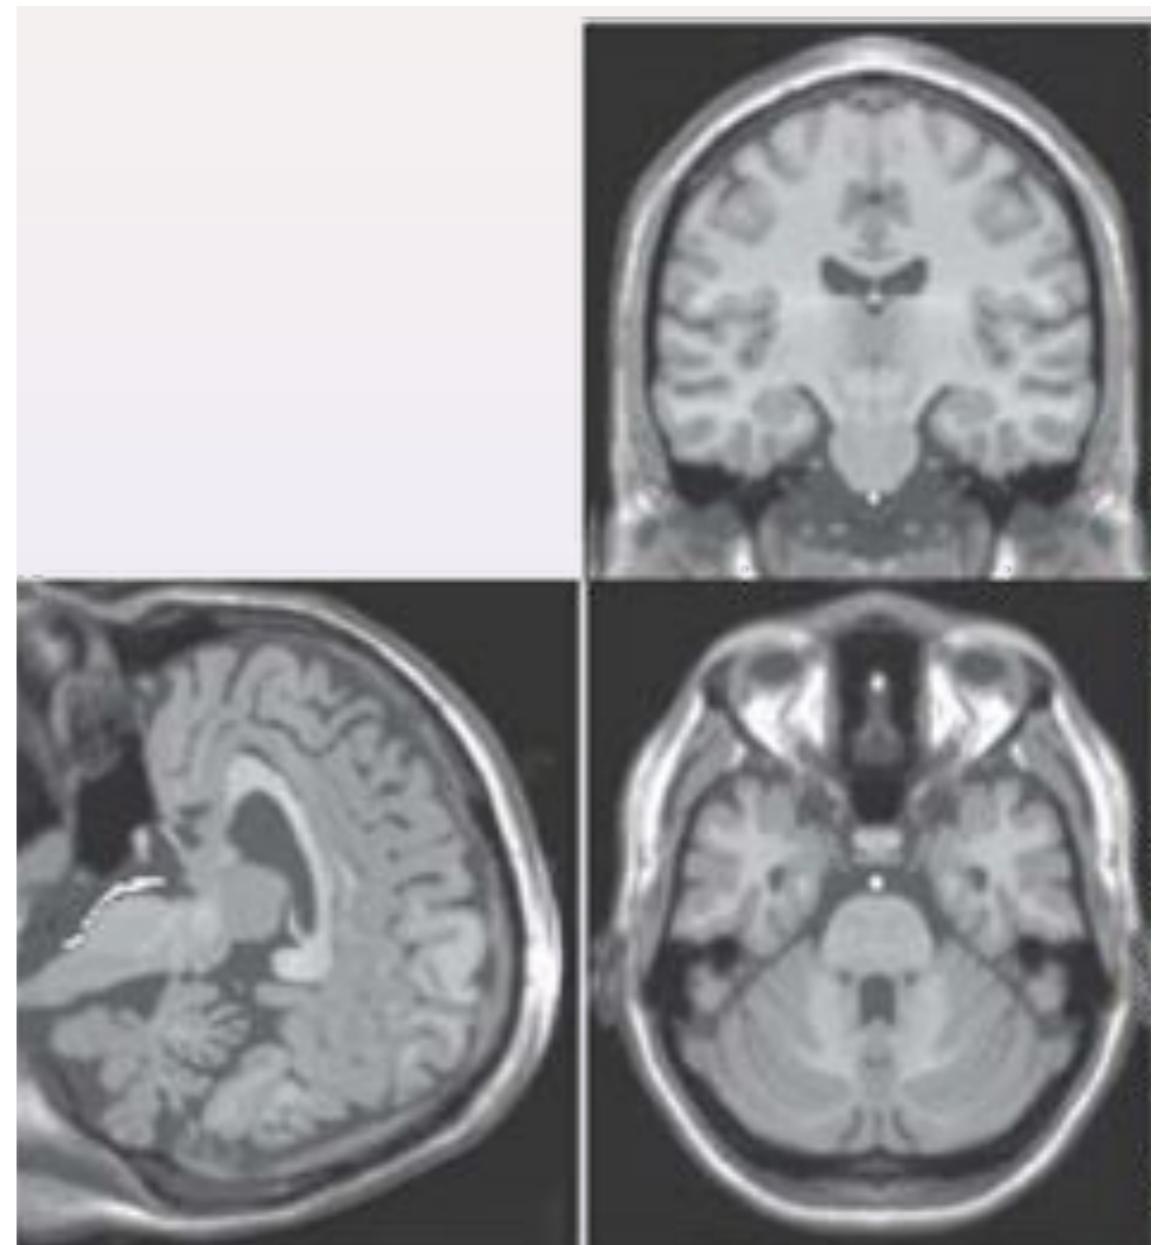
# Recalage en imagerie médicale

- Superposition sur un atlas



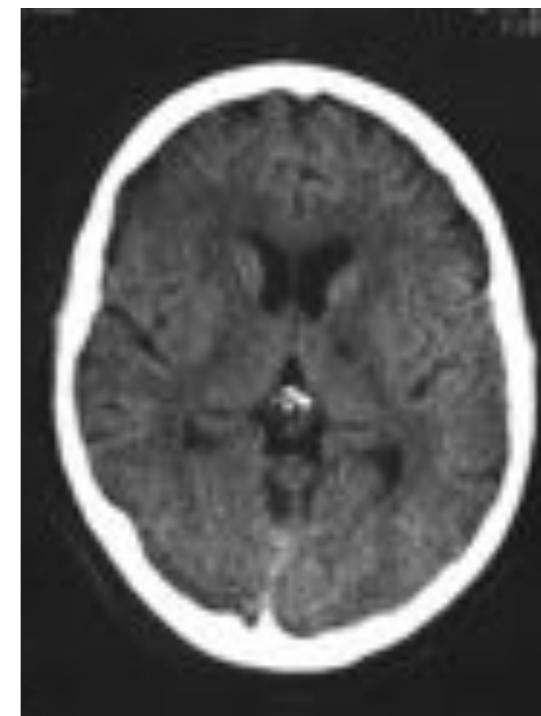
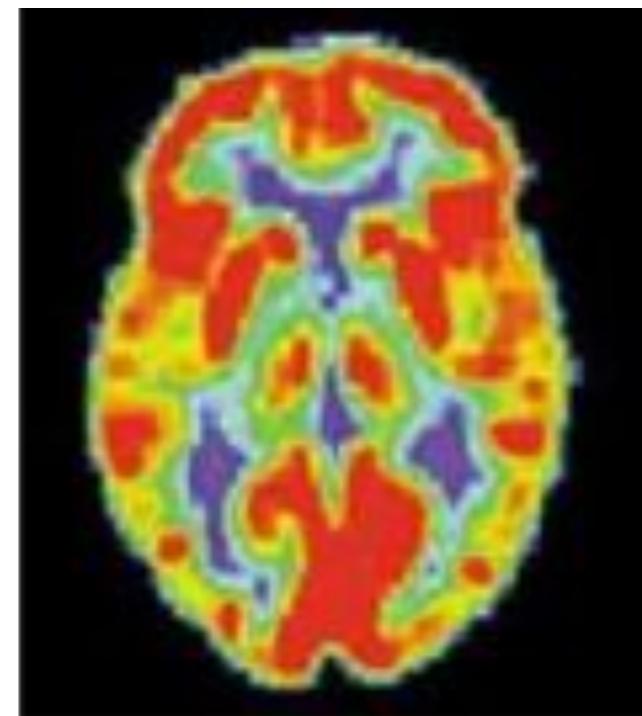
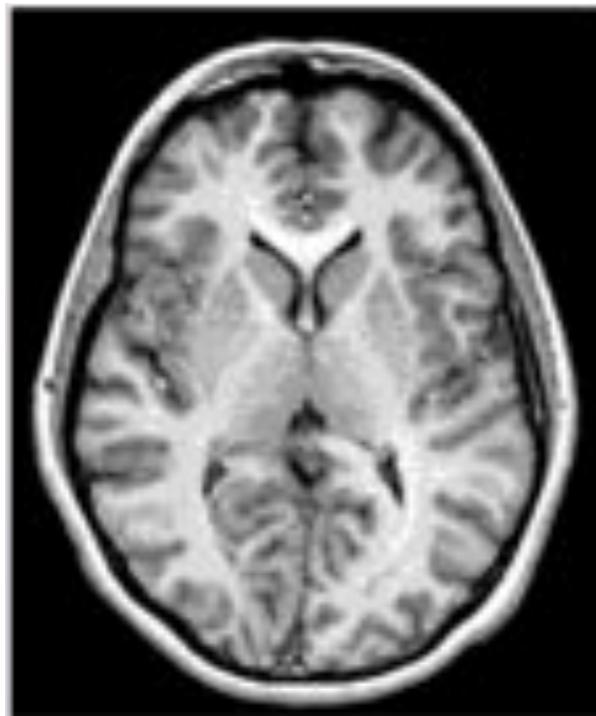
Atlas

IRM

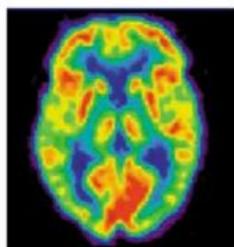


# Recalage en imagerie médicale

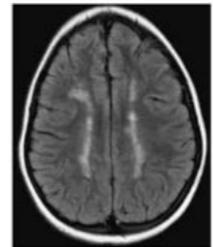
- Fusion de modalité - certainement le plus important et répandu



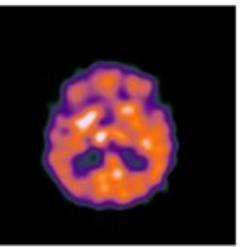
# Les maths derrière le recalage



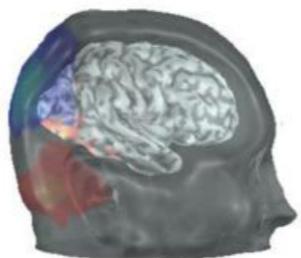
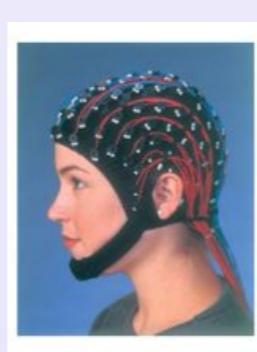
TEP



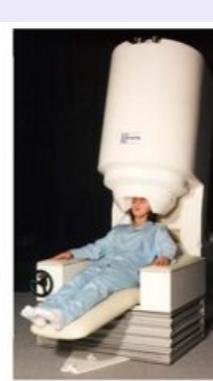
IRM



SPECT



EEG



MEG

# Principe des méthodes de recalage

- L'approche générale du recalage consiste à **optimiser un critère de similarité** entre les deux images
- Ce critère est la fonction de **transformation** appliquée entre les 2 images



# Principe des méthodes de recalage

- Tout se joue sur 3 choix importants:
  - Critère de similarité
  - Transformations considérées
  - Méthode d'optimisation

# Critère de similarité

- Supposons que l'on se donne un critère de similarité:  
 $\text{Simil}(I, J)$  qui mesure la “*ressemblance*” entre deux images I et J

$$\text{Simil}(\text{Image 1}, \text{Image 2}) = \text{:(sad face)}$$

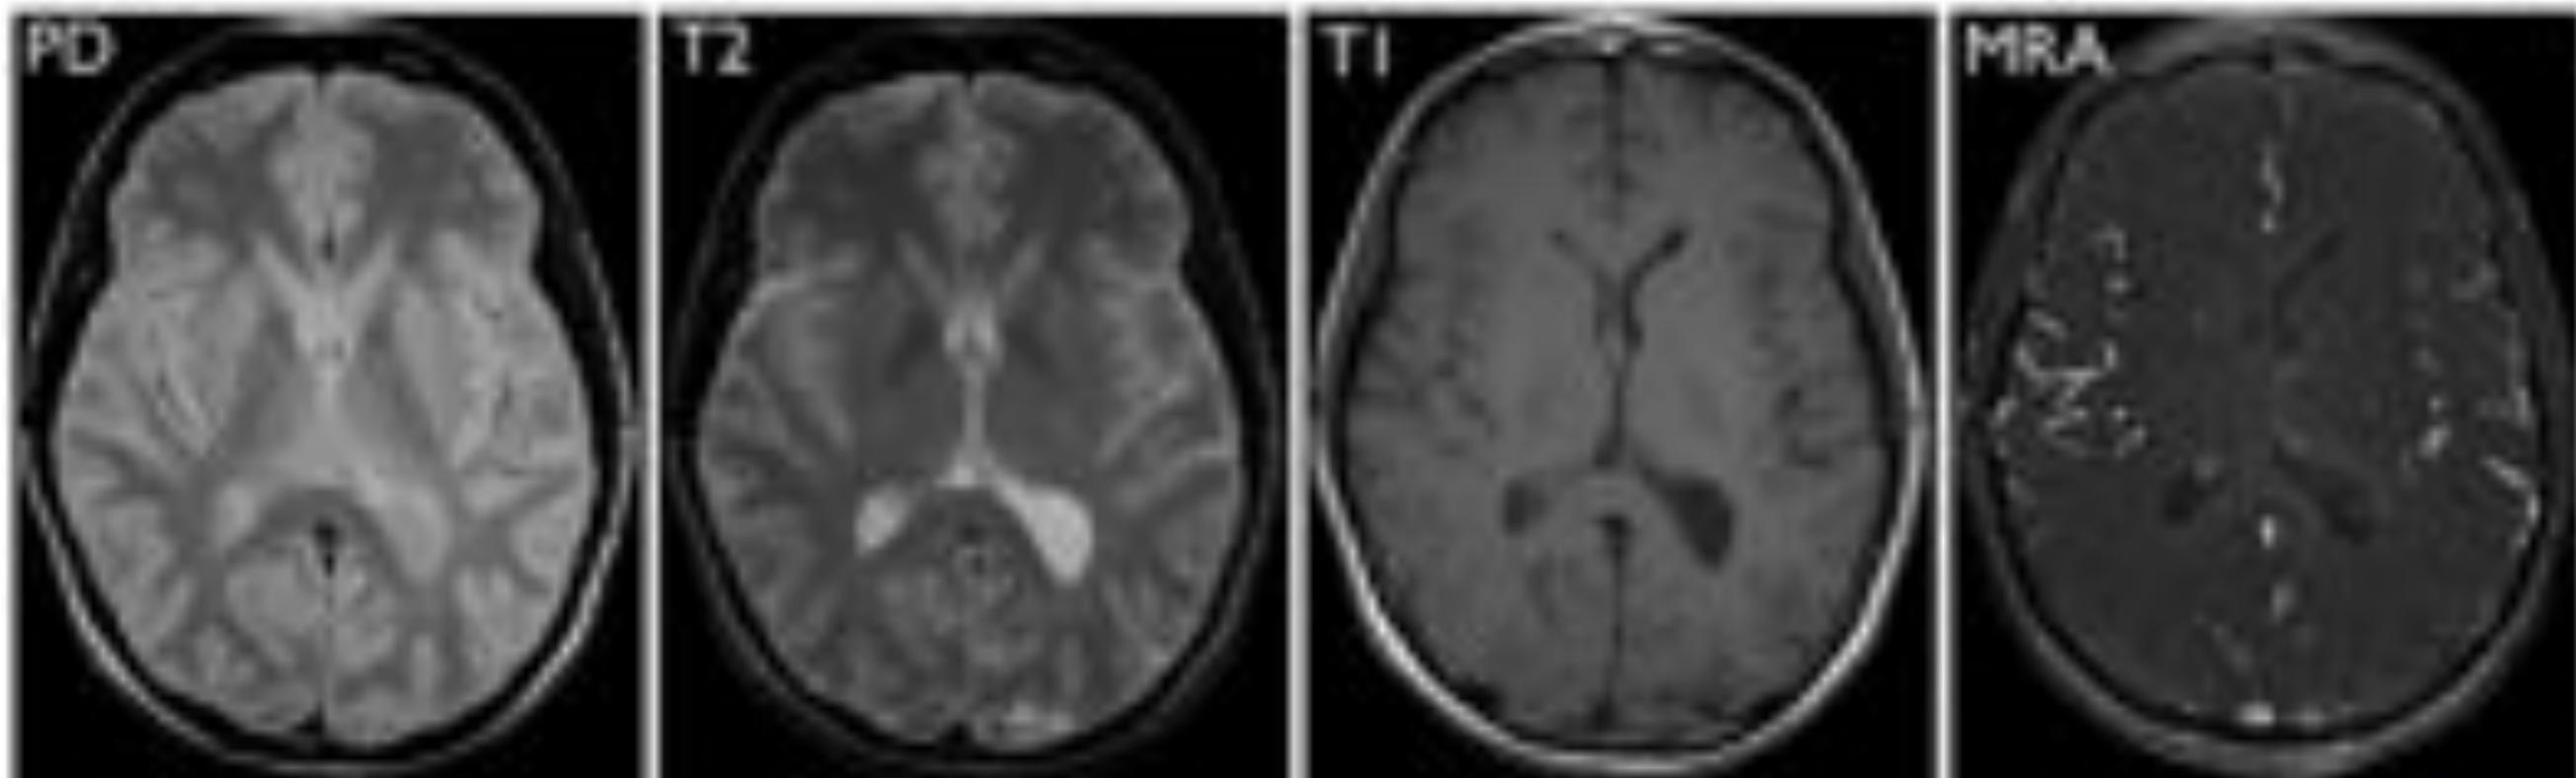
$$\text{Simil}(\text{Image 1}, \text{Image 2}) = \text{:)(smiley face)}$$

- On choisit également une famille de transformation  $\mathcal{F}$
- Le problème de recalage s'écrit alors comme :

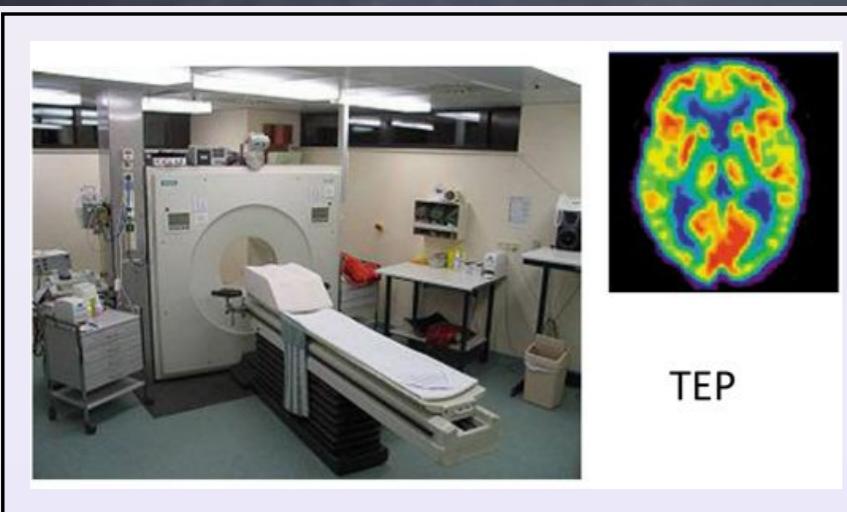
$$\arg \min_{T \in \mathcal{F}} \text{Simil}(T(I), J) = ?$$

# Critère de similarité

- Des idées?
- Les difficultés?



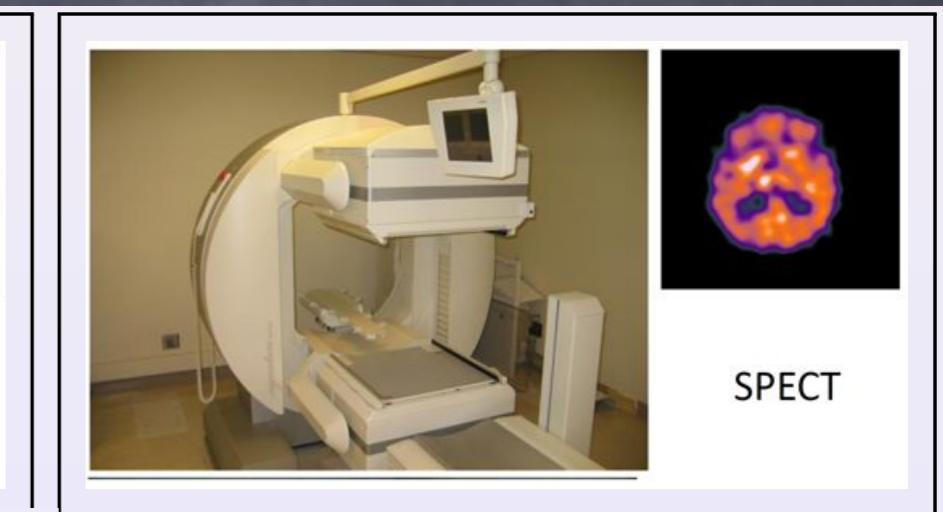
# Les critères de similarité



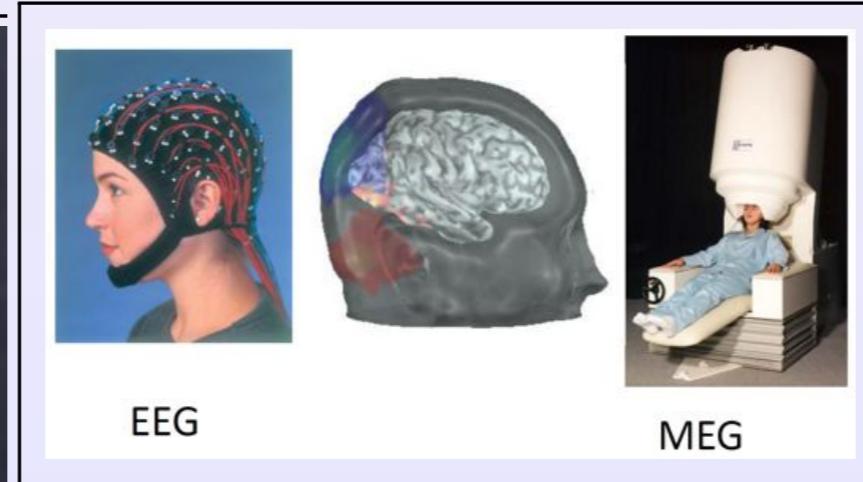
TEP



IRM



SPECT



# Critère de similarité

- Comparaison des histogrammes de  $I$  et  $J$ ?



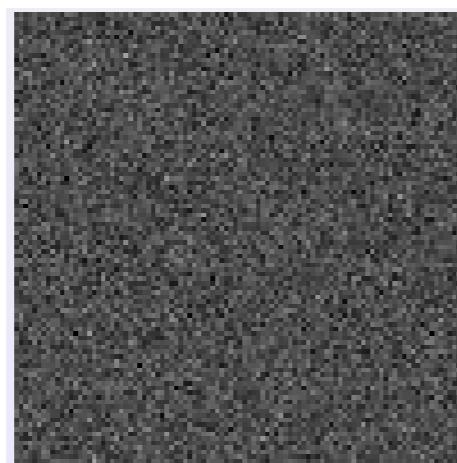
&



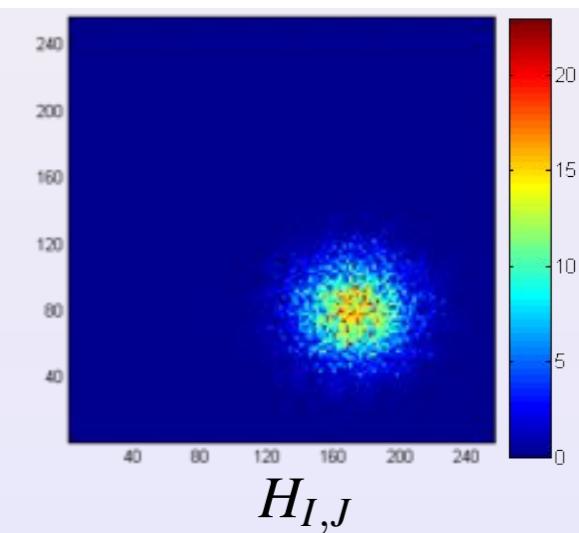
&



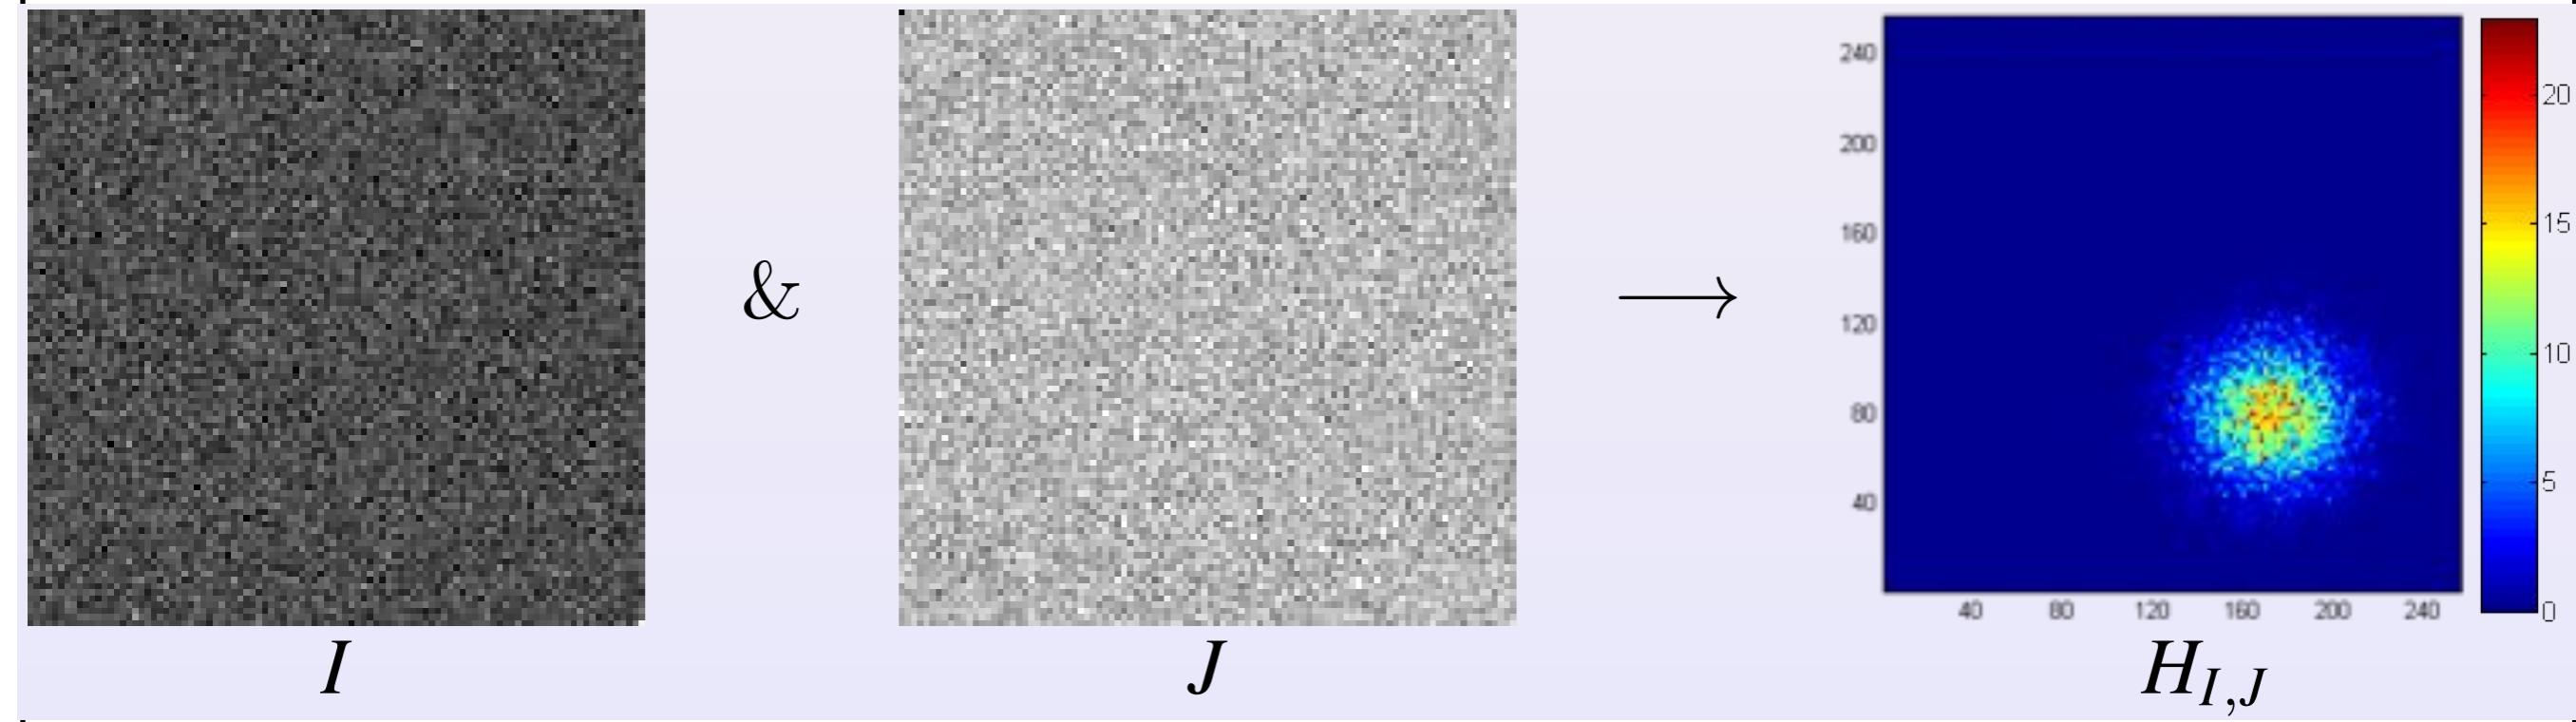
- Histogramme conjoint :



&



# Histogramme conjoint



$$H_{I,J}(i,j) = \text{Card}\left\{(x,y) \mid I(x,y) = i \text{ et } J(x,y) = j\right\}$$

# Histogramme conjoint

$$H_{I,J}(i,j) = \text{Card} \left\{ (x,y) \mid I(x,y) = i \text{ et } J(x,y) = j \right\}$$

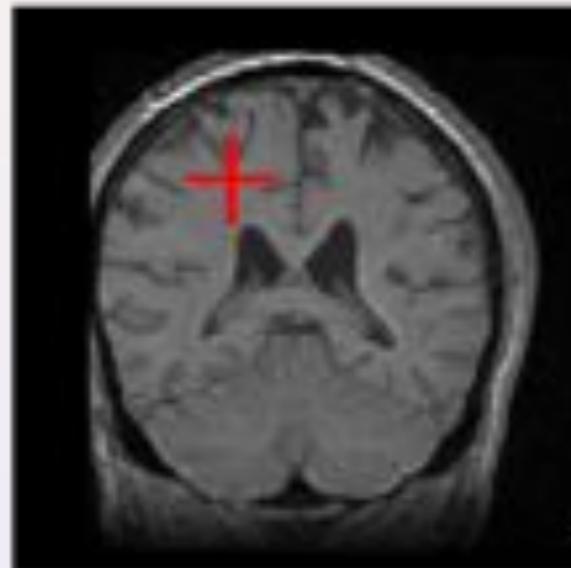


Image 2

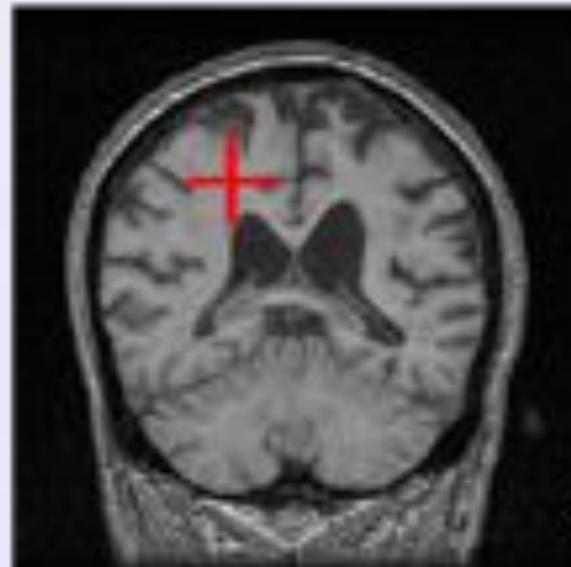
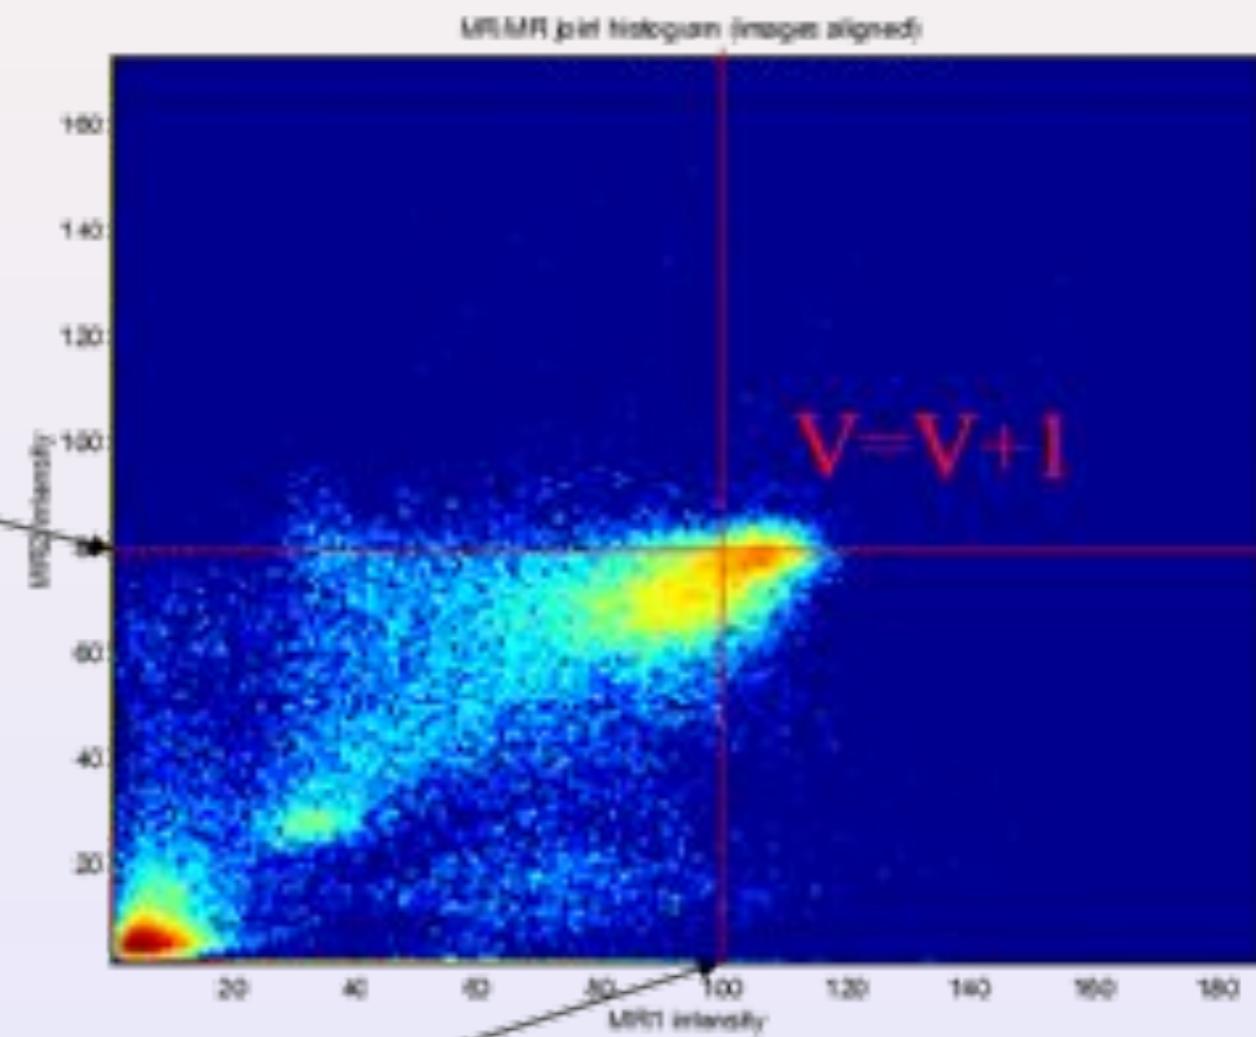


Image 1

Intensity = 80

Intensity = 100

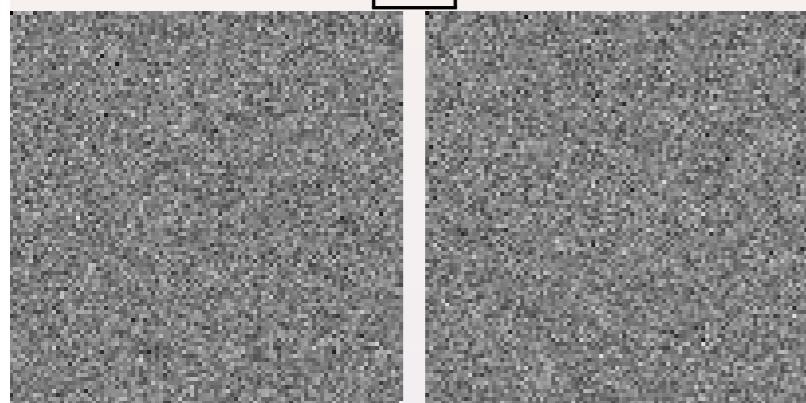
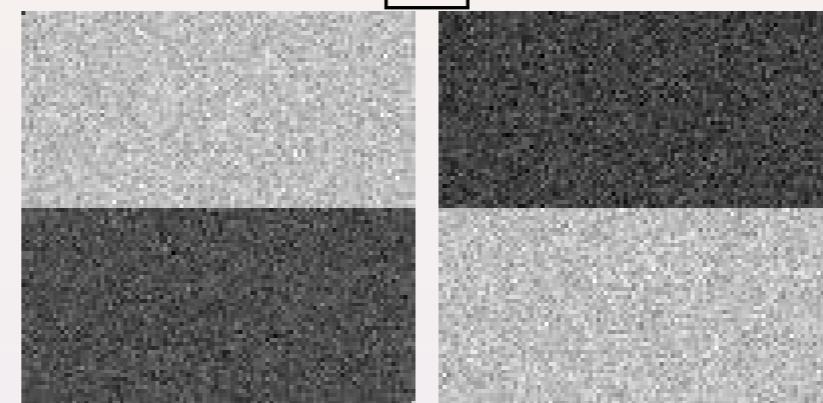
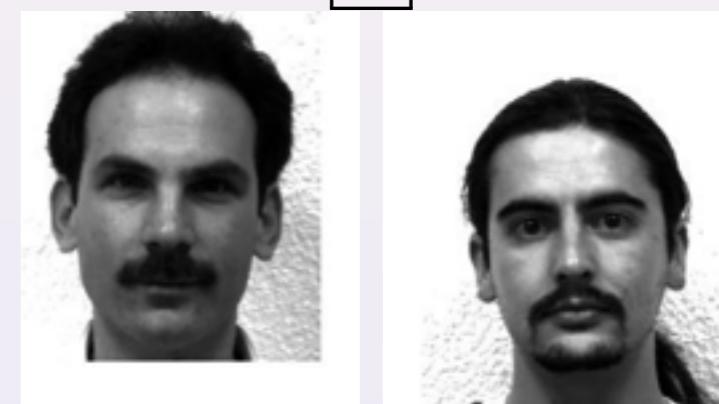
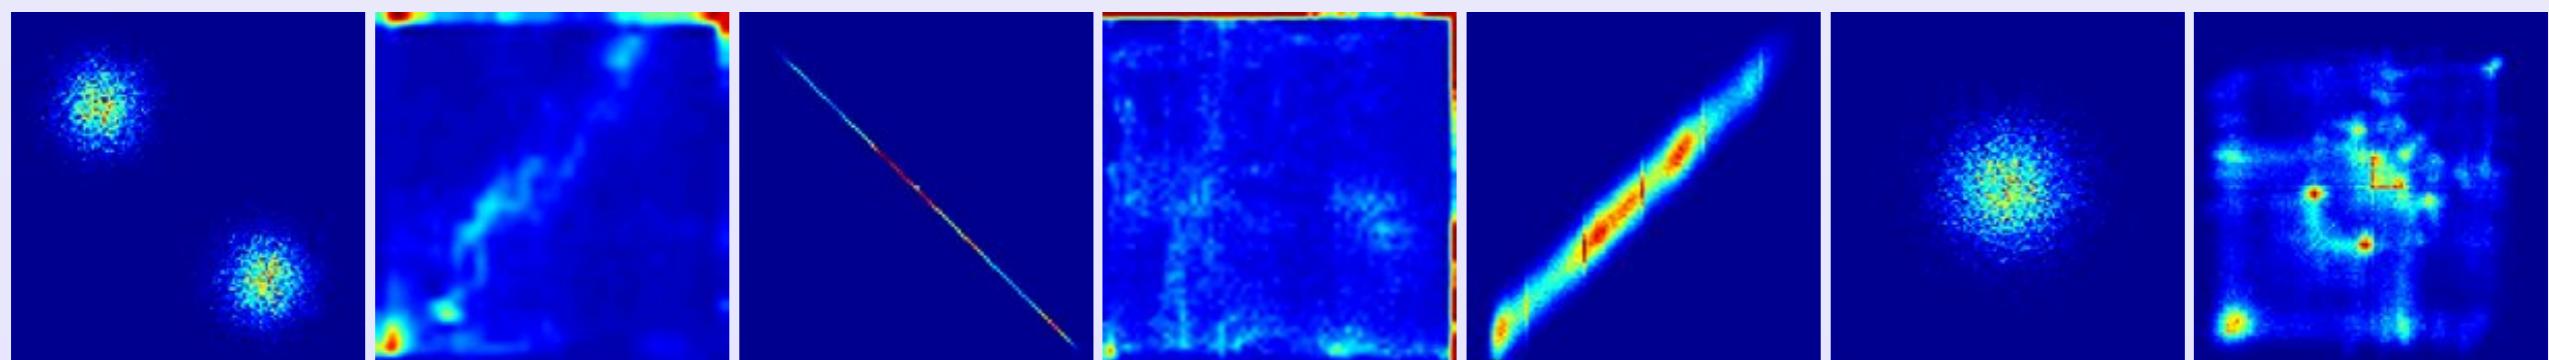


# Histogramme conjoint

$$H_{I,J}(i,j) = \text{Card}\left\{(x,y) \mid I(x,y) = i \text{ et } J(x,y) = j\right\}$$

- si I et J sont de tailles X x Y à valeurs dans  $\{0, \dots, 255\}$  :
- Taille de  $H_{I,J} = ?$ 
  - $256 \times 256$
- $\sum_i (\sum_j (H_{I,J})) = ?$ 
  - $X * Y$



**A****B****C****D****E****F****G**

1

2

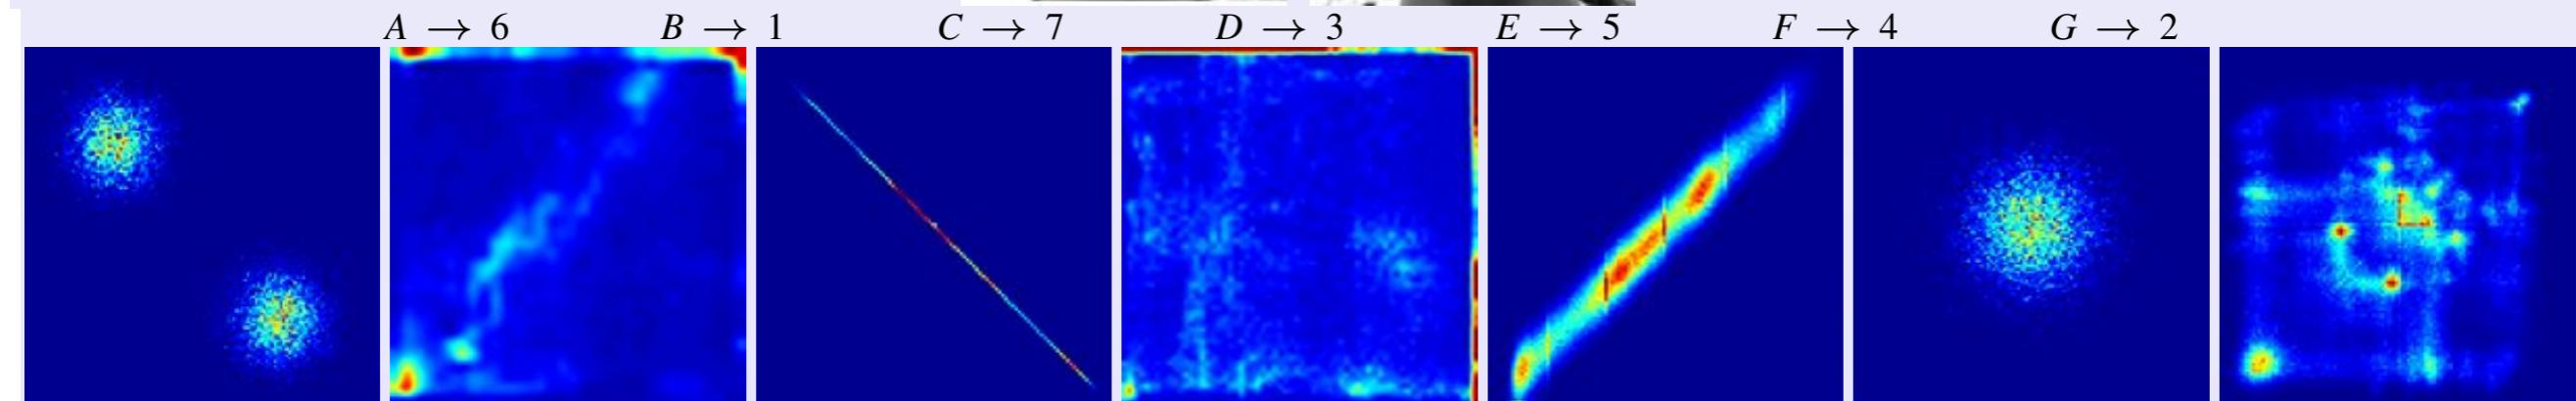
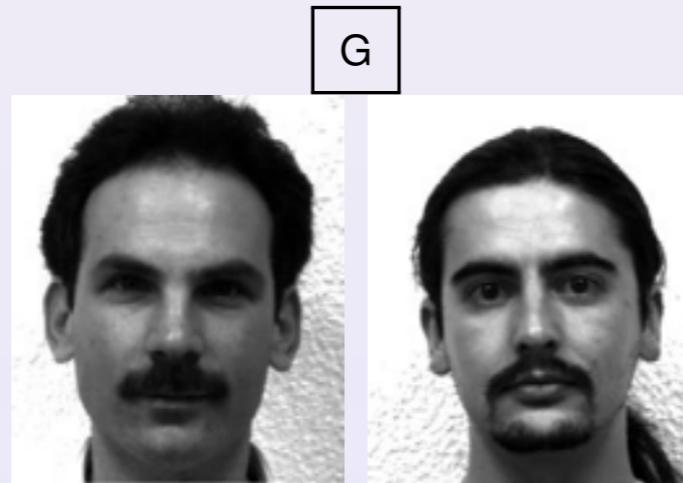
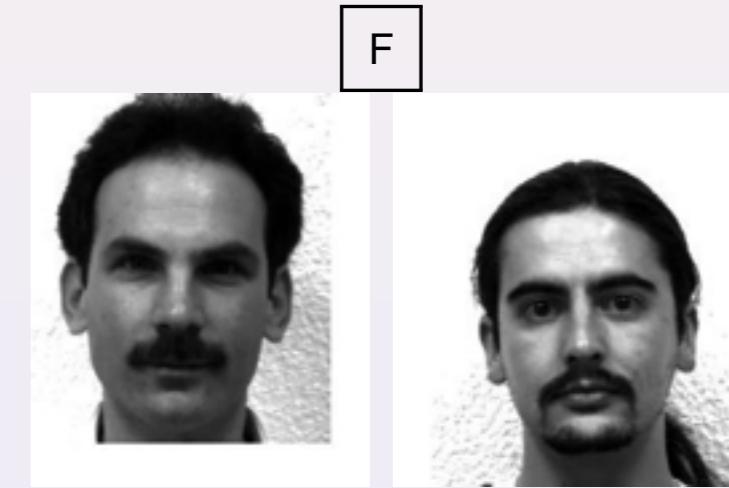
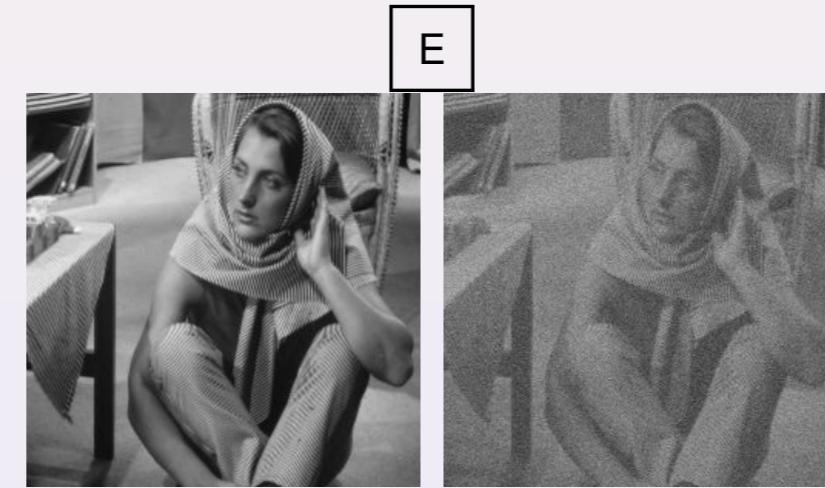
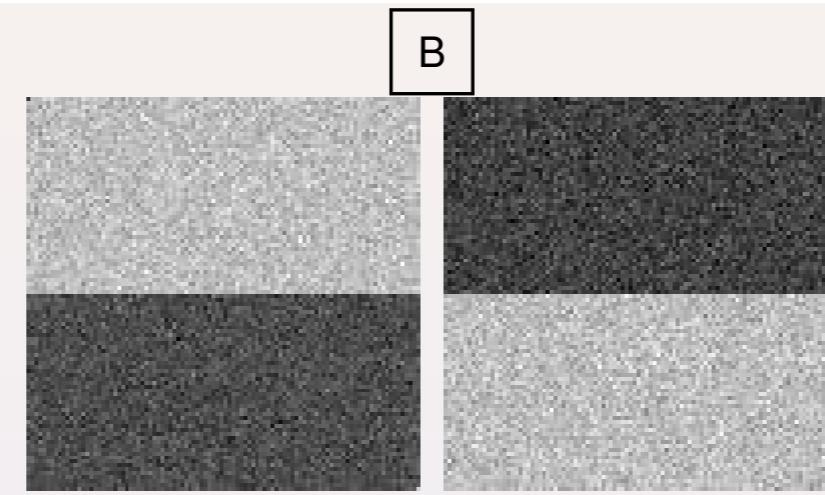
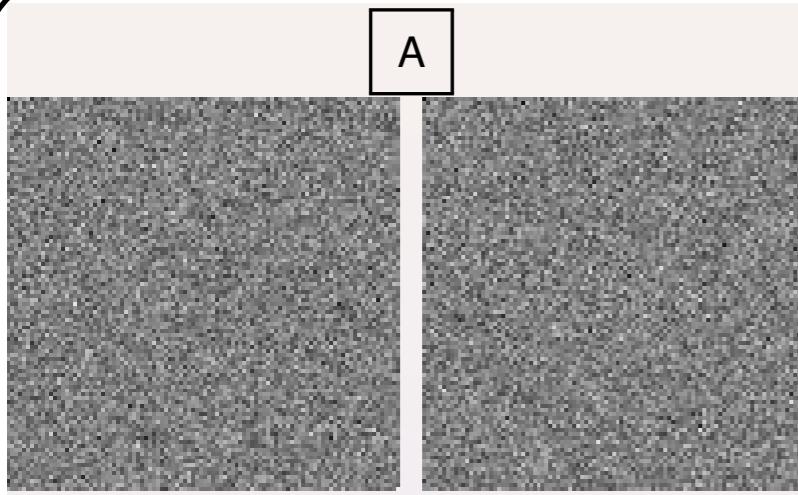
3

4

5

6

7



1      2      3      4      5      6      7

# Histogramme conjoint

- Construction: comme pour un histogramme classique : discréétisation
  - Images encodées sur 1 octet : à valeurs dans  $\{0, \dots, 255\}$  - OK
  - Images encodées sur plusieurs octets : on regroupe les valeurs en divisant en intervalles (*bins*)
  - Définition continue (somme - intégrale) : fenêtrage de Parzen (1973)
- Histogramme conjoint normalisé.  $H_{I,J}(i,j) =$  “probabilité qu’un pixel tiré aléatoirement ait l’intensité  $i$  dans l’image  $I$  et que son correspondant ait l’intensité  $j$  dans l’image  $J”$

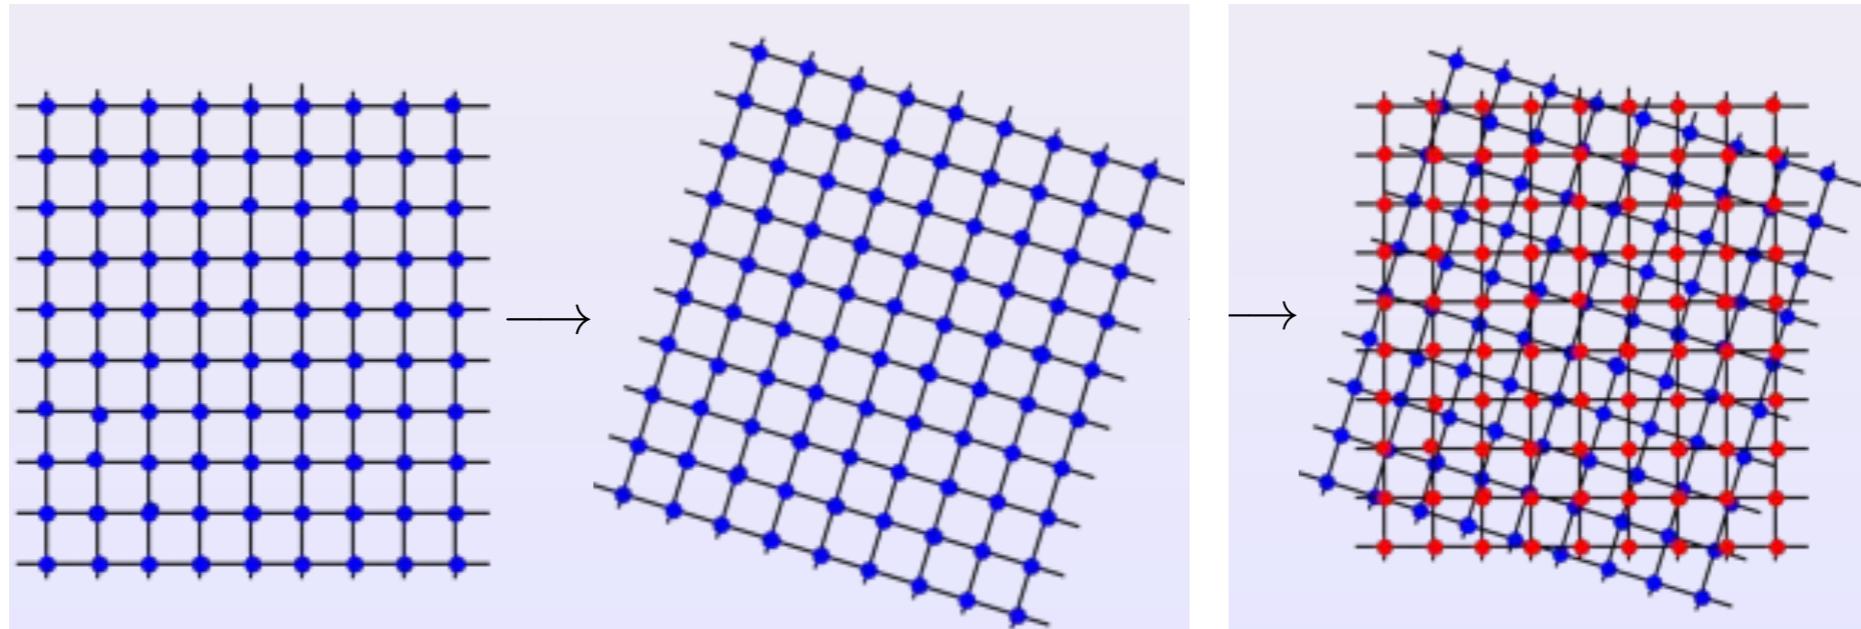
$$H_{I,J}(i,j) = \frac{1}{n} \operatorname{Card} \left\{ (x,y) \mid I(x,y) = i \text{ et } J(x,y) = j \right\}$$

$$\sum_{i,j} H_{I,J}(i,j) = 1$$

# Histogramme conjoint et recalage

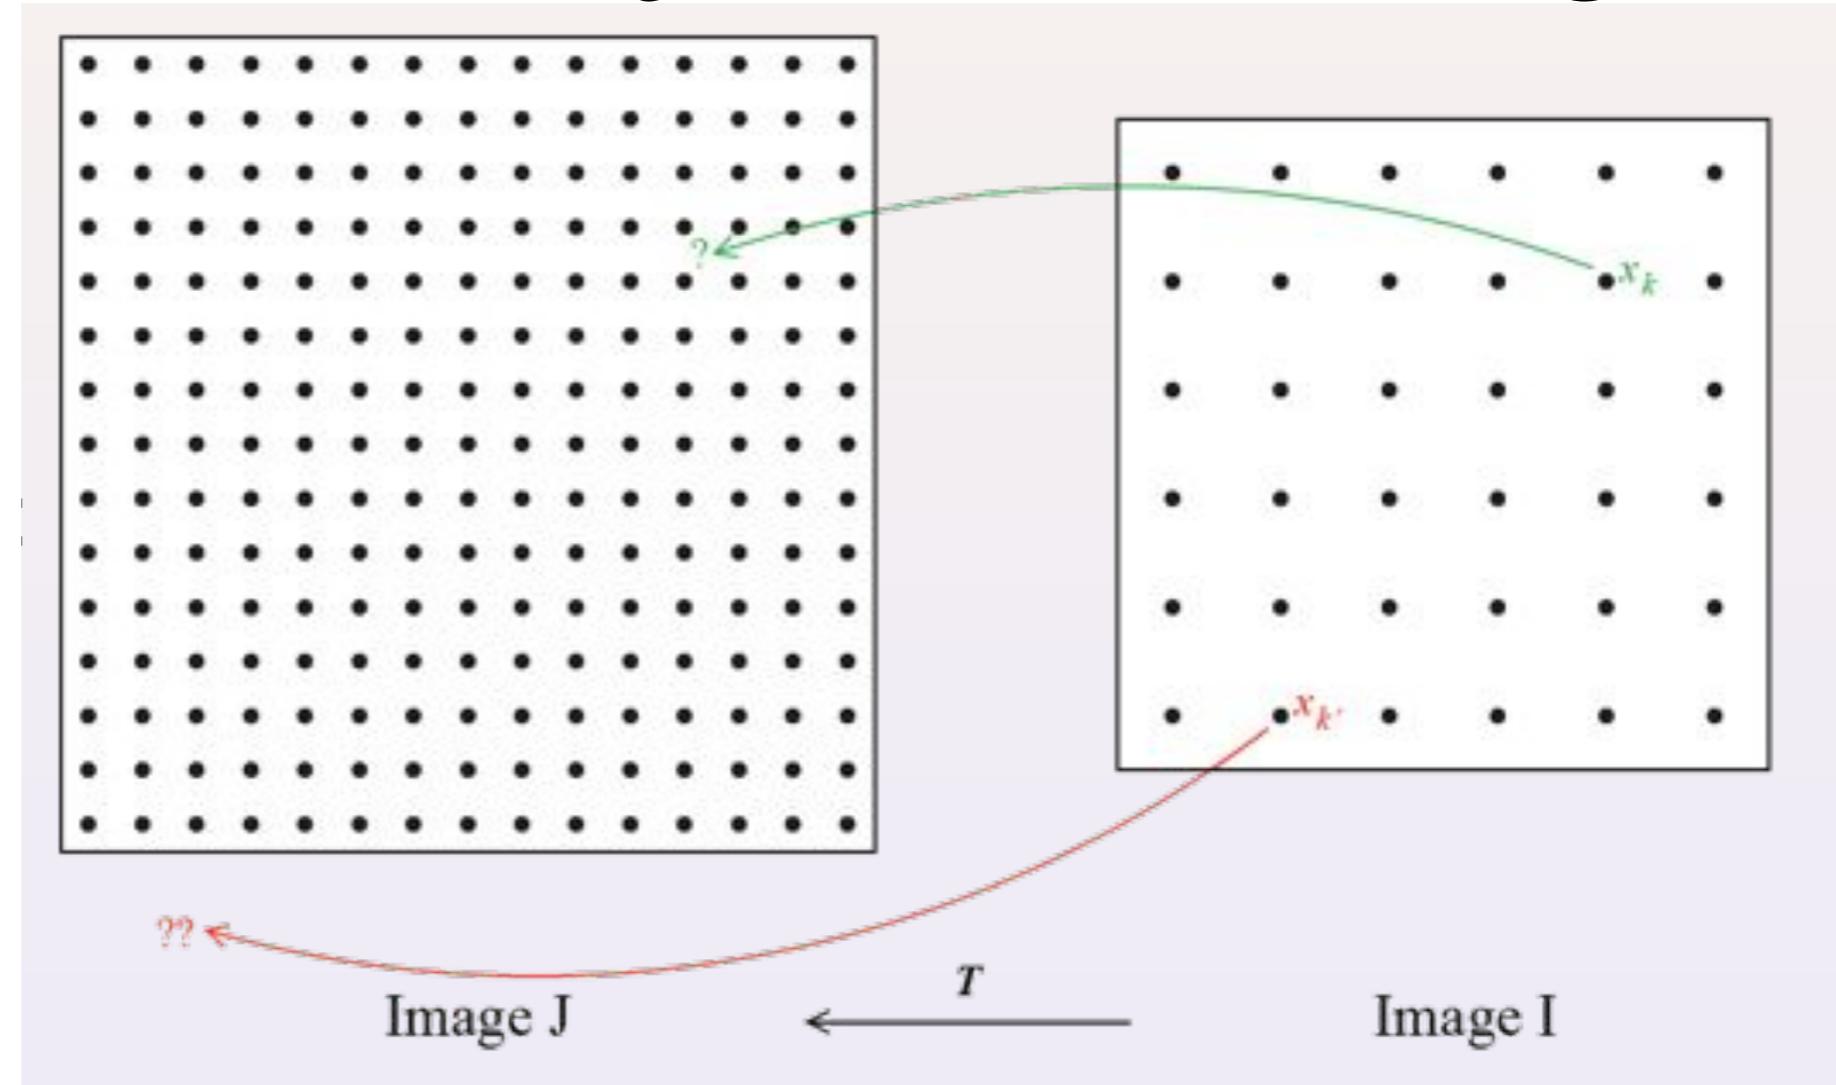
$$\arg \min_{T \in \mathcal{F}} \text{Simil}(T(I), J) = ?$$

- Pour définir  $\text{Simil}(T(I), J)$ , il faut pouvoir calculer l'histogramme conjoint de  $T(I)$  et  $J$
- Si  $T(i)$  envoie les pixels de  $I$  exactement sur les pixels de  $J$ , pas de problème, mais peu intéressant car ça n'arrive jamais
- Exemple simple



# Histogramme conjoint et recalage

- Cas général :



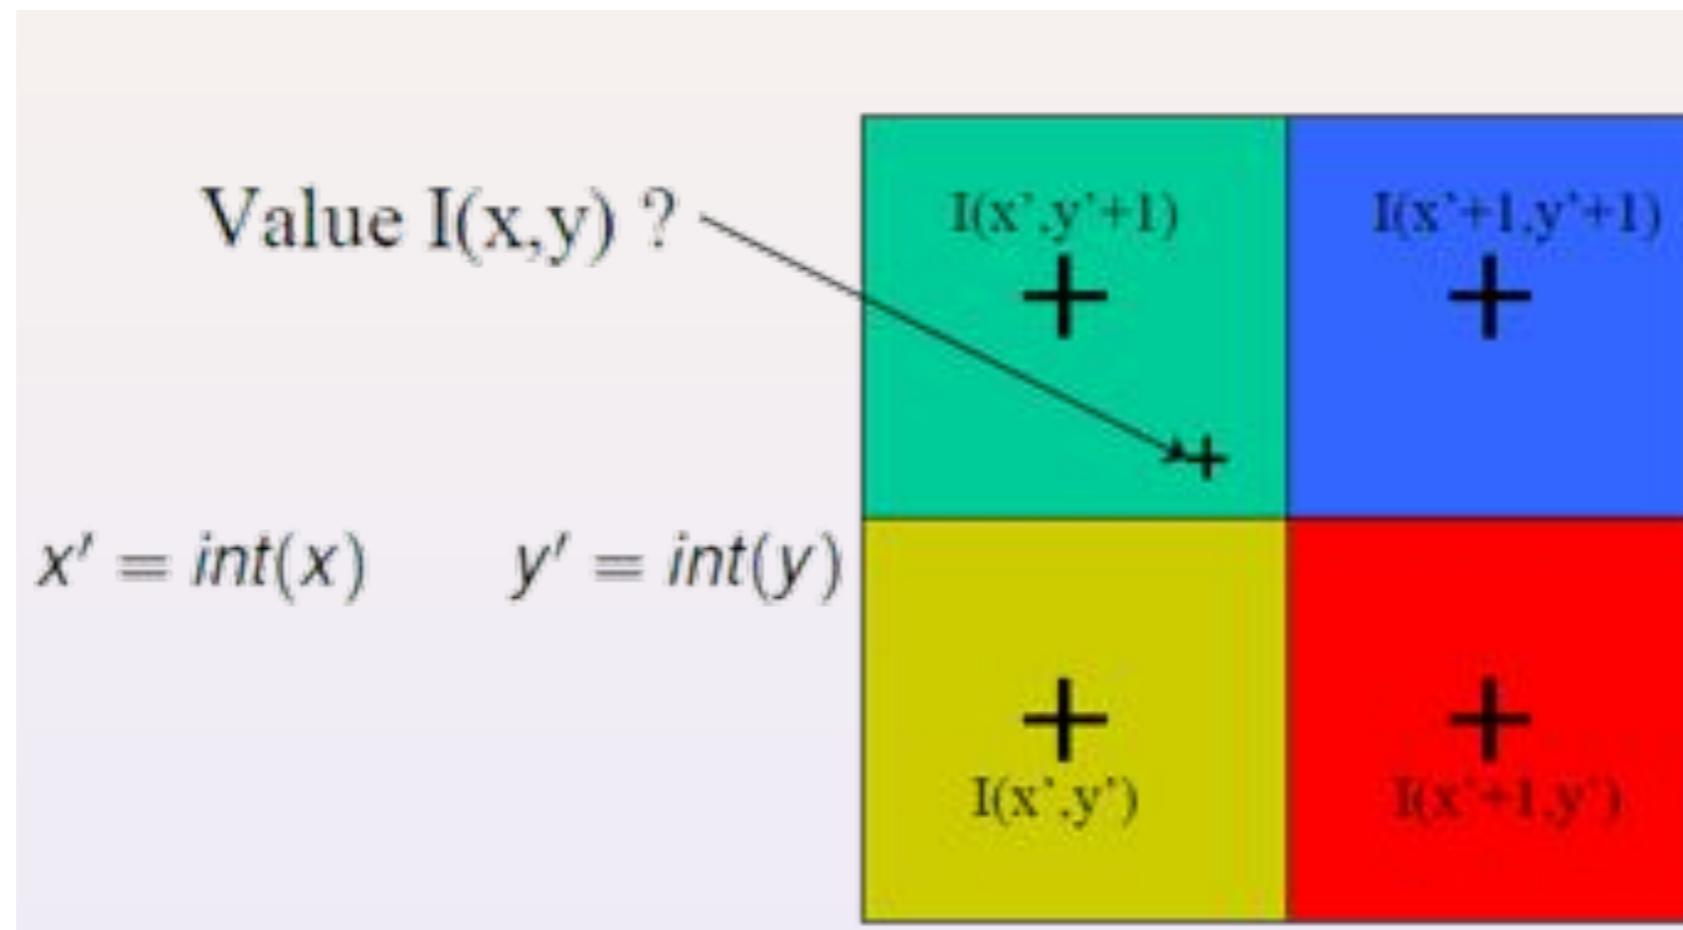
- Problèmes :
  - **Extrapolation** pour les points  $T(x_k)$  tombant à l'extérieur de la grille  $J$
  - **Interpolation** pour les points  $T(x_k)$  tombant à l'intérieur de la grille  $J$

# Histogramme conjoint et recalage

- Extrapolation
- Soit on ne prend pas en compte les pixels  $T(x_k)$  qui tombent à l'extérieur du domaine  $J$
- Soit on prolonge  $J$  de manière arbitraire (conditions aux bords)
  - Constante
  - Miroir
  - etc...

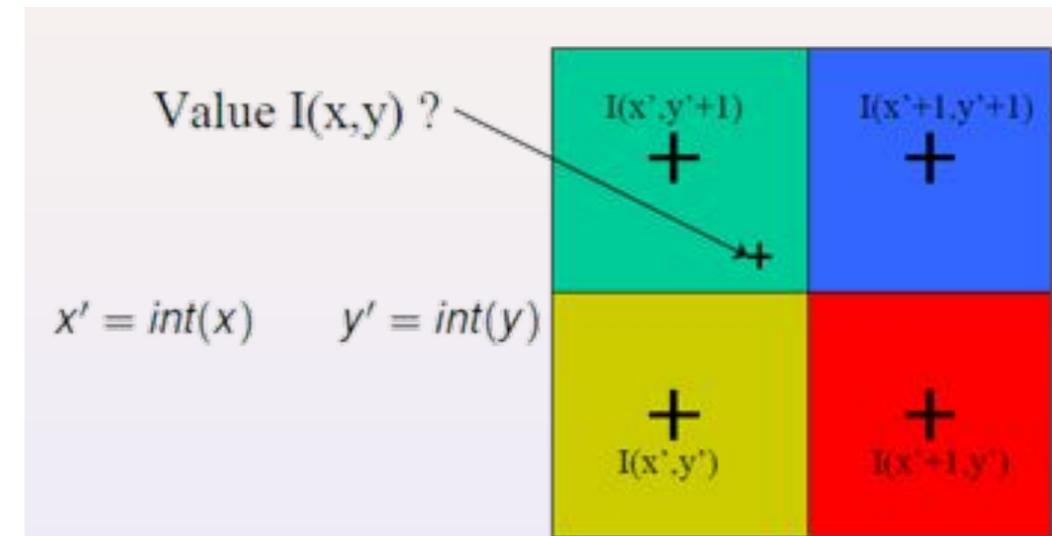
# Histogramme conjoint et recalage

- Interpolation

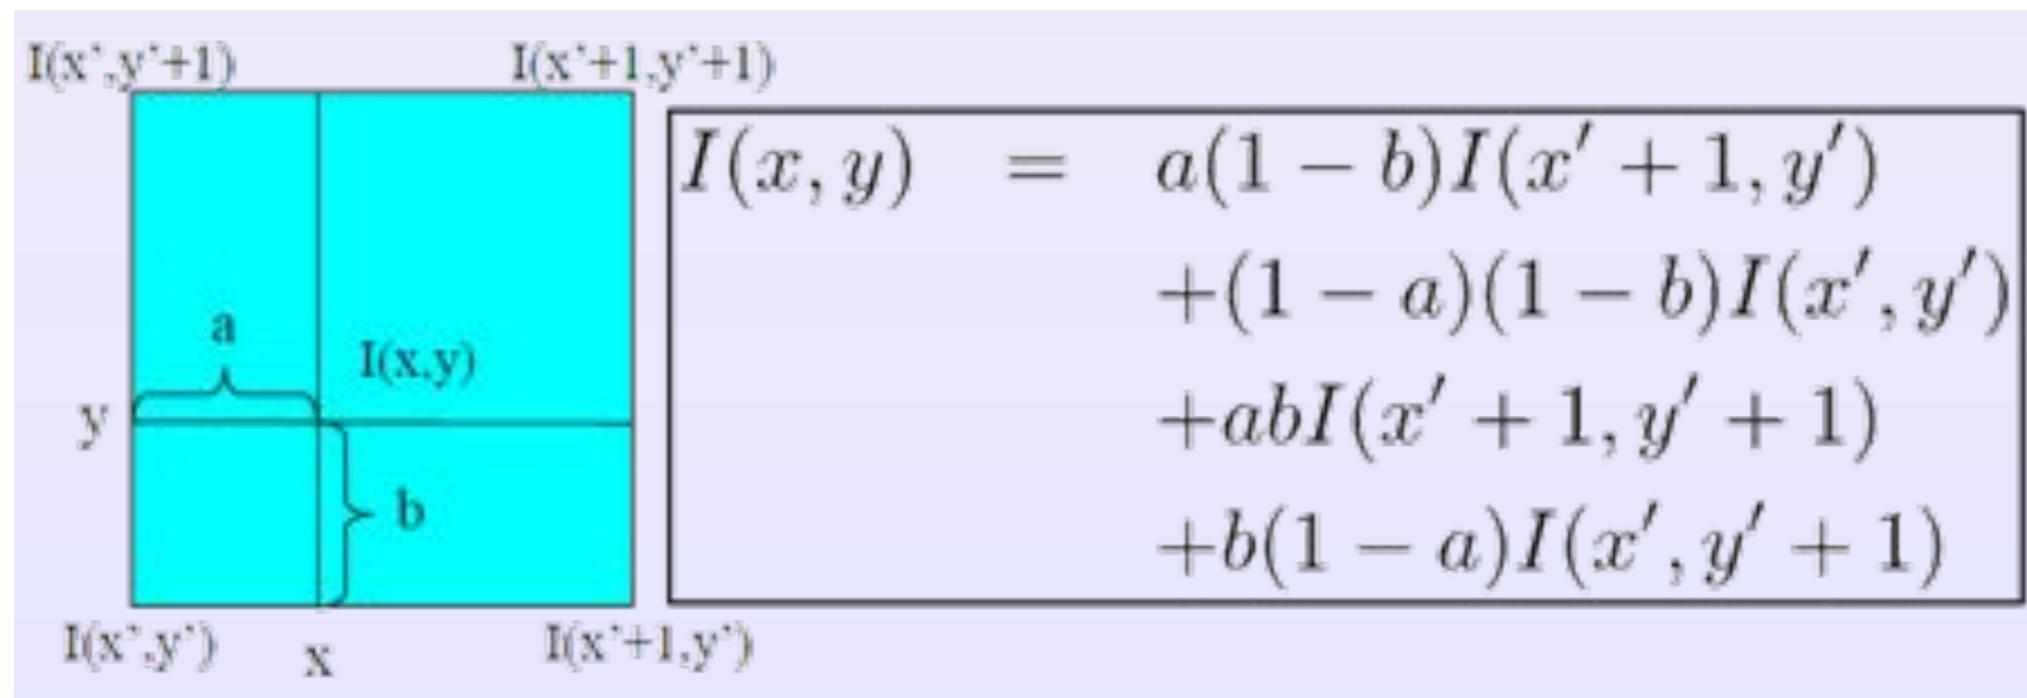


- 2 approches de bases

# Interpolation



- Plus proche voisins :  $I(x,y) = I(\text{round}(x), \text{round}(y))$
- Bi-(tri)-linéaire

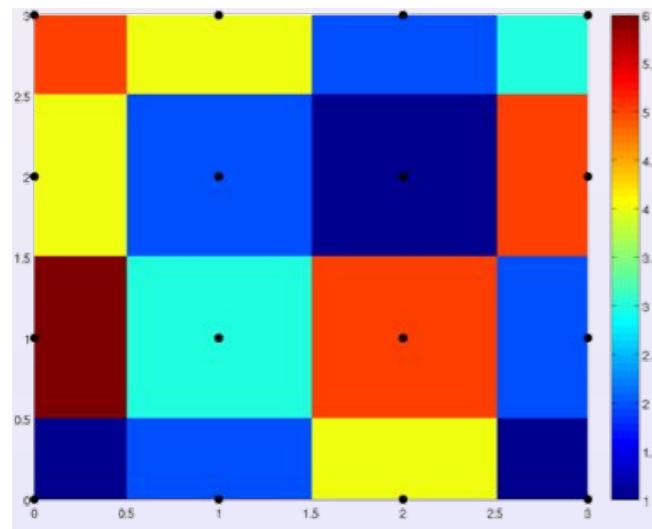


# Interpolation avancée

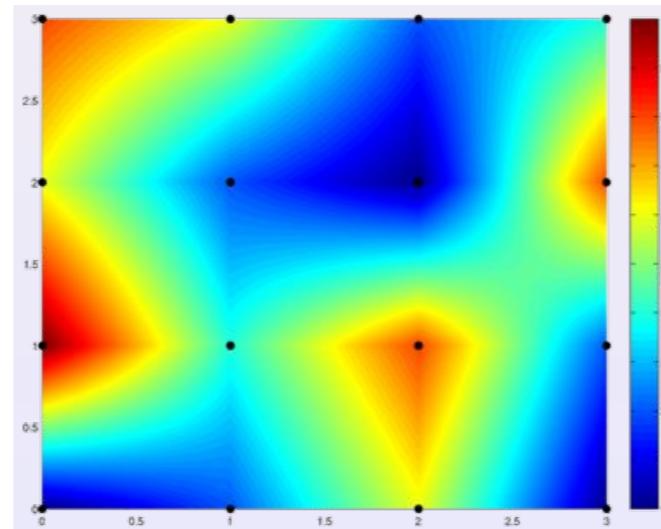
- Approches plus sophistiquées
- On cherche une fonction “simple” qui passe par les différents points **connus**, et on regarde la valeur de cette fonction au point qui nous intéresse
- Fonctions possibles :
  - Bicubique (spline) :

$$I(x, y) = \sum_{i=0}^3 \sum_{j=0}^3 a_{ij} x^i y^j$$

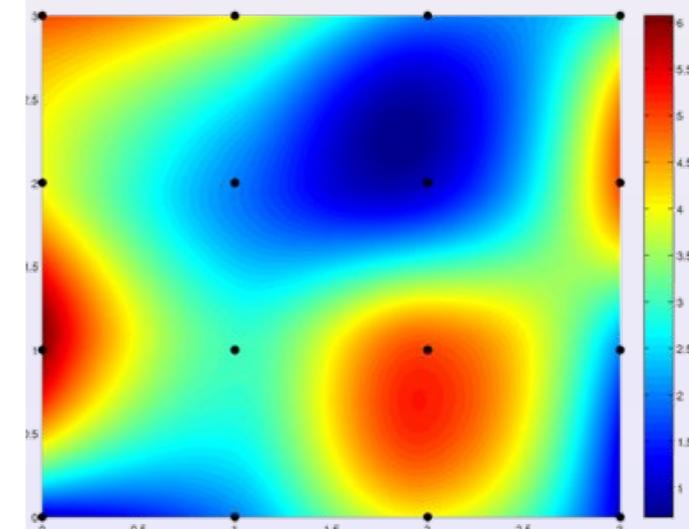
Plusieurs autres:  
e.g. basée sur des sinc  
(Lanczos3)



Plus proche voisin



Bilinéaire



Bicubique

# Histogramme conjoint

$$H_{I,J}(i,j) = \text{Card} \left\{ (x,y) \mid I(x,y) = i \text{ et } J(x,y) = j \right\}$$

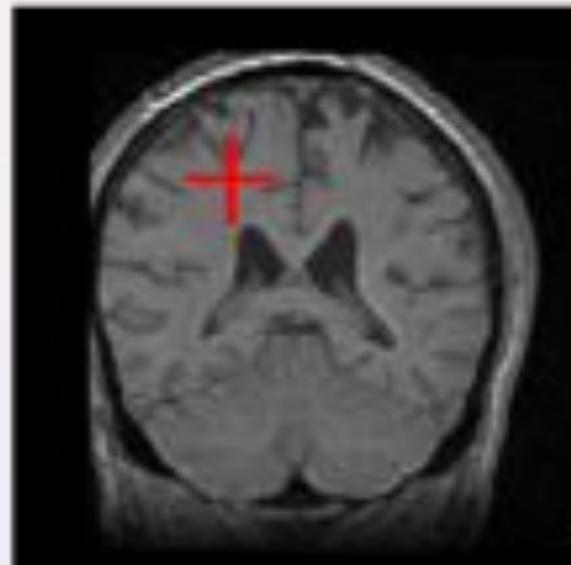


Image 2

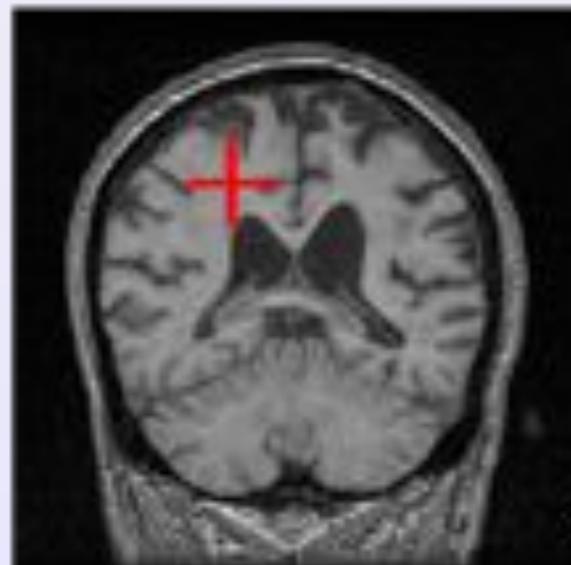
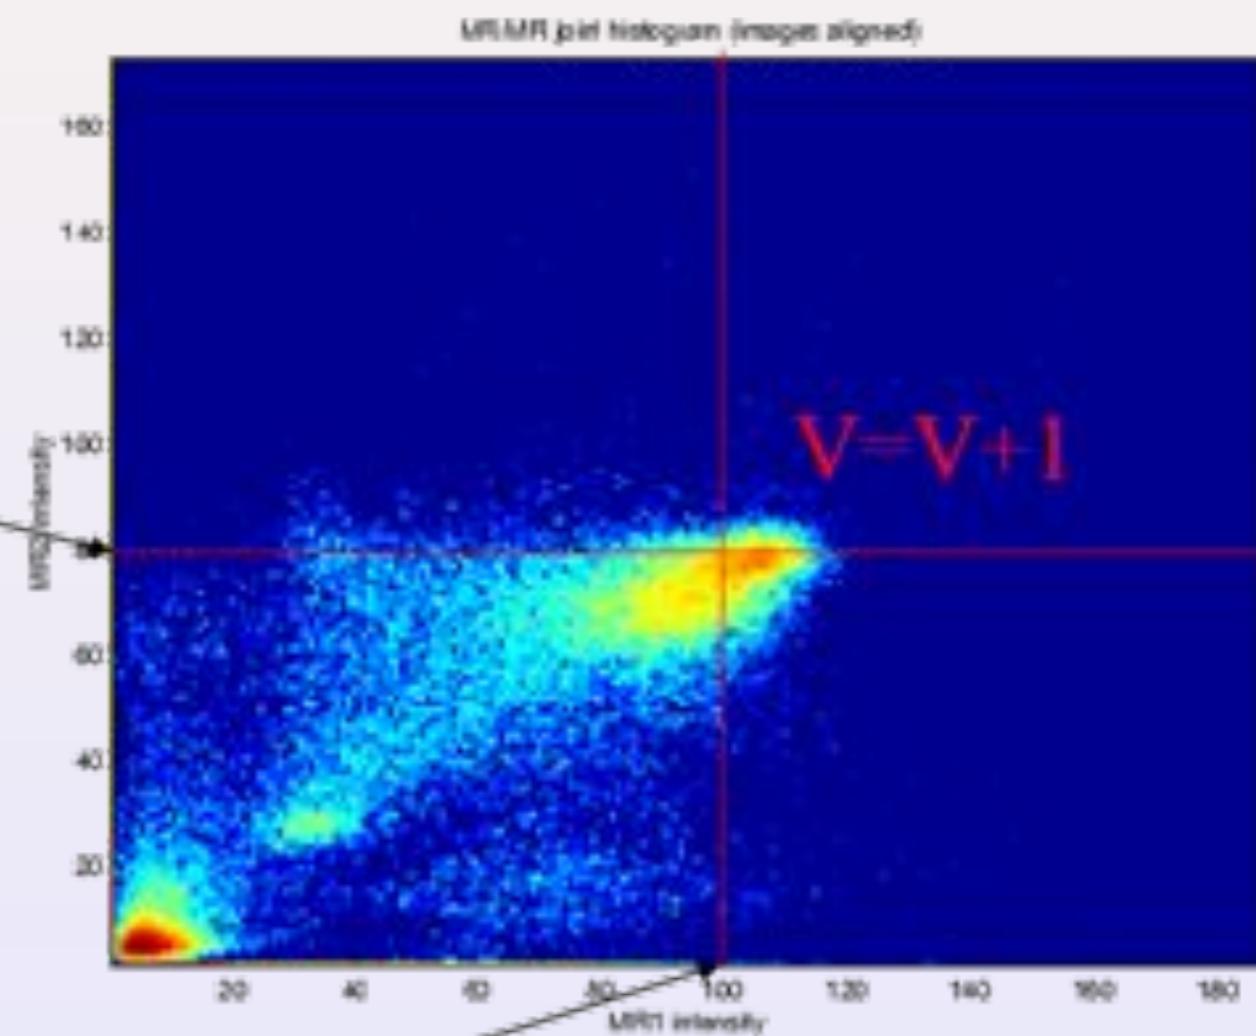


Image 1

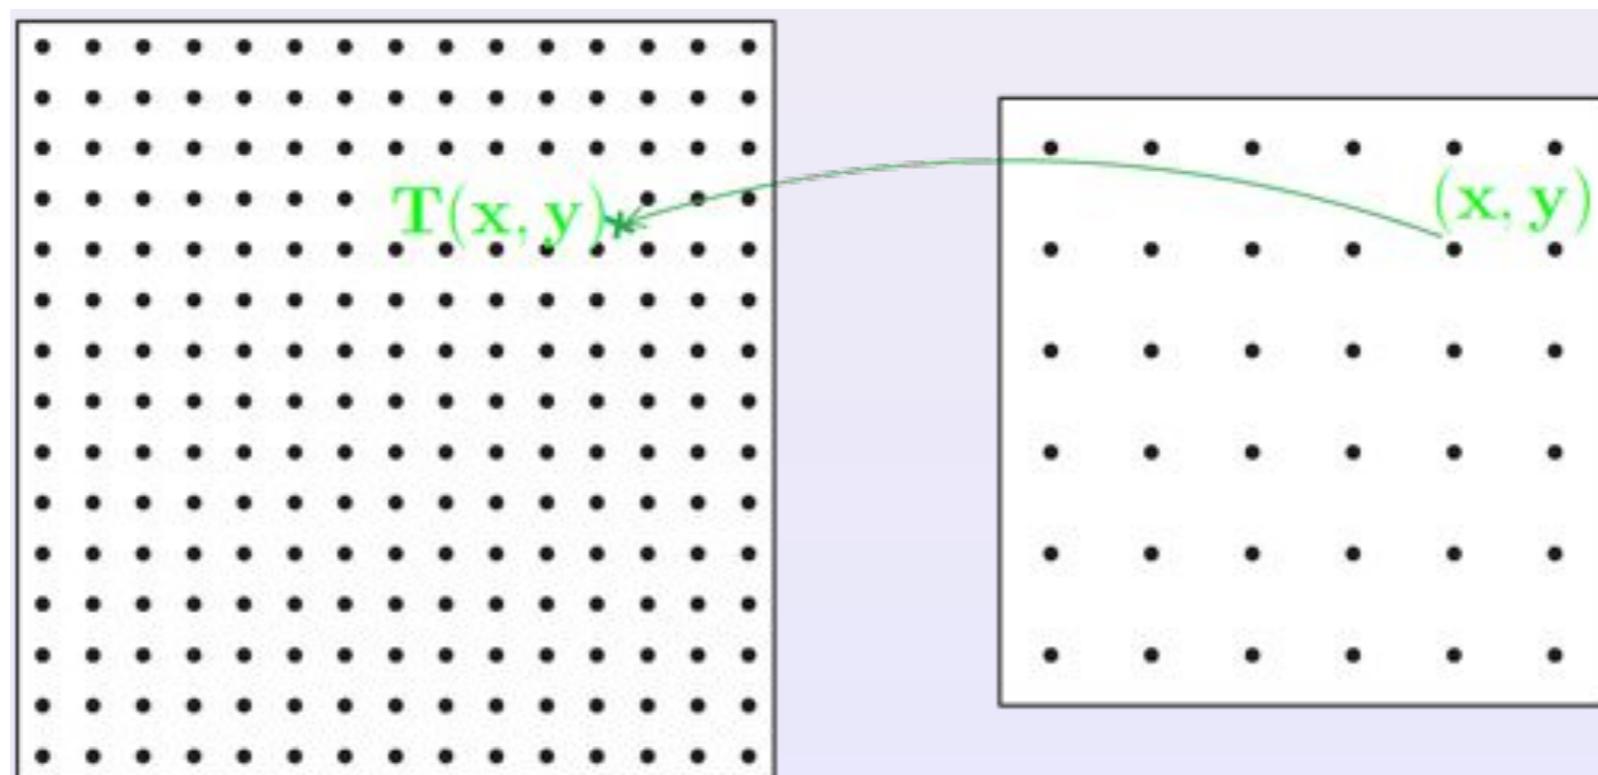
Intensity = 80

Intensity = 100



# Critère de similarité

- On note  $S(T)$  le critère de similarité associé à une transformation  $T$  avec  $\text{Simil}( T(I), J )$



# Critère de similarité

- Conservation de l'énergie: Cas idéal:  $T(I) = J$ , images identiques
  - Somme des différences au carré (SSD) :

$$S(T) = \sum_{x,y} \left( I(x,y) - \tilde{J}(T(x,y)) \right)^2$$

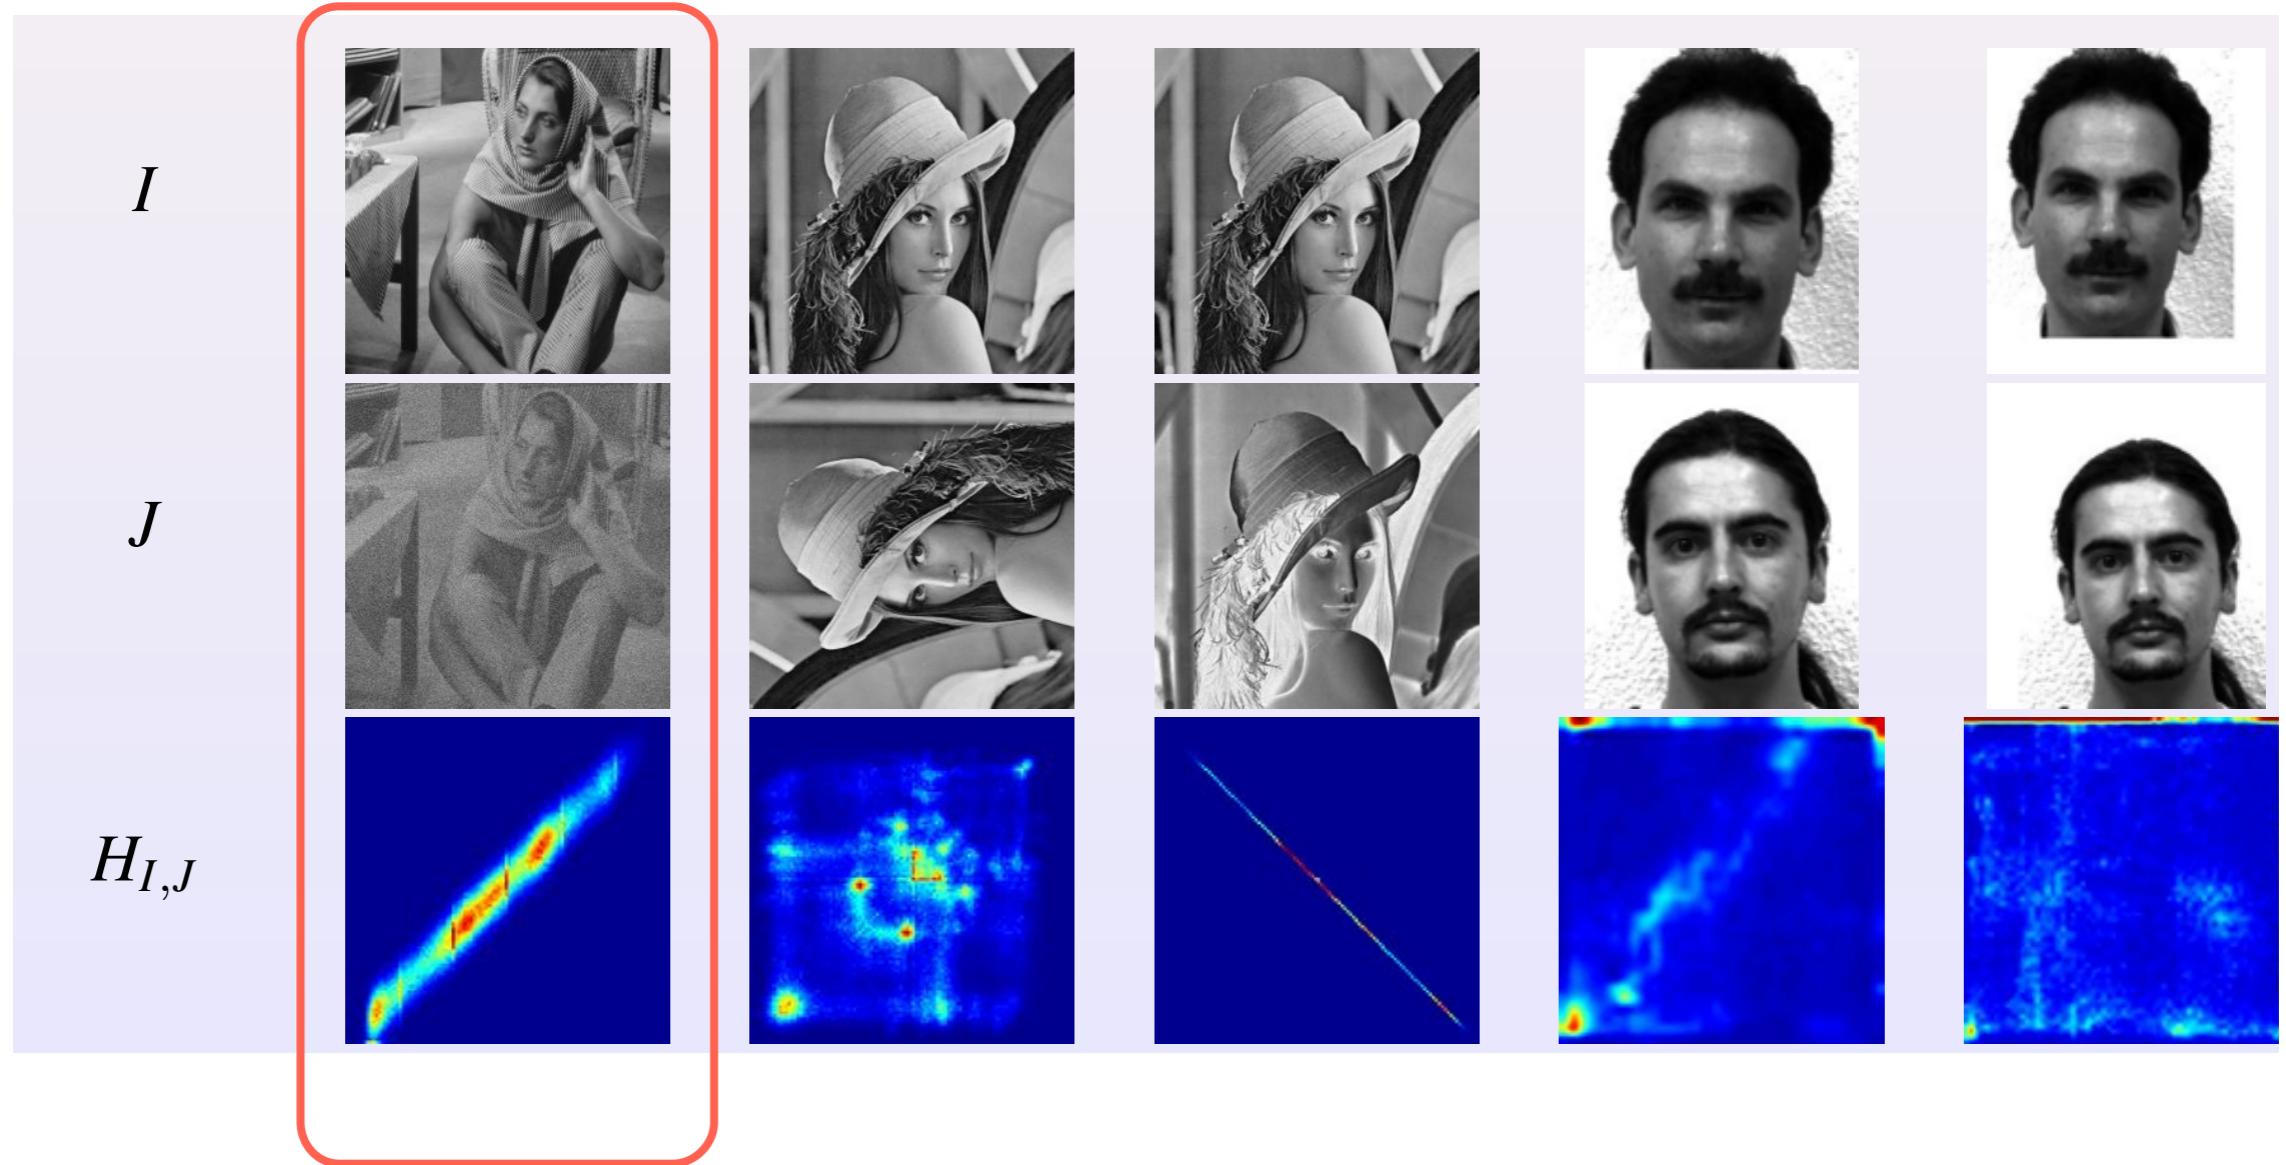
où  $\tilde{J}(T(x,y))$  est l'interpolation de  $J$  au point  $T(x,y)$

- Somme des différences en valeur absolue (SAD) :

$$S(T) = \sum_{x,y} |I(x,y) - \tilde{J}(T(x,y))|$$

# Conservation de l'intensité

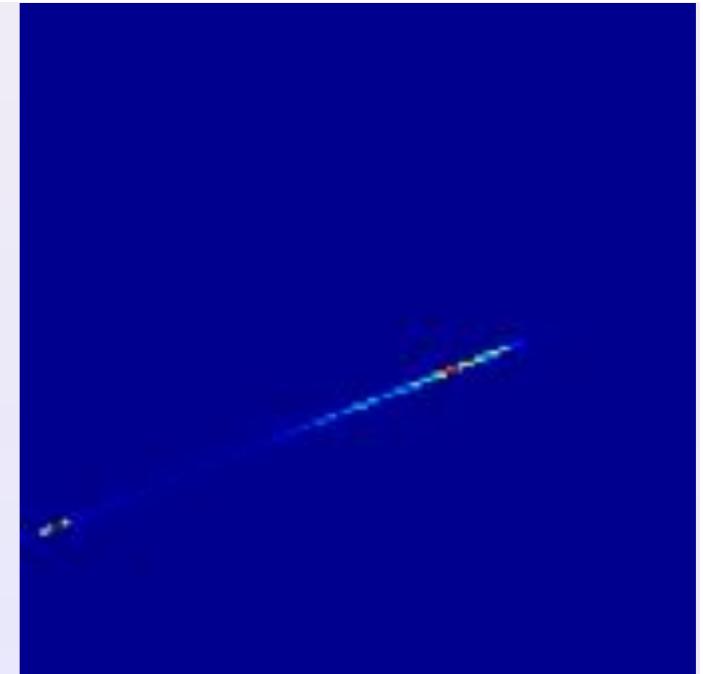
- SSD et SAD calculables à partir de l'histogramme conjoint  $H_{T(I),J}$ ?



# Critère de similarité - dépendance linéaire ou affine

- On ne cherche plus à avoir  $T(I) = J$
- Mais une relation (affine) de la forme  $T(I) = \alpha * J + \Beta$  (détailé plus tard dans la section transformation)
- Cas  $\Beta = 0$ , dépendance linéaire
- Modélise aussi les différents contrastes dans les images

SSD = 4000



# Coefficient de corrélation

- Critère adapté : **coefficient de corrélation**

$$\rho(I, J) = \frac{\sum_{x,y} (I(x, y) - \bar{I}) (J(x, y) - \bar{J})}{\sqrt{\sum_{x,y} (I(x, y) - \bar{I})^2} \sqrt{\sum_{x,y} (J(x, y) - \bar{J})^2}}$$

avec  $\bar{I} = \frac{1}{n} \sum_{x,y} I(x, y)$ , valeur moyenne de  $I$  (idem pour  $\bar{J}$ )

- $p(I, I) = 1$
- $p(I, -I) = -1$
- $p(I, \alpha * I + \beta) = \text{sign}(\alpha) \quad (1 \text{ ou } -1)$

# Coefficient de corrélation

- Si  $p(I, J)$  proche de 0?

$$\sum_{x,y} (I(x, y) - \bar{I}) (J(x, y) - \bar{J}) \text{ petit (par rapport à } \sqrt{\sum_{x,y} (I(x, y) - \bar{I})^2} \sqrt{\sum_{x,y} (J(x, y) - \bar{J})^2})$$

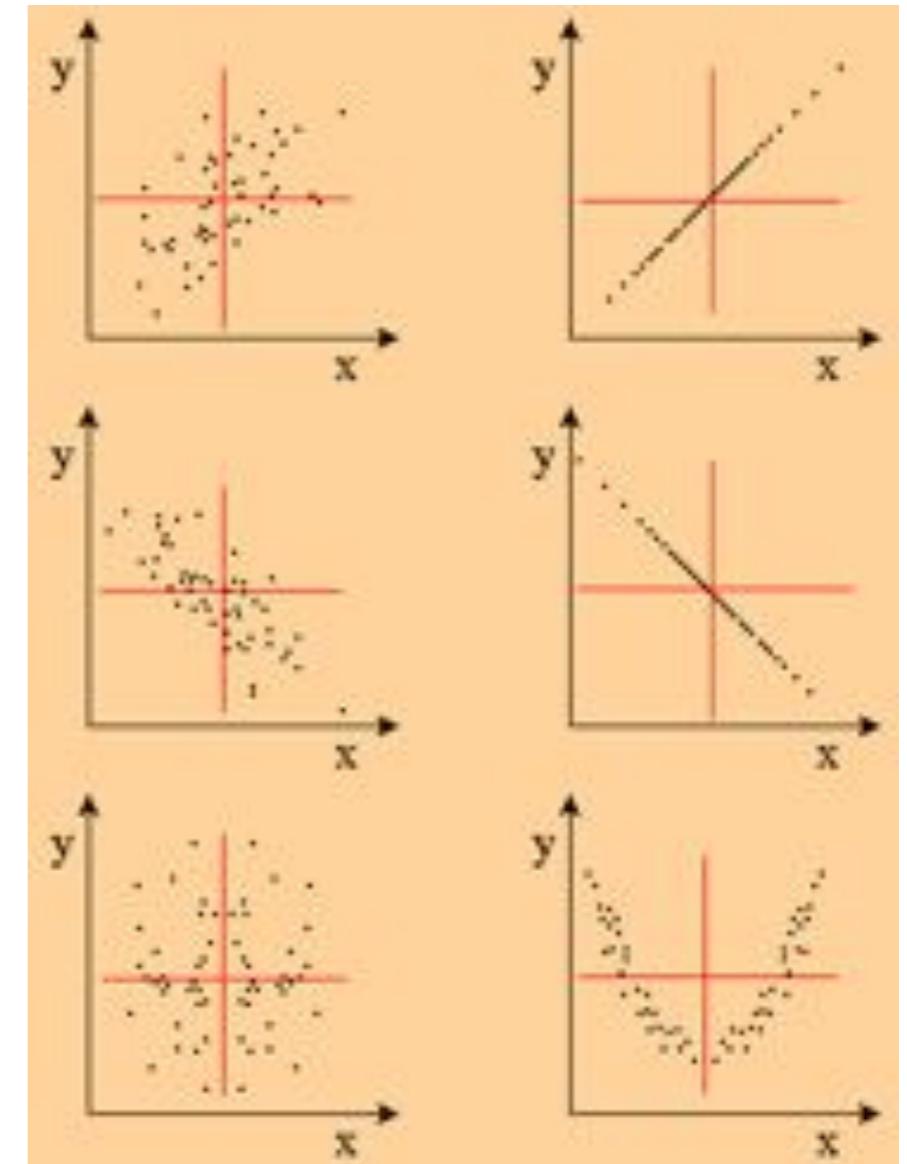
- Les pixels de même signe (produit  $> 0$ ) ou de signes opposés (produit  $< 0$ ) se compensent
- Les intensités des 2 images ne sont pas corrélées linéairement
- $p(I, J)$  toujours compris entre -1 et 1:
  - proche 1 : corrélation positive
  - proche -1 : corrélation négative
  - proche de 0 : absence de corrélation linéaire

# Coefficient de corrélation

- Un outil statistique plus général qui permet d'étudier l'intensité de liaison entre deux (ou plus) variables aléatoires

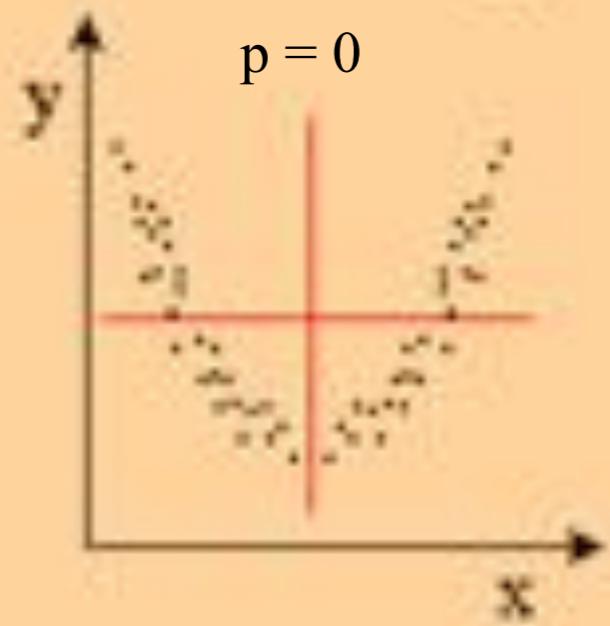
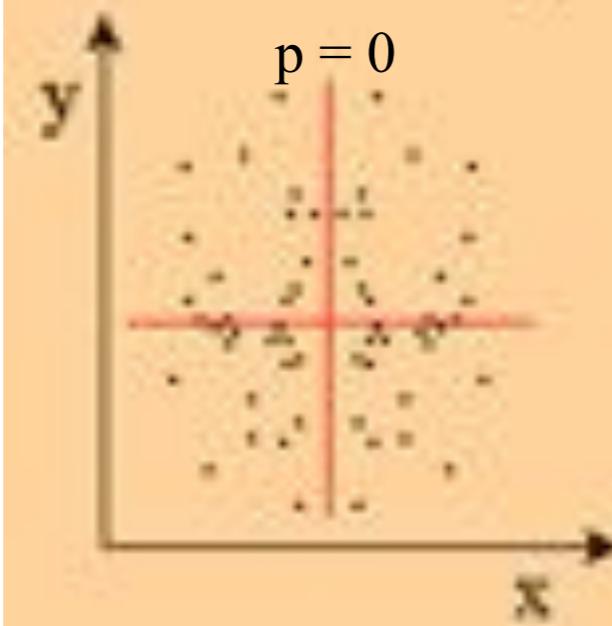
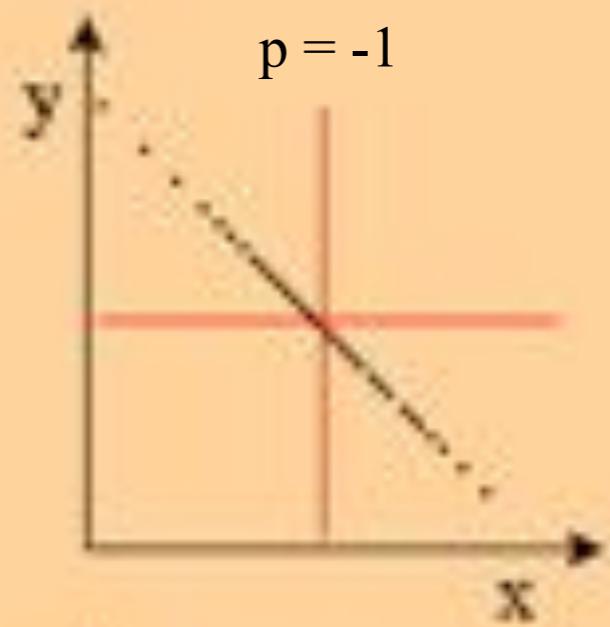
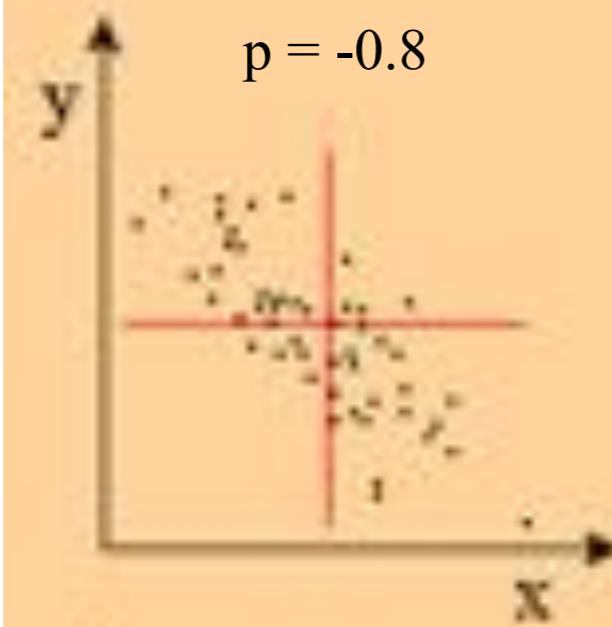
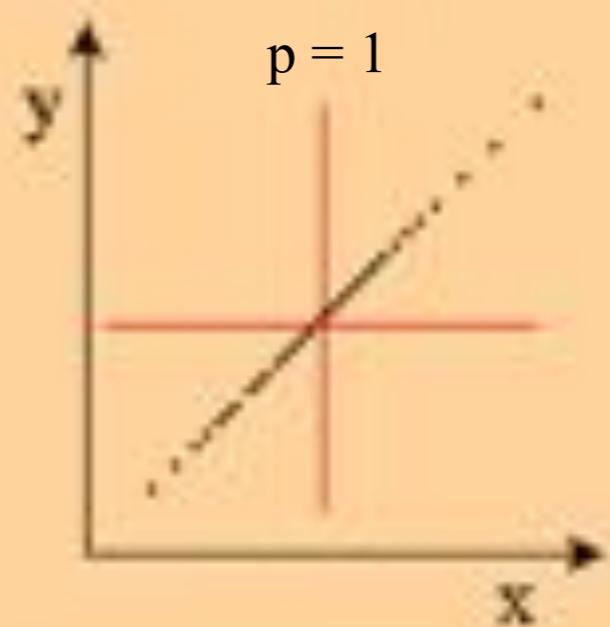
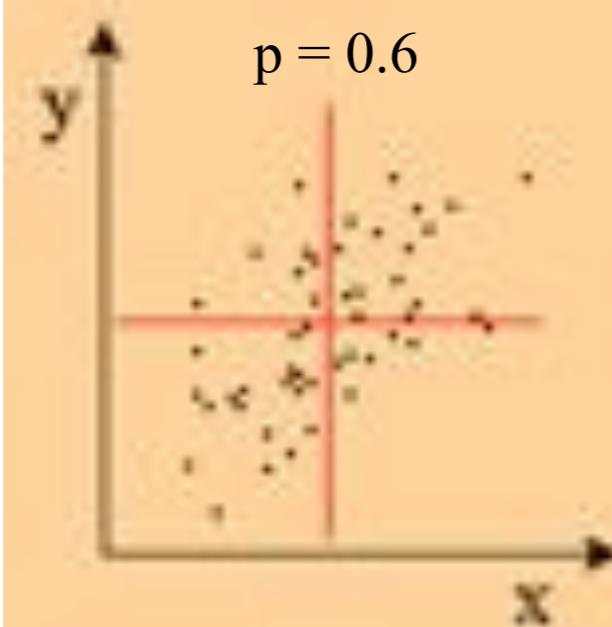
$$\rho(I, J) = \frac{\sum_{x,y} (I(x, y) - \bar{I})(J(x, y) - \bar{J})}{\sqrt{\sum_{x,y} (I(x, y) - \bar{I})^2} \sqrt{\sum_{x,y} (J(x, y) - \bar{J})^2}}$$

$$\rho = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$



Exemples

$$\rho = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$



# Coefficient de corrélation

- Calculable à partir de l'histogramme conjoint  $H_{I,J}$ ?
- $n$ , nombre de pixels dans chaque image
- $I$  et  $J$  moyens

$$\bar{I} = \frac{1}{n} \sum_{i,j} H(i,j) i \quad (\text{idem pour } \bar{J})$$

- Covariance

$$\sum_{x,y} (I(x,y) - \bar{I}) (J(x,y) - \bar{J}) = \sum_{i,j} H(i,j) (i - \bar{I}) (j - \bar{J})$$

$$\sum_{x,y} (I(x,y) - \bar{I})^2 = \frac{1}{n} \sum_{i,j} H_{i,j} i^2 - \bar{I}^2 \quad (\text{idem pour J})$$

# Coefficient de corrélation

- À partir de l'histogramme conjoint

$$\rho(I, J) = \frac{\sum_{i,j} H(i,j) (i - \bar{I}) (j - \bar{J})}{\sqrt{(\frac{1}{n} \sum_{i,j} H_{i,j} i^2 - \bar{I}^2)(\frac{1}{n} \sum_{i,j} H_{i,j} j^2 - \bar{J}^2)}}$$

# Conservation de l'intensité - SSD

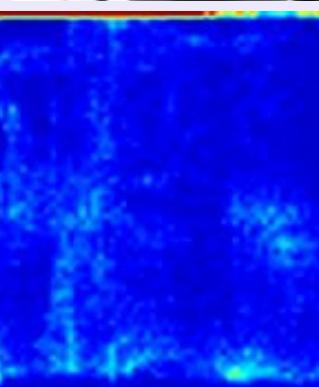
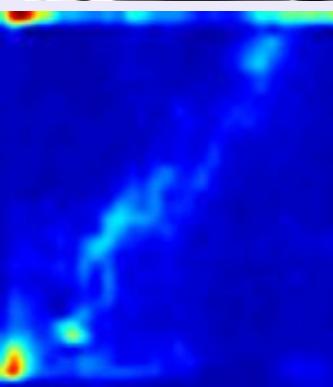
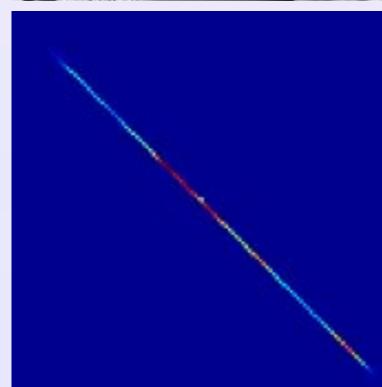
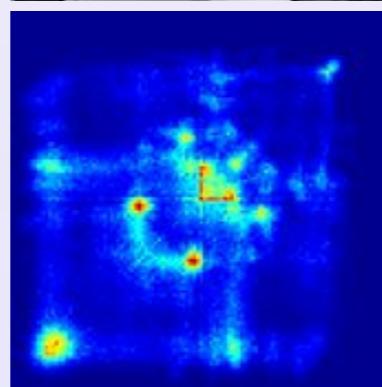
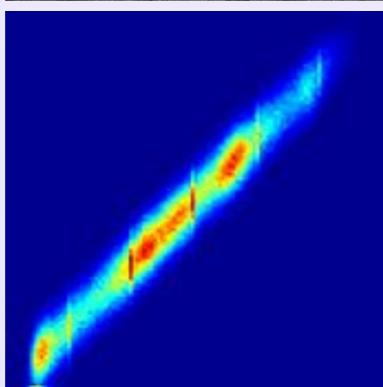
*I*



*J*



$H_{I,J}$



$\text{SSD}(I, J)$

652

$10^9$

$10^{10}$

5600

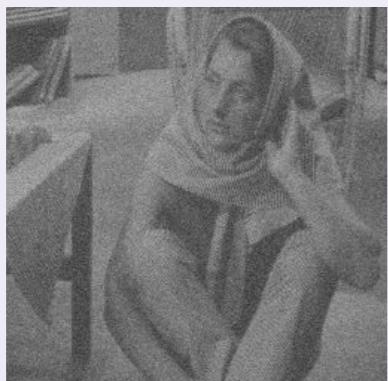
13400

# Coefficient de corrélation

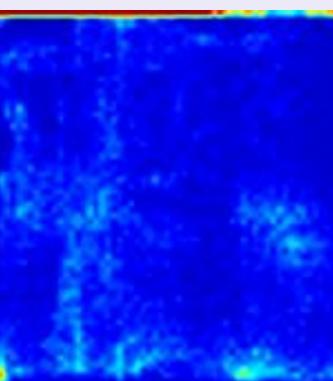
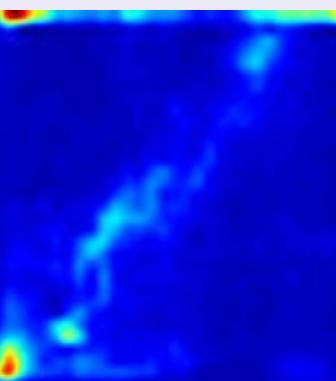
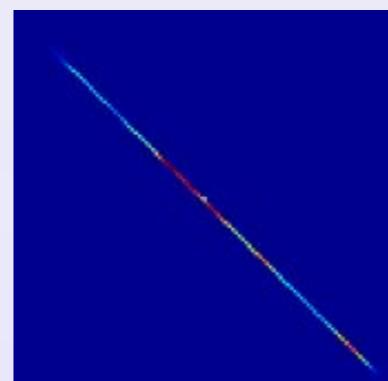
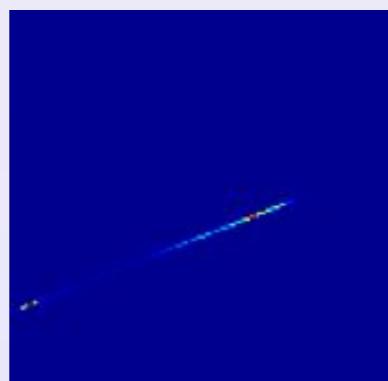
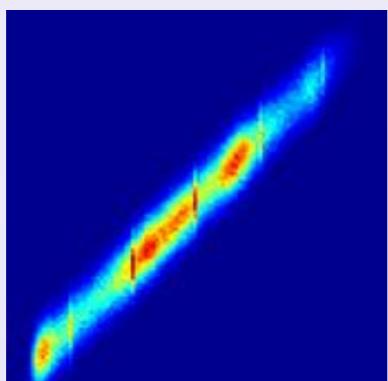
$I$



$J$



$H_{I,J}$



$\rho(I, J)$

0.95

1

-1

0.54

0.14

# Dépendance fonctionnelle

- Quand les images viennent de modalités différentes, l'hypothèse *affine* est souvent grossièrement fausse
- On peut alors supposer l'existence d'une relation fonctionnelle plus générale (non-linéaire, non-monotone) entre les intensités
- Critères possibles
  - Critère de Woods
  - rapport de corrélation

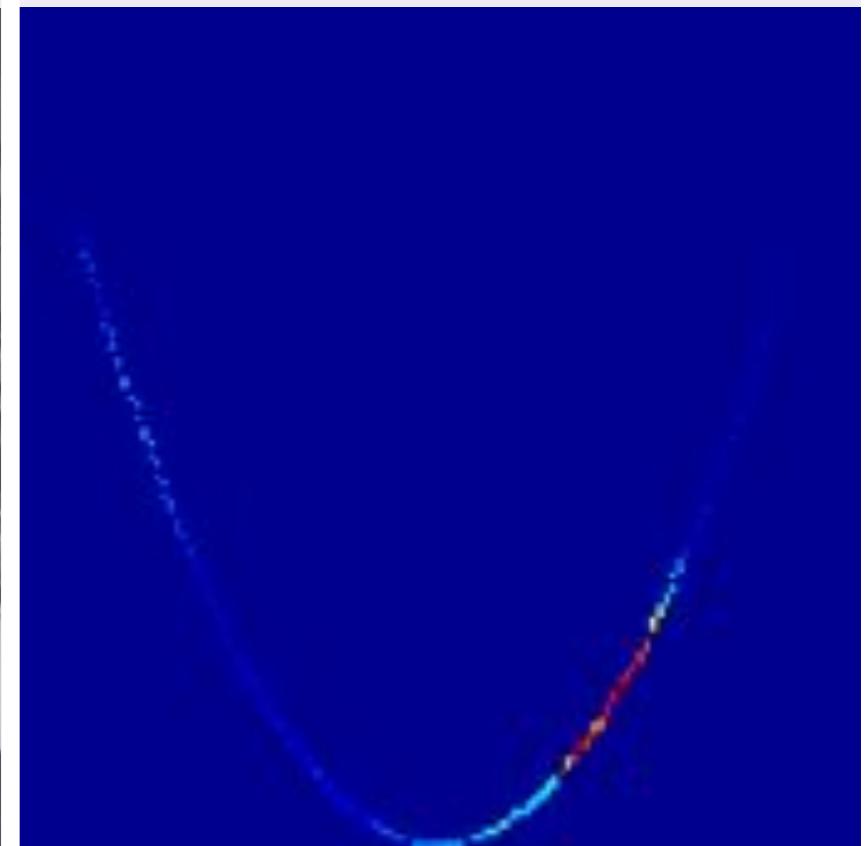
Critères asymétriques : on peut voir  $I$  presque égale à  $f(J)$  sans que l'inverse soit possible (si  $f$  est non-monotone ou non-linéaire par exemple). On doit donc choisir à l'avance dans quel sens la mesure est calculée.

Pour plus de détails... voir  
[Woods et al 1993, Roche 1998].

# Dépendance fonctionnelle

- Exemple:  $I(x,y)$  valeur dans  $[0, 255]$
- $J(x,y) = (I(x,y) - 127)^2$

$$p(I, J) = -0.3$$



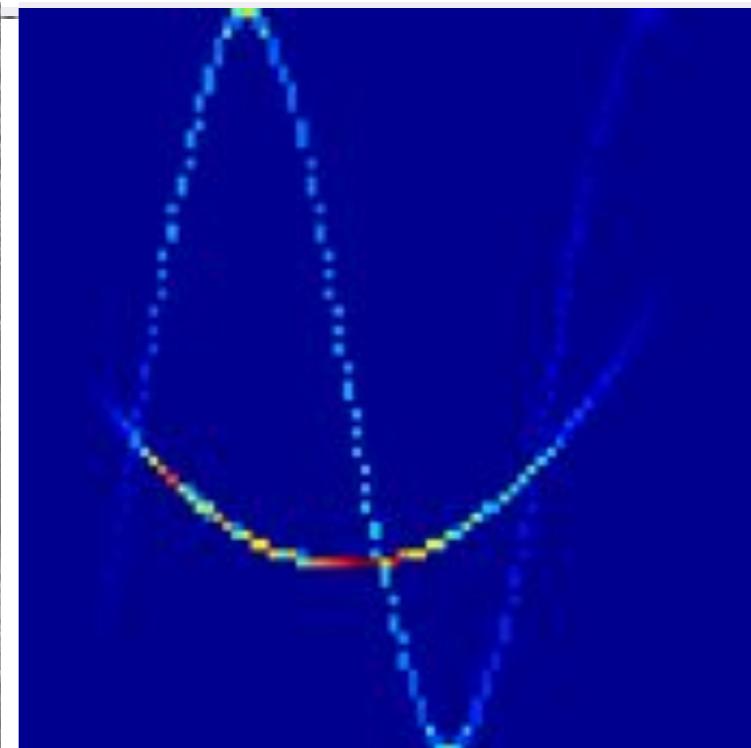
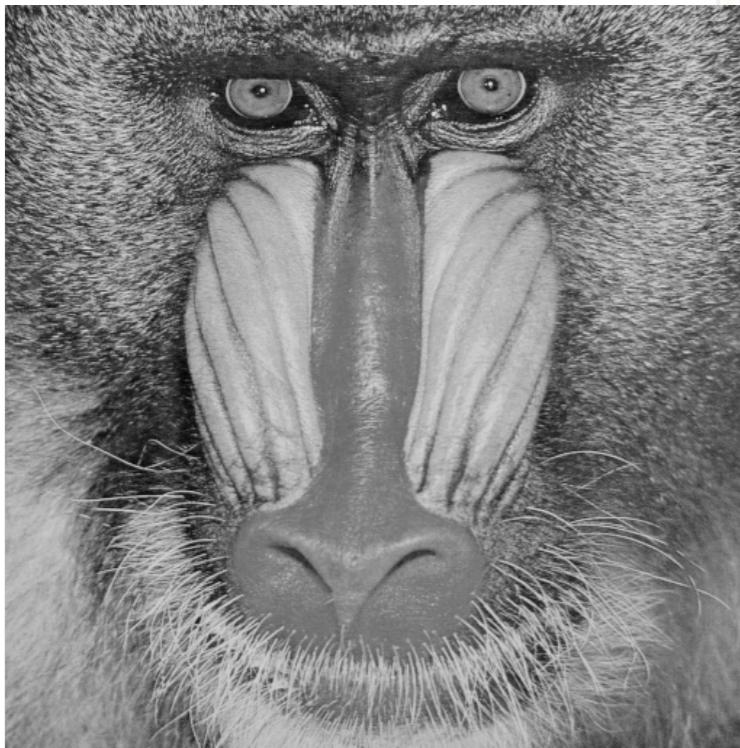
SSD = 85000

# Dépendance fonctionnelle

```
I = double(imread('mandrill.png'));
I = I/256;
J = arrayfun(@f, I);

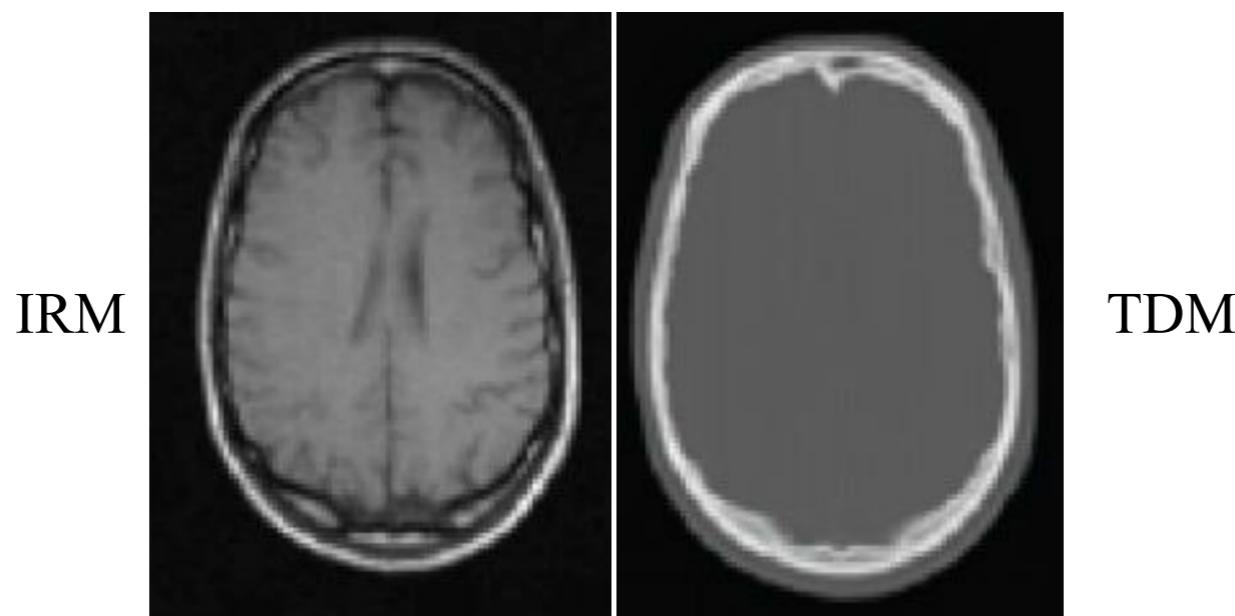
function y = f(x)
if (rand<.5)
    y = sin(4*pi*x)+.5;
else
    y = 5*(x-.5).^2;
end
end
```

SSD	p(I, J)
78000	0.2



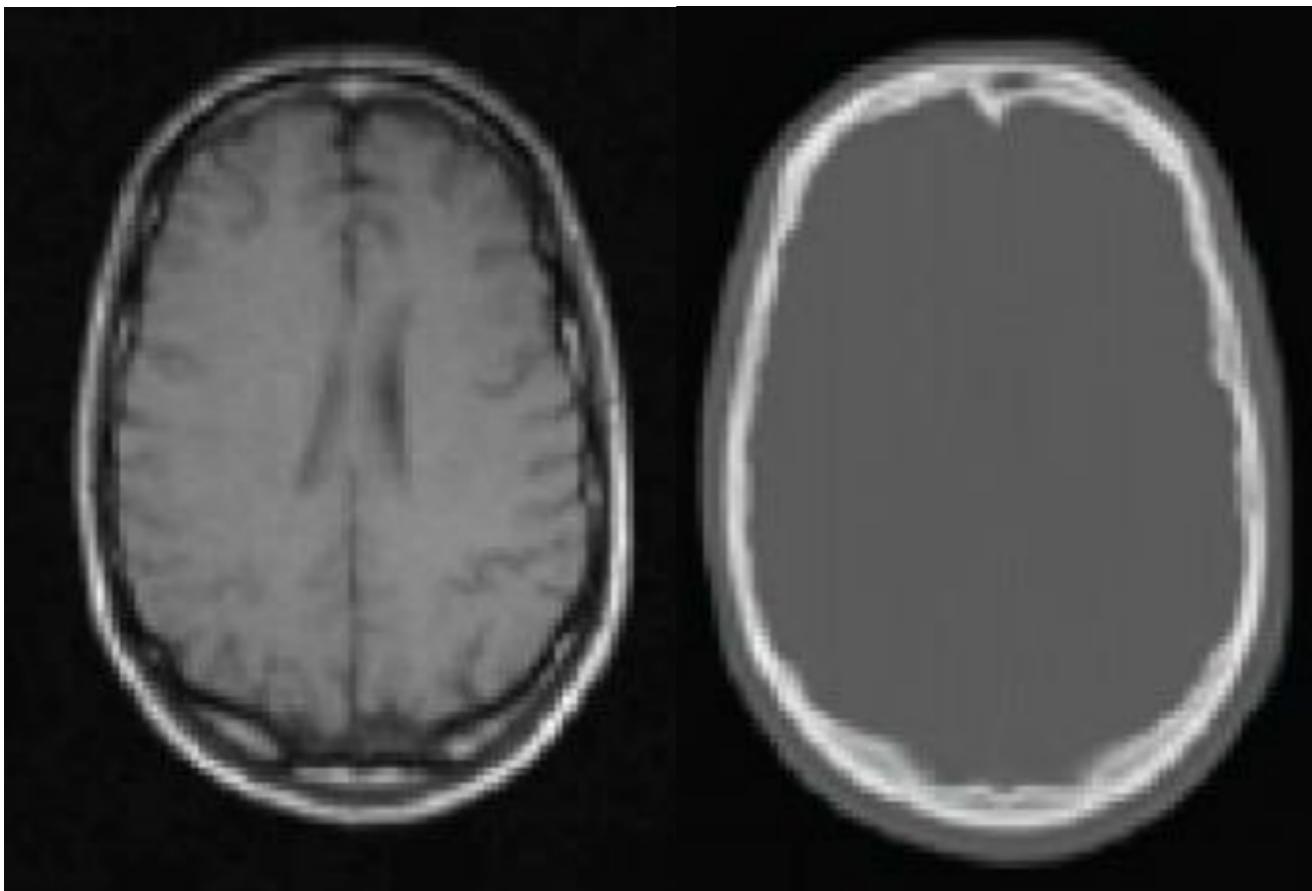
# Critère de similarité

- Dépendance fonctionnelle : souvent pas suffisant
- Exemple: fusion IRM-TDM.
- En IRM T1, le liquide céphalo-rachidien et l'os donnent sensiblement les mêmes réponses alors qu'ils sont nettement différenciés dans la TDM
- À l'inverse, les tissus mous (matière blanche / grise) sont généralement différenciés en IRM T1, mais confondus en TDM



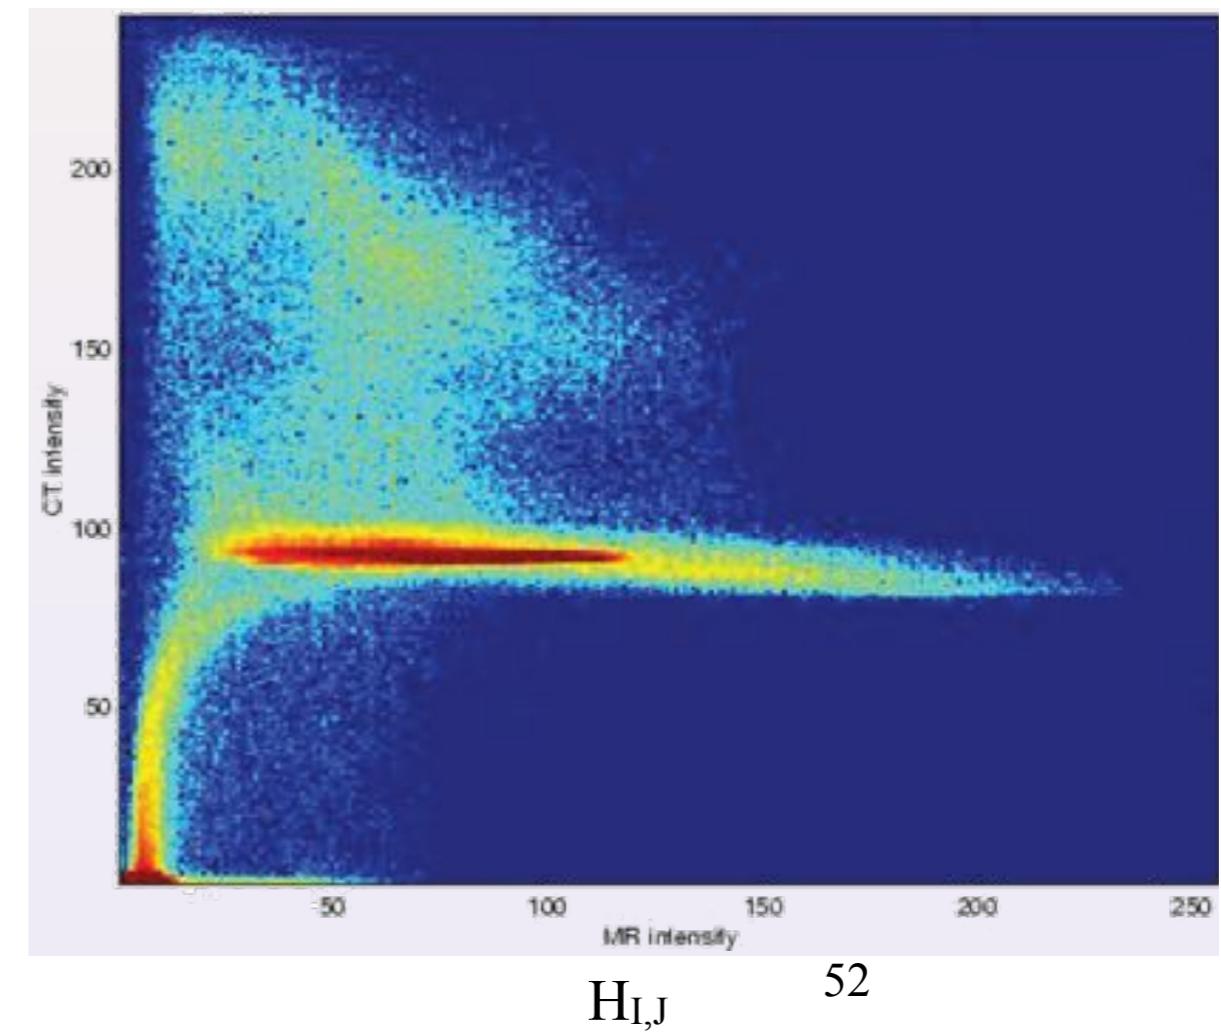
# Limite de la dépendance fonctionnelle

- Il n'est donc pas possible de relier fonctionnellement les deux modalités



IRM

TDM



$H_{I,J}$  52

# Dépendance statistique

- C'est ici que  $H_{I,J}$  prend toute sa dimension et puissance
- Rappel : interprétation statistique de  $H_{I,J}$
- $H_{I,J}(i,j) =$  “probabilité d'un pixel tiré aléatoirement ait l'intensité  $i$  dans l'image  $I$  et que son correspondant ait l'intensité  $j$  dans l'image  $J$ ”
- Donc, naturel de considérer une mesure de similarité qui prend le degré de dépendance statistique entre ces variables

# Dépendance statistique

- Les différentes mesures de similarités proposées:
  - Entropie conjointe (1995)
  - Coefficient de corrélation entropique (1998)
  - Information mutuelle (1995)

# Dépendance statistique

- La notion de dépendance statistique est celle la plus générale (hypothèses les plus faibles sur la relation entre les intensités)
- On veut tester le degré de dépendance statistique entre l'intensité de l'image I et l'intensité de l'image J : Peut-on dire qqch sur les valeurs probables de  $J(x,y)$  si l'on connaît  $I(x,y)$  (et réciproquement)?

## Information mutuelle

Soit  $X$  et  $Y$  deux variables aléatoires, on définit l'information mutuelle de ce couple de v.a. par

$$IM(X, Y) = \sum_{x,y} p(x, y) \log \left( \frac{p(x, y)}{p(x) p(y)} \right)$$

$$IM(X, Y) = IM(Y, X)$$

$$IM(X, Y) = \sum_{x,y} p(x, y) \log \left( \frac{p(x, y)}{p(x) p(y)} \right)$$

# Information mutuelle (IM)

- Si les 2 variables sont indépendantes
  - $p(x, y) = p(x)p(y)$ , ce qui implique que  $IM(x, y) = 0$
- On peut démontrer que  $IM(X, Y) = 0$  ssi X et Y sont indépendantes
- On peut aussi démontrer que  $IM(X, Y) \geq 0$ , pour tout X et Y
- L'IM d'un couple  $(X, Y)$  de variables aléatoires représente leur degré de dépendance au sens *probabiliste*
- Une interprétation : “distance” entre  $p(x, y)$  et  $p(x)p(y)$  (divergence de Kullback-Leibler)
- L'IM est donc d'autant plus grande que le couple de variables aléatoires  $(X, Y)$  est lié/dépendant

# Information mutuelle

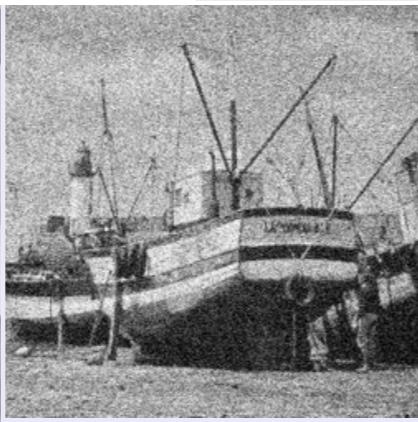
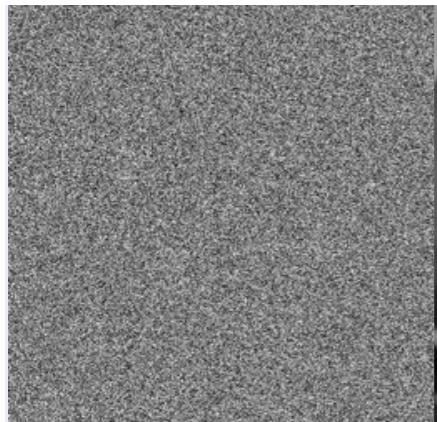
- On peut la calculer directement à partir de l'histogramme conjoint  $H_{I,J} = p_{ij}$

$$p_{i,j} = \frac{1}{n} \text{Card}\left\{(x, y) \mid I(x, y) = i \text{ et } J(x, y) = j\right\}$$

$$IM = \sum_{i,j} p_{i,j} \log \frac{p_{i,j}}{p_i p_j} \quad \text{avec} \quad p_i = \sum_j p_{i,j} \text{ et } p_j = \sum_i p_{i,j}$$

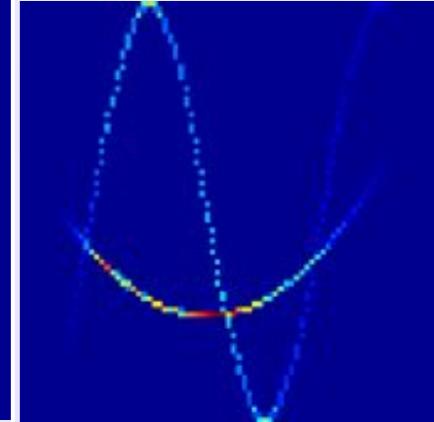
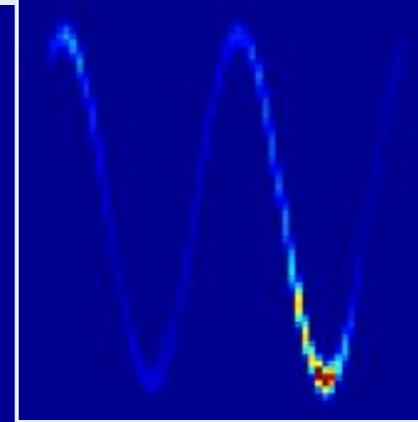
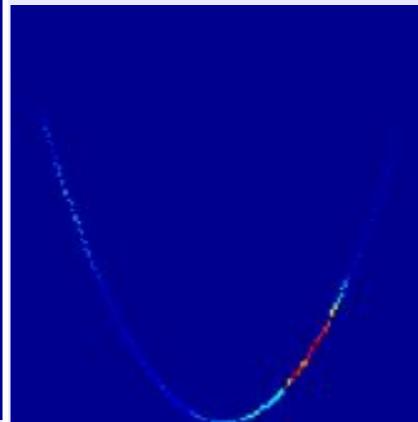
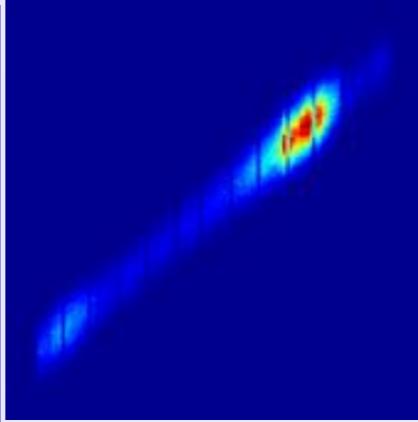
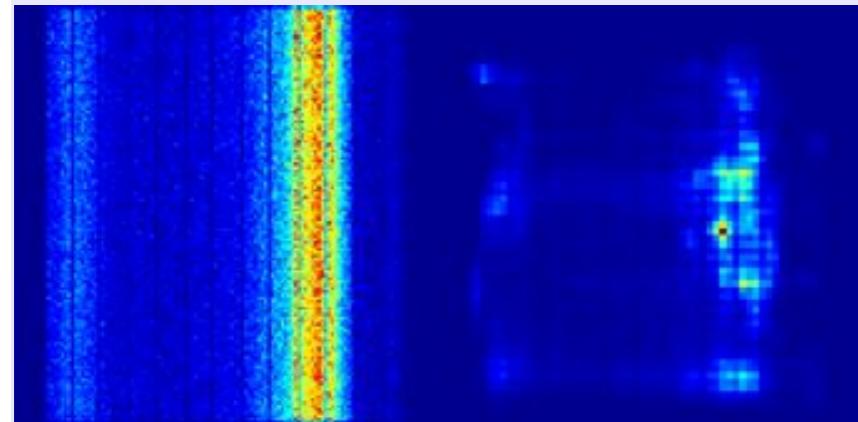
# Information mutuelle : exemples

I =



J

$H_{IJ}$



IM(I,J)

0.03

0.09

1.22

3.50

1.88

2.70

# Information mutuelles : exemples

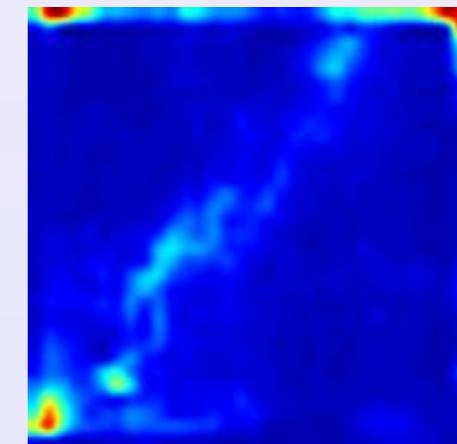
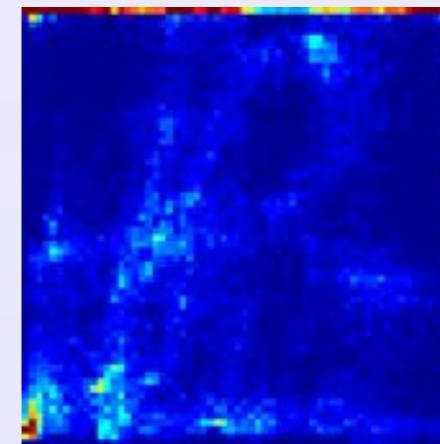
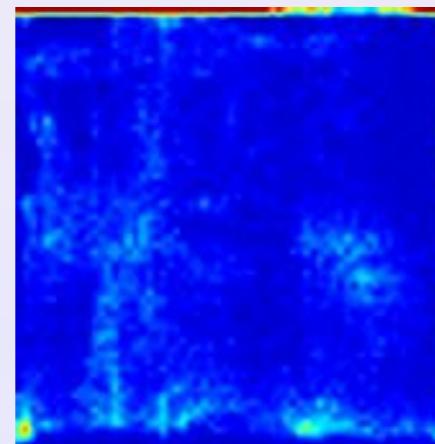
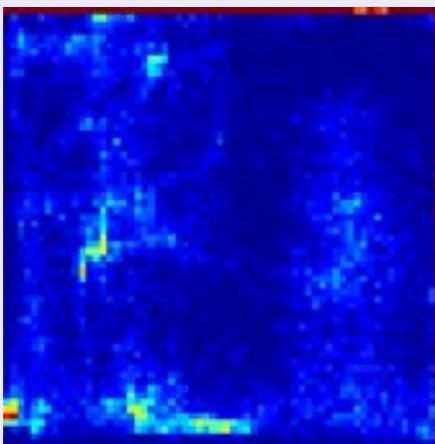
I



I



$H_{I,J}$



$IM(I,J)$

# Information mutuelle

I =

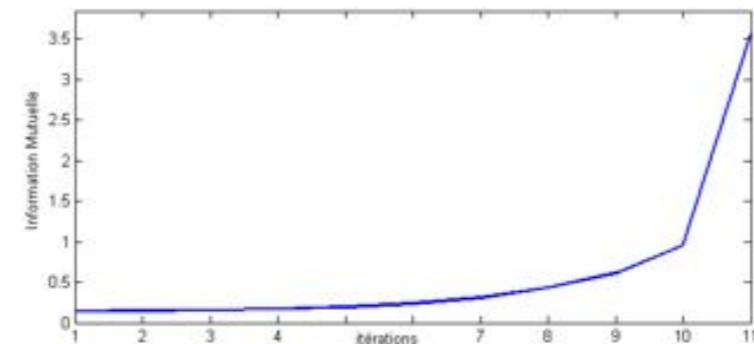


*J*



$IM(I, J)$

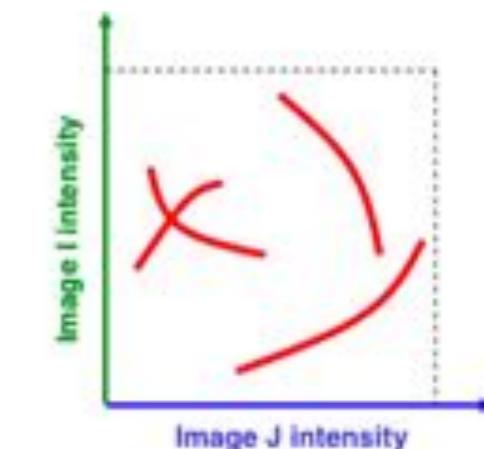
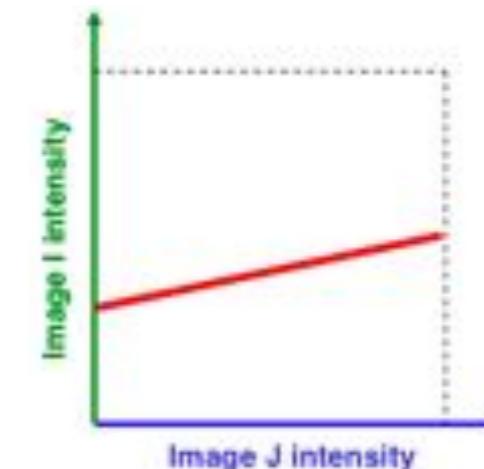
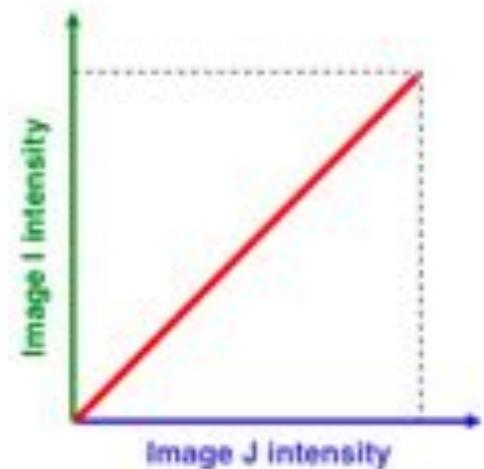
0.15



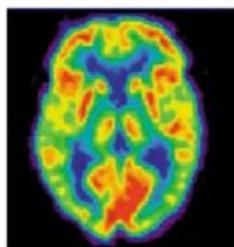
60

# Critère de similarité - sommaire

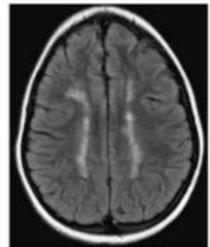
- Conservation des intensités :
  - **SSD** (à minimiser)
  - Adapté pour le recalage mono-modal intra-patient
- Dépendance affine :
  - **Coefficient de corrélation** (à maximiser)
  - Adapté pour le recalage mono-modal intra et inter-patient
- Dépendance statistique :
  - **Information mutuelle** (à maximiser)
  - Adapté pour le recalage multi-modal (TDM/TEP, TDM/IRM, ...)



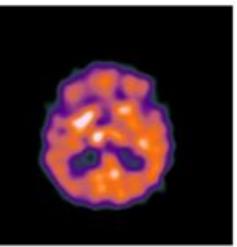
# Les transformations linéaires



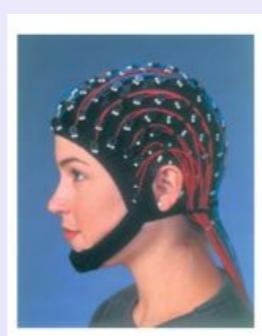
TEP



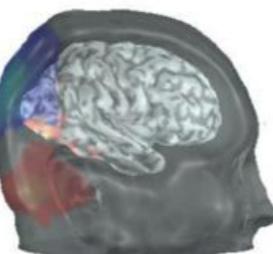
IRM



SPECT



EEG



MEG

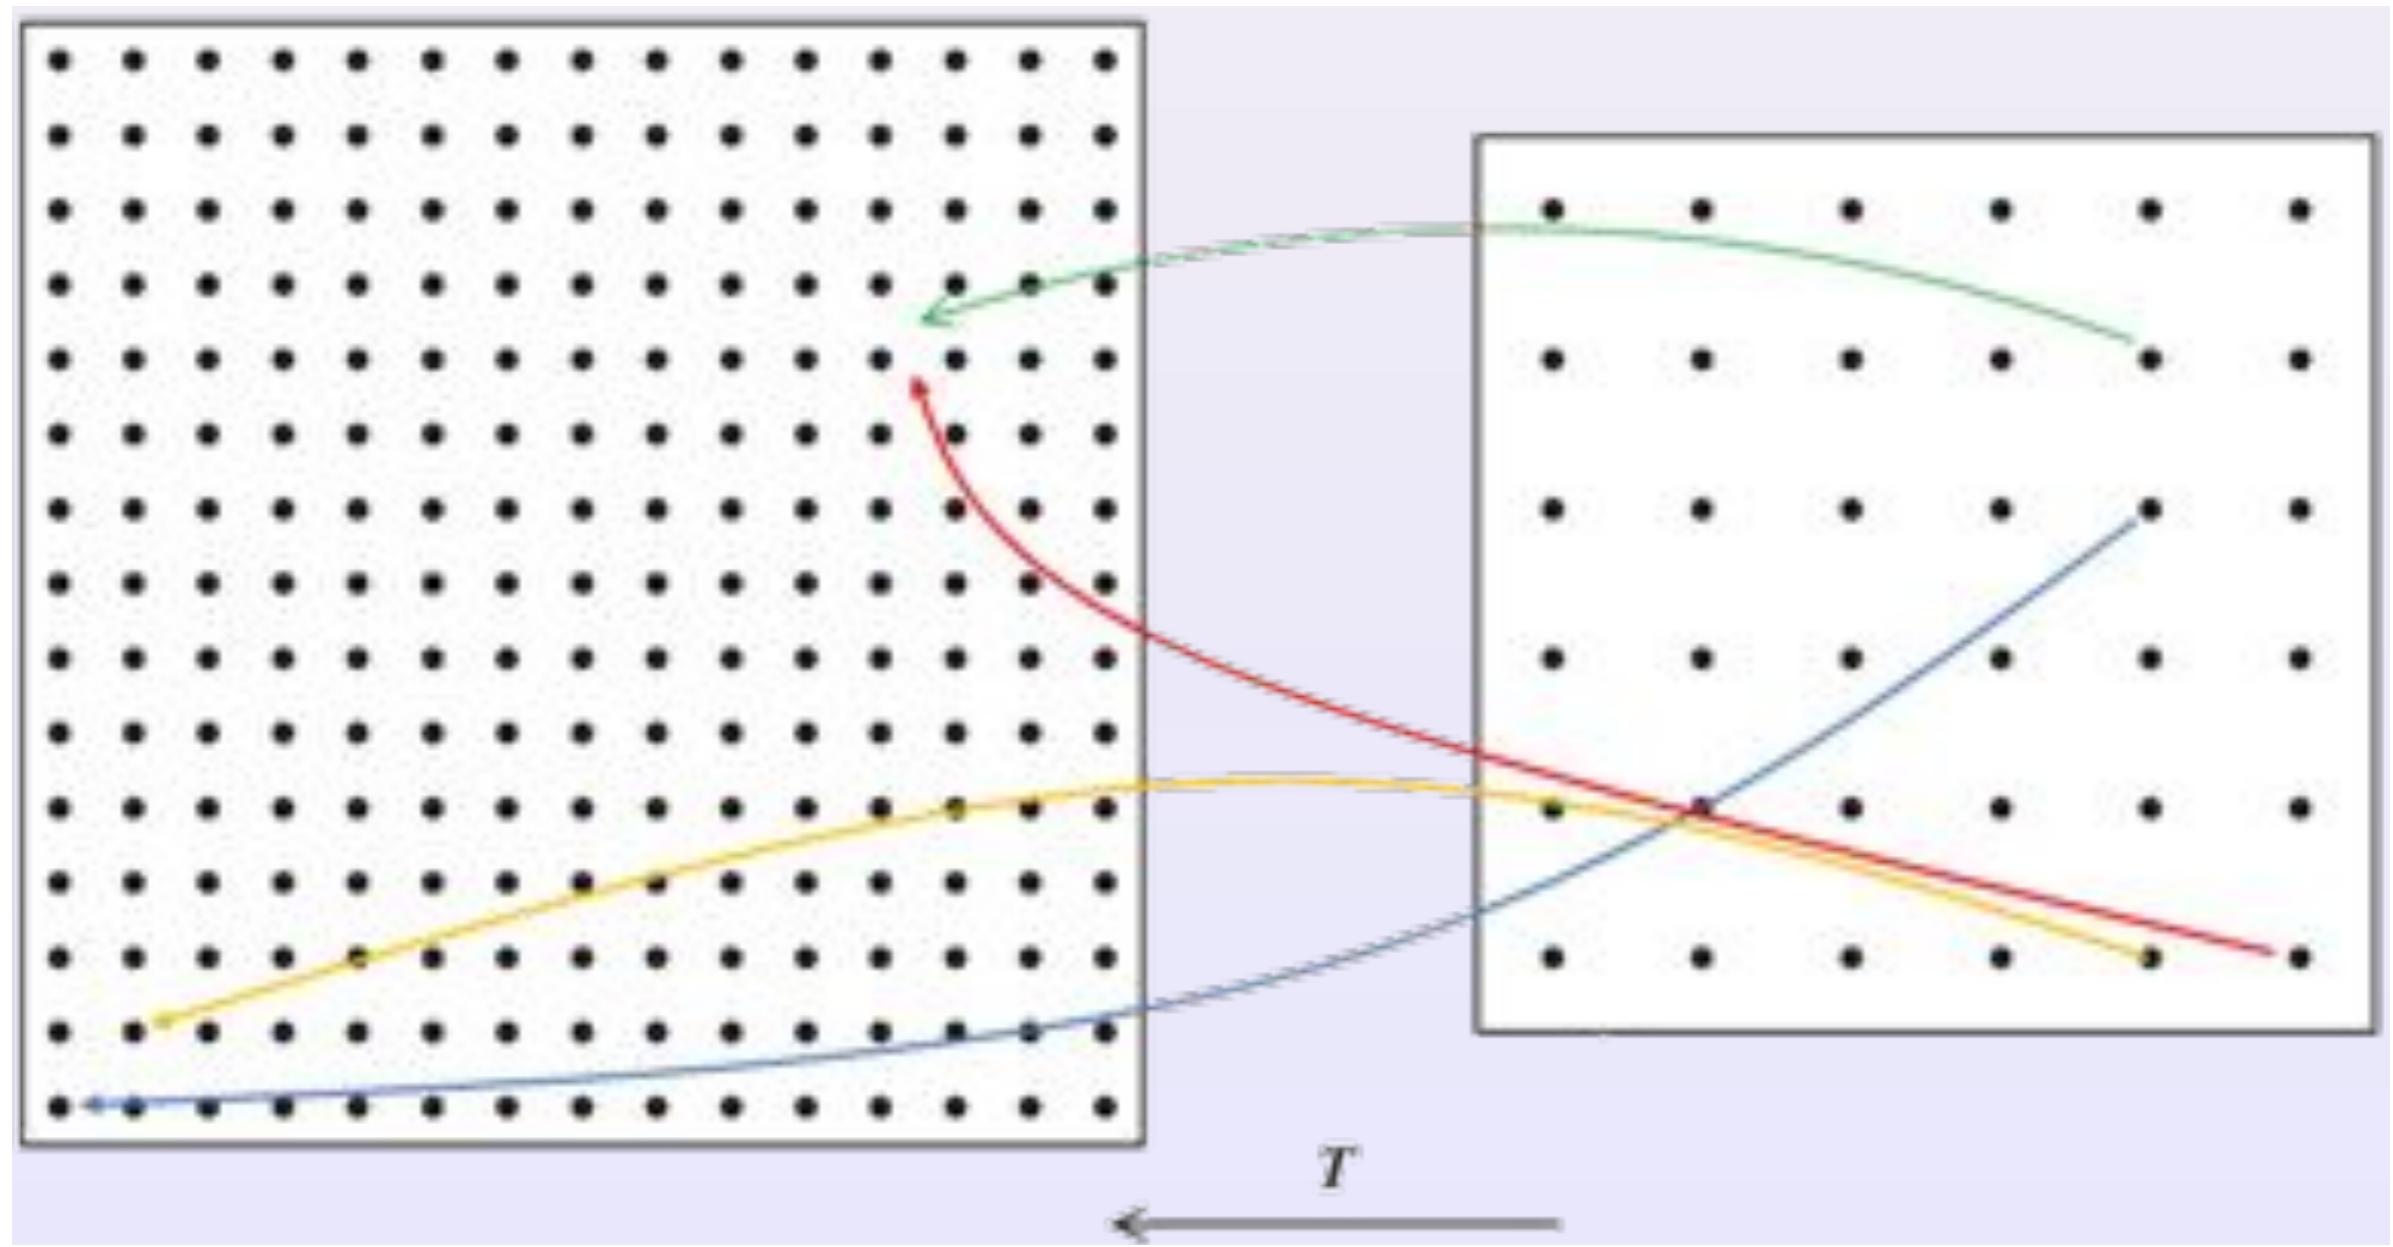
# Transformations

- Rappel : le problème de recalage

$$\arg \min_{T \in \mathcal{F}} \text{Simil}(T(I), J) = ?$$

- On vient de voir différentes possibilités pour Simil (SSD, coefficient de corrélation, IM)
- On cherche  $T$ , une transformation **spatiale** seulement (ne doit pas toucher les intensités de  $I$  et  $J$ )
- On se doit d'imposer des contraintes sur  $T$  (sinon aucun sens physique)

# Transformations - T



# Modèles mathématiques de transformation

- Pour aligner 2 images, il est nécessaire d'établir la **relation mathématique** qui les relie
- Considérons deux images I et J (dans leur système de coordonnées respectif), et  $p(x, y, 1)$  et  $q(x', y', 1)$  sont les coordonnées homogènes des pixels dans les images
- Le modèle mathématique permet d'associer à un point  $p$  dans I le point  $q$  lui correspondant dans J



# Modèles mathématiques de transformation

On parle généralement d'homographie lorsqu'il existe une transformation globale reliant chaque pixel  $p$  à son binôme  $q$  :

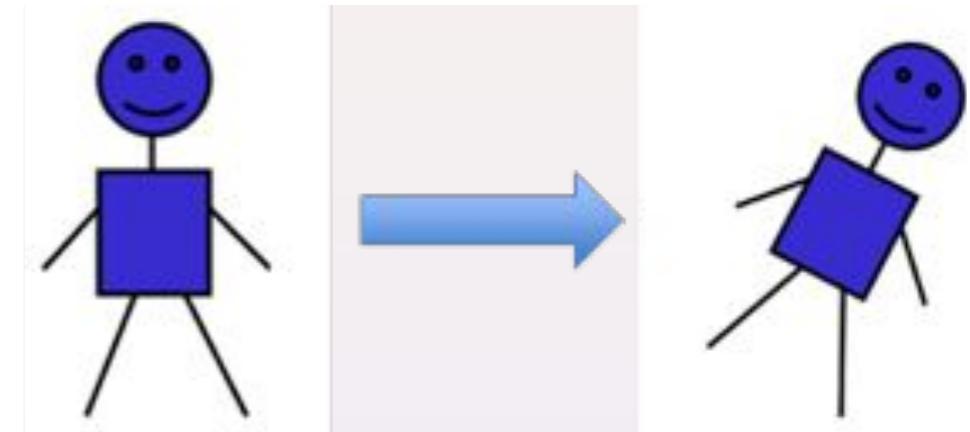
$$Hp = q$$

En d'autres mots, on parle d'homographie lorsqu'il existe une matrice  $3 \times 3$  globale reliant tous les pixels  $p$  dans  $I$  aux pixels  $q$  dans  $J$ . On utilise les *coordonnées homogènes* pour  $p$  et  $q$ .

# Modèles mathématiques de transformation rigide

Translation 2D décrite par un vecteur u

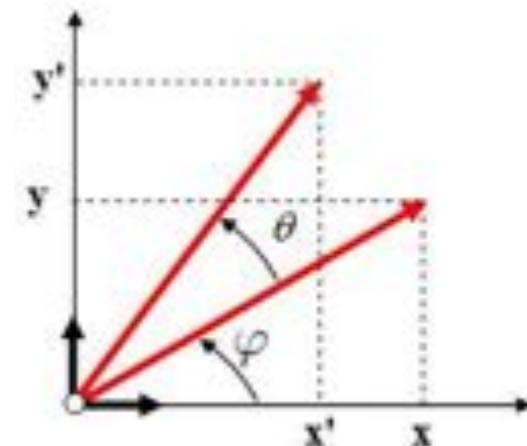
$$\begin{pmatrix} 1 & 0 & u_x \\ 0 & 1 & u_y \\ 0 & 0 & 1 \end{pmatrix} p = q$$



Rotation/Translation 2D décrite par une matrice de rotation R et un vecteur u

# Transformation rigide 2D

- 3 paramètres (2 pour la translation  $t$  et 1 pour la rotation  $R$ )
- $T(\mathbf{x}) = R\mathbf{x} + t$
- Sous forme matricielle



$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix} * \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} p \\ q \end{bmatrix}$$

# Coordonnées homogènes

$$\begin{pmatrix} \cos \theta & -\sin \theta & u_x \\ \sin \theta & \cos \theta & u_y \\ 0 & 0 & 1 \end{pmatrix} p = q$$

Très utile en visualisation et infographie. Code la transformation dans une seule opération matricielle

# Transformation rigide 3D

(3 angles rotation, 3 translation)

Translation

$$\begin{bmatrix} x' \\ y' \\ z' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & p \\ 0 & 1 & 0 & q \\ 0 & 0 & 1 & r \\ 0 & 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

Rotation par rapport à x

$$\begin{bmatrix} x' \\ y' \\ z' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & \cos(\theta) & -\sin(\theta) & 0 \\ 0 & \sin(\theta) & \cos(\theta) & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

Rotation par rapport à y

$$\begin{bmatrix} x' \\ y' \\ z' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos(\omega) & 0 & -\sin(\omega) & 0 \\ 0 & 1 & 0 & 0 \\ \sin(\omega) & 0 & \cos(\omega) & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

Rotation par rapport à z

$$\begin{bmatrix} x' \\ y' \\ z' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos(\phi) & -\sin(\phi) & 0 & 0 \\ \sin(\phi) & \cos(\phi) & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

$$T(p, q, r) * R_z(\phi) * R_y(\omega) * R_x(\theta)$$

# Décomposition en valeurs singulières (SVD)

- Rappel: généralisation de la diagonalisation de matrices carrés

## Théorème

Soit  $M$  une matrice  $m \times n$ , il existe une factorisation de la forme :

$$M = U \Sigma V^*$$

avec

- $U$  une matrice unitaire  $m \times m$
- $\Sigma$  une matrice  $m \times n$  "diagonale"
- $V^*$  est la matrice transposée (ou transconjuguée) à  $V$ , matrice unitaire  $n \times n$ .

On appelle cette factorisation la décomposition en valeurs singulières de  $M$ .

$U$  et  $V$  matrices unitaires :  $U^*U = UU^* = \text{Id}$ , ce qui implique que  $U$  est une matrice de rotation!

# Transformations rigides 3D

- Soit  $M$  une matrice  $4 \times 4$  de la forme

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & p \\ a_{21} & a_{22} & a_{23} & q \\ a_{31} & a_{32} & a_{33} & r \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

- On veut savoir si c'est une matrice de rotation rigide?
- On décompose la partie  $3 \times 3$  du haut à gauche

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = U S V^* \quad \text{avec} \quad S = \begin{bmatrix} v_1 & 0 & 0 \\ 0 & v_2 & 0 \\ 0 & 0 & v_3 \end{bmatrix}$$

- Alors,  $S$  (et donc  $M$ ) correspond à une trans. rigide ssi :

$$S = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \text{ ou } \begin{bmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \text{ ou } \begin{bmatrix} -1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -1 \end{bmatrix} \text{ ou } \begin{bmatrix} 1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \end{bmatrix}$$

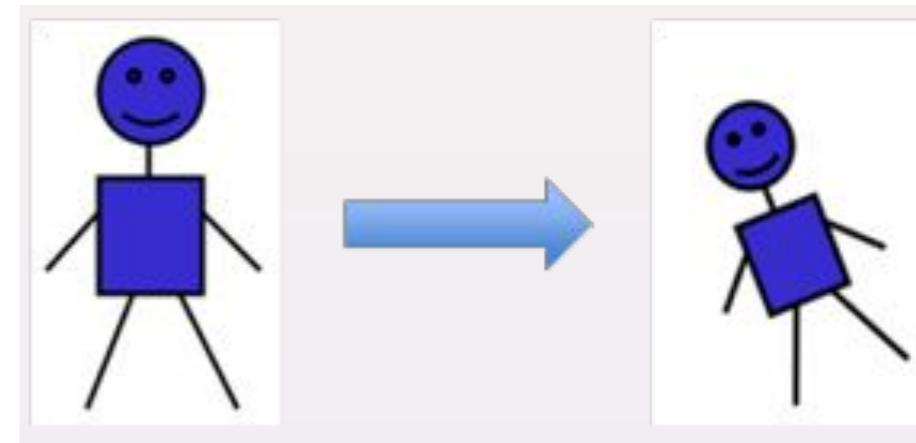
# Modèles mathématiques de transformation

Similitude 2D (rotation R pondérée par un facteur d et translation u)

$$\begin{pmatrix} d \cdot \cos\theta & -\sin\theta & u_x \\ \sin\theta & d \cdot \cos\theta & u_y \\ 0 & 0 & 1 \end{pmatrix} p = q$$

d est un facteur d'échelle quelconque.

- $d$  est un “scaling”,  $T(x) = d \cdot Rx + t$
- S de la diapo d'avant multiplié par le facteur  $d$
- Conserve le rapport de distances, orientations, angles, lignes



# Transformation affine

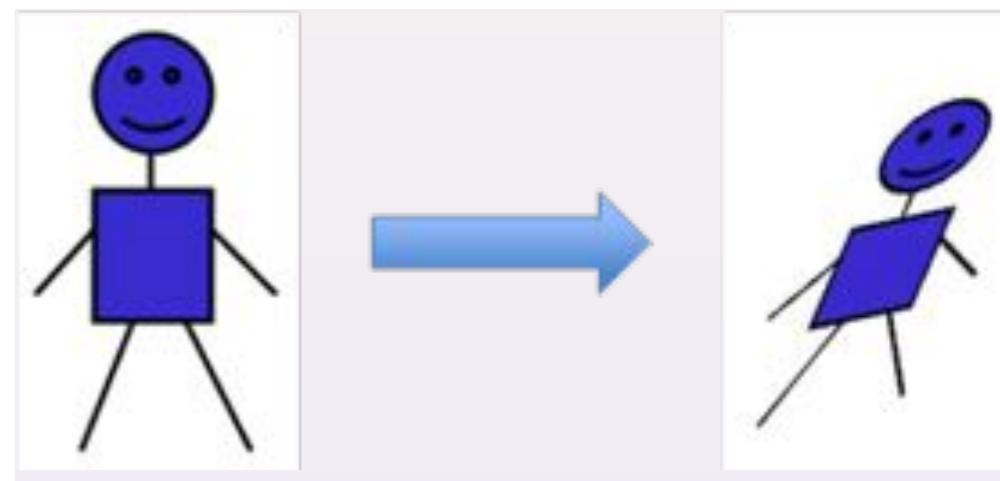
- $T(\mathbf{x}) = B\mathbf{x} + \mathbf{t}$ , avec  $B$  une matrice  $3 \times 3$  quelconque

$$Hp = q$$
$$p = (x^p, y^p, 1)^T$$
$$q = (x^q, y^q, 1)^T$$

- Nombre de paramètres?
- 12 ( $B = 9$  et  $\mathbf{t} = 3$ )

$$\begin{bmatrix} x' \\ y' \\ z' \\ 1 \end{bmatrix} = \begin{bmatrix} e_{11} & e_{12} & e_{13} & e_{14} \\ e_{21} & e_{22} & e_{23} & e_{24} \\ e_{31} & e_{32} & e_{33} & e_{34} \\ 0 & 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

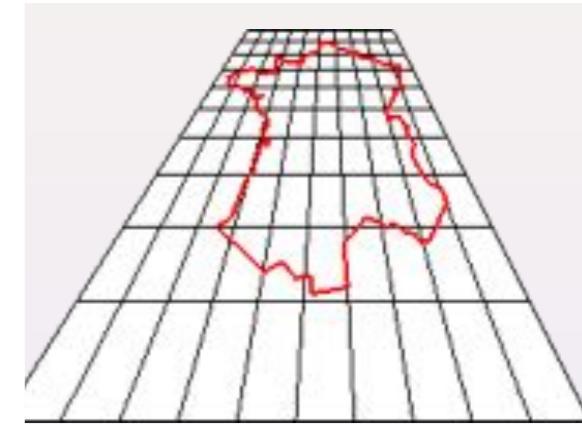
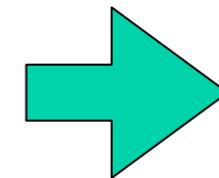
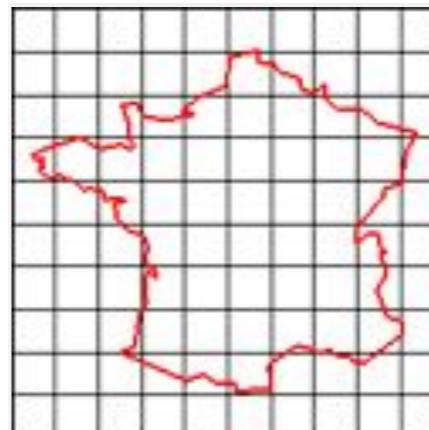
- Conserve les lignes et le parallélisme



# Transformation projective

- La plus générale des transformations linéaires

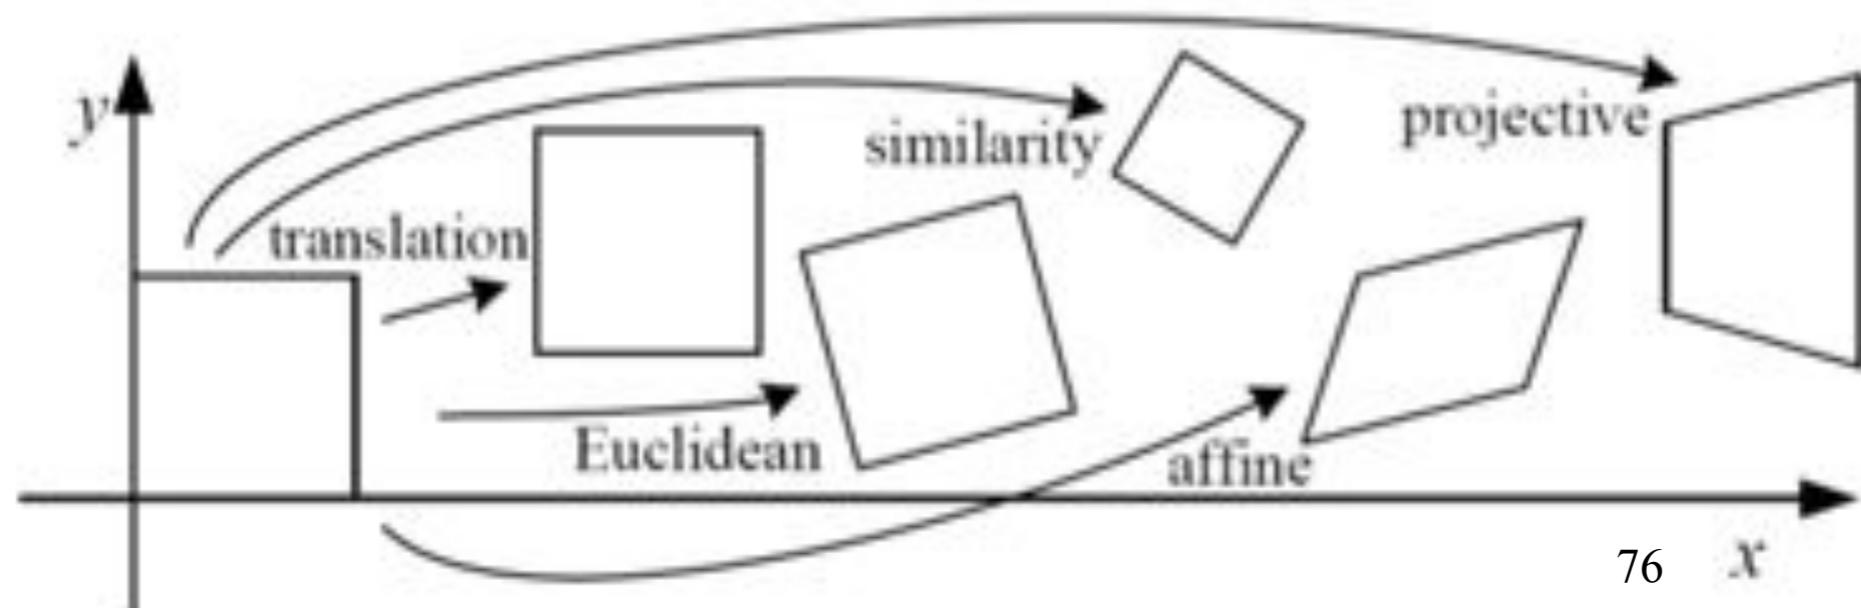
$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} e_{11} & e_{12} & p \\ e_{21} & e_{22} & q \\ f & g & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$



- Les lignes restent des lignes, mais des lignes qui étaient parallèles peuvent s'intersecter après transformation
- Typiquement: imagerie non-médicale
- Images 3D recalées avec des images 2D acquises au moyen d'une caméra (images vidéo ou radiologiques)

# Toutes les transformations 2D - sommaire

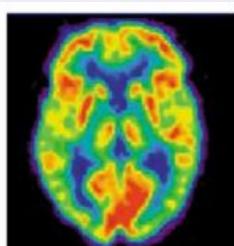
- **Translation** : 2 degrés de liberté
- **Rotation + translation** : 3 degrés de liberté
- **Similitude** : 4 degrés de liberté
- **Transformation affine** : 6 degrés de liberté
- **Transformation projective** : 8 degrés de liberté



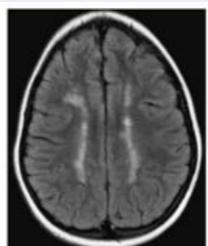
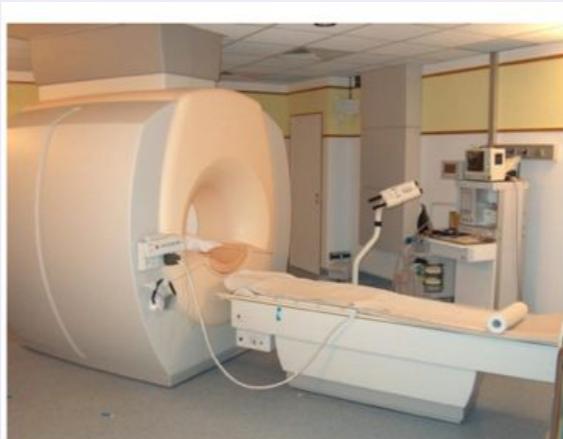
# Transformations linéaire - sommaire

- Peuvent s'écrire sous forme d'une seule matrice  $H$  (rigide, affine, projective) ... trans. "globale" ... une seule matrice
- Transformations rigides
  - Intra-sujet, même séance, mono-modalité (souvent)
- Transformations affines
  - Résolution spatiale des 2 images différentes
  - Intra-sujet, multi-modalité
- Transformations projectives
  - Recalages 3D/2D
  - e.g. recalage de radiographies sur des données TDM ou IRM

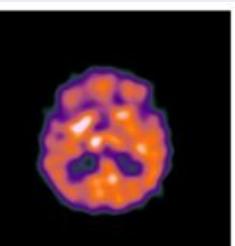
# Les techniques d'alignement (optimisation)



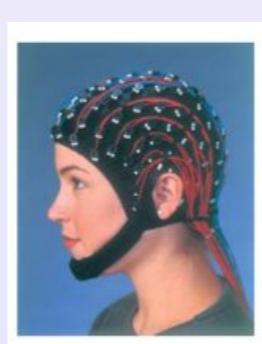
TEP



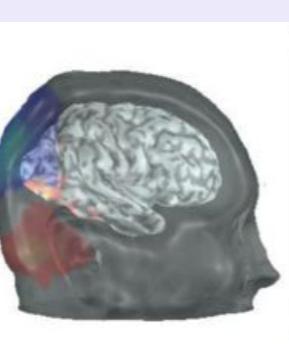
IRM



SPECT



EEG



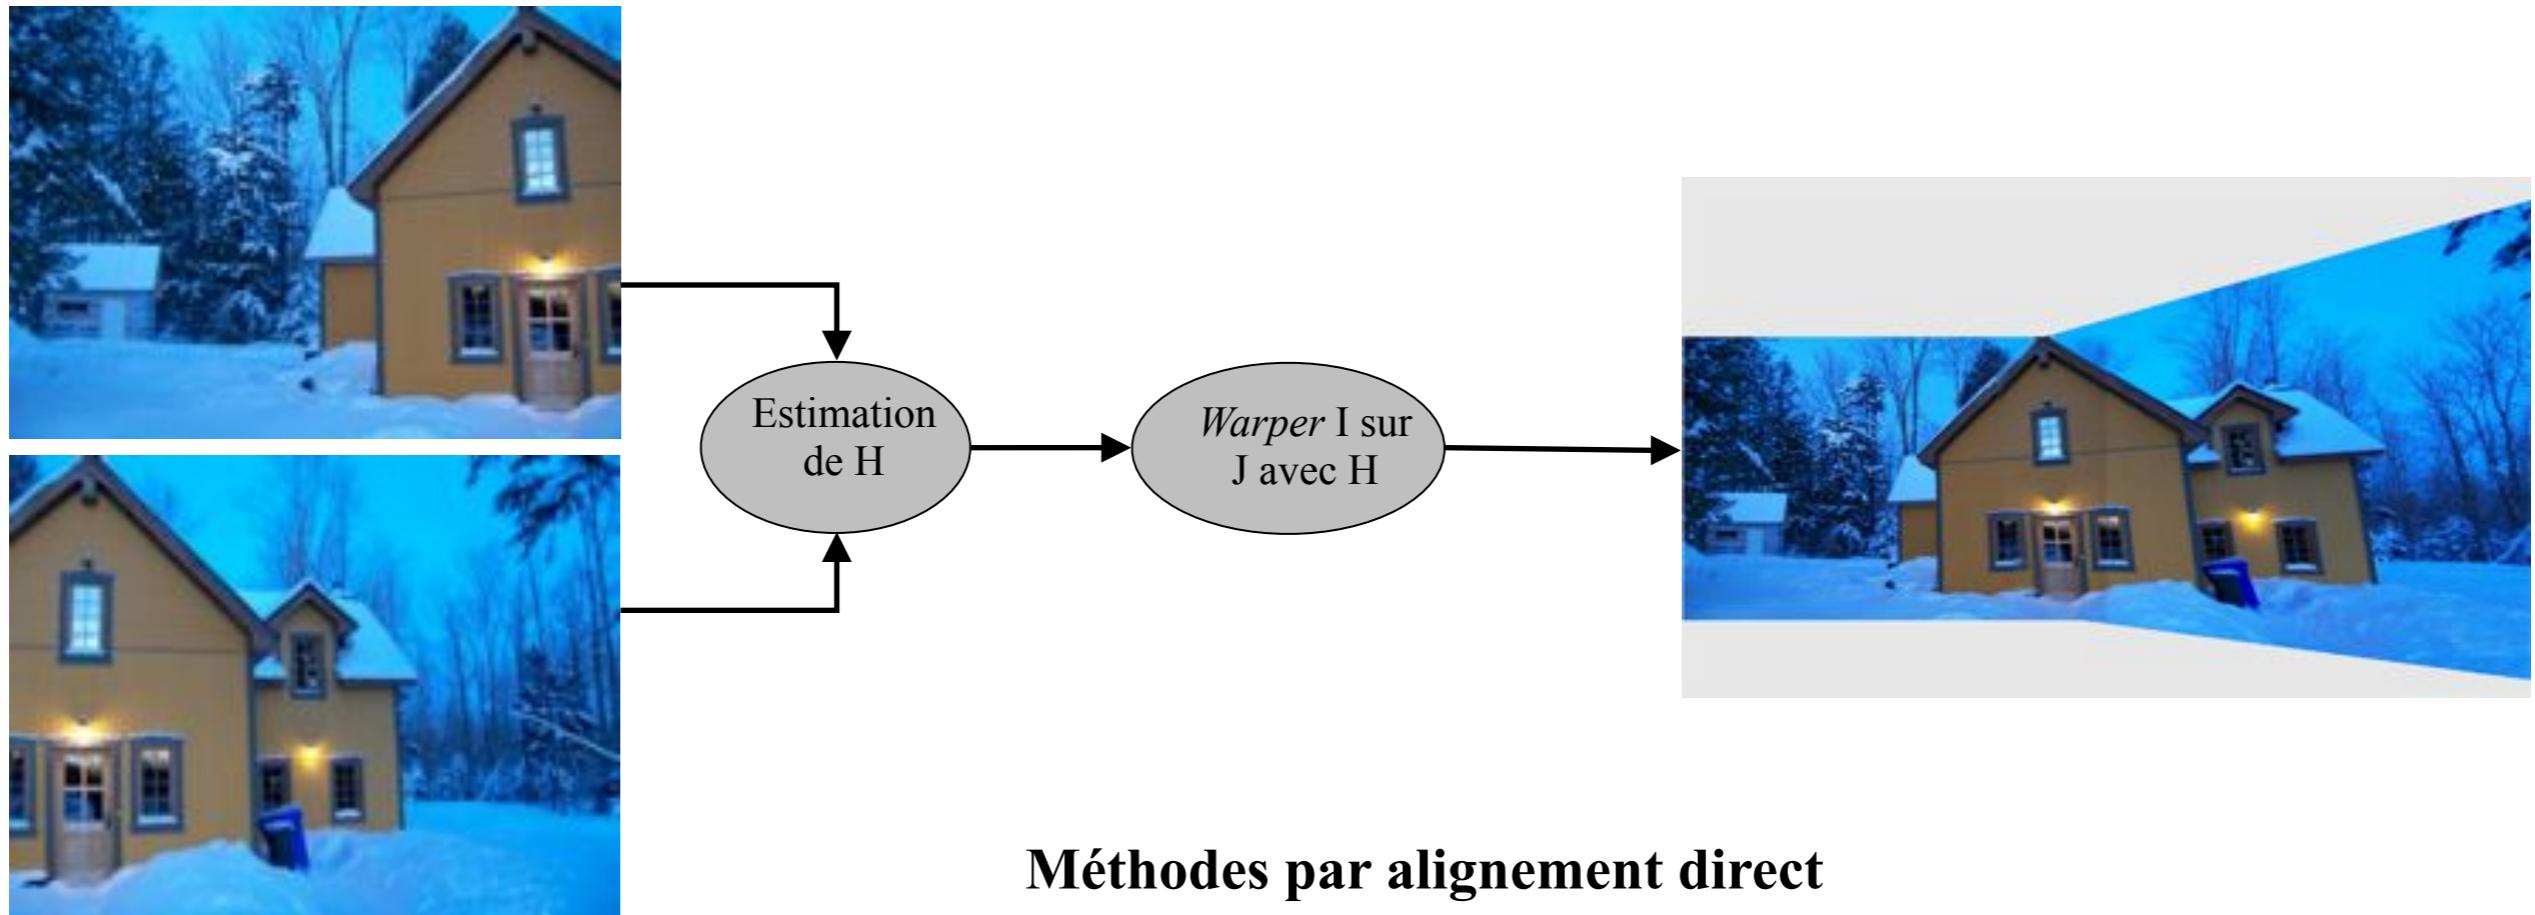
MEG

# Optimisation

- Étant donné un certain critère de similarité (SSD, CR, IM) et une famille de transformation (rigide, affine), comment trouver la transformation  $T$  telle que  $T(I)$  et  $J$  se ressemblent?
- Deux grandes familles d'approches:
  - Approches iconiques (directement sur les intensités des images)
  - Approches géométriques (d'abord segmentation, puis appariement de primitives géométriques ou caractéristiques extraites)

# Alignements

D'ici la fin, nous verrons plusieurs façons d'estimer la **matrice de transformation  $H$**  à partir de 2 images.



# Alignement direct par corrélation

Translation

Plutôt que de mesurer les différences d'intensité, on peut effectuer une **corrélation**, c'est-à-dire **maximiser** le produit terme à terme (corrélation croisée) de l'image  $I_1$  avec l'image  $I_2$  décalée.

$$E_{corr}(\vec{u}) = (I_1 \circ I_2)(\vec{u}) = \sum_s I_2(s + \vec{u})I_1(s)$$

# Alignement direct par corrélation

## Translation

Dans le cas où  $\vec{u}$  est petit, maximiser  $E_{corr}(\vec{u})$  revient à minimiser  $E_{SSD}(\vec{u})$

**Preuve :**

$$\begin{aligned} E_{SSD}(\vec{u}) &= \sum_s (I_2(s + \vec{u}) - I_1(s))^2 \\ &= \sum_s (I_2(s + \vec{u}))^2 - 2I_2(s + \vec{u})I_1(s) + (I_1(s))^2 \\ &= \sum_s (I_2(s + \vec{u}))^2 - 2 \sum_s I_2(s + \vec{u})I_1(s) + \sum_s (I_1(s))^2 \end{aligned}$$

où  $\sum_s (I_2(s + \vec{u}))^2 \approx cst$  pour tout  $\vec{u}$  lorsque  $\vec{u}$  est petit

$$\sum_s (I_1(s))^2 = cst$$

$$(I_1 \circ I_2)(\vec{u}) = \sum_s I_2(s + \vec{u})I_1(s)$$

Par conséquent,  $E_{SSD}(\vec{u})$  est minimale lorsque  $(I_1 \circ I_2)(\vec{u})$  est maximale.

# Alignment direct

Translation

Maintenant que nous avons défini une fonction de coût, on s'intéresse aux techniques d'optimisation qui seront utilisées pour trouver le vecteur  $\vec{u}$  qui la minimise :

$$\hat{\vec{u}} = \arg \min_{\vec{u}} E(\vec{u})$$

Il y a *grosso modo* 3 solutions envisageables ici :

1. **La recherche exhaustive**
  - \* Lent et précis au pixel près
2. **FFT**
  - \* Rapide, précis au pixel près, mais valide uniquement pour de petits  $|\vec{u}|$
3. **Lucas-Kanade**
  - \* Moyennement rapide, requiert que  $|\vec{u}|$  soit petit, précis au sous-pixel

# Alignement direct

Recallage par FFT

Sachant que la corrélation dans le domaine spatial entre 2 images est une opération **très très coûteuse** en temps de calculs, il est très avantageux de tirer profit des propriétés de la Transformée de Fourier (TF) car

$$f \circ g \xrightleftharpoons[\mathfrak{F}^{-1}]{\mathfrak{F}} \overline{FG}$$

Où  $f$  et  $g$  sont deux images

$F$  et  $G$  sont leur TF

$\overline{F}$  est le conjugué complexe de  $F$

# Alignement direct

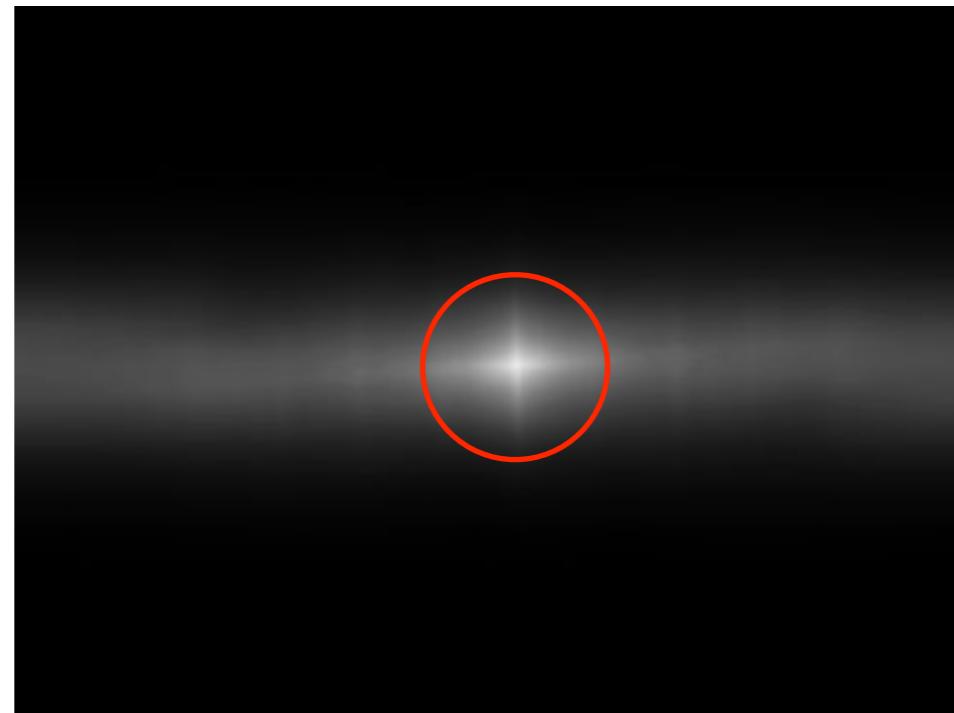
Recalage par FFT



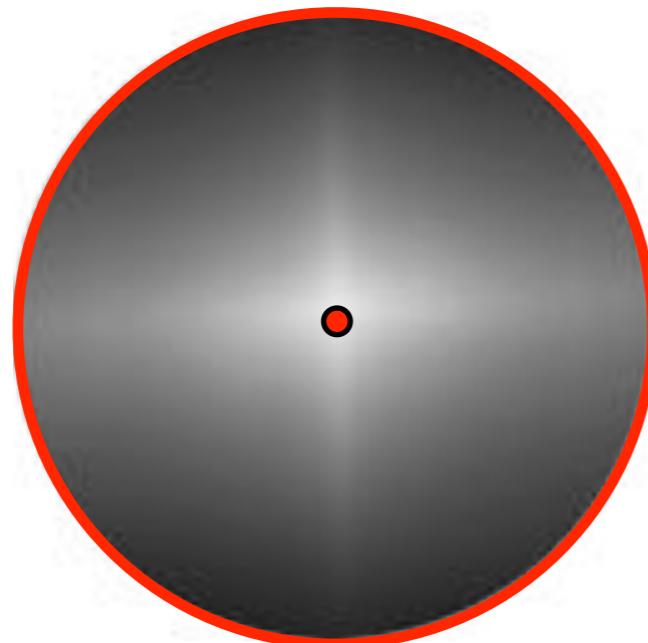
$I_1$



$I_2$



$I_1 \circ I_2$



- Pixel avec maximum d'intensité décalé de **38 pixels** à droite et de **17 pixels** vers le haut par rapport au centre de l'image. Par conséquent :

$$\begin{aligned} u_x &= 38 \text{ pixels} \\ u_y &= -17 \text{ pixels} \end{aligned}$$

## Recalage de 2 images par corrélation

Prendre images  $I_1$  et  $I_2$ .

$$F = \text{FFT}(I_1);$$

$$G = \text{FFT}(I_2);$$

$\bar{F}$  = conjugué complexe de  $F$

$$K = \bar{F}G$$

$$k = \text{IFFT}(K)$$

$[U, V]$  = position du pixel d'intensité maximale dans  $k$

$$\vec{u} = [U - N/2, V - M/2]$$

Translater  $I_2$  de  $\vec{u}$

\*  $I_1$  et  $I_2$  sont de dimensions  $N \times M$

# Alignement direct

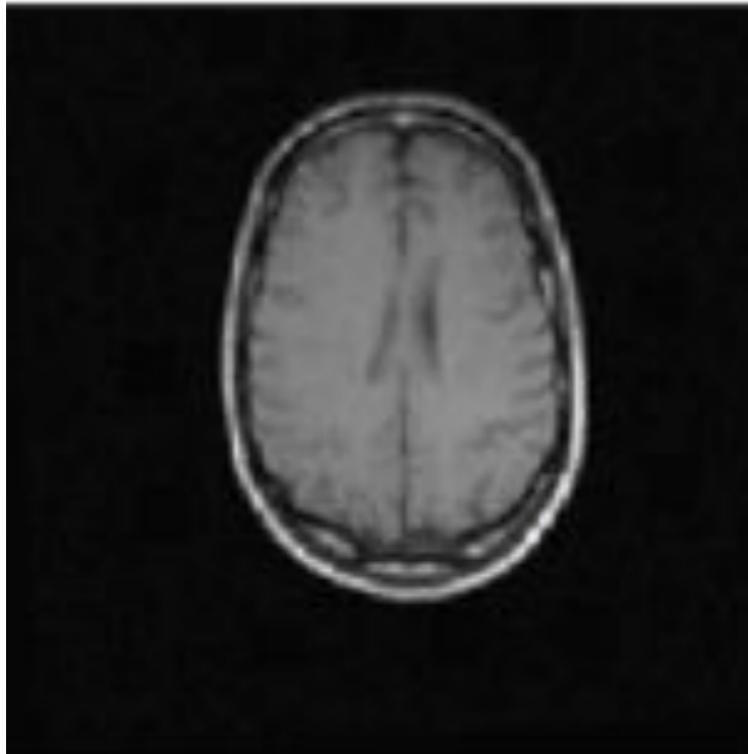
Recalage par FFT

**Note :** pour que le résultat de la corrélation apparaisse centré dans l'image et non diffusé dans les 4 coins, il faut effectuer un **recalage cyclique** (*fftshift*). Ce recalage peut s'effectuer avant ou après la « IFFT » tout dépendant de la méthode employée.

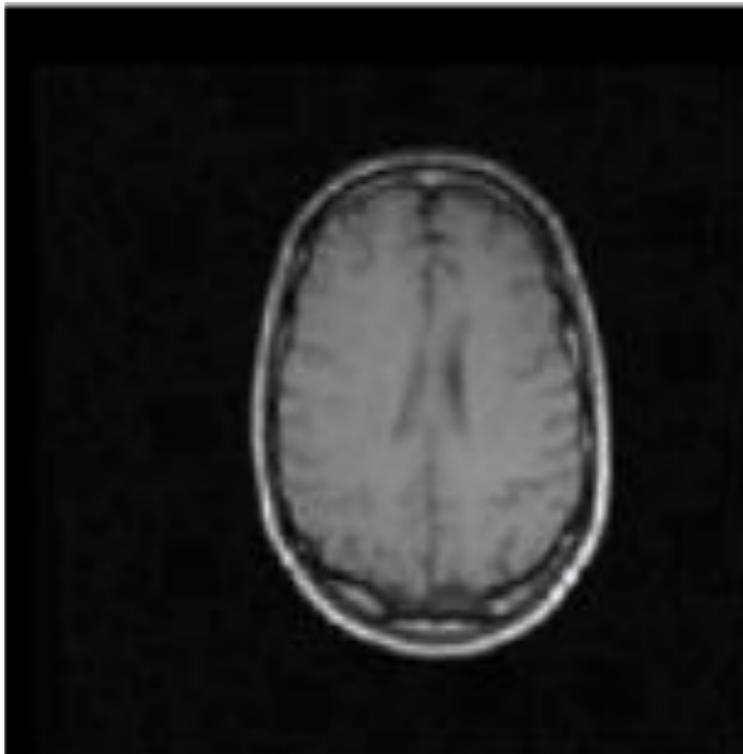
# Alignment direct

L'idée ici est d'estimer  $H$  à partir de TOUS les pixels des 2 images. Pour ce faire, nous verrons d'abord une méthode pour estimer les 2 paramètres de la translation  $\mathbf{u} = (u_x, u_y)$

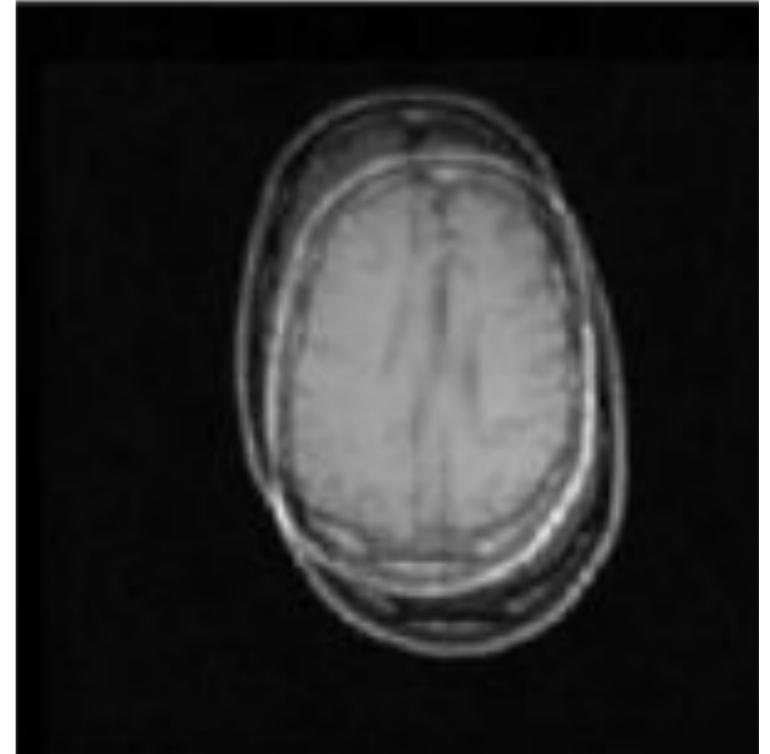
Source



Cible



Moyenne



# Alignement direct

- SSD + translation 2D,  $\mathbf{u} = \mathbf{t} = (p, q)$

$$SSD(\vec{t}) = \sum_{x,y} (I(x+p, y+q) - J(x, y))^2$$

- Comment faire?
- Calcul des dérivées :

$$\frac{\partial SSD}{\partial p} = 2 \sum_{x,y} [(I(x+p, y+q) - J(x, y)) * \frac{\partial I}{\partial x}(x+p, y+q)]$$

$$\frac{\partial SSD}{\partial q} = 2 \sum_{x,y} [(I(x+p, y+q) - J(x, y)) * \frac{\partial I}{\partial y}(x+p, y+q)]$$

# SSD + translation 2D

- Descente du gradient à pas fixe :

$$p_{i+1} = p_i - \varepsilon \frac{\partial SSD}{\partial p} \quad q_{i+1} = q_i - \varepsilon \frac{\partial SSD}{\partial q}$$

$$\frac{\partial SSD}{\partial p} = 2 \sum_{x,y} \left[ (I(x+p, y+q) - J(x, y)) * \frac{\partial I}{\partial x}(x+p, y+q) \right]$$

$$\frac{\partial SSD}{\partial q} = 2 \sum_{x,y} \left[ (I(x+p, y+q) - J(x, y)) * \frac{\partial I}{\partial y}(x+p, y+q) \right]$$

# Alignement direct

Lucas-Kanade

On cherche le meilleur vecteur  $\vec{u}$  tel que

$$E_{SSD}(\vec{u}) = \sum_s (I_2(s + \vec{u}) - I_1(s))^2$$

est minimum. On peut démontrer que la solution optimale est

$$\vec{u} = M^{-1} \vec{b}$$

où

$$M = \begin{pmatrix} \sum_s I_x^2 & \sum_s I_y I_x \\ \sum_s I_y I_x & \sum_s I_y^2 \end{pmatrix} \quad \vec{b} = \begin{pmatrix} -\sum_s I_x I_t \\ -\sum_s I_y I_t \end{pmatrix} \quad \begin{aligned} I_x &= \partial_x I_2(s) \\ I_y &= \partial_y I_2(s) \\ I_t &= I_2(p) - I_1(s) \end{aligned}$$

# Alignement direct

Lucas-Kanade

Preuve:

$$\begin{aligned} E_{SSD}(\vec{u}) &= \sum_s (I_2(s + \vec{u}) - I_1(s))^2 \\ &= \sum_{x,y} (I_2(x + u_x, y + u_y) - I_1(x, y))^2 \end{aligned}$$

À l'aide d'une expansion en série de Taylor, on peut démontrer que

$$E_{SSD}(\vec{u}) \approx \sum_{x,y} \left( \frac{\partial I_2(x, y)}{\partial x} u_x + \frac{\partial I_2(x, y)}{\partial y} u_y + I_2(x, y) - I_1(x, y) \right)^2$$

Pour alléger la notation

$$\begin{aligned} E_{SSD}(\vec{u}) &\approx \sum_s (I_x u_x + I_y u_y + I_t)^2 \\ &= \sum_s (\nabla I^T \vec{u} + I_t)^2 \end{aligned}$$

# Alignement direct

Lucas-Kanade

Suite preuve:

$$E_{SSD}(\vec{u}) \approx \sum_s (\nabla I^T \vec{u} + I_t)$$

Le meilleur  $\vec{u}$  est celui pour lequel  $\frac{dE_{SSD}(\vec{u})}{d\vec{u}} = 0$

$$\begin{aligned}\frac{dE_{SSD}(\vec{u})}{d\vec{u}} &\approx \sum_s 2\nabla I (\nabla I^T \vec{u} + I_t) = 0 \\ &= \sum_s (\nabla I \nabla I^T \vec{u} + \nabla I I_t) = 0 \\ &= \sum_s (M_s \vec{u} + \vec{b}_s) = 0 \\ &= M\vec{u} + \vec{b} = 0\end{aligned}$$

où

$$M = \begin{pmatrix} \sum_s I_x^2 & \sum_s I_y I_x \\ \sum_s I_y I_x & \sum_s I_y^2 \end{pmatrix} \quad \vec{b} = \begin{pmatrix} \sum_s I_x I_t \\ \sum_s I_y I_t \end{pmatrix}$$

## Recalage de 2 images par Lucas-Kanade

Prendre images  $I_1$  et  $I_2$ .

$I_x$  = dérivée en  $x$  de  $I_2$

$I_y$  = dérivée en  $y$  de  $I_2$

$I_t = I_2 - I_1$

$$M = \begin{pmatrix} \sum_s I_x^2 & \sum_s I_y I_x \\ \sum_s I_y I_x & \sum_s I_y^2 \end{pmatrix} \quad \vec{b} = \begin{pmatrix} \sum_s I_x I_t \\ \sum_s I_y I_t \end{pmatrix}$$

$$\vec{u} = -M^{-1}\vec{b}$$

Translater  $I_2$  de  $\vec{u}$

Afin d'améliorer les résultats, la méthode Lucas-Kanade peut être implémentée de façon itérative.

### Recalage de 2 images par Lucas-Kanade **itératif**

Prendre images  $I_1$  et  $I_2$

$$\vec{u} = (0,0);$$

POUR i allant de 0 à ITER\_MAX

$\hat{I}_2$  = Translater  $I_2$  de  $\vec{u}$

$I_x$  = dérivée en  $x$  de  $\hat{I}_2$

$I_y$  = dérivée en  $y$  de  $\hat{I}_2$

$$I_t = \hat{I}_2 - I_1$$

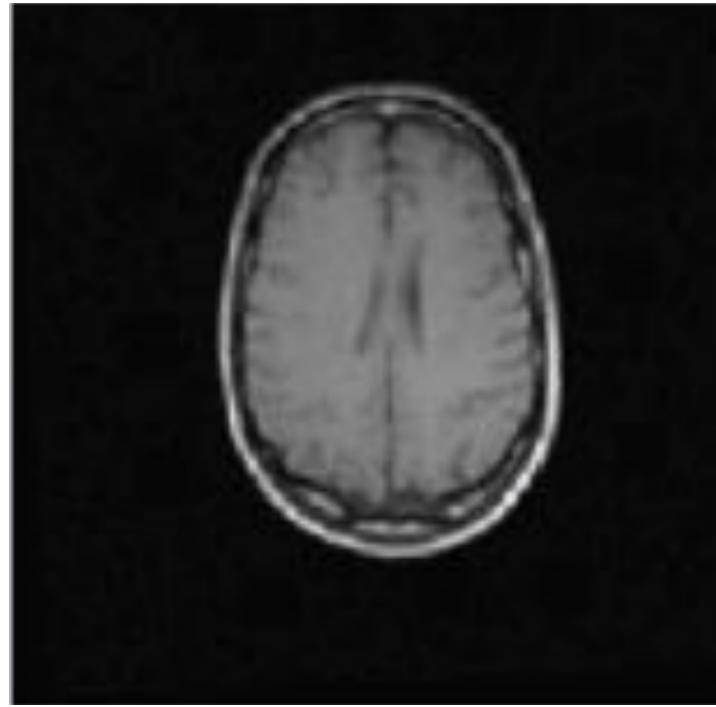
$$M = \begin{pmatrix} \sum_s I_x^2 & \sum_s I_y I_x \\ \sum_s I_y I_x & \sum_s I_y^2 \end{pmatrix} \quad \vec{b} = \begin{pmatrix} \sum_s I_x I_t \\ \sum_s I_y I_t \end{pmatrix}$$

$$\vec{u} = \vec{u} - M^{-1} \vec{b}$$

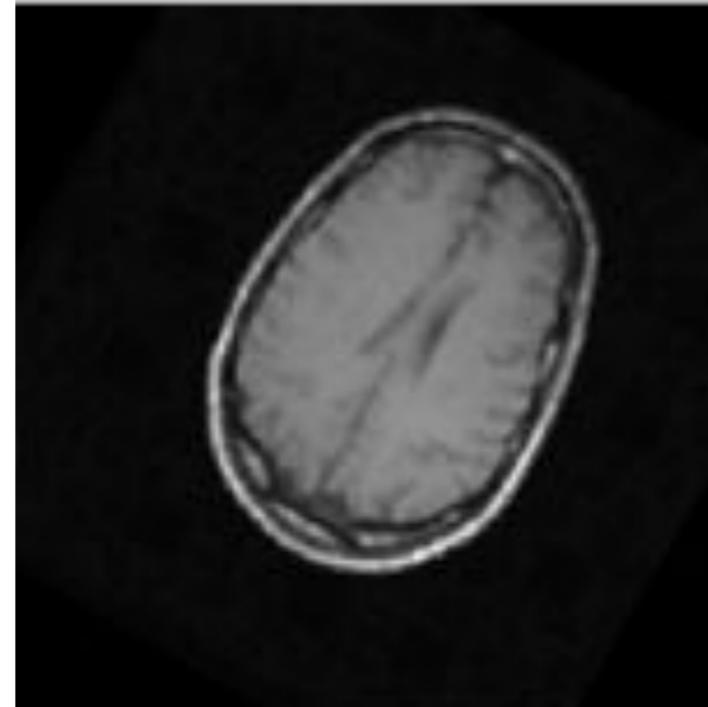
Translater  $I_2$  de  $\vec{u}$

# SSD + rotation

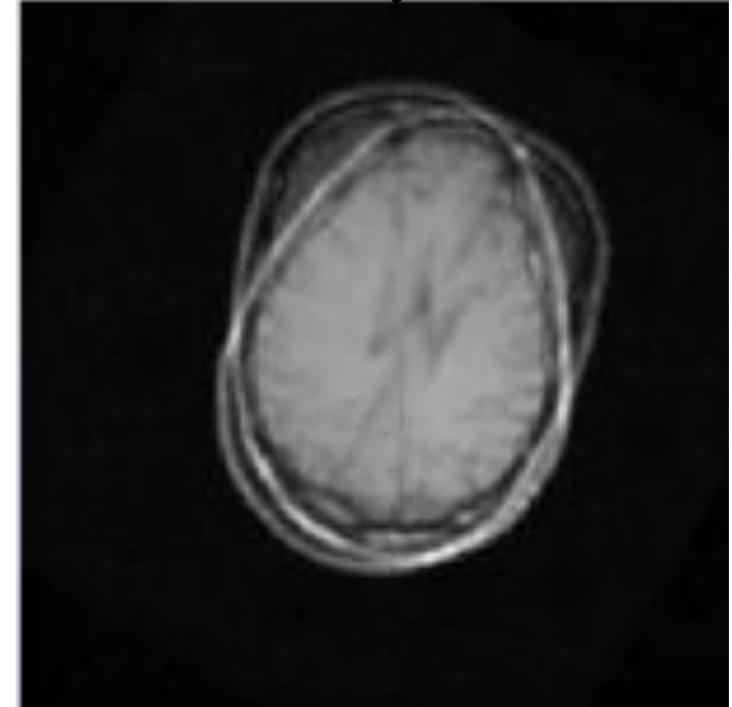
Source



Cible



Moyenne



- On cherche theta qui minimise :

$$SSD(\theta) = \sum_{x,y} \left( I(x \cos(\theta) - y \sin(\theta), x \sin(\theta) + y \cos(\theta)) - J(x, y) \right)^2$$

# SSD + rotation

- Comment faire la minimisation?

$$SSD(\theta) = \sum_{x,y} \left( I(x \cos(\theta) - y \sin(\theta), x \sin(\theta) + y \cos(\theta)) - J(x, y) \right)^2$$

- Calcul des dérivées :

$$\begin{aligned} \frac{\partial SSD}{\partial \theta} &= 2 \sum_{x,y} \left( I(x \cos(\theta) - y \sin(\theta), x \sin(\theta) + y \cos(\theta)) - J(x, y) \right) * \\ &\quad \left( \frac{\partial I}{\partial x} * (-x \sin(\theta) - y \cos(\theta)) + \frac{\partial I}{\partial y} * (x \cos(\theta) - y \sin(\theta)) \right) \end{aligned}$$

# SSD + rotation

- Descente du gradient à pas fixe :

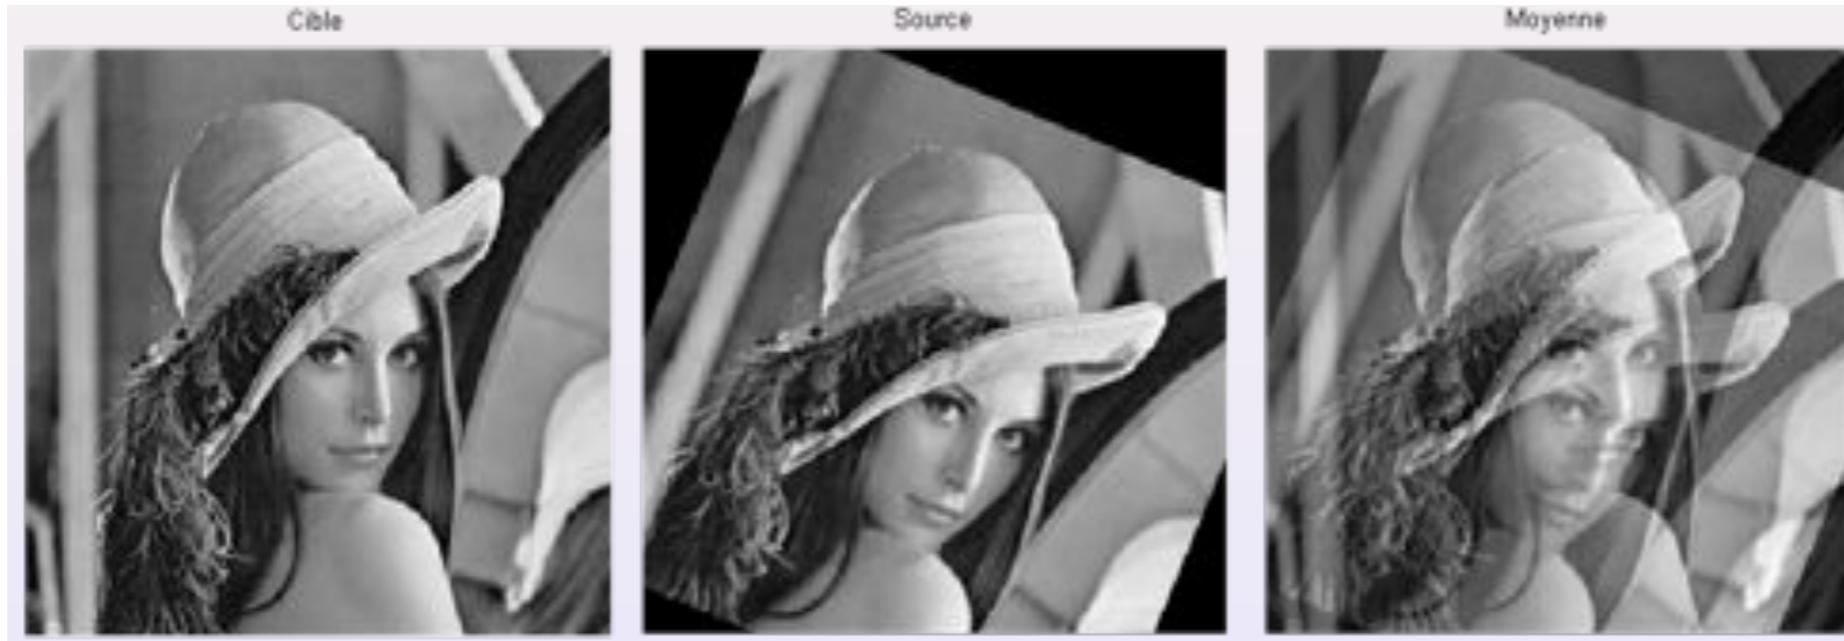
$$\theta_{i+1} = \theta_i - \varepsilon \frac{\partial SSD}{\partial \theta}$$

$$\begin{aligned}\frac{\partial SSD}{\partial \theta} = & 2 \sum_{x,y} \left( I(x \cos(\theta) - y \sin(\theta), x \sin(\theta) + y \cos(\theta)) - J(x, y) \right) * \\ & \left( \frac{\partial I}{\partial x} * (-x \sin(\theta) - y \cos(\theta)) + \frac{\partial I}{\partial y} * (x \cos(\theta) - y \sin(\theta)) \right)\end{aligned}$$

# Recalage iconique rigide 2D

- Critère de similarité :

$$SSD(\theta, p, q) = \sum_{x,y} \left( I(x \cos(\theta) - y \sin(\theta) + p, x \sin(\theta) + y \cos(\theta) + q) - J(x, y) \right)^2$$

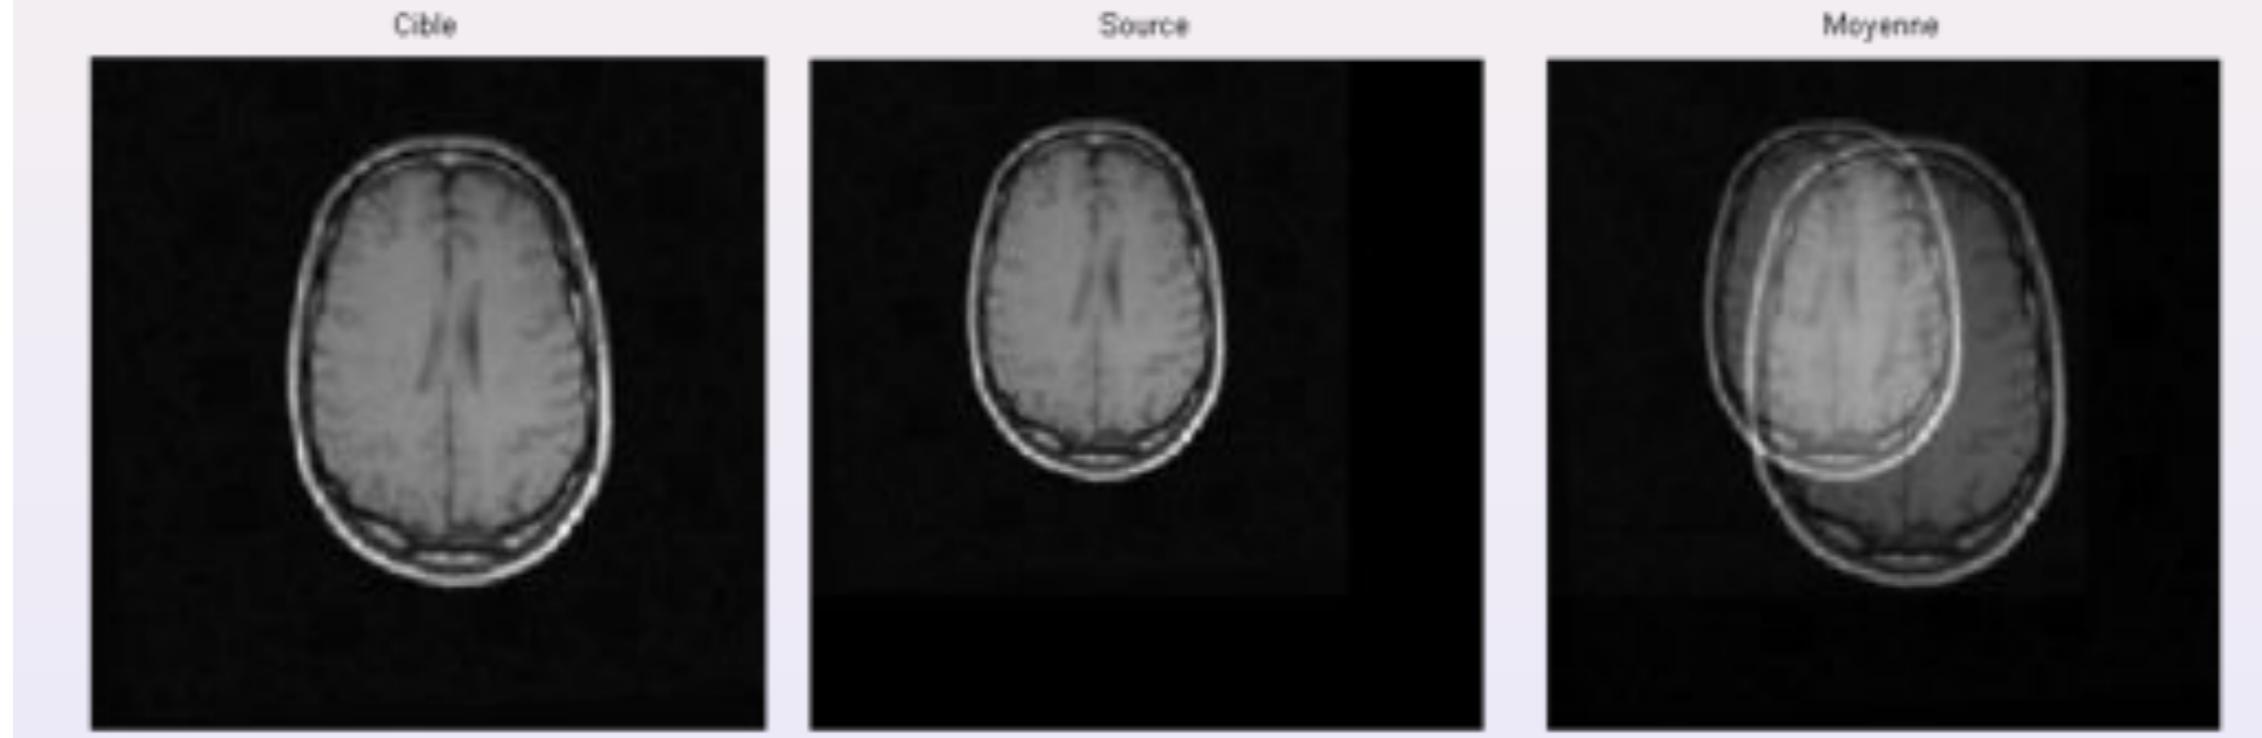


- Descente du gradient à pas fixe :

$$\theta_{i+1} = \theta_i - \varepsilon \frac{\partial SSD}{\partial \theta} \quad p_{i+1} = p_i - \varepsilon \frac{\partial SSD}{\partial p} \quad q_{i+1} = q_i - \varepsilon \frac{\partial SSD}{\partial q}$$

# SSD + trans. rigide + scaling

$$SSD(\theta, p, q) = \sum_{x,y} \left( I(sx, sy) - J(x, y) \right)^2$$

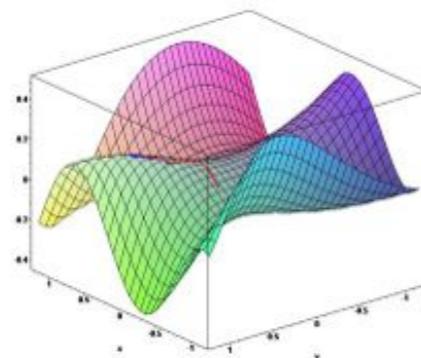


– Dérivées + descente du gradient :

$$\frac{\partial SSD}{\partial s} = 2 \sum_{x,y} \left( I(sx, sy) - J(x, y) \right) \left( x \frac{\partial I}{\partial x} + y \frac{\partial I}{\partial y} \right) \quad s_{i+1} = s_i - \varepsilon \frac{\partial SSD}{\partial s}$$

# Approches iconiques

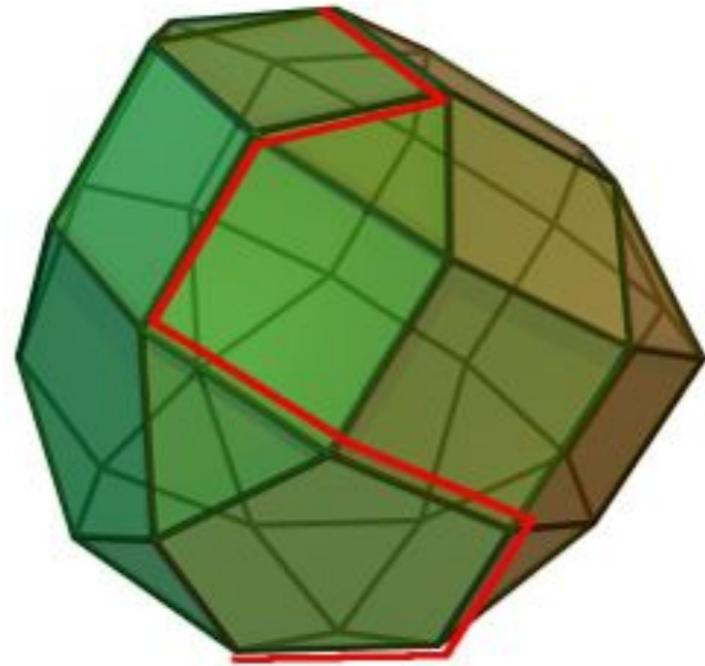
- Point crucial : interpolation
- Pour minimiser un critère de similarité directement à partir des intensités d'images, on applique donc des algorithmes de type “descente du gradient”
- En pratique, la descente du gradient simple n'est (ou ne devrait) jamais être utilisée
  - Recherche du pas optimal epsilon (*line search*)
  - Gradient conjugué
  - Méthode de Newton, quasi-Newton, et bien d'autres



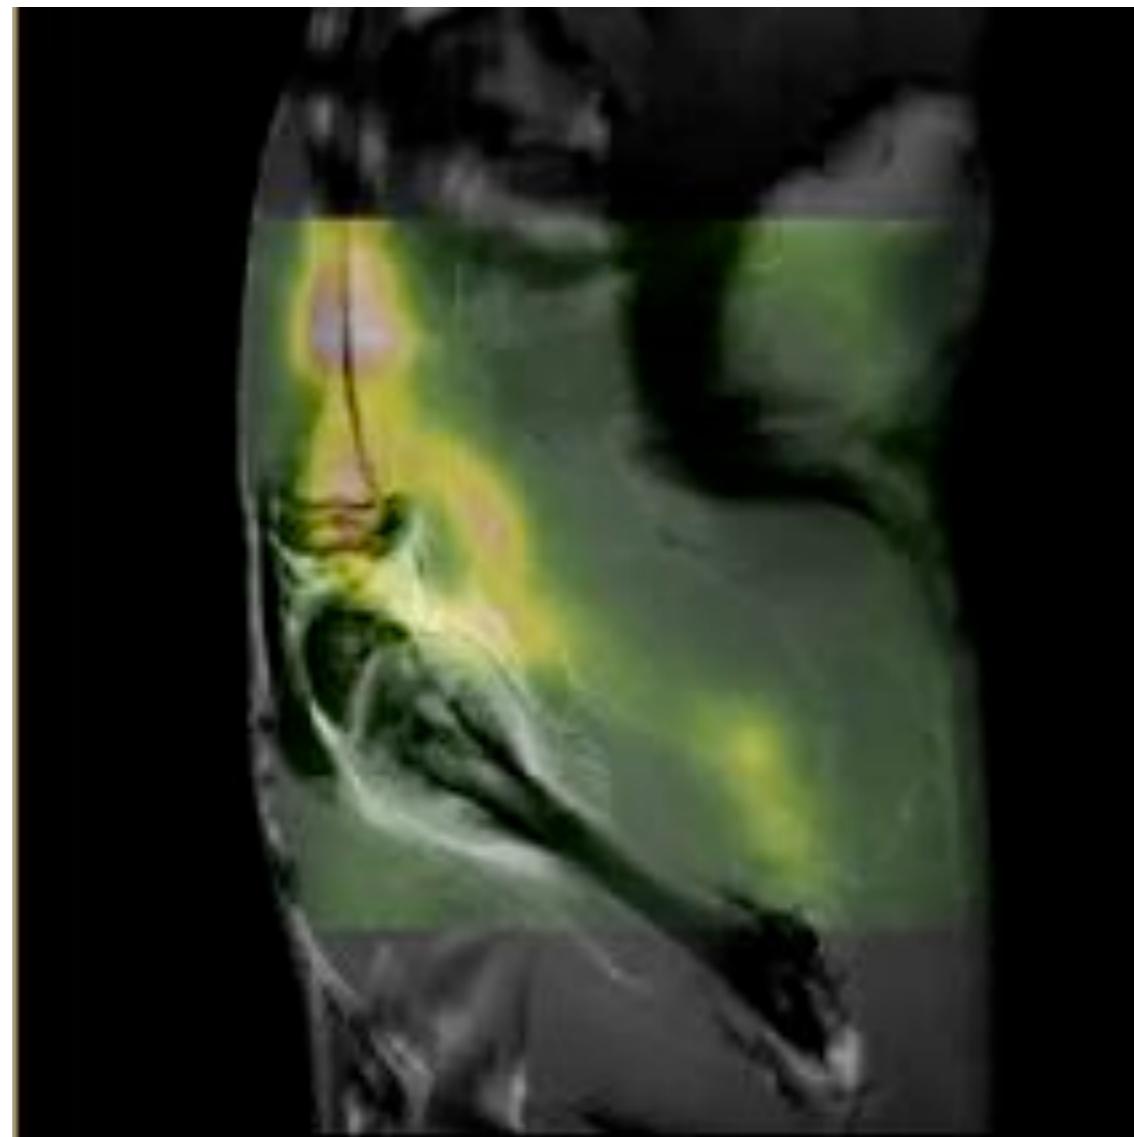
Besoin des dérivés du critère de similarité  
Convergence difficile

# Approches iconiques

- On ne peut pas toujours calculer le gradient du critère de similarité
  - Information mutuelle ou coefficient de corrélation calculés à partir de l'histogramme conjoint...
- Approche sans gradient :
  - Méthode du Simplex, Powell
  - Méthode d'ordre 0
  - Idéal pour plusieurs variables (translation, rotation, scaling)
  - Converge plus facilement vers le minimum global



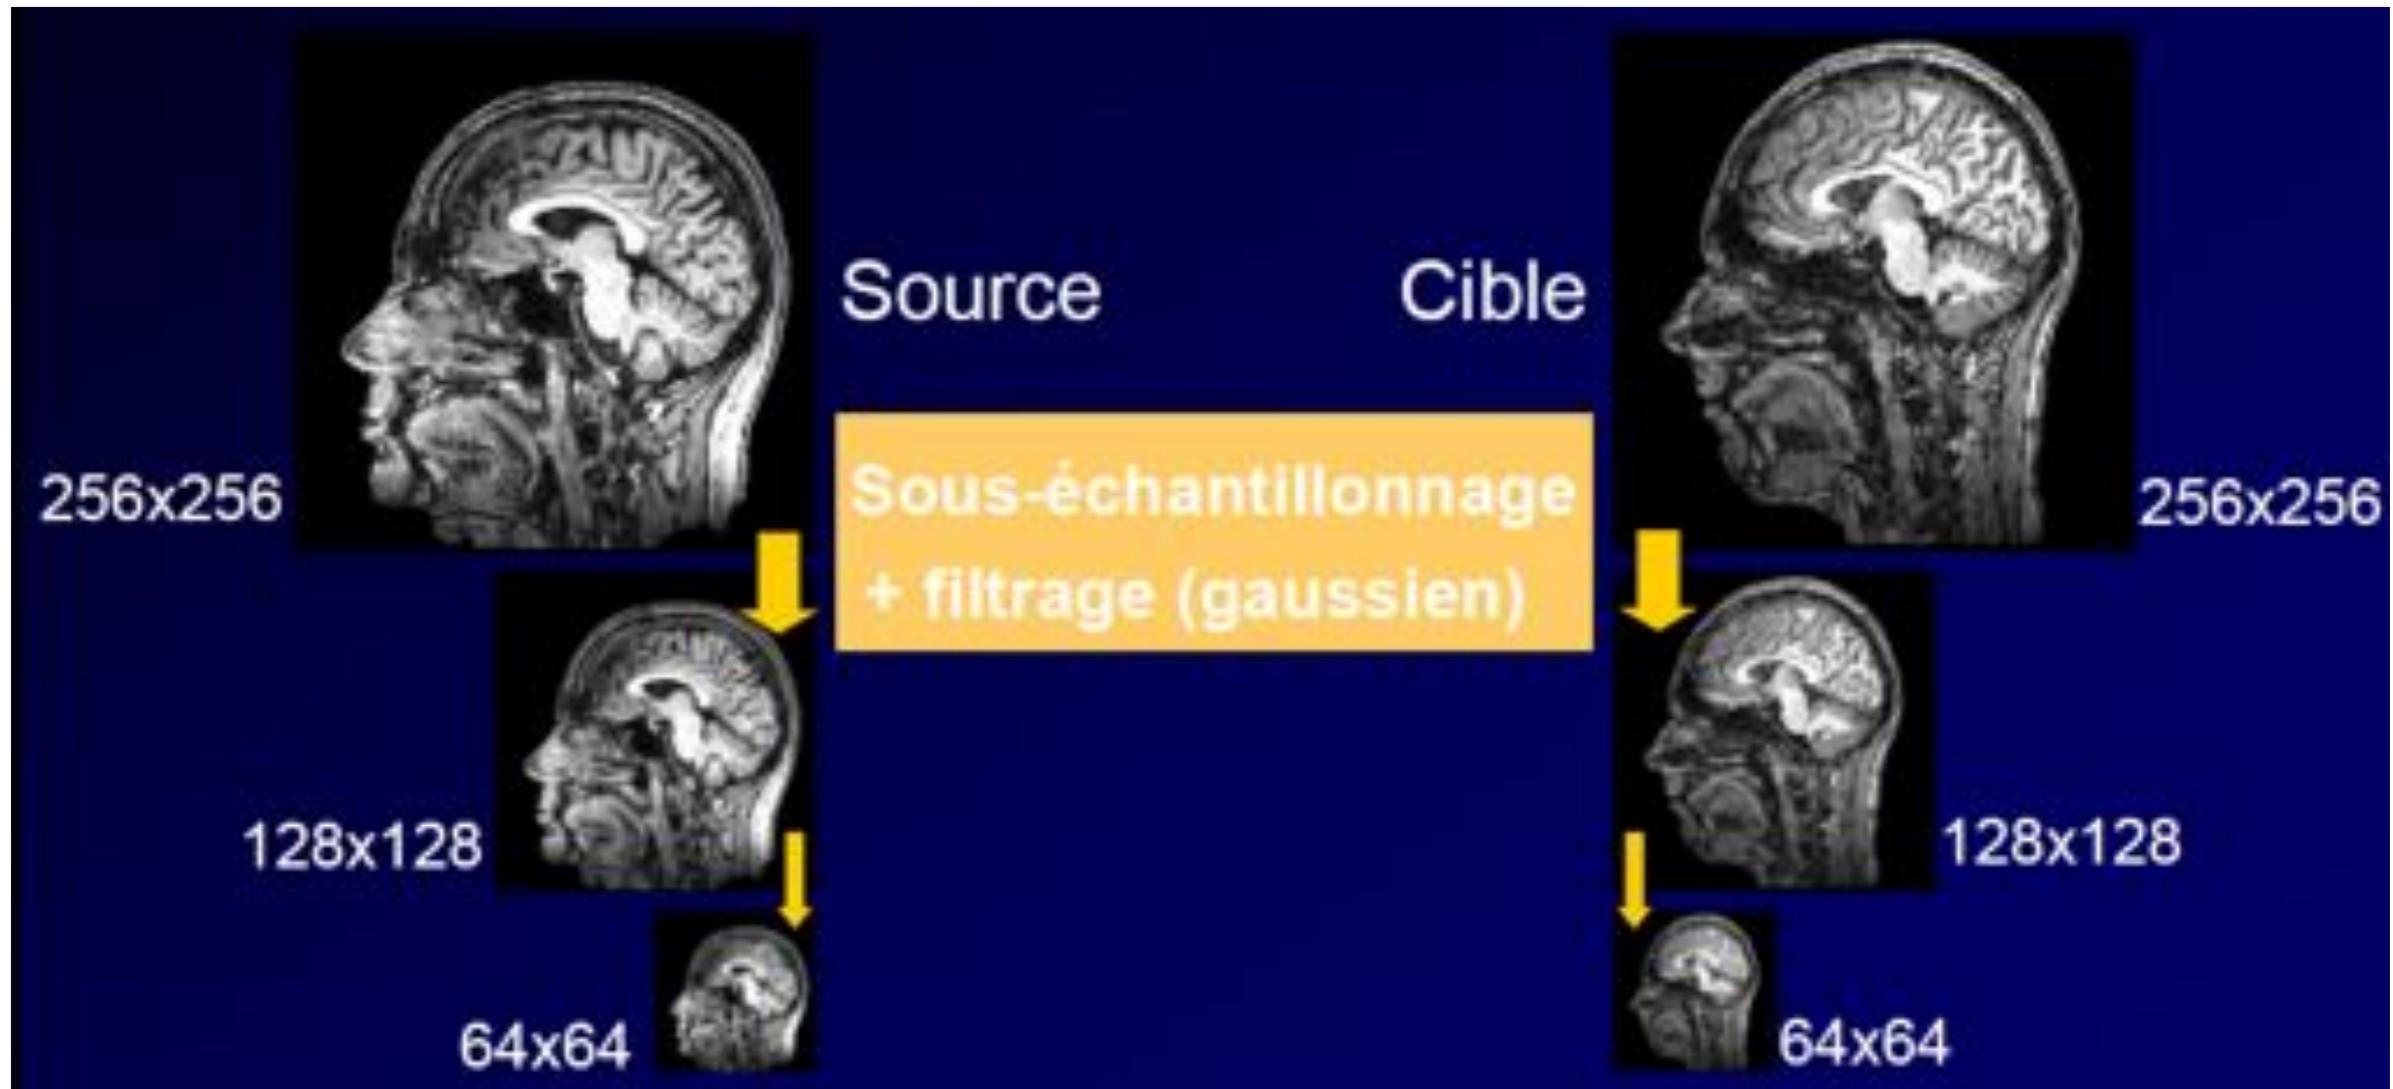
# Simplex



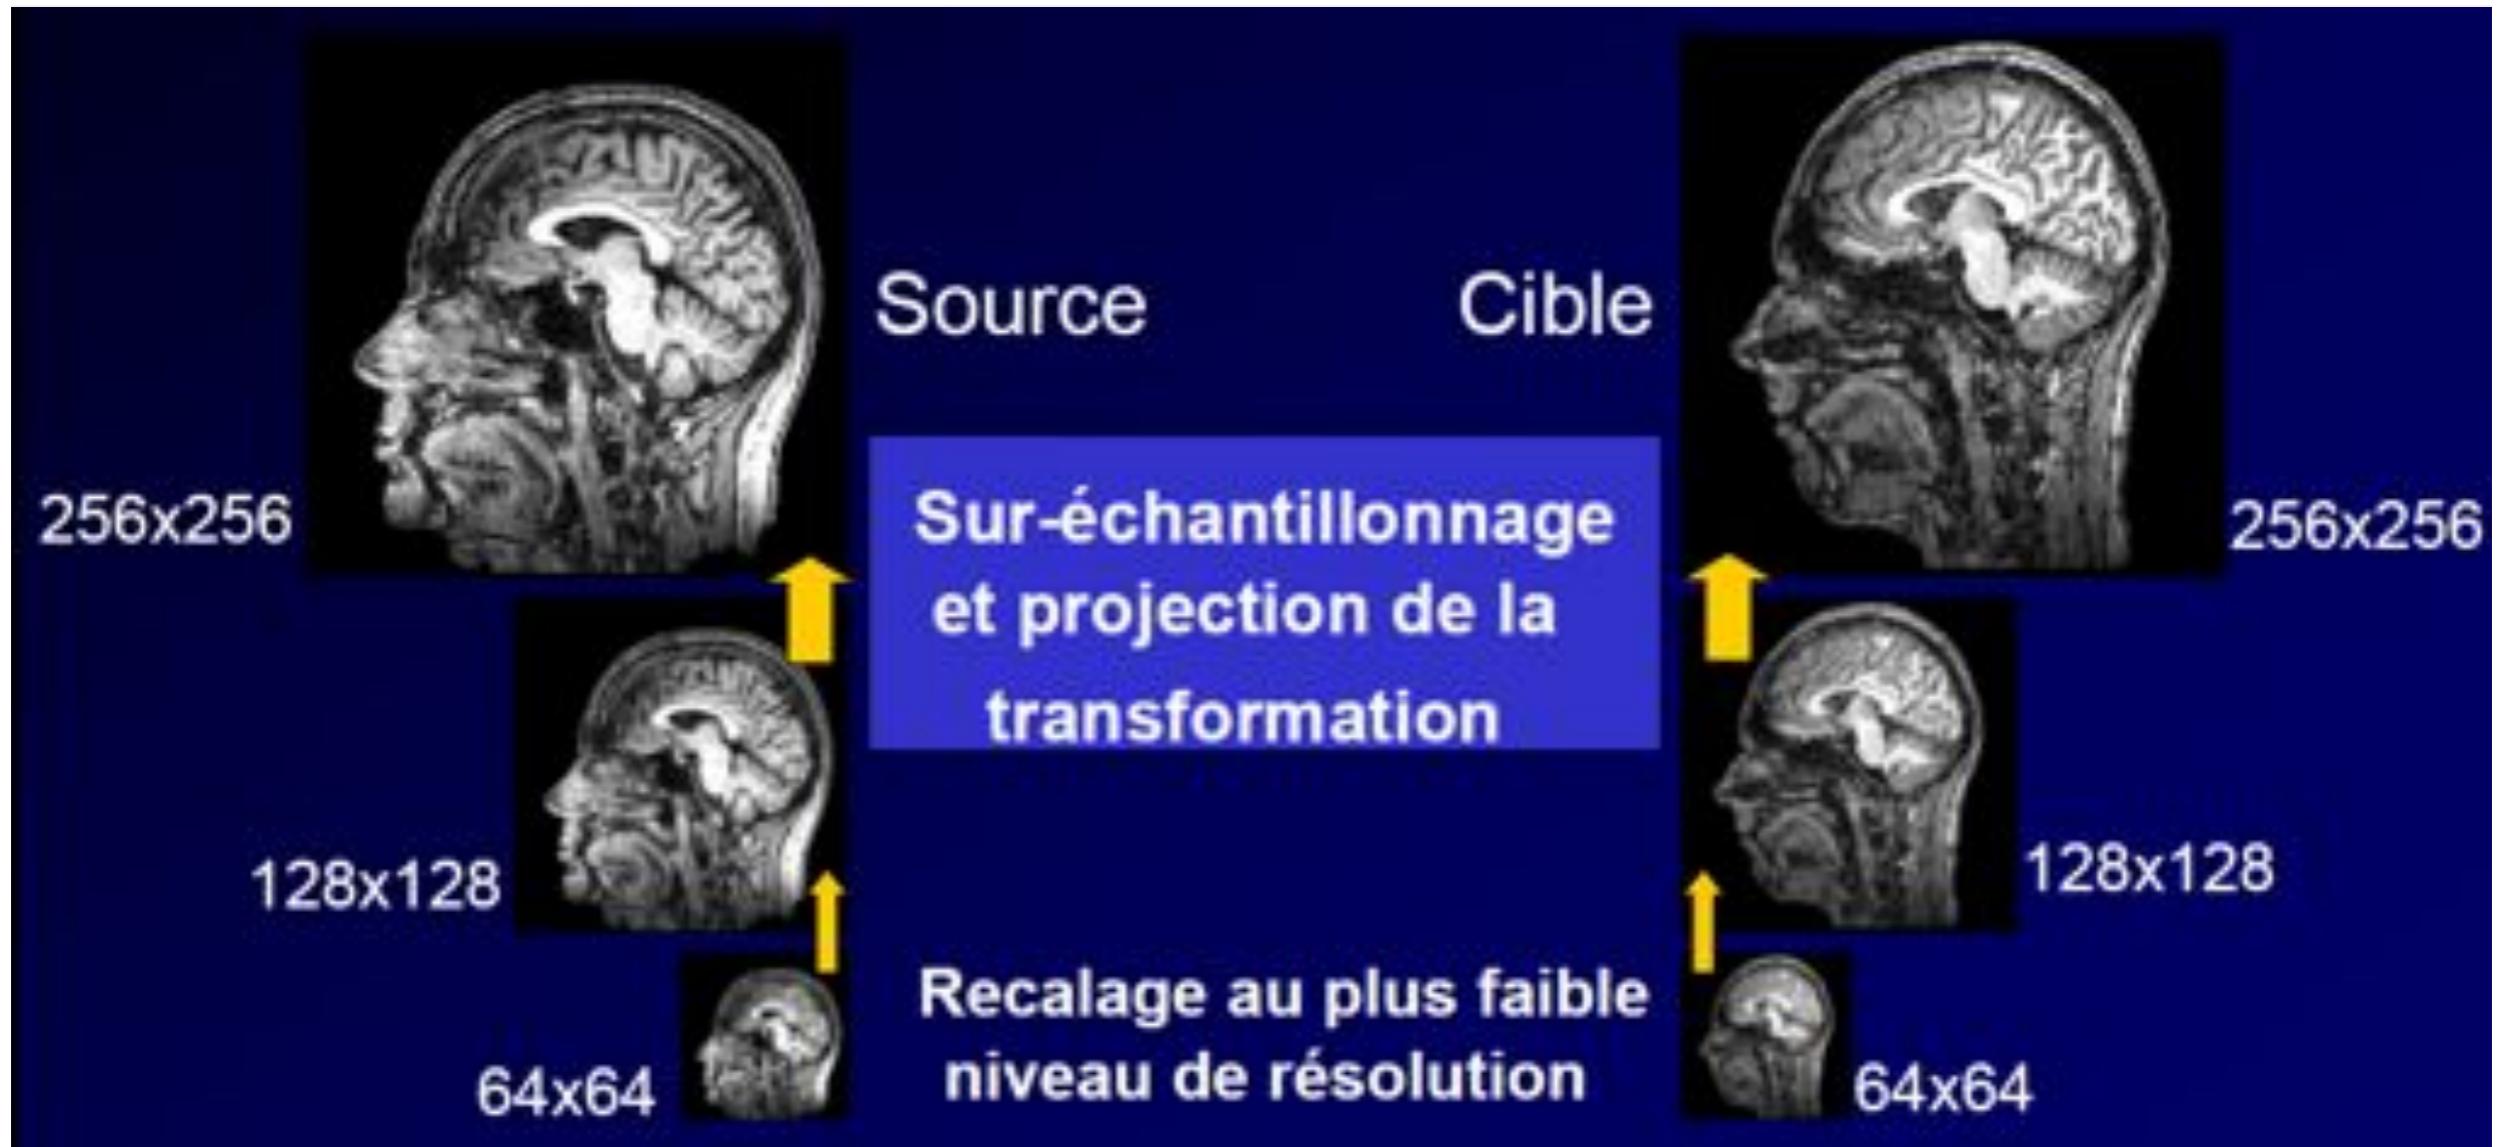
# Multirésolution

- Approches hiérarchiques
- On veut mieux gérer la complexité des données
- On construit une pyramide d'images sous-échantillonnées (faible résolution à haute résolution en augmentant progressivement la taille des images)
- On fait d'abord le recalage sur les images de faible résolution
- La solution obtenue initialise la solution du recalage à la résolution suivant

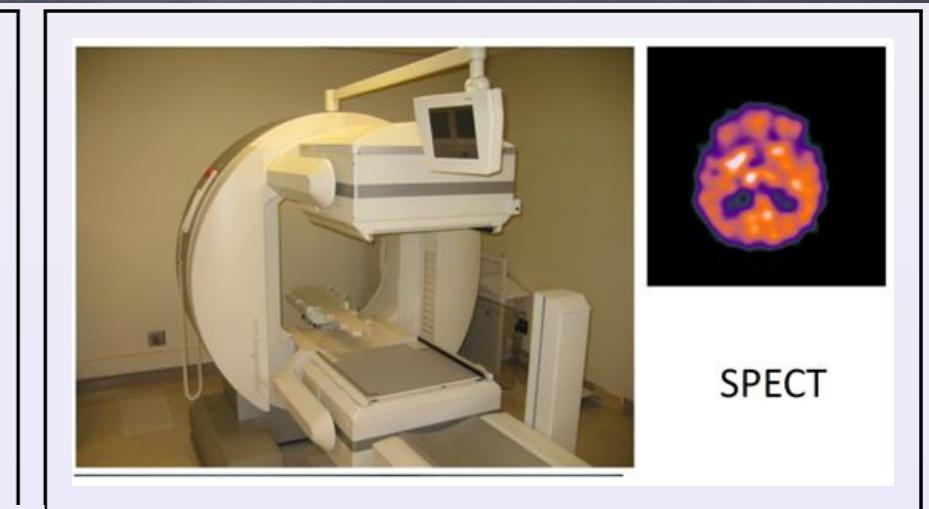
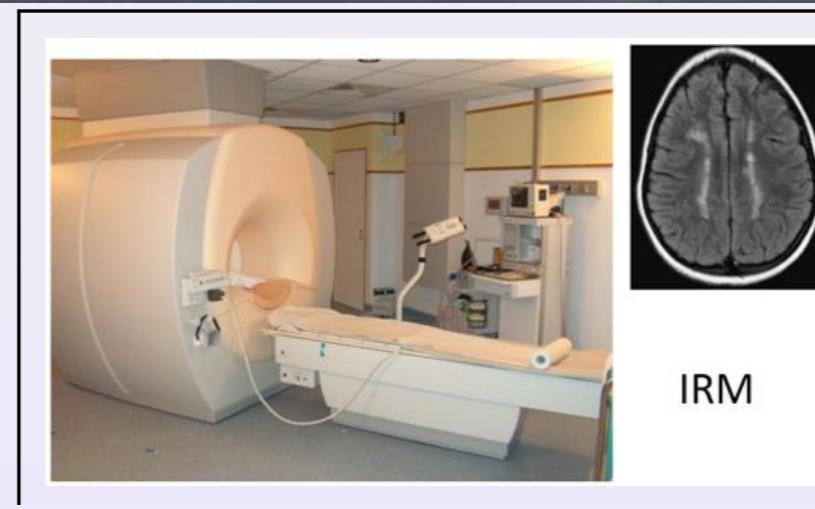
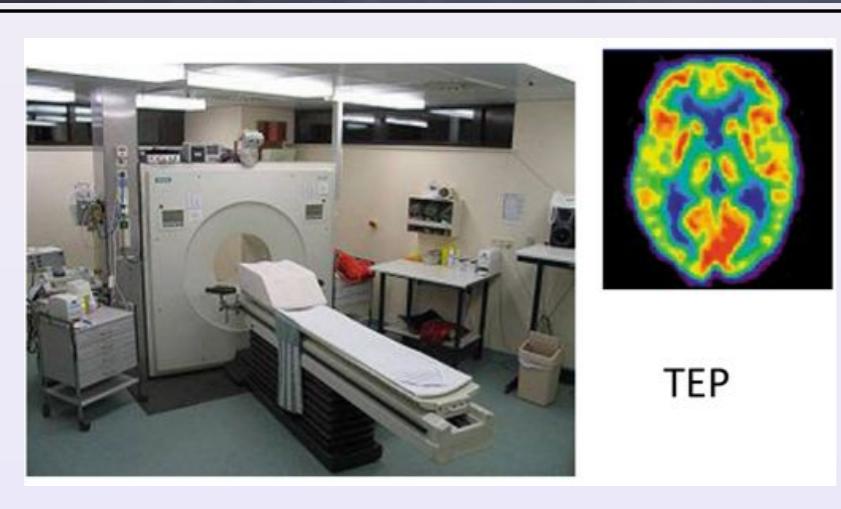
# Multirésolution



# Multirésolution



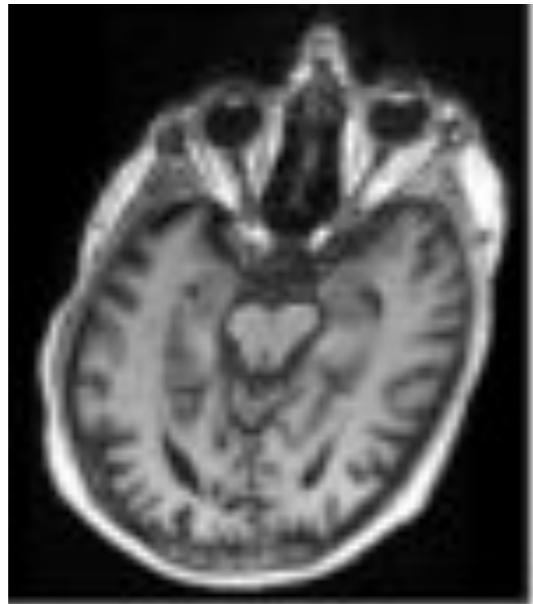
# Approches géométriques (points caractéristiques, features)



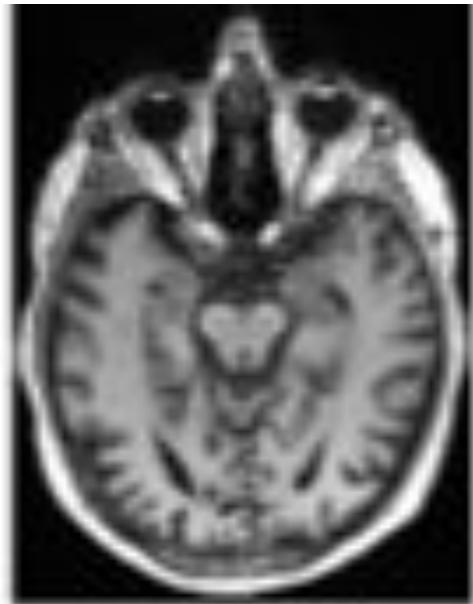
# Approches géométriques

- Sûrement les plus “naturelles” car analogue à l'esprit humain
- On commence par identifier dans les 2 images des caractéristiques géométriques communes
- Ces caractéristiques sont appelées “primitives” : points, lignes, surfaces, volumes, repères orientés
- On réduit les images à quelques primitives géométriquement pertinentes et on cherche la trans. spatiale qui apparie “au mieux” les différentes primitives

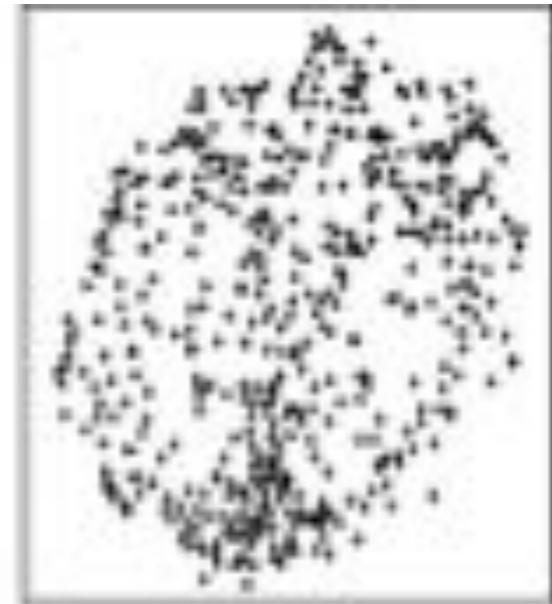
# Exemple : points caractéristiques



(a)



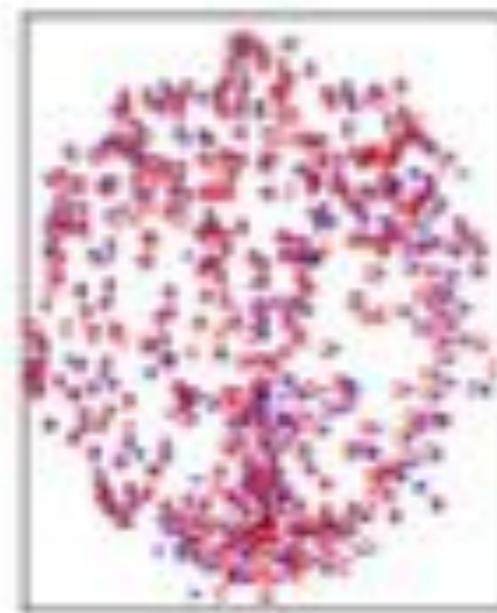
(b)



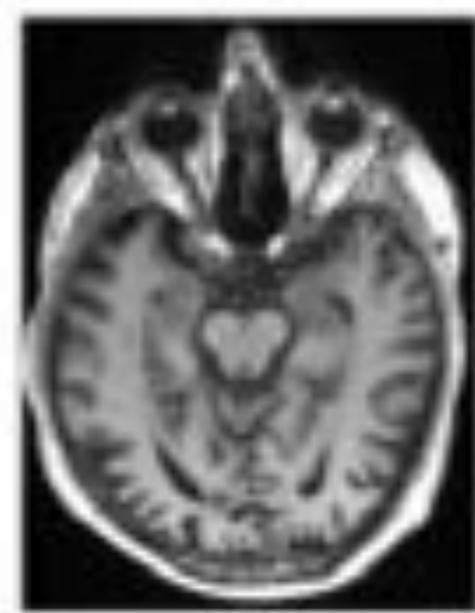
(c)



(d)



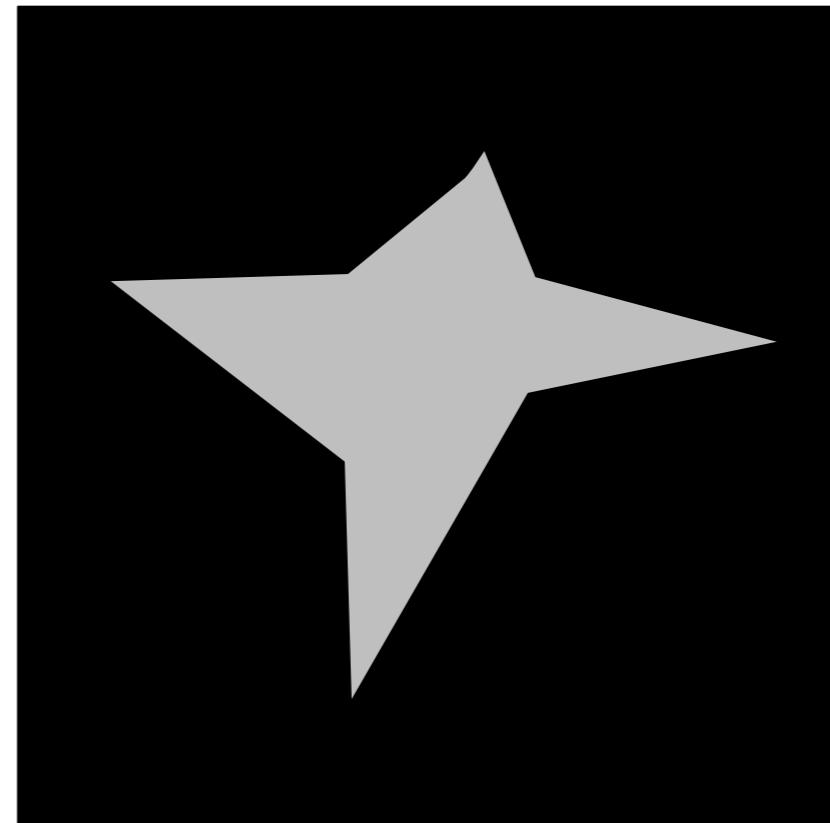
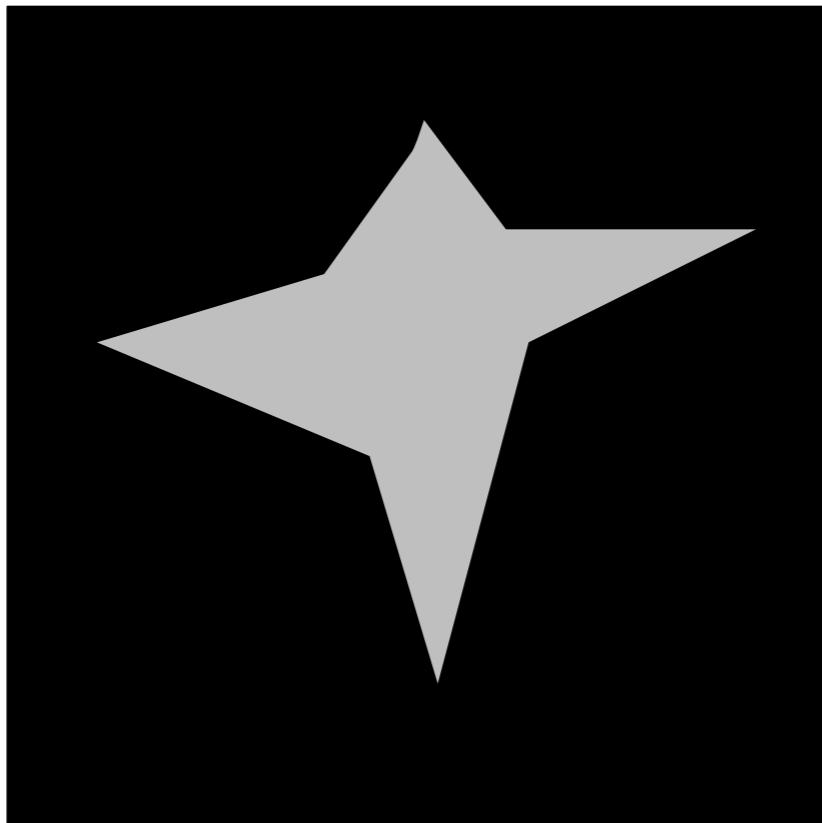
(e)



(f)

# Exemple intuitif

Comment recaler ces deux images ?

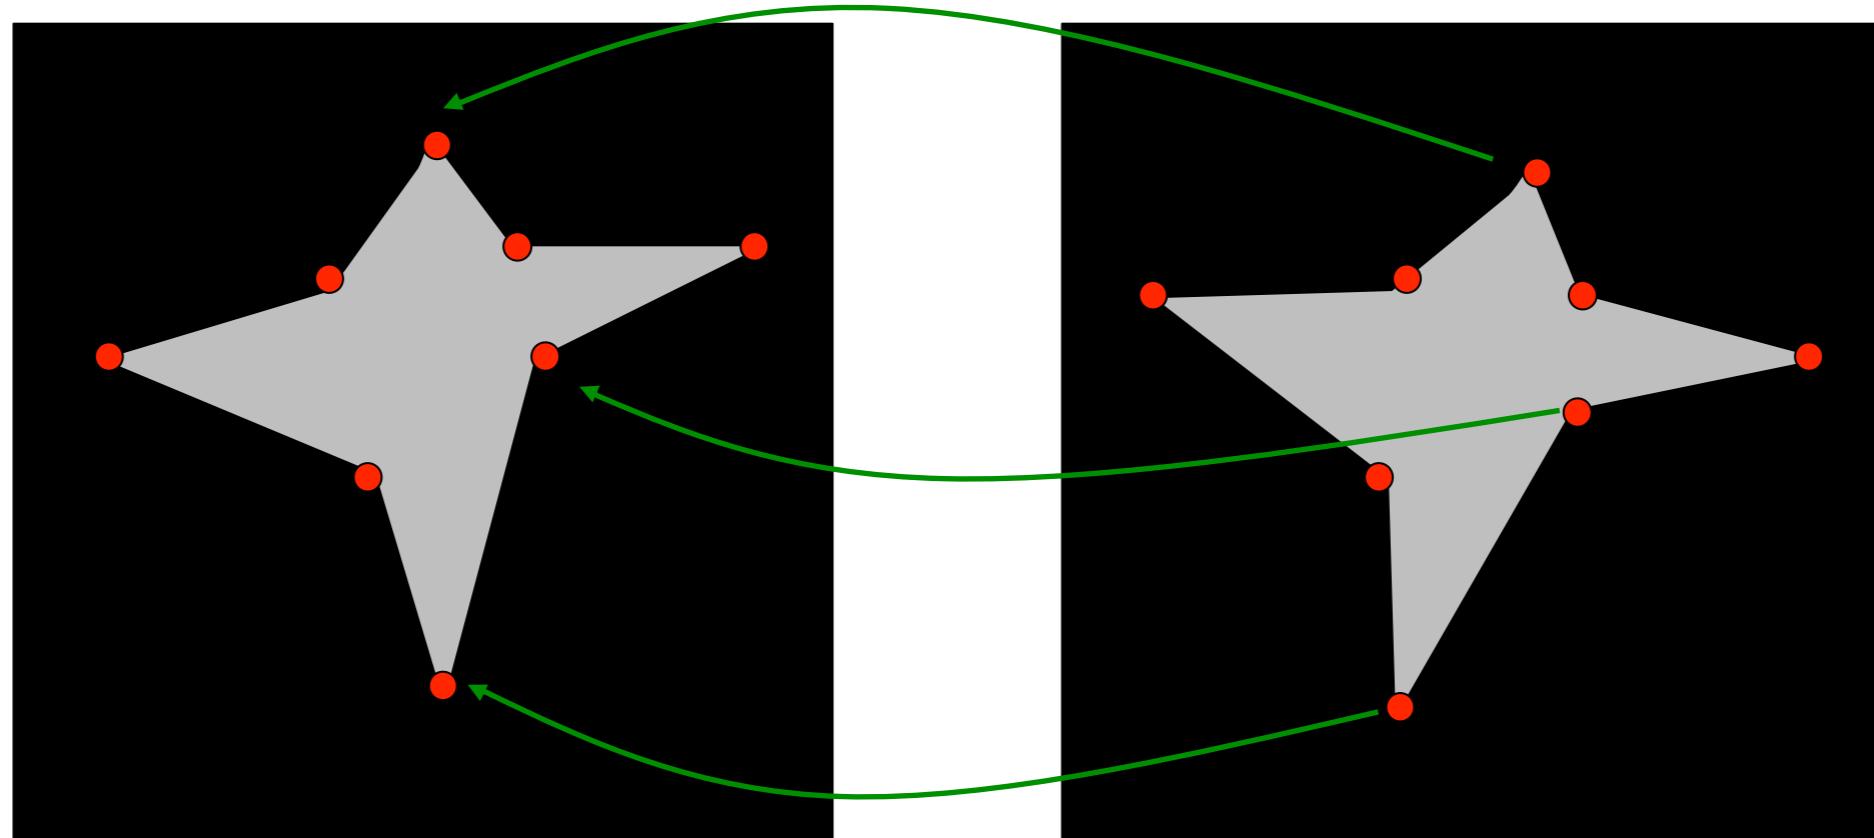


# Approches géométriques

Détection des primitives (ici, points de forte courbure)

Mesure: moindres carrés

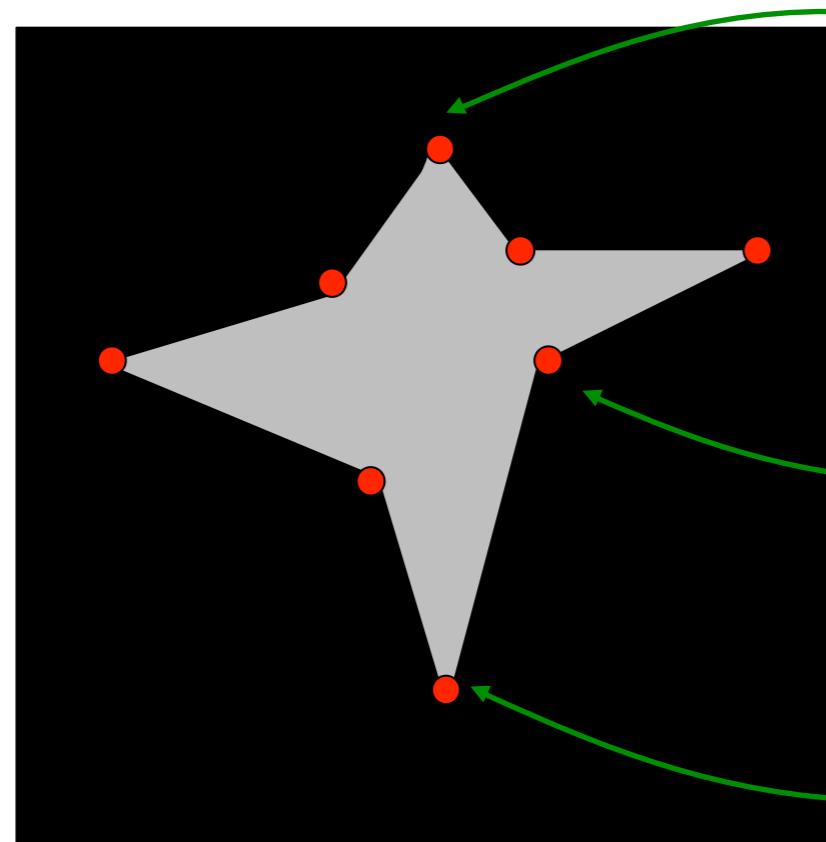
$$S(T) = \sum_k \|T(\mathbf{x}_k) - \mathbf{y}_{CP(k)}\|^2$$



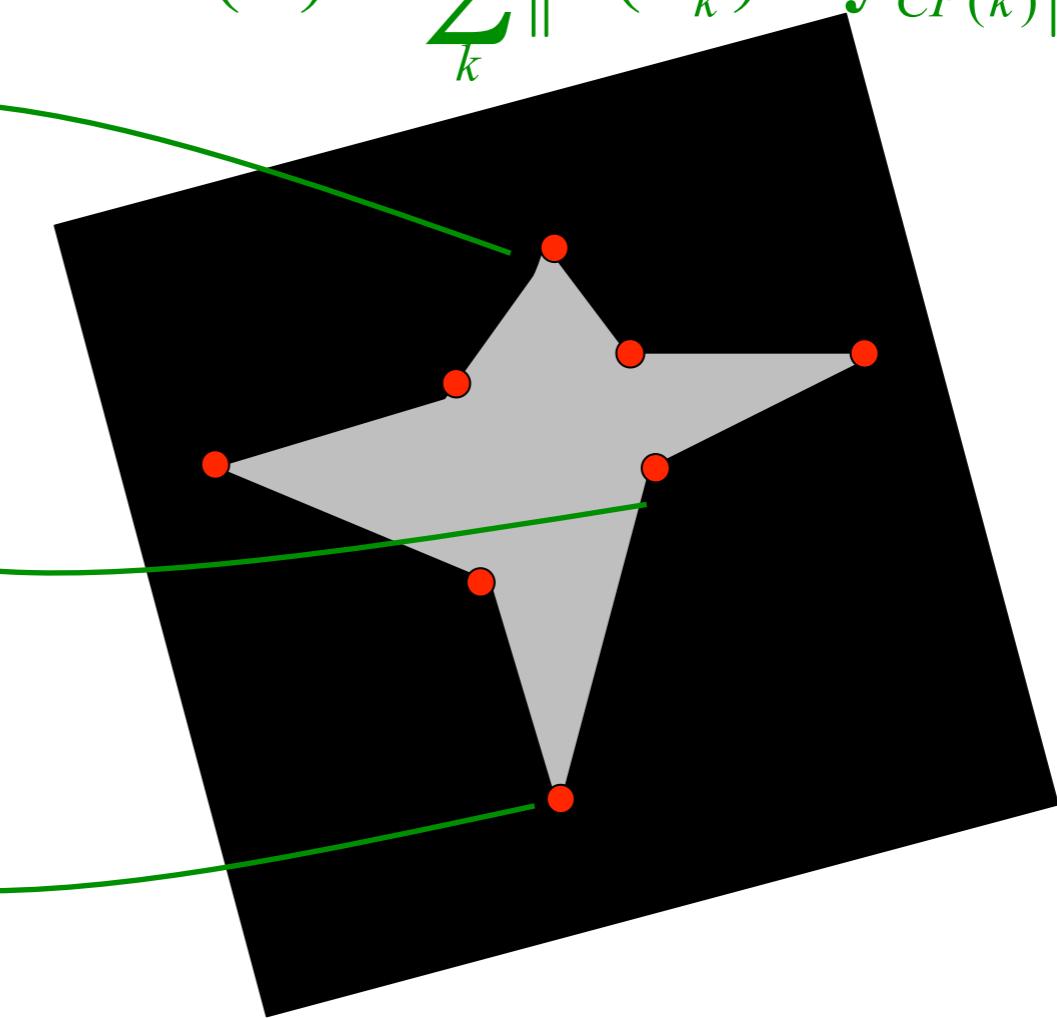
# Approches géométriques

Détection des primitives (ici, points de forte courbure)

Mesure: moindres carrés



$$S(T) = \sum_k \|T(\mathbf{x}_k) - \mathbf{y}_{CP(k)}\|^2$$

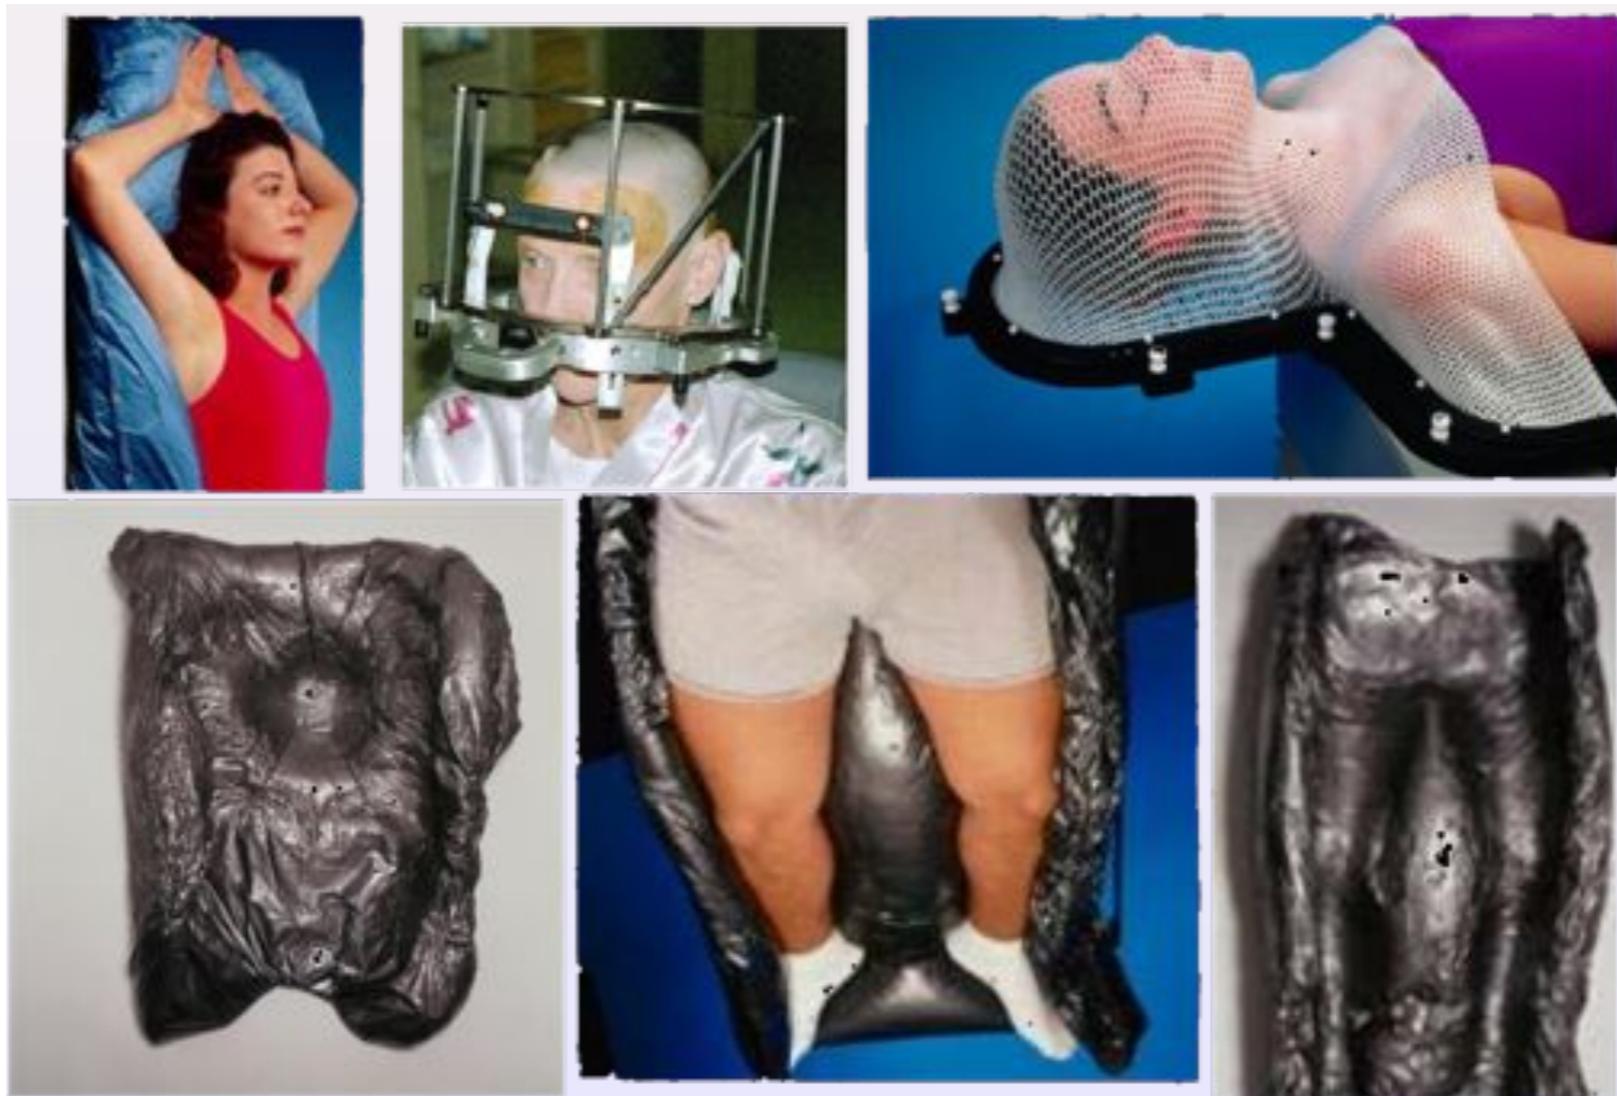


# Optimisation : approches géométriques

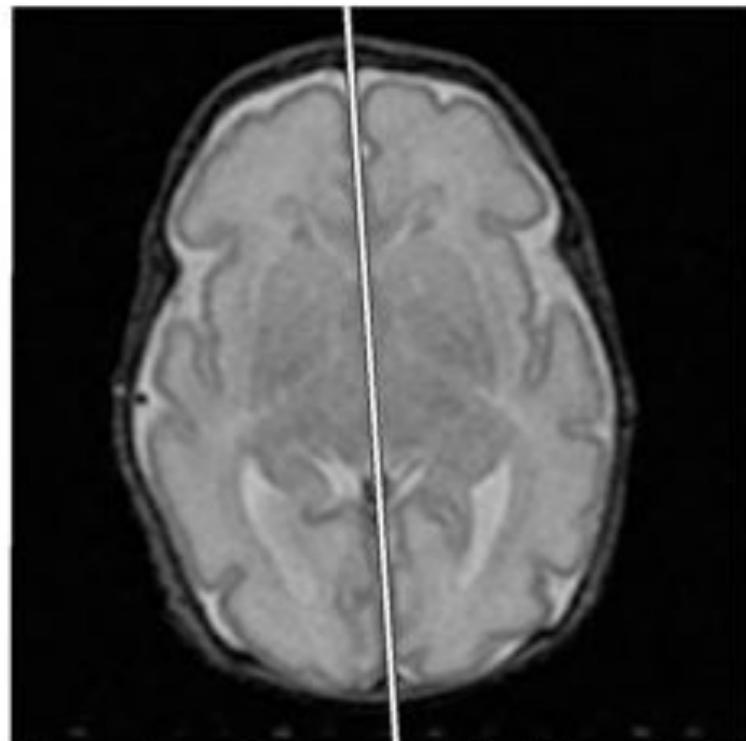
- Repose sur deux étapes bien distinctes
- Première étape : “segmentation”  
(souvent le plus dur, surtout si effectuée de façon automatique)
  - Extraire les primitives significatives.  
**Difficulté** : bruit (images ultrasonores ou autres)
  - Les primitives doivent correspondre aux **mêmes** réalités physiques dans les **2** images.  
Difficulté: recalage multi-modal (IRM T1 - IRM diffusion, TEP/IRM)
- Remarque: extraction automatique des primitives = idéal.  
Possible aussi:
  - manuel (médecin - expert)
  - stéréotaxiques (inclus dans les images)

# Repère stéréotaxique

- Cadre stéréotaxique
- Contention



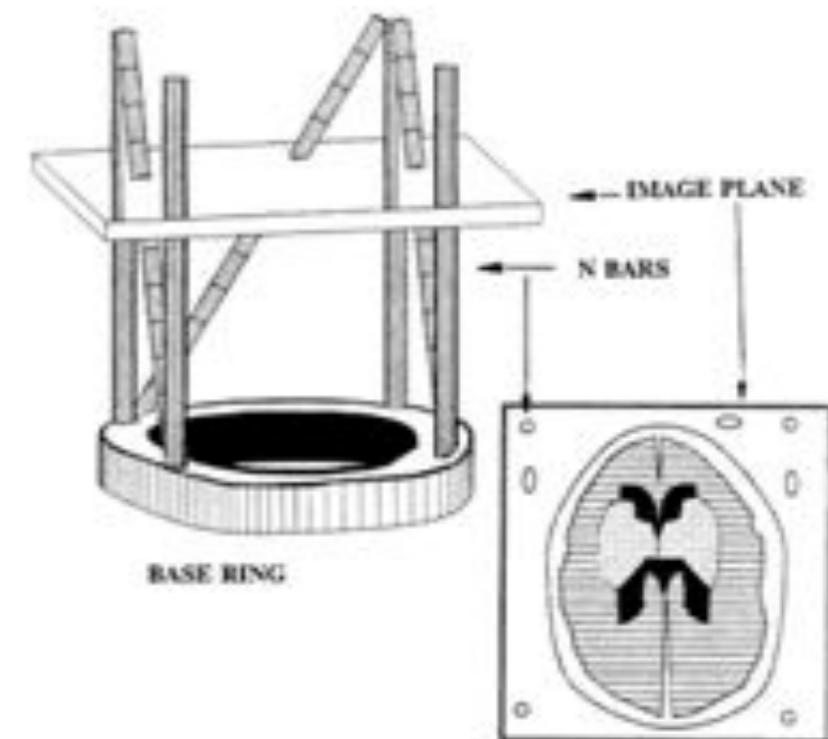
# Repères intrinsèques et extrinsèques



Intrinsic marker: midplane separating the two hemispheres

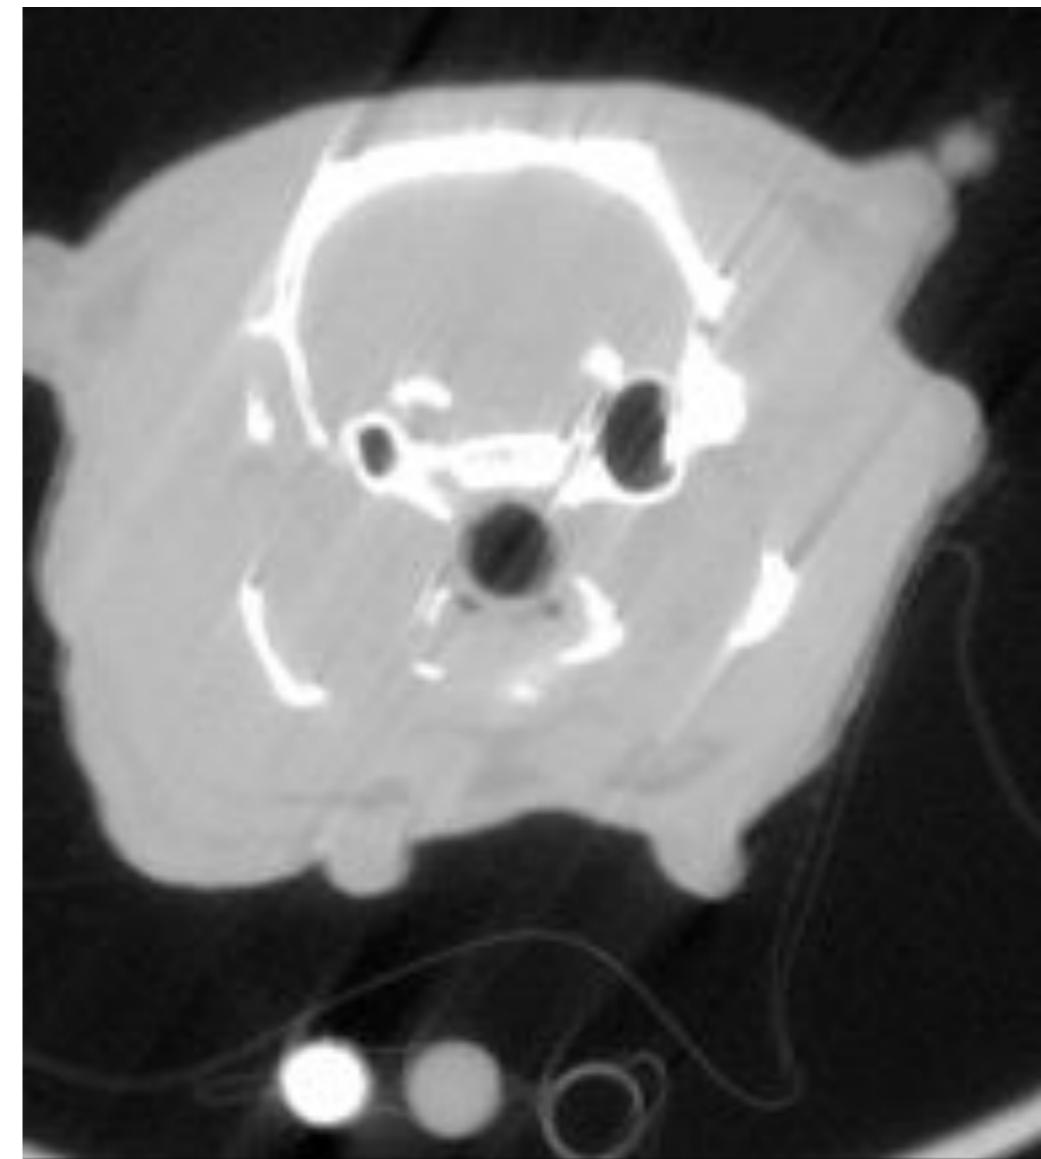
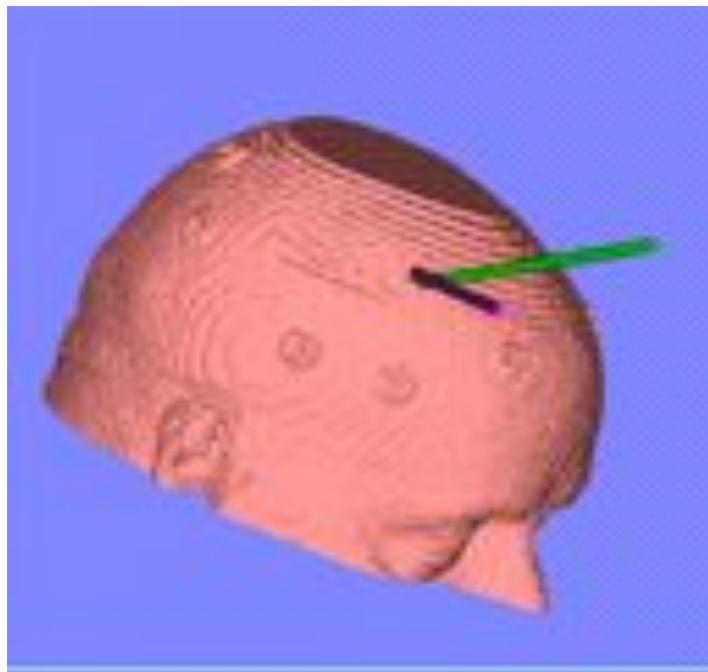


Extrinsic marker: stereotactic frame



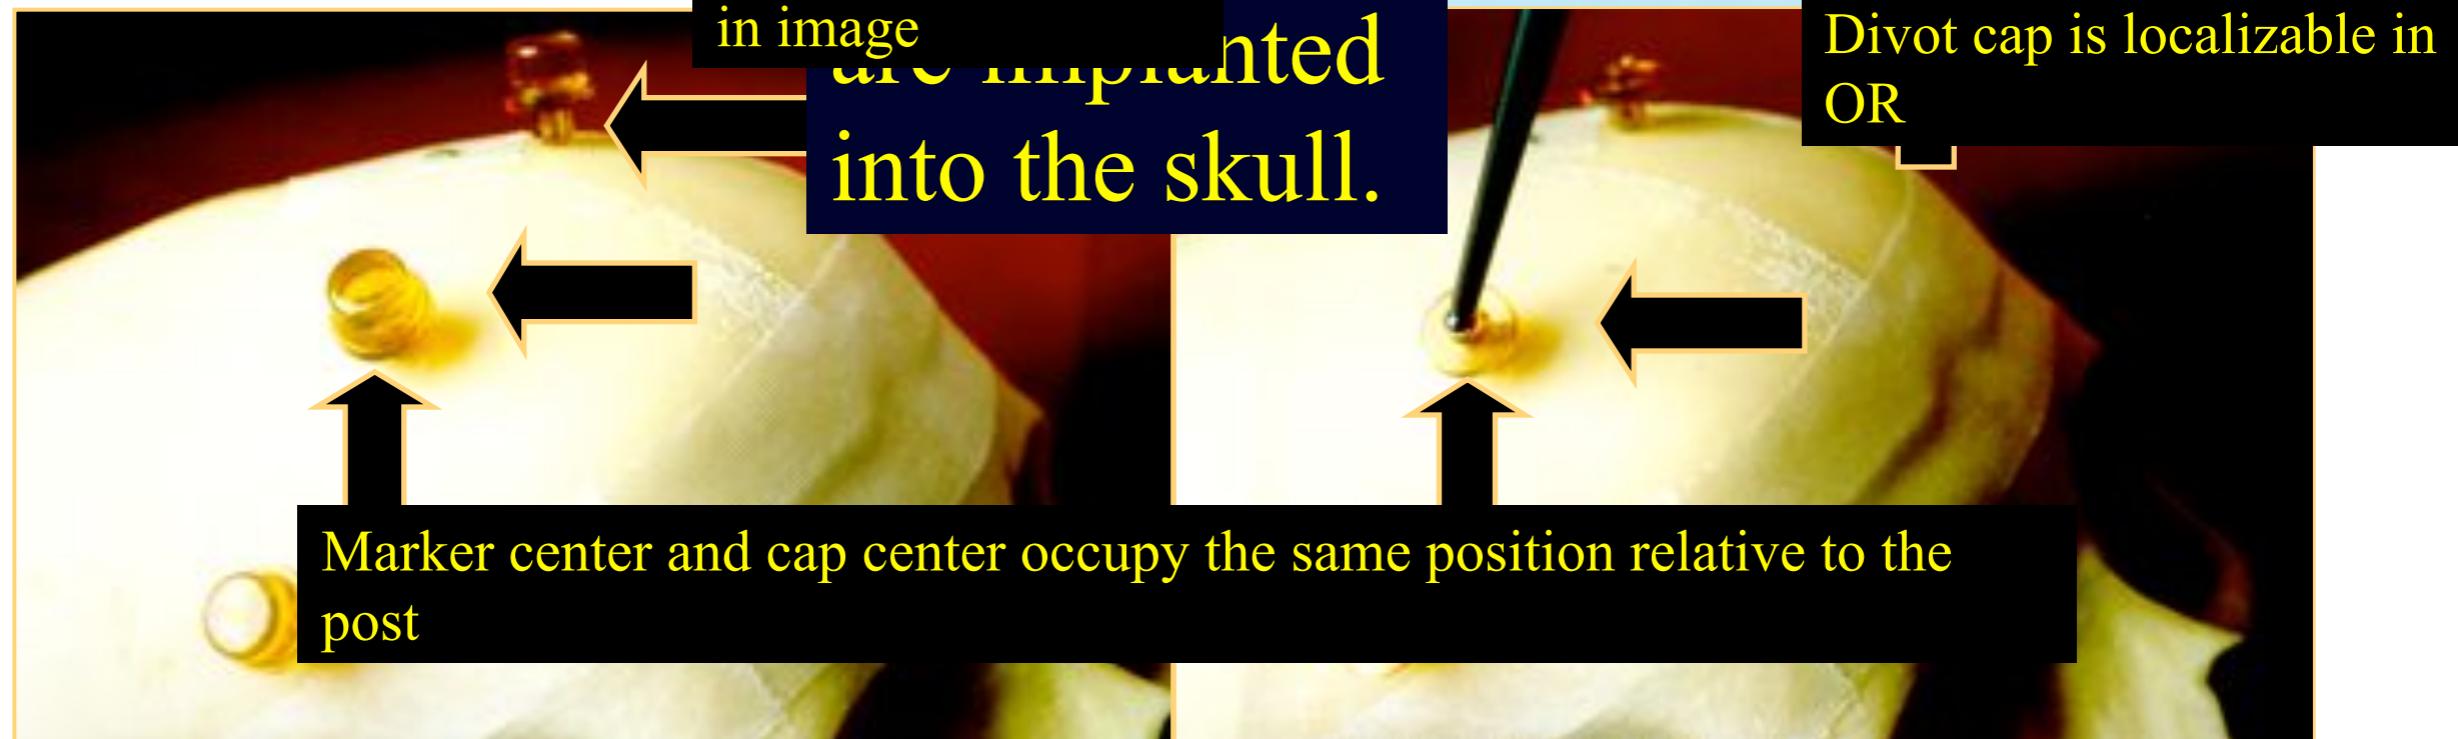
# Repère externe

- Exemple: mires en imagerie petit animal ou pour les interventions chirurgicales



# Acustar™

*Allen, Maciunas,  
Fitzpatrick, and  
Galloway*



[Maurer, *et al.*, TMI, 1997]

# Détection automatique de primitives

- Points/lignes extrémaux: Thirion et al, 1996.

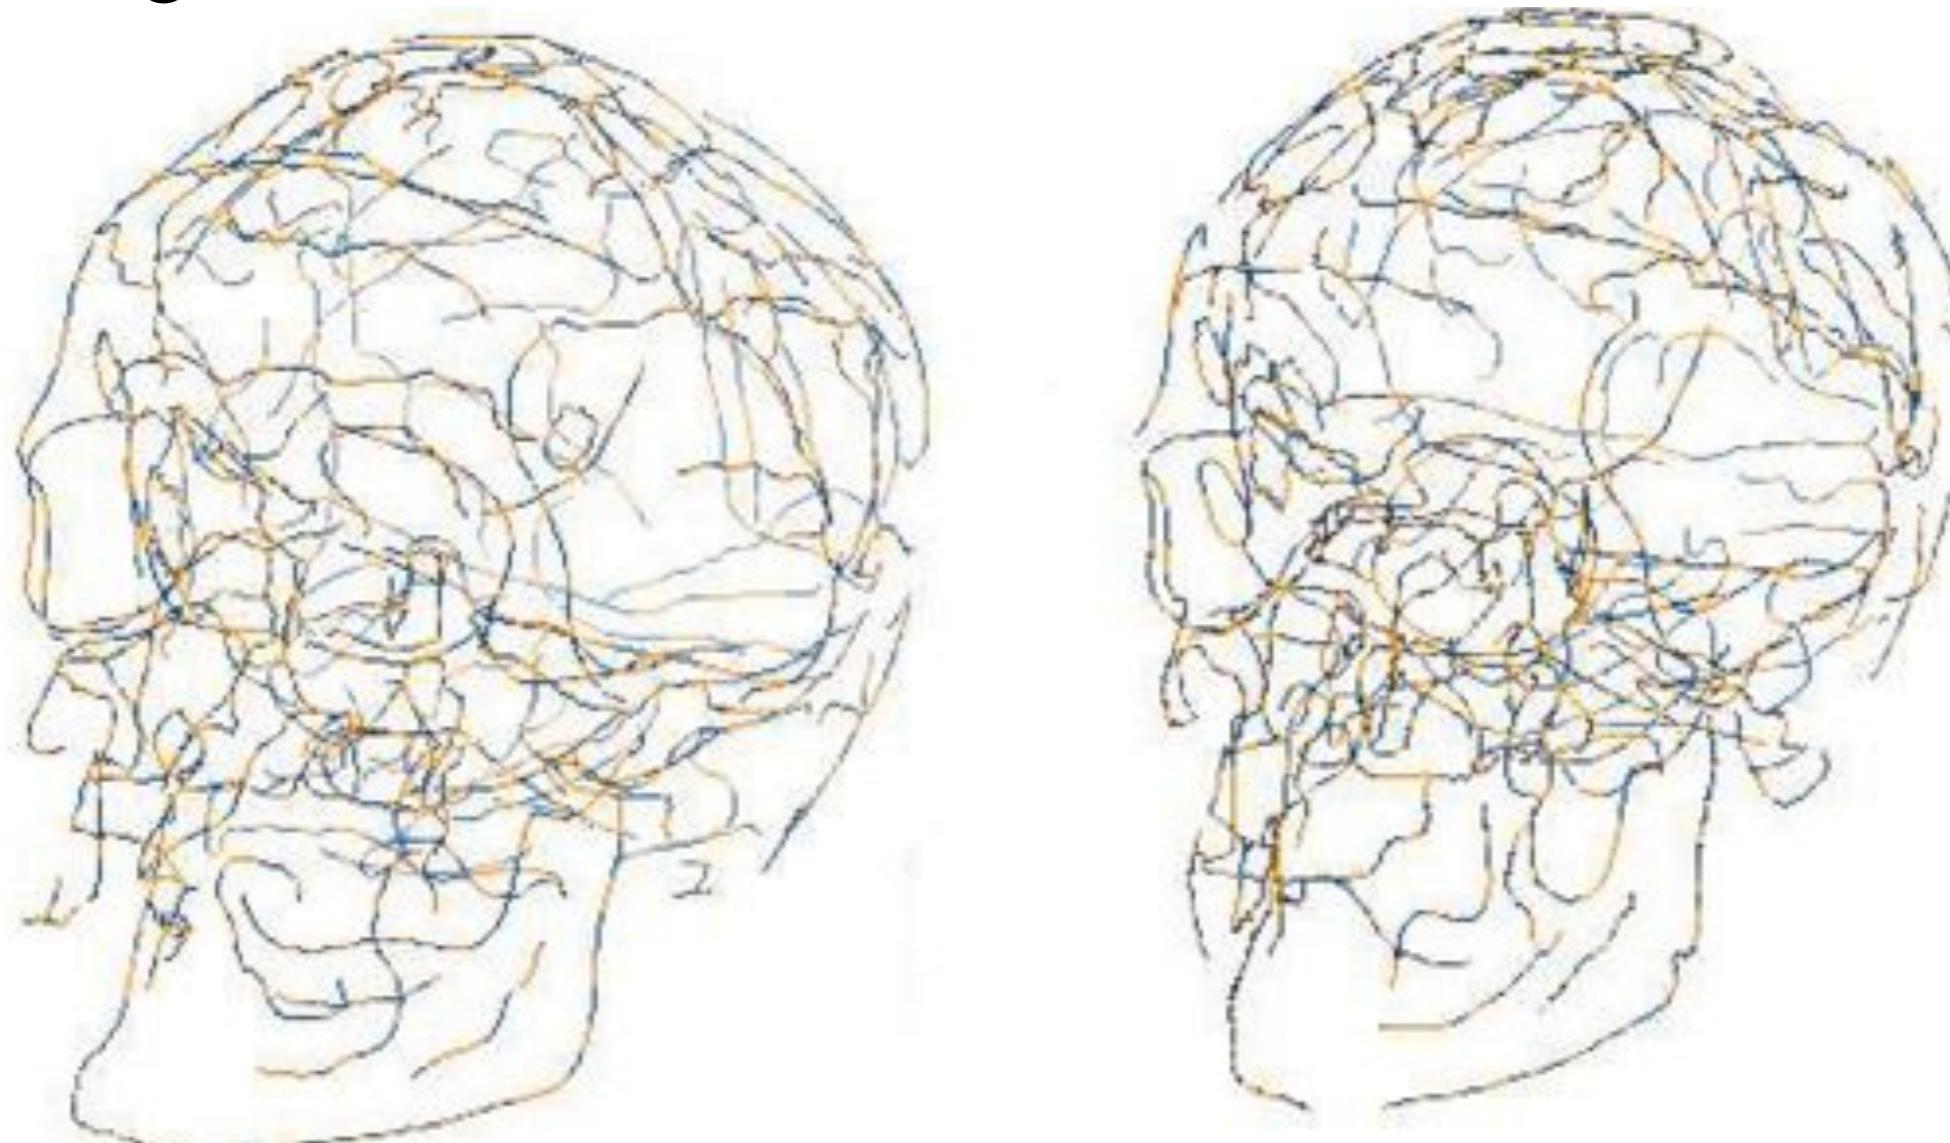
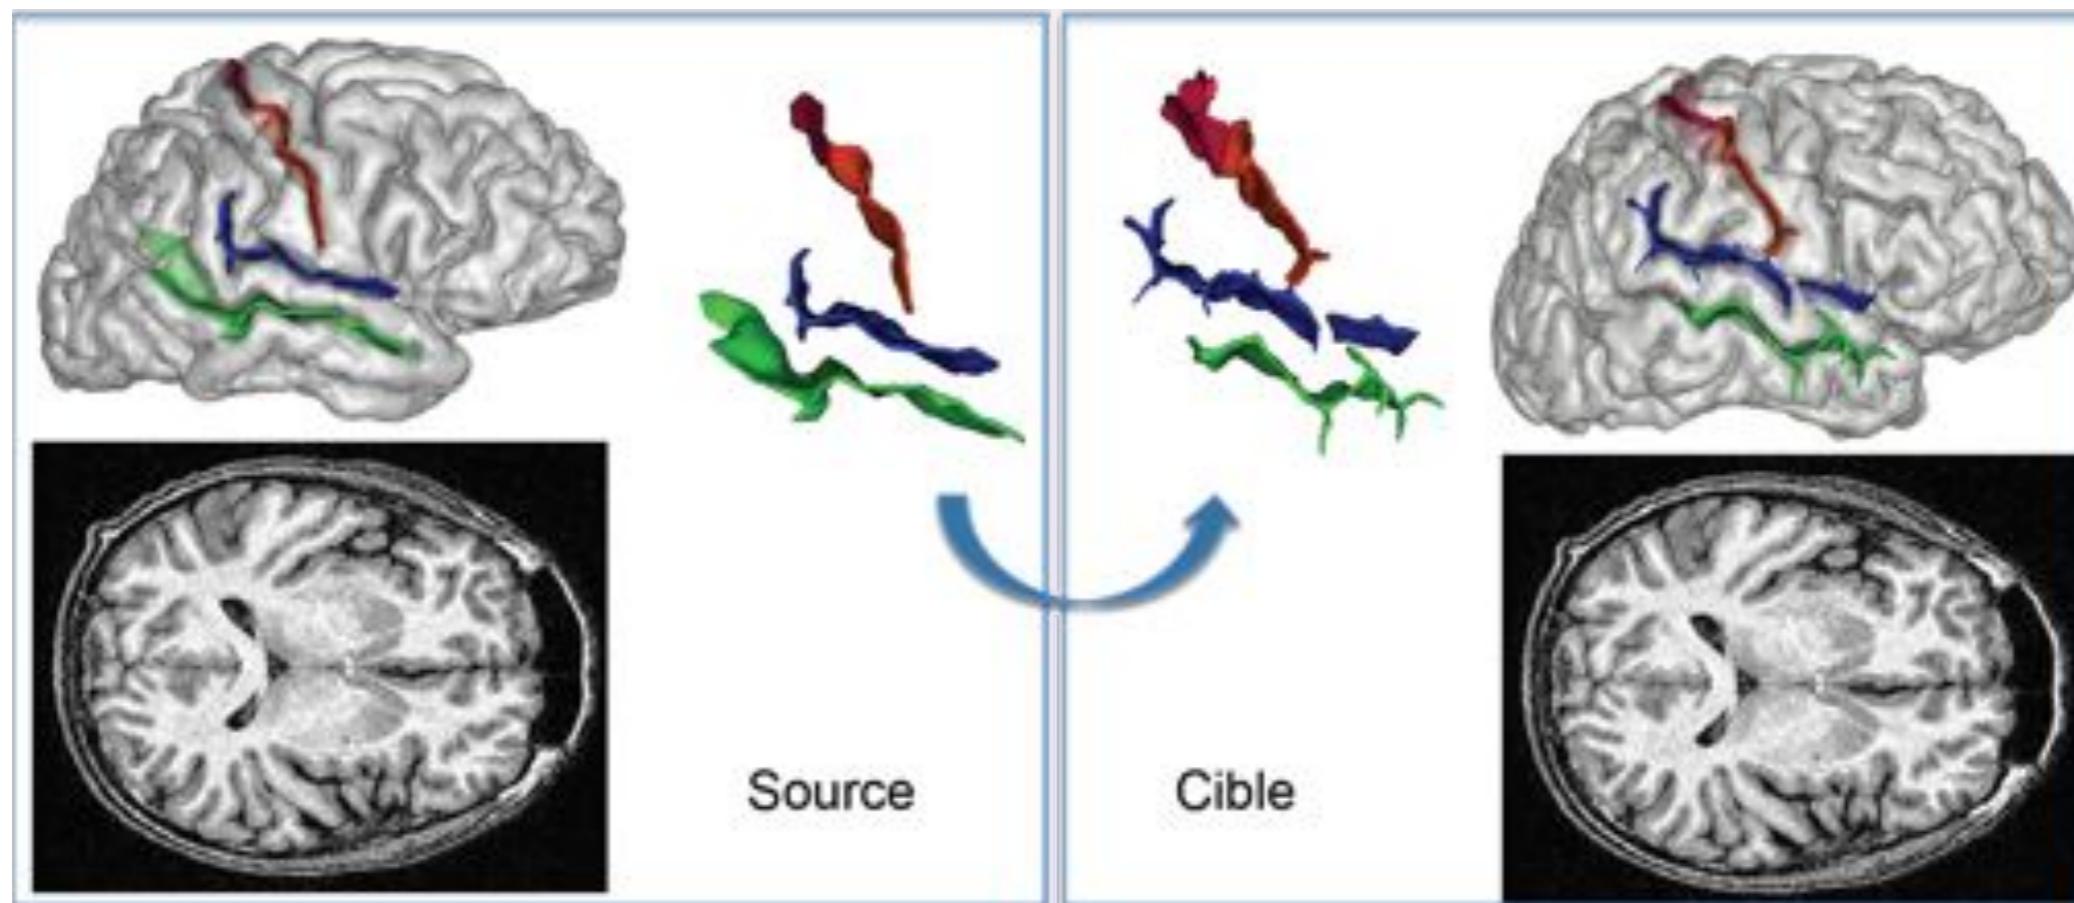


Figure 12: The two sets of crest lines, extracted from two different 3D Xray scanner images of the same skull (1x1x1.5mm) with the randomized version

# Détection automatique de primitives

- Sillons corticaux. Auzias et al. IEEE Transactions on Medical Imaging, 2010.



# SIFT

*(Scale-Invariant Feature Transform)*

D. Lowe, « *Distinctive Image Features from Scale-Invariant Keypoints* », IJCV 60(2), 2004, p. 91-110.

F. Estrada, A. Jepson, D. Fleet « *SIFT Tutorial* », 2004

# Alignement par points caractéristiques

- Sélection automatique de points

Procédure à suivre :

SIFT

 Détection de N points caractéristiques dans  $I_1 : \{p_1, p_2, \dots, p_N\}$

Détection de M points caractéristiques dans  $I_2 : \{q_1, q_2, \dots, q_M\}$

Mise en correspondance des points caractéristiques  $\Gamma = \{(p_1, q_j), (p_2, q_k), \dots, (p_N, q_l)\}$

## Mise en correspondance de points par SIFT (vue d'ensemble)

**Extraction de points** {  
  
**Mise en correspondance des points** {

Détection de  $N$  points caractéristiques dans

$$I_1 : \Gamma_p = \{p_1, p_2, \dots, p_N\}$$

Détection de  $N$  points caractéristiques dans  
 $\Gamma = \{ \}$

$$I_2 : \Gamma_q = \{q_1, q_2, \dots, q_N\}$$

POUR  $i$  allant de  $1$  à  $N$  FAIRE

$$q_j = \arg \min_{q \in \Gamma_q} dist(p_i, q)$$

$$\Gamma = \Gamma \cup \{p_i, q_j\}$$

Enlever  $q_j$  de  $\Gamma_q$

Note :  $dist(p_i, q)$  est une fonction qui mesure à quel point  $p_i$  ressemble à  $q$

# Alignement par points caractéristiques

## Détection de $N$ points caractéristiques

Détection de  $N$  points dans les 2 images :



Image de gauche  
Points caractéristiques



Image de droite  
Points caractéristiques

# SIFT

## Objectif :

Extraire des points dont les caractéristiques sont raisonnablement invariantes à

- **Translation;**
- **Rotation;**
- **Changement d'échelle;**
- **Changements d'angle de vue;**
- **Changements d'illumination.**

en plus d'exiger peu de calculs!

# Alignement par points caractéristiques

Détection de  $N$  points caractéristiques dans une image

La localisation de points d'intérêt à l'aide de SIFT est fondée sur le principe de filtres par la **différence de gaussiennes (DOG)**.

Soit une image floue

$$I(x, y, \sigma) = g(x, y, \sigma) * I(x, y)$$

où

$$g(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{(x^2+y^2)}{\sigma^2}}$$

est une gaussienne d'échelle  $\sigma$ . Le résultat d'un image convoluée par un filtre DOG

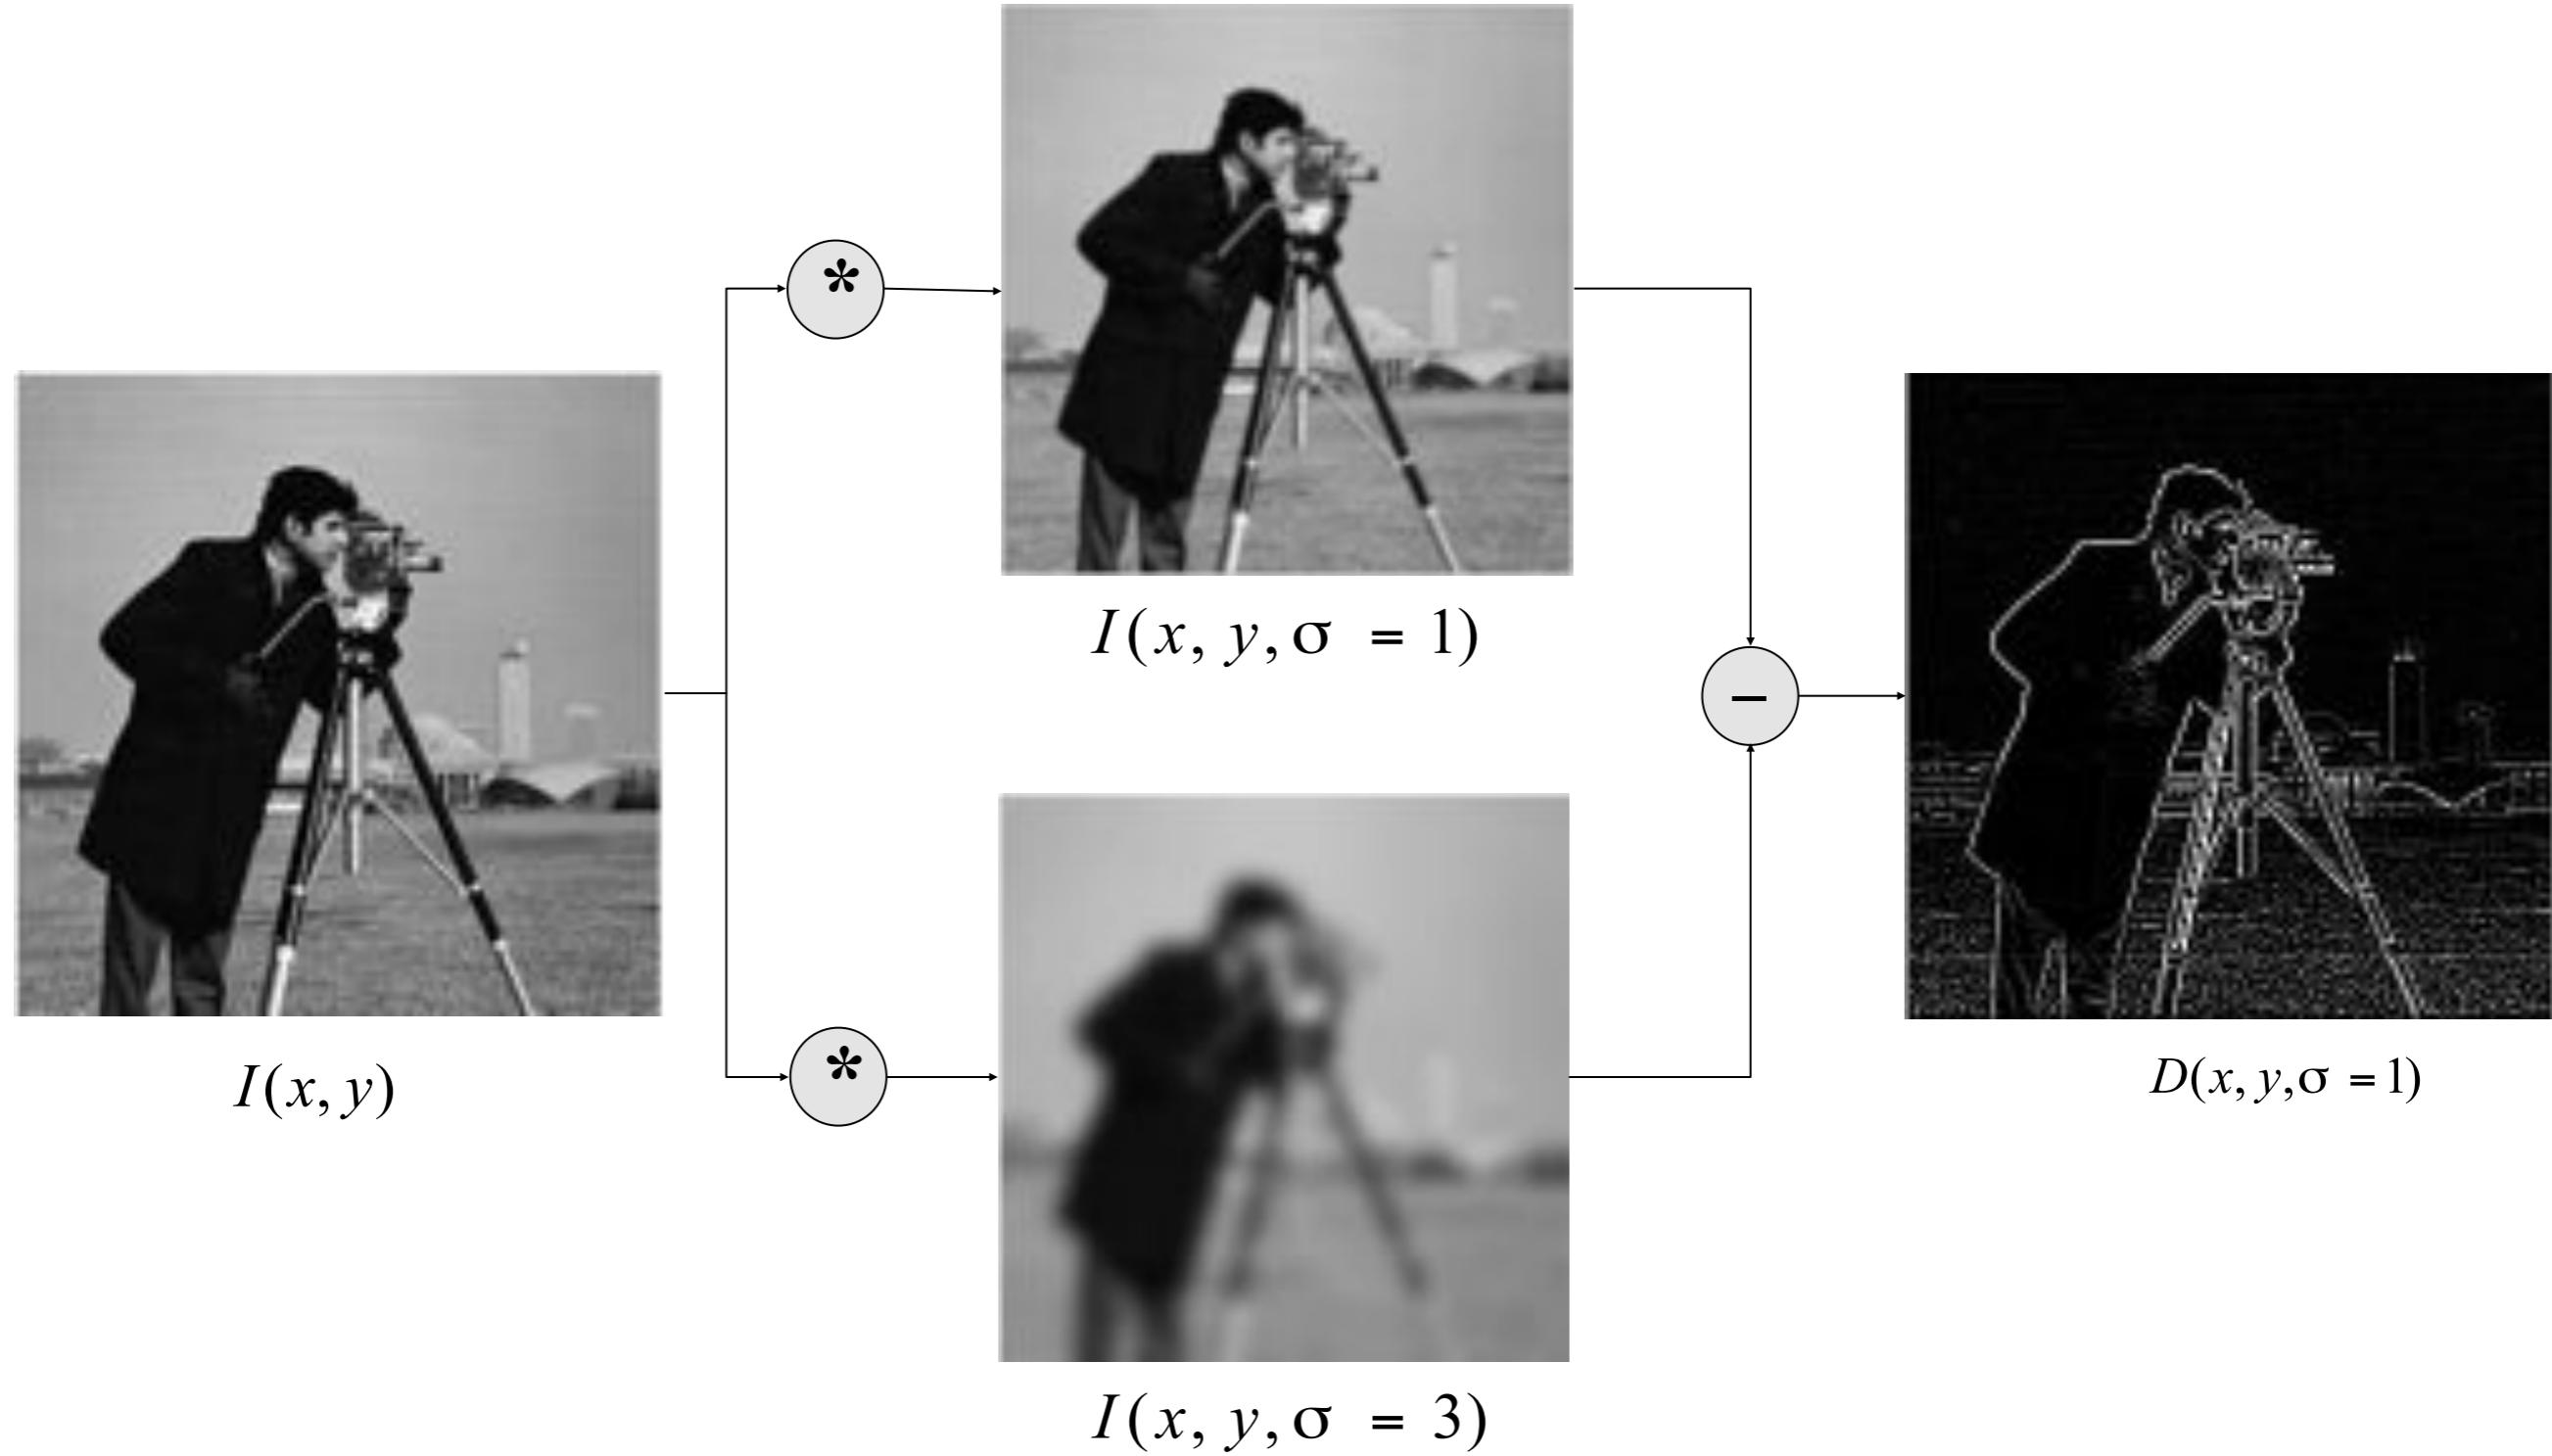
$$g(x, y, k\sigma) - g(x, y, \sigma)$$

est

$$D(x, y, \sigma) = I(x, y, k\sigma) - I(x, y, \sigma)$$

# Alignement par points caractéristiques

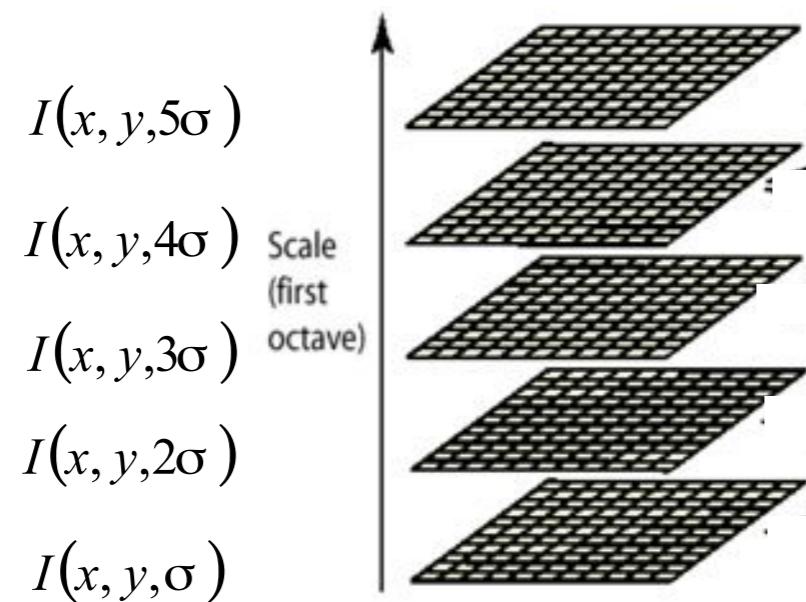
Détection de  $N$  points caractéristiques dans une image



# Alignement par points caractéristiques

Détection de  $N$  points caractéristiques dans une image

La première étape est donc de **convoluer l'image à plusieurs échelles**



$I(x, y, \sigma)$



$I(x, y, 2\sigma)$



$I(x, y, 3\sigma)$

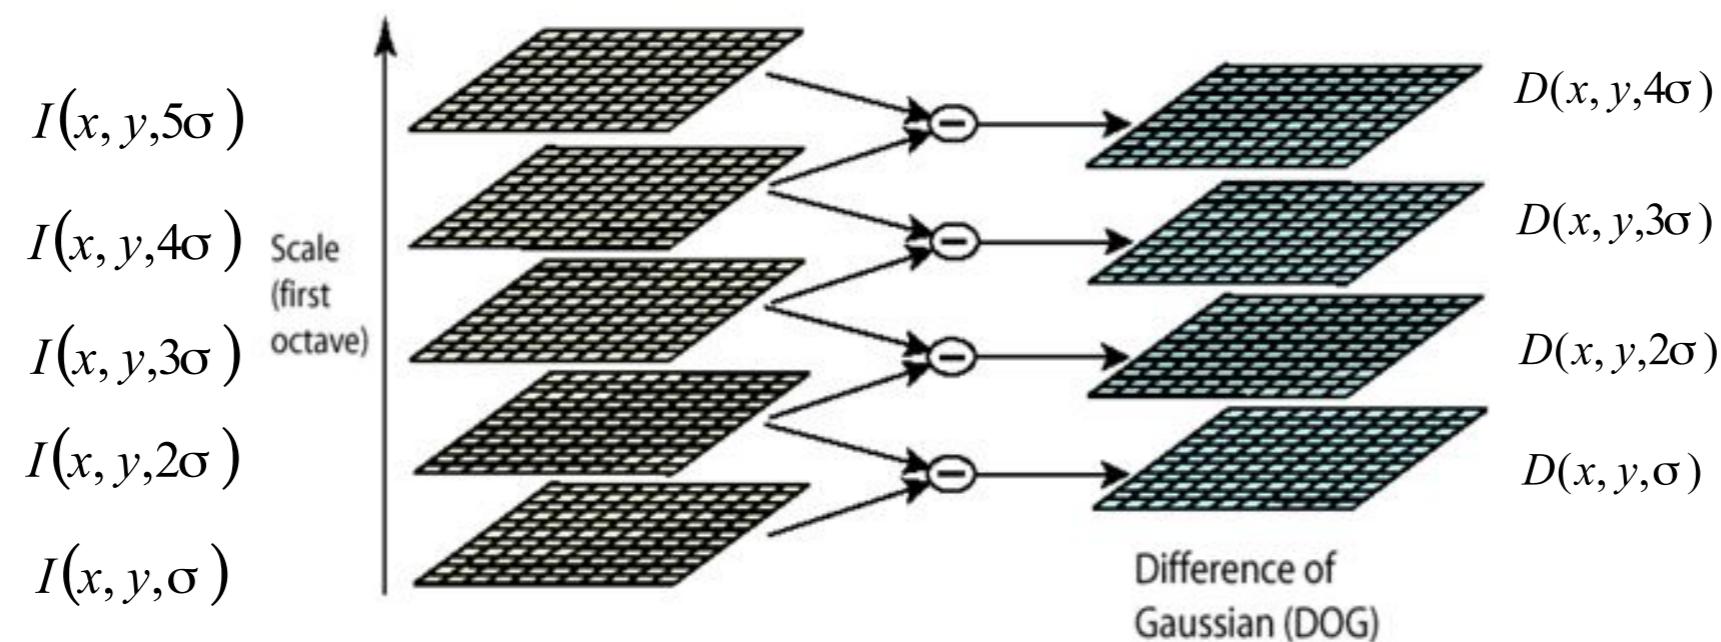


$I(x, y, 4\sigma)$

# Alignement par points caractéristiques

Détection de  $N$  points caractéristiques dans une image

Faire la **différence d'images** adjacentes



$I(x, y, \sigma)$



$I(x, y, 2\sigma)$



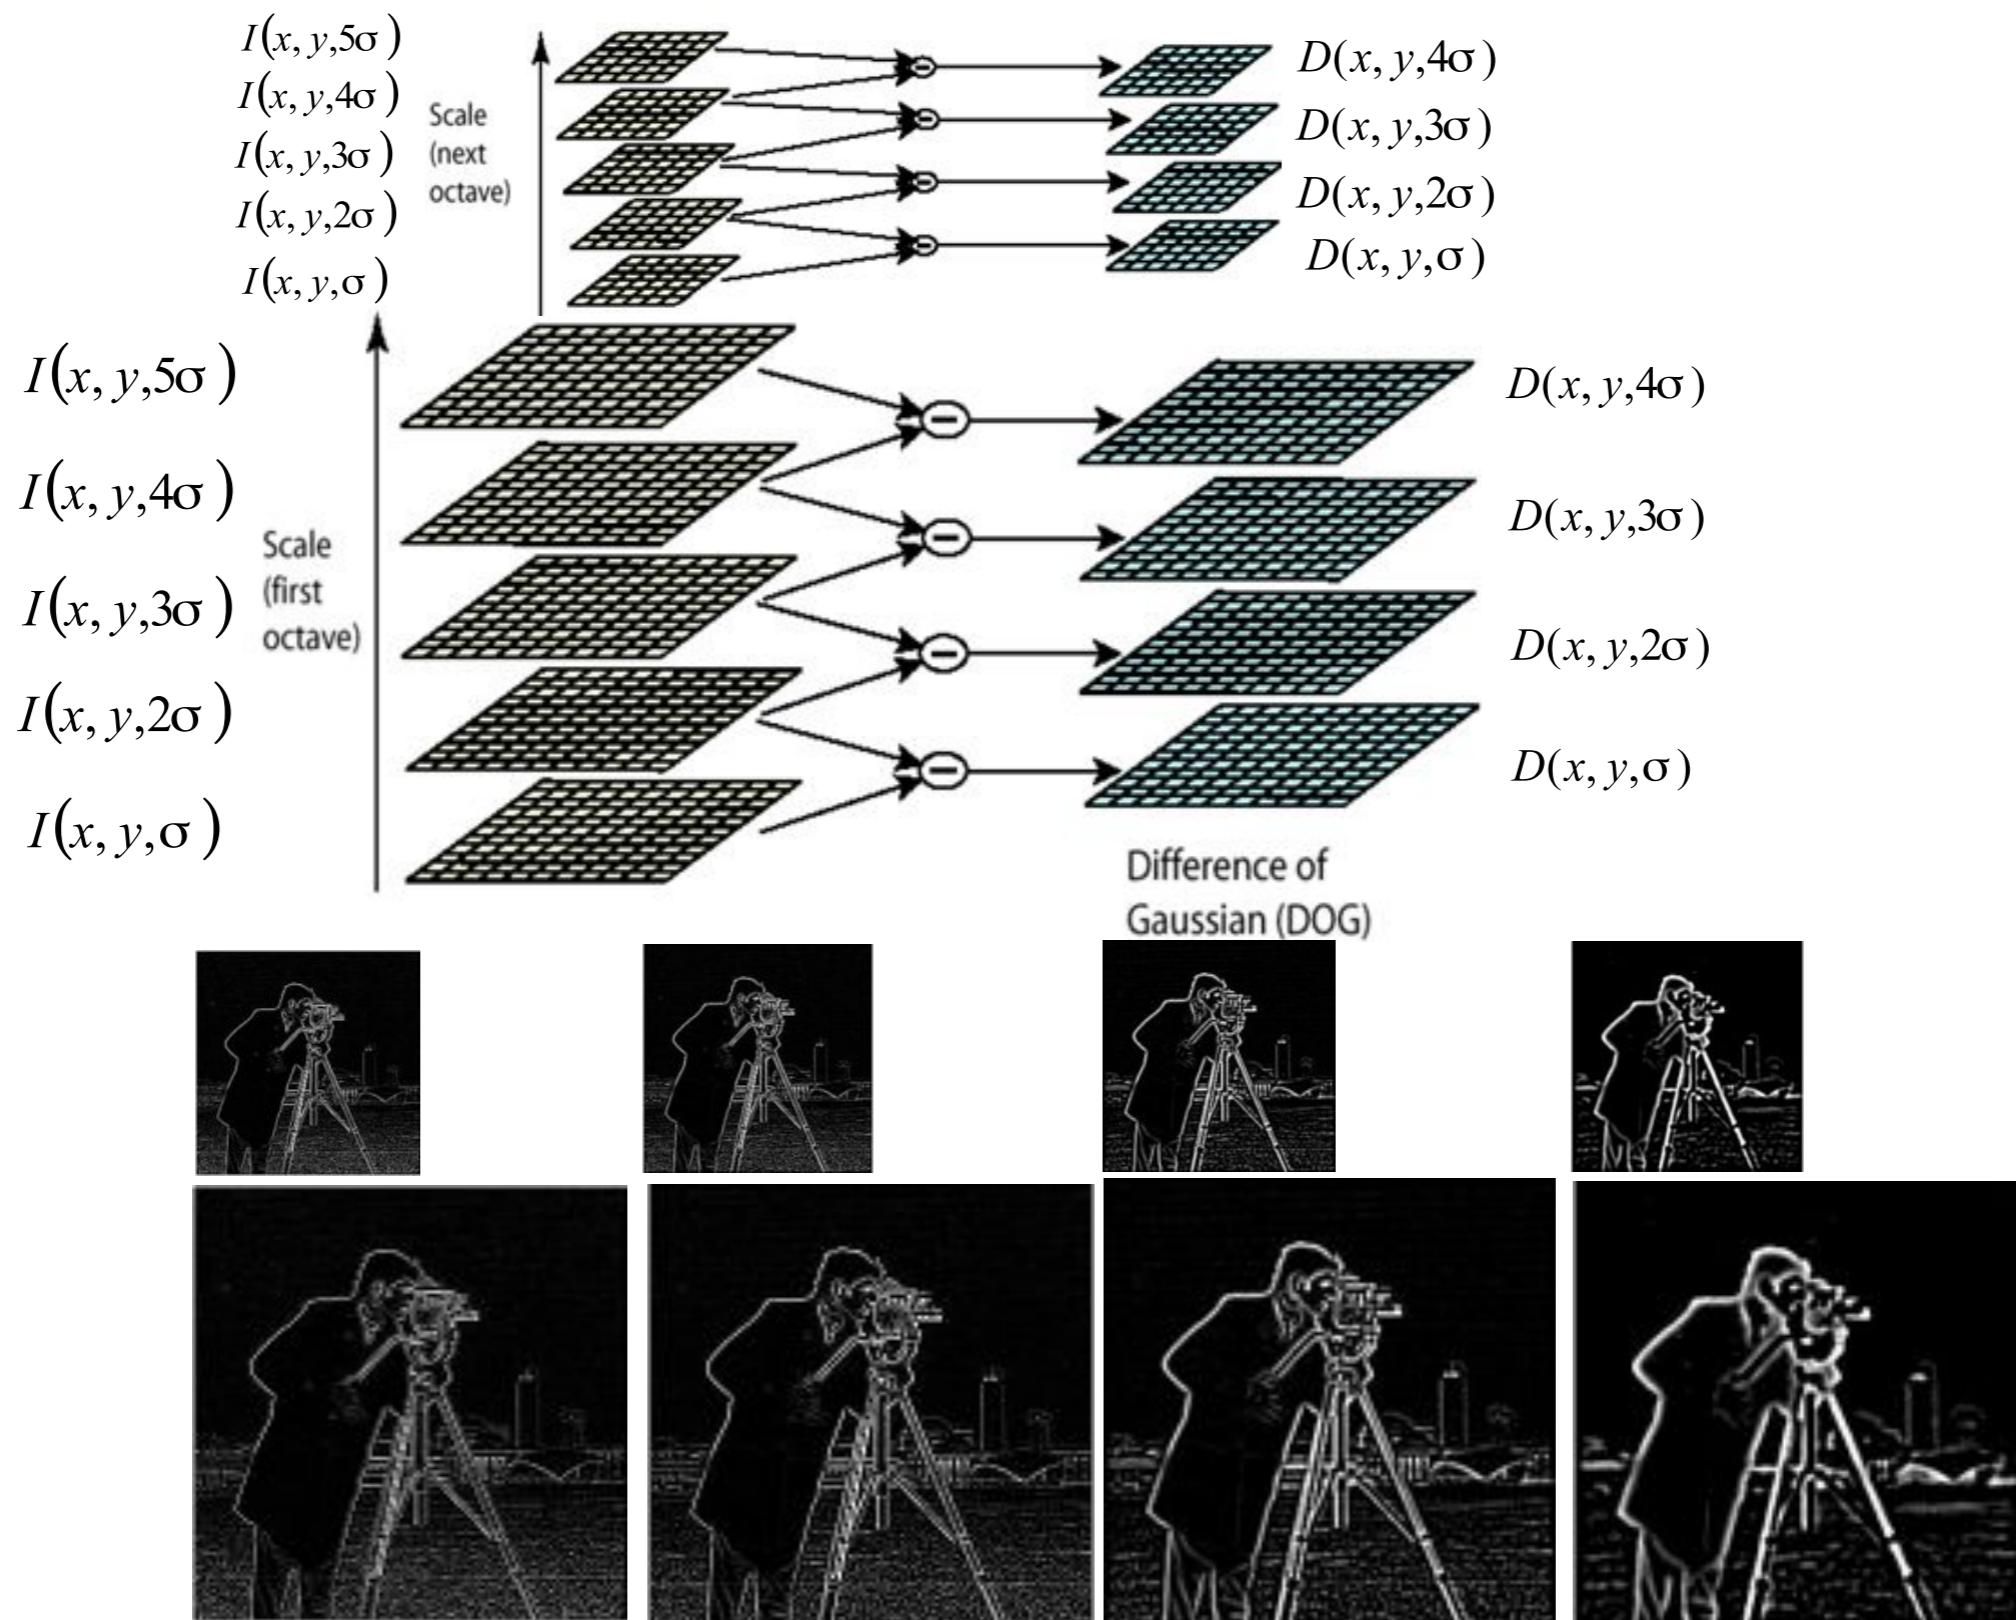
$I(x, y, 3\sigma)$



$I(x, y, 4\sigma)$

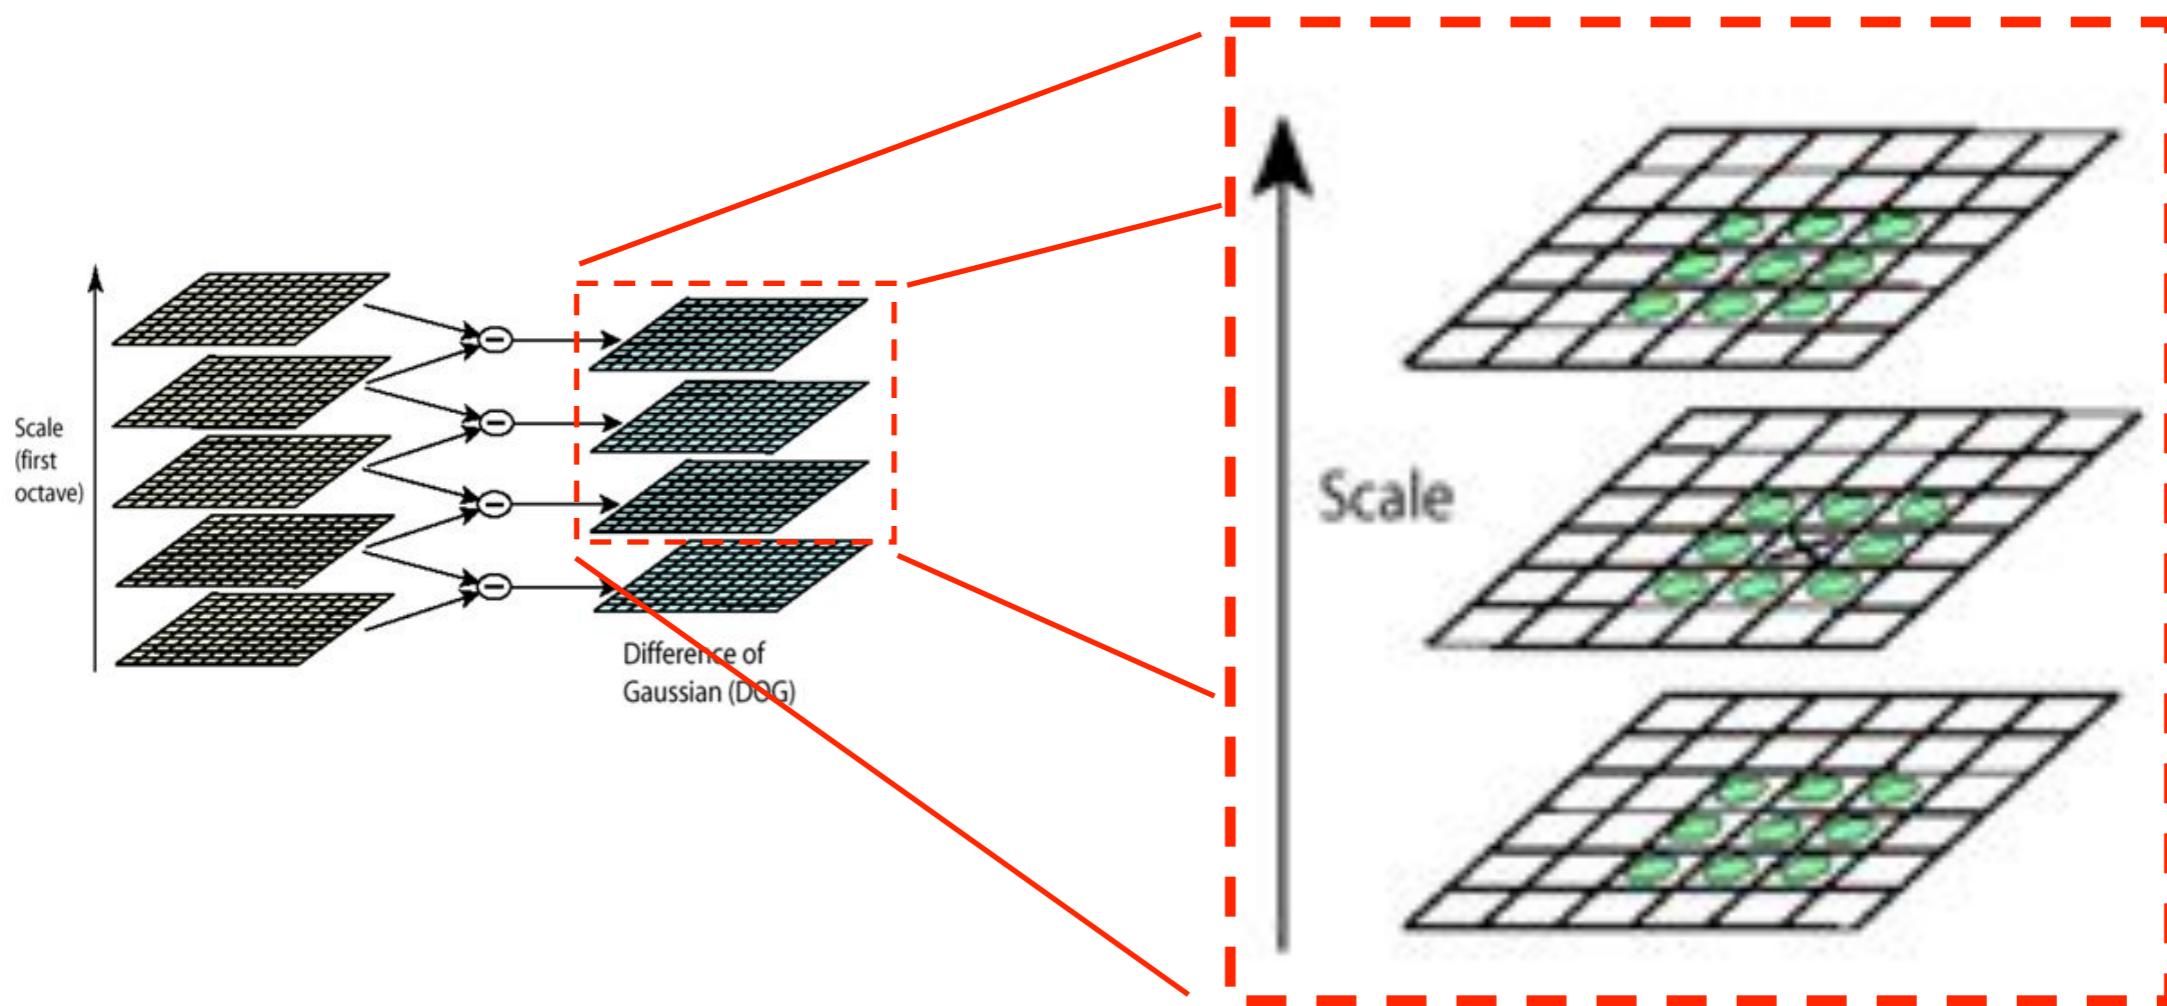
# Alignement par points caractéristiques

Puis de recommencer sur d'autres octaves



# Alignement par points caractéristiques

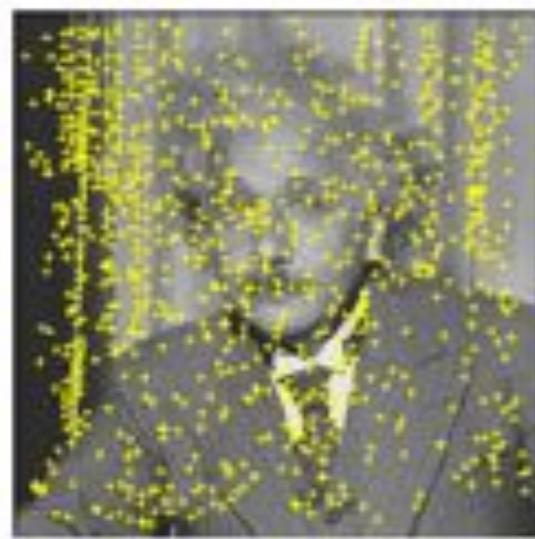
Détection de  $N$  points caractéristiques dans une image



Si un pixel  $x$  est plus grand que ses 26 voisins, alors ce dernier est retenu comme étant un **point caractéristique potentiel**.

# Alignement par points caractéristiques

Détection de  $N$  points caractéristiques dans une image



Afin de réduire le nombre de points :

- On élimine les points dans les zones de **contraste faible**
- On élimine les points **proches d'un contour**

# Alignement par points caractéristiques

Détection de  $N$  points caractéristiques dans une image

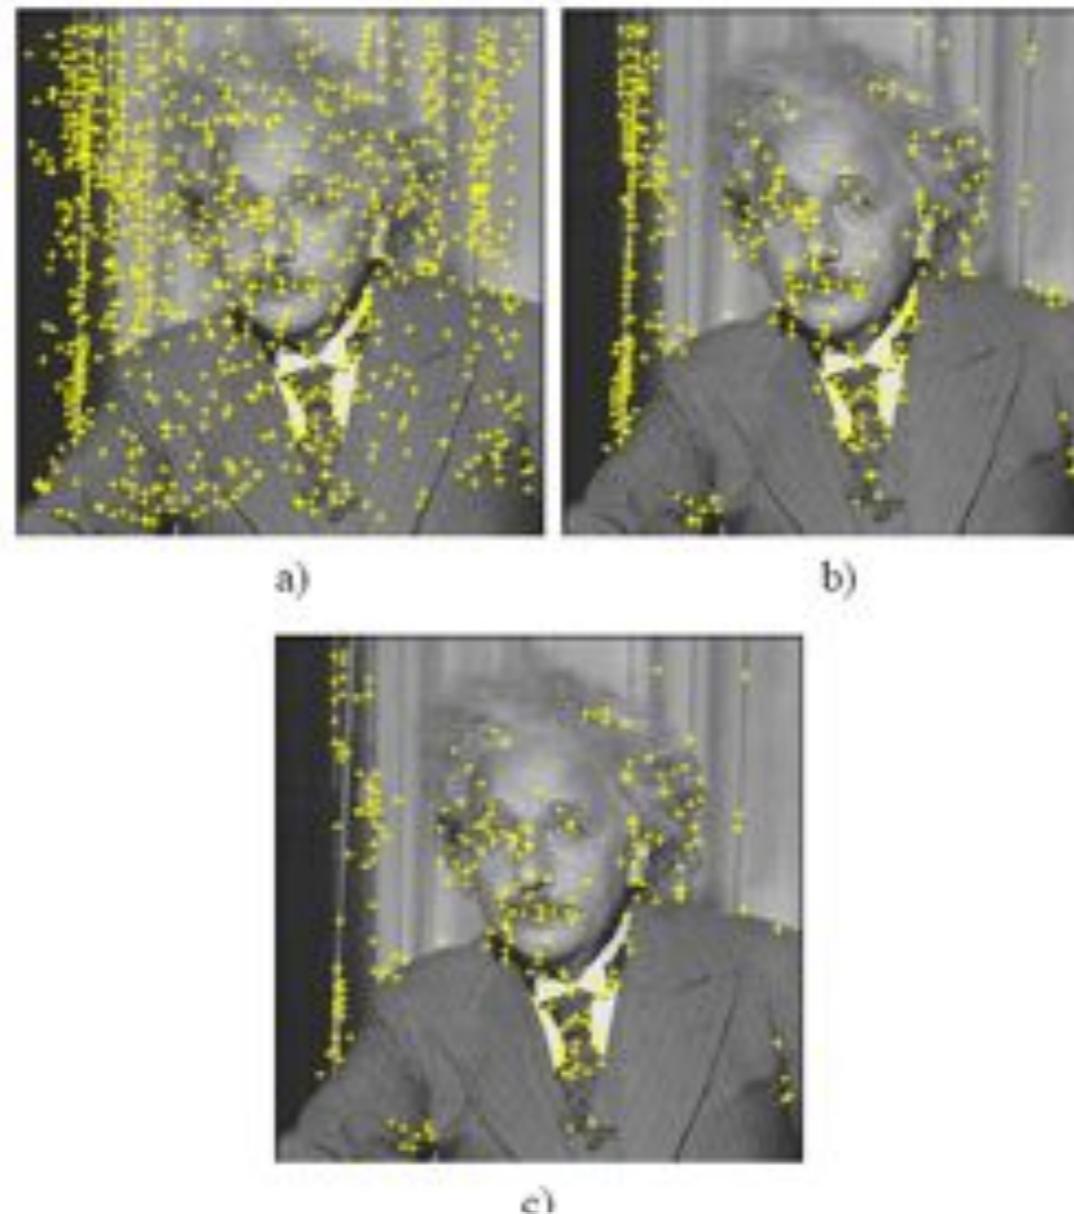


Figure 5: a) Maxima of DoG across scales. b) Remaining keypoints after removal of low contrast points. C) Remaining keypoints after removal of edge responses (bottom).

[Crédit : F. Estrada, A. Jepson, D. Fleet]

# RAPPEL

## Mise en correspondance de points par SIFT (vue d'ensemble)

Extraction de points      {  
Mise en correspondance des points      {

Détection de  $N$  points caractéristiques dans

Détection de  $N$  points caractéristiques dans  
 $\Gamma = \{ \}$

POUR  $i$  allant de  $1$  à  $N$  FAIRE

$$q_j = \arg \min_{q \in \Gamma_q} dist(p_i, q)$$

$$\Gamma = \Gamma \cup \{p_i, q_j\}$$

Enlever  $q_j$  de  $\Gamma_q$

$$I_1 : \Gamma_p = \{p_1, p_2, \dots, p_N\}$$

$$I_2 : \Gamma_q = \{q_1, q_2, \dots, q_N\}$$

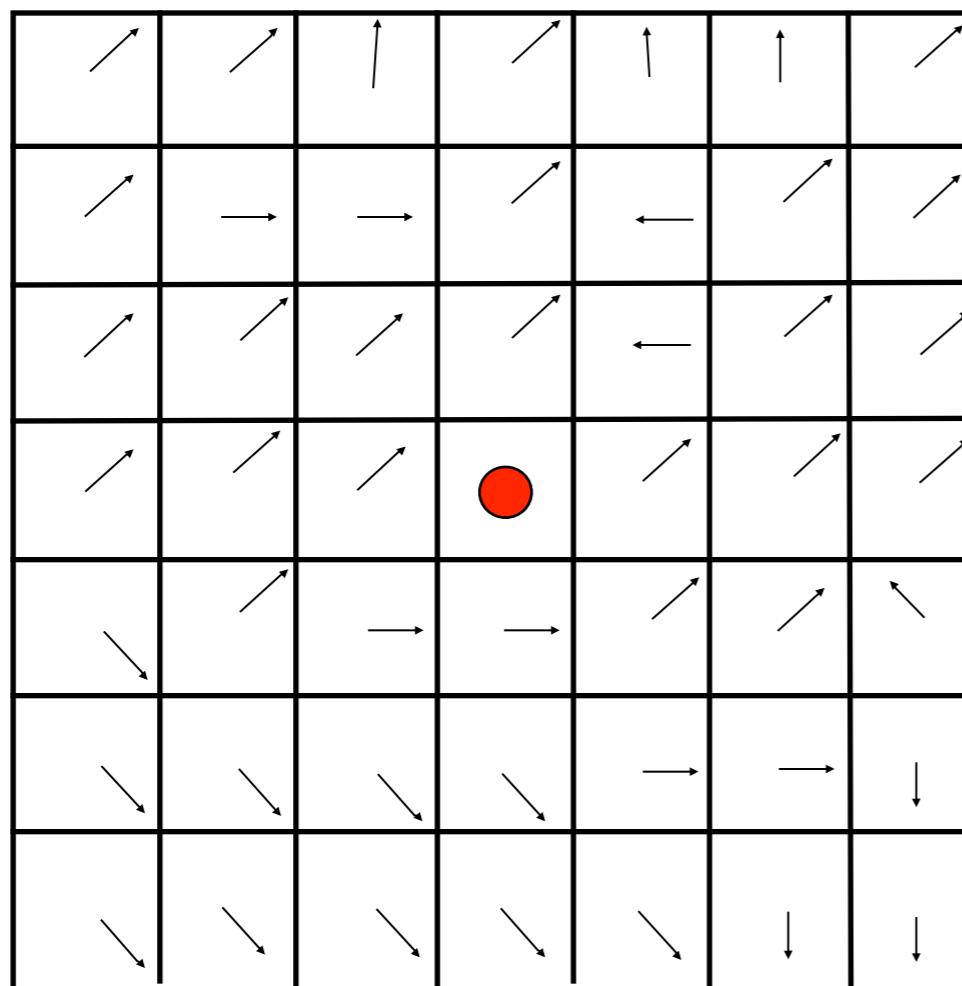
Note:  $dist(p_i, q)$  est une fonction qui mesure à quel point  $p_i$  ressemble à  $q$

# Alignement par points caractéristiques

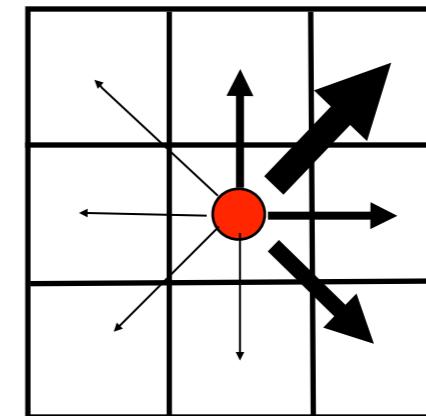
## Mise en correspondance avec SIFT

Pour effectuer une mise en correspondance, on doit d'abord assigner des caractéristiques à chaque point. Tout d'abord, on cherche **l'orientation du point**. Pour ce faire, on calcul **un histogramme d'orientation**.

- Point SIFT.



**histogramme d'orientation**



→ : Orientation du point ●

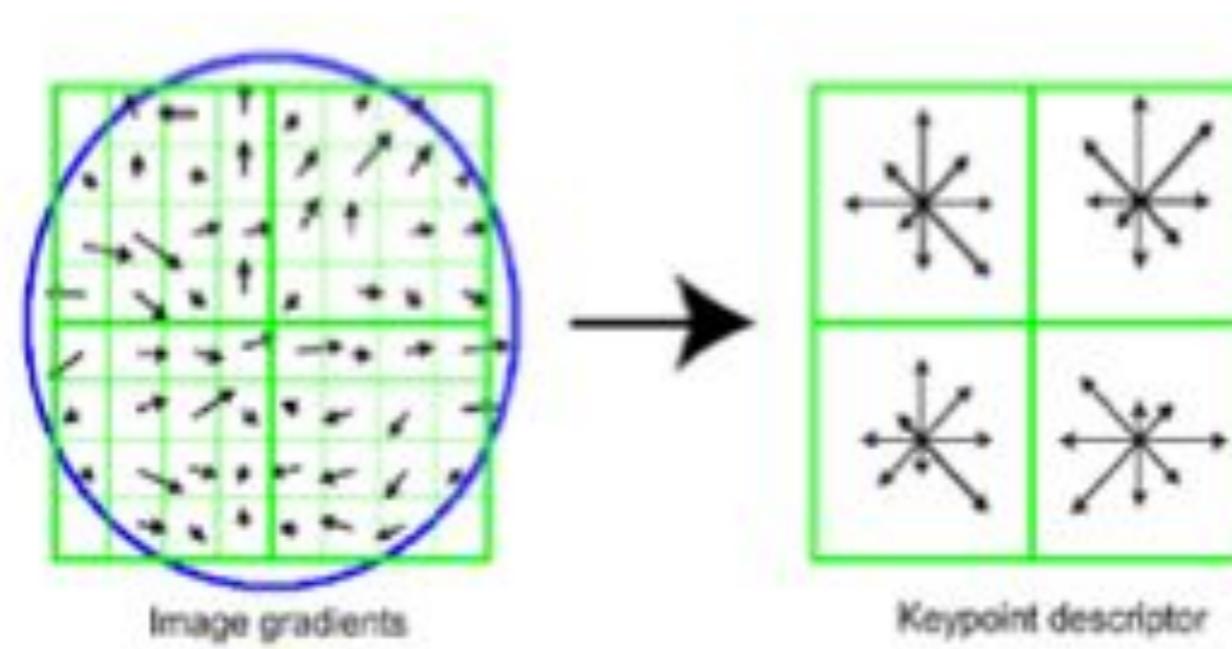
# Alignement par points caractéristiques

## Mise en correspondance avec SIFT

Pour chaque point caractéristique, on sélectionne un voisinage  $8 \times 8$  duquel on extrait **4 histogrammes d'orientation**. Ces histogrammes sont relatifs à l'orientation du point précédemment calculé, ce qui le rend invariant à la rotation.

Avec 4 histogrammes de 8 valeurs chaque, le descripteur SIFT d'un point caractéristique contient **32 valeurs**.

Ce vecteur de 32 valeurs est **normalisé** afin d'être robuste aux changements d'illumination.



[Crédit : Lowe 2004]

# RAPPEL

## Mise en correspondance de points par SIFT (vue d'ensemble)

**Extraction de points** {  
  
**Mise en correspondance des points** {

Détection de  $N$  points caractéristiques dans

Détection de  $N$  points caractéristiques dans  
 $\Gamma = \{ \}$

POUR  $i$  allant de  $1$  à  $N$  FAIRE

$$q_j = \arg \min_{q \in \Gamma_q} dist(p_i, q)$$

$$\Gamma = \Gamma \cup \{p_i, q_j\}$$

Enlever  $q_j$  de  $\Gamma_q$

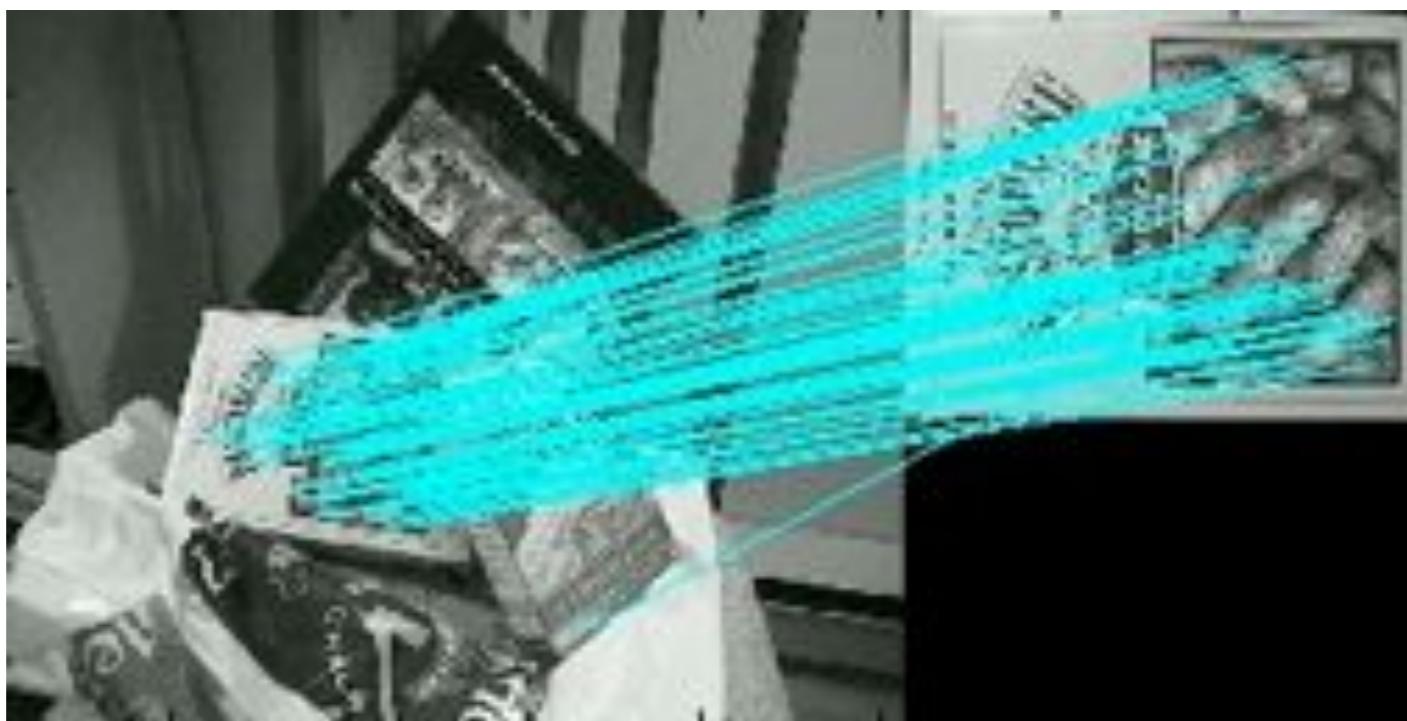
$$I_1 : \Gamma_p = \{p_1, p_2, \dots, p_N\}$$

$$I_2 : \Gamma_q = \{q_1, q_2, \dots, q_N\}$$

Comparaison des histogrammes d'orientation SIFT comme fonction de distance

# Alignment par points caractéristiques

Mise en correspondance avec SIFT



[Crédit : Lowe 2004]

# Recalage des primitives extraites

- Une fois les primitives extraites, la deuxième étape est le recalage proprement dit, i.e. calcul d'une transformation spatiale “optimale”
- Cas le plus simple, primitives labélisées : on connaît les correspondances (la  $k$ -ième primitive dans  $I$  correspond à la  $k$ -ième primitive dans  $J$ )
- On cherche donc la transformation spatiale  $T$  telle que  $T(x^k) = (y^k)$  avec
  - $x^k = (x_1^k, x_2^k, x_3^k)$  coordonnées de la  $k$ -ième primitive dans l'image  $I$
  - $y^k = (y_1^k, y_2^k, y_3^k)$  coordonnées de la  $k$ -ième primitive dans l'image  $J$

# Recalage des primitives extraites

- Si  $T$  est linéaire, on peut récrire sous forme matricielle :  
$$Y = T X$$

$$Y = \begin{bmatrix} y_1^1 & y_1^2 & \dots & y_1^N \\ y_2^1 & y_2^2 & \dots & y_2^N \\ y_3^1 & y_3^2 & \dots & y_3^N \end{bmatrix}$$

$$X = \begin{bmatrix} x_1^1 & x_1^2 & \dots & x_1^N \\ x_2^1 & x_2^2 & \dots & x_2^N \\ x_3^1 & x_3^2 & \dots & x_3^N \end{bmatrix}$$

- En pratique, pas de solution exacte
- Exemple: 12 paramètres pour une transformation affine et souvent beaucoup plus de primitives + bruit

# Optimisation : approches géométriques

- On cherche une  $T$  qui minimise l'écart entre  $T(x^k)$  et  $(y^k)$
- Méthode des moindres carrés :

$$\inf_T \sum_{k=1}^N \|T(x^k) - y^k\|^2$$

# Recalage de primitives non-labélisées

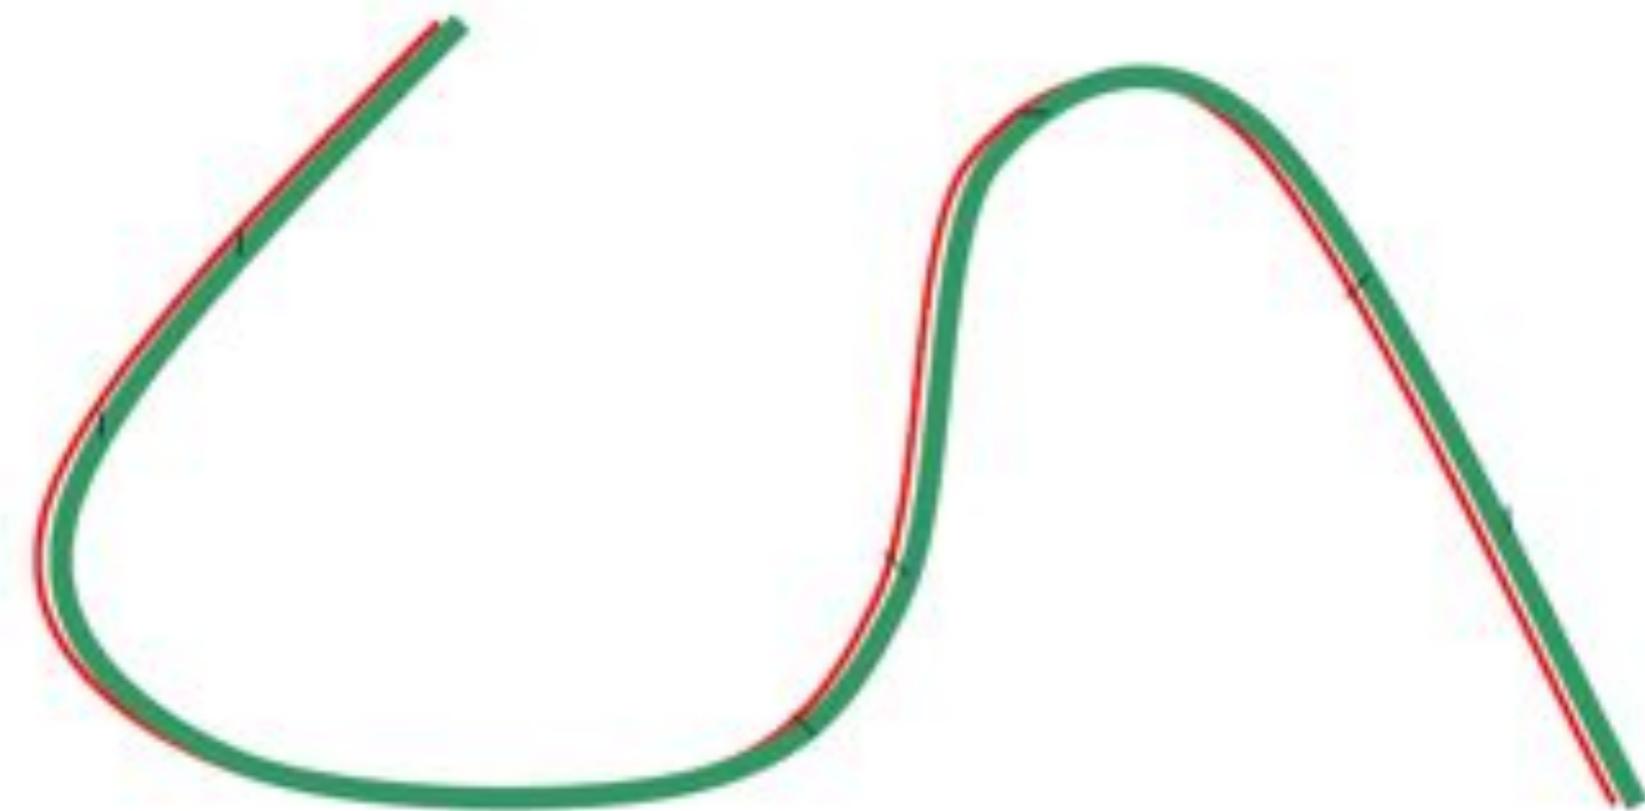
- En pratique, si détection automatique, primitives non-étiquetées
- On a extrait des primitives dans chaque image et on pense qu'elles correspondent aux mêmes structures anatomiques
- Mais, on ne sait pas quelle primitive dans  $J$  correspond à la  $k$ -ième primitive dans  $I$
- Différentes méthodes possibles :
  - Algorithmes de type prédiction-vérification
  - minimisation d'une carte de distances
  - Algorithmes basées sur des correspondances floues
  - Algorithmes ICP (Iterative closest point)

# ICP - Besl et McKay 1992

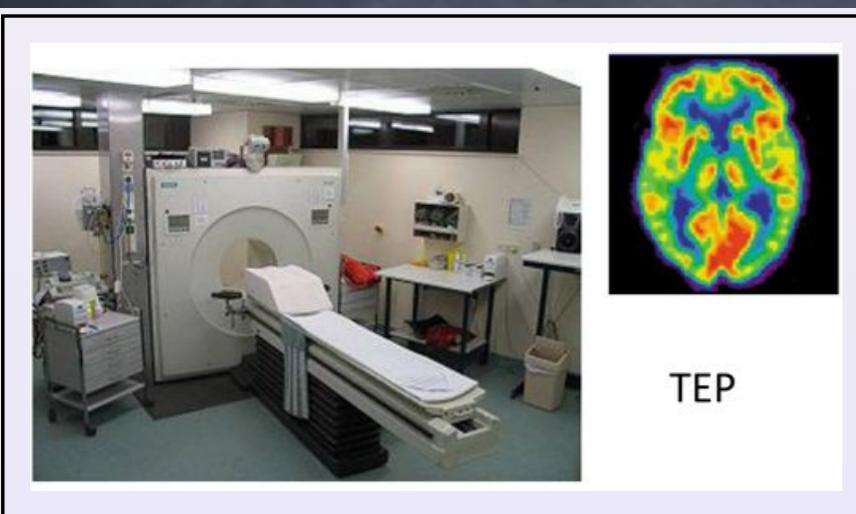
- Étant donné 2 nuages de points  $x^k$  et  $y^k$
- On cherche à les mettre en correspondance **et** à trouver la transformation spatiale correspondante
- On procède itérativement :
  - Association des points par les critères du plus proche voisin
  - Estimation des paramètres de transformation
  - Transformer les points en utilisant les paramètres estimés
  - Itération jusqu'à “convergence”

# ICP

2. Association de la points plan et écriture dans les poins



# Approches hybrides (géométrique et iconique)



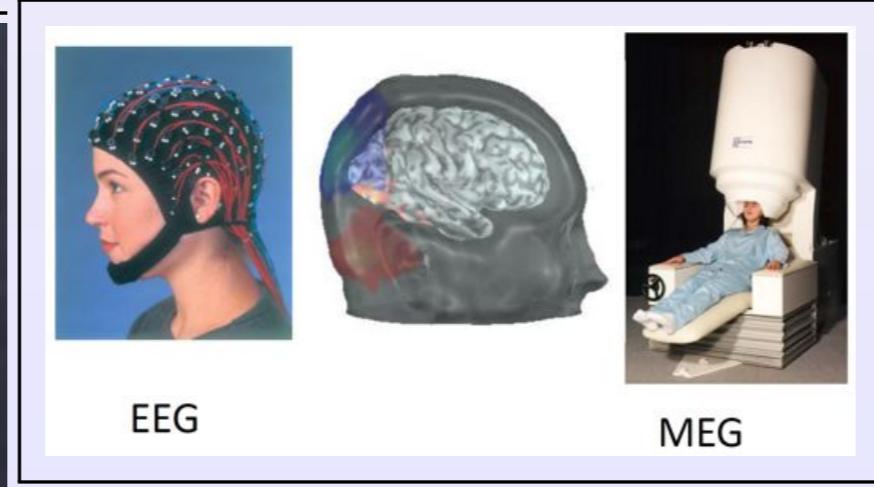
TEP



IRM



SPECT

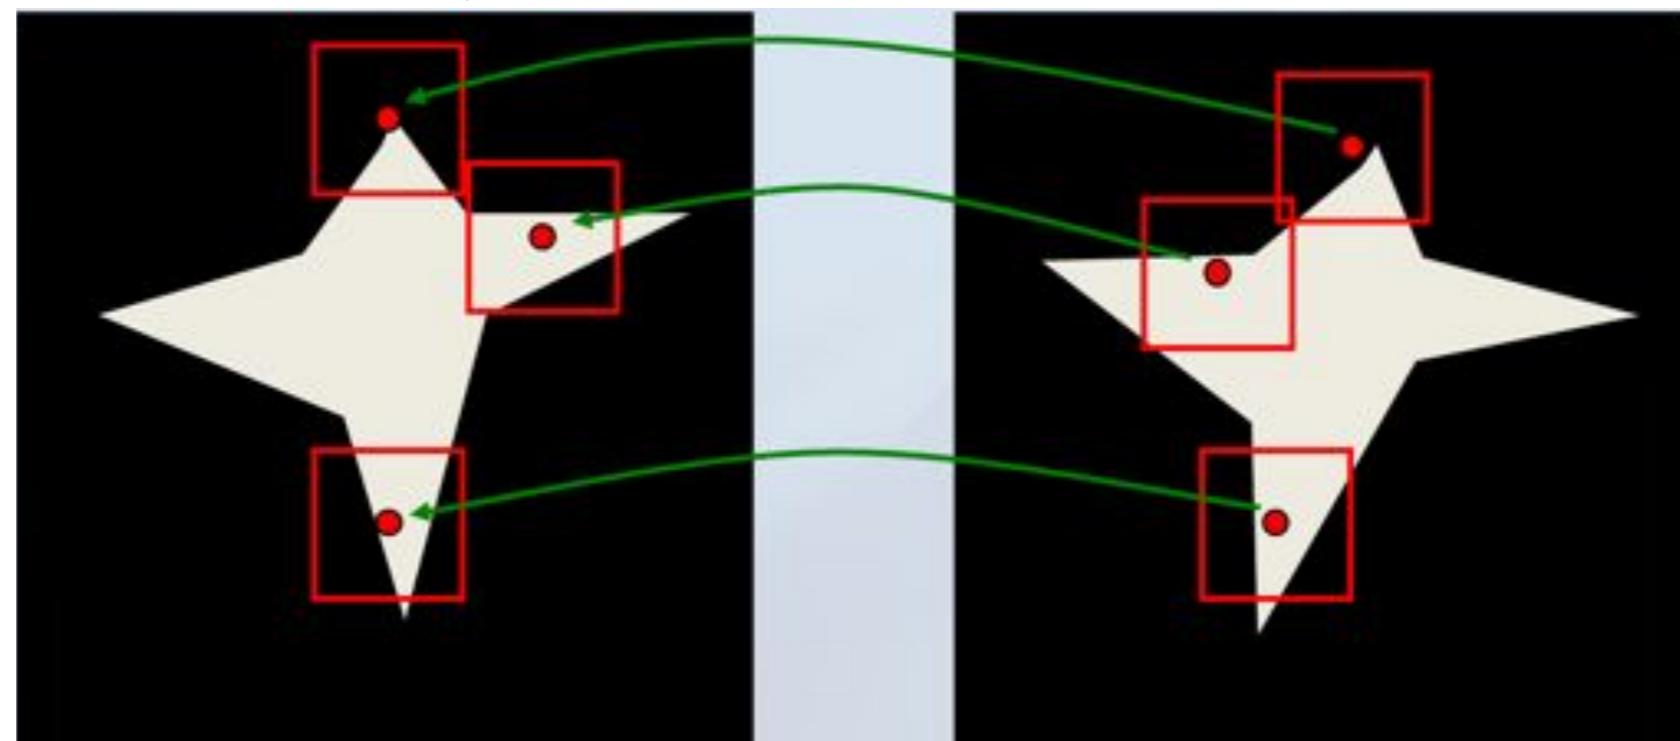


EEG

MEG

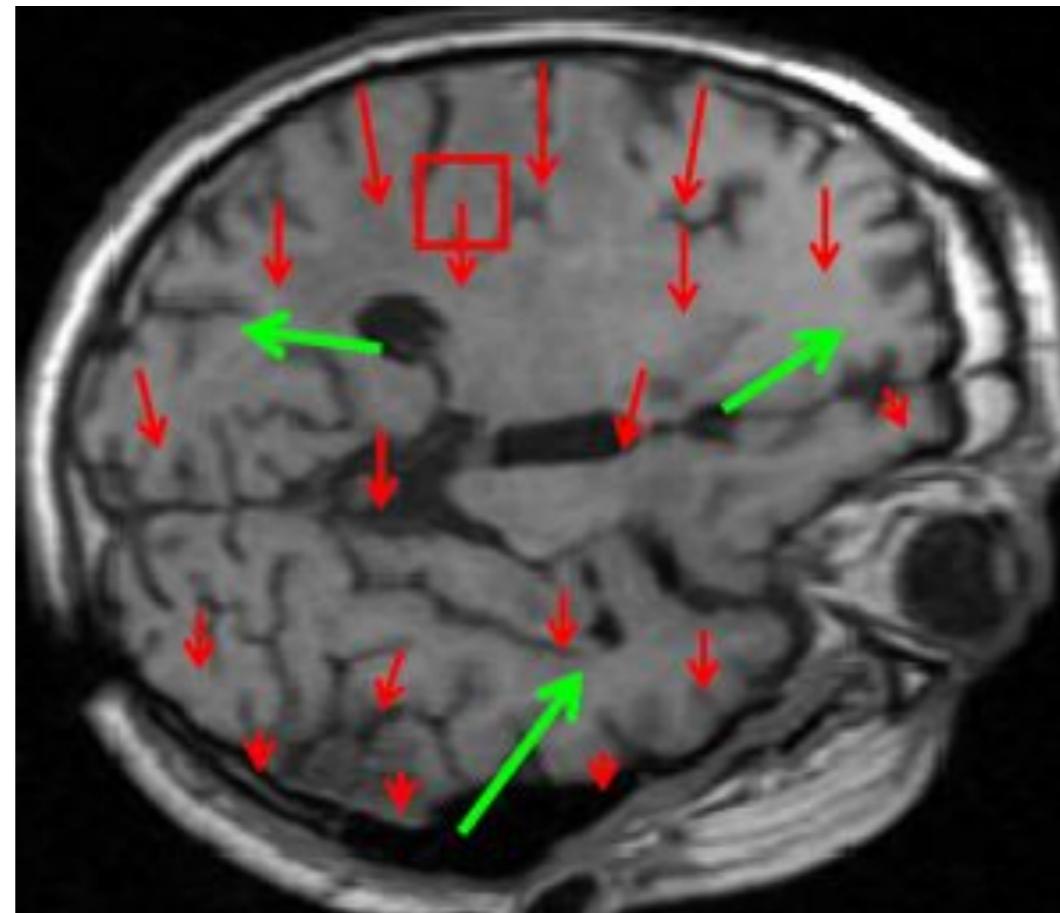
# Approches hybrides : bloc-matching

- On considère des sous-images (ou “blocs”) régulièrement échantillonnés
- On cherche dans l’autre image le bloc le “plus similaire”
- On obtient ainsi des appariements entre des images ou régions (et donc des points) avec éventuellement des outliers (des données aberrantes)



# Approches hybrides : block-matching

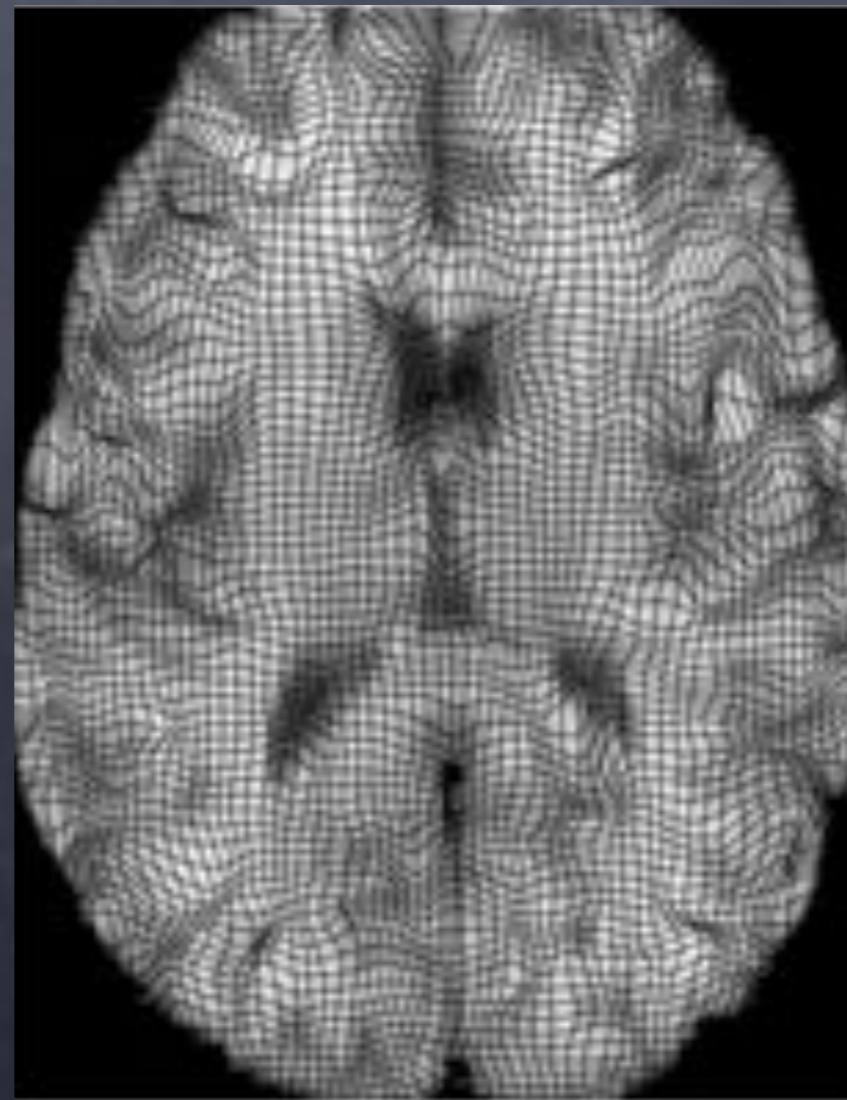
- Pour obtenir ce bloc le “plus similaire” on choisit un critère similarité (SSD souvent), coeff. de corr. ou info. mutuelle (approche iconique)
- On obtient ensuite un appariement entre les blocs:



# Approches hybrides : block-matching

4. On cherche finalement la transformation qui apparie au mieux ces blocs : souvent par moindres carrés (approche géométrique)
5. On itère comme pour l'ICP ou autre méthode de type simplex

# Les transformations non-linéaires



# Transformations non-linéaires

- Pourquoi?
- Intra-sujet multi-modalité
- Inter-patient
- Sujet - atlas
- Intra-patient dans le temps (changements anatomiques, évolution de la maladie, tumeur, autres)



Source

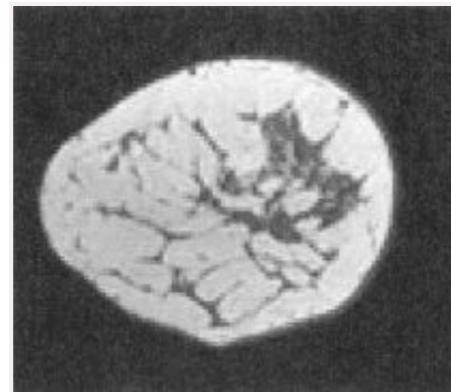


Cible



Source-Cible

# Recalage inter-patient de mammographies en IRM



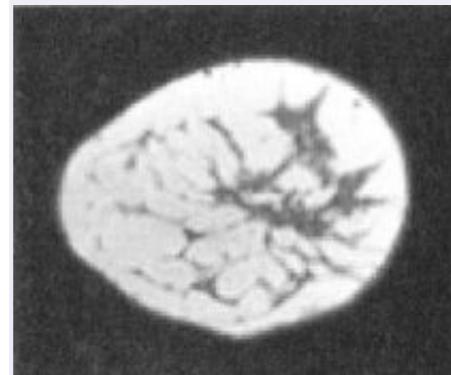
Source



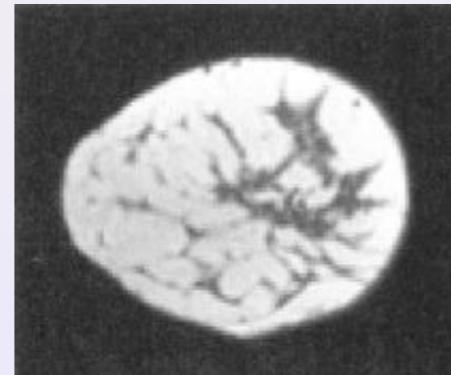
Cible



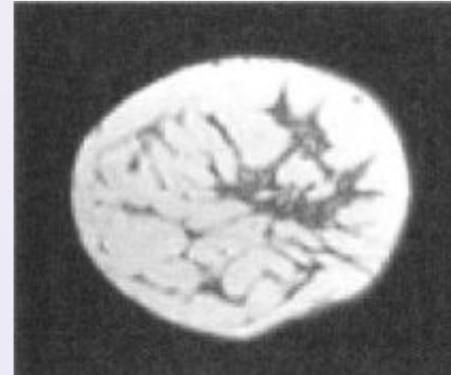
Source-Cible



Rigide



Affine



Non linéaire



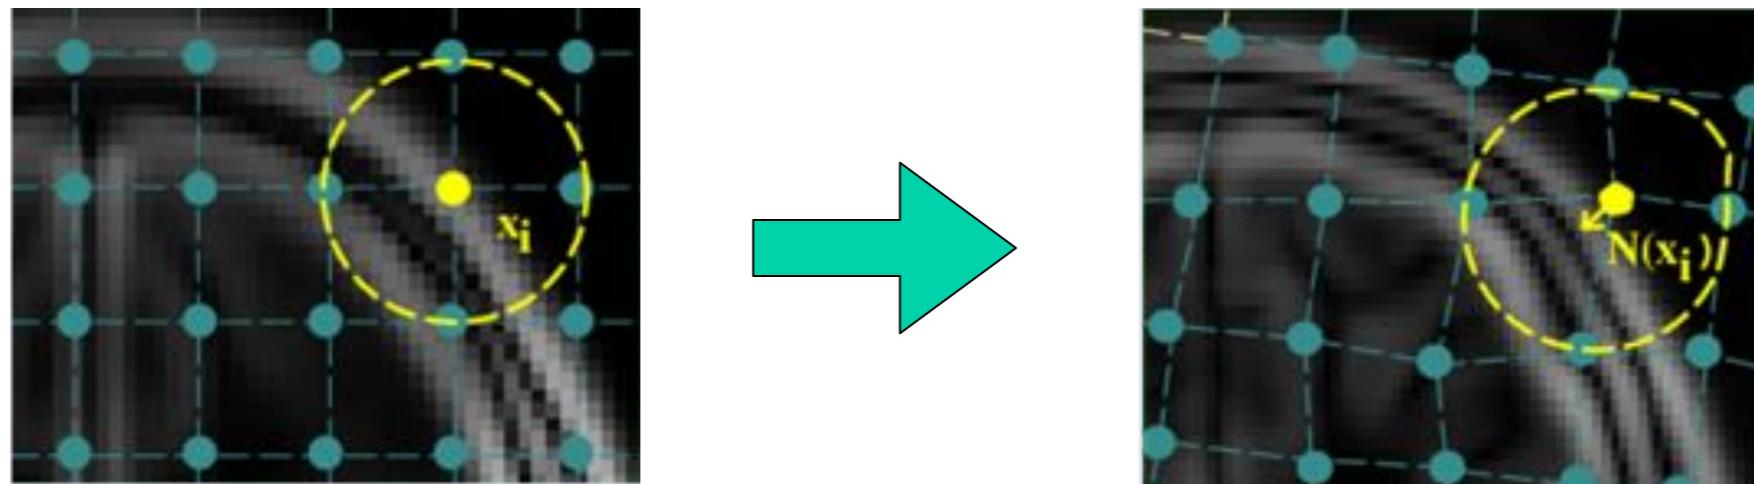
# Transformations non linéaires

- Les trans. linéaires ne permettent pas de modéliser convenablement les déformations complexes d'un ensemble de tissus ou les distorsions géométriques inhérentes à certaines modalités d'acquisition (e.g. IRM T1 et IRMd - démo)
- Deux catégories de transformations non linéaires:
  - Transformations locales paramétriques
  - Transformations locales non-paramétriques  
(aussi appelées transformations denses)

# Transformations locales paramétriques

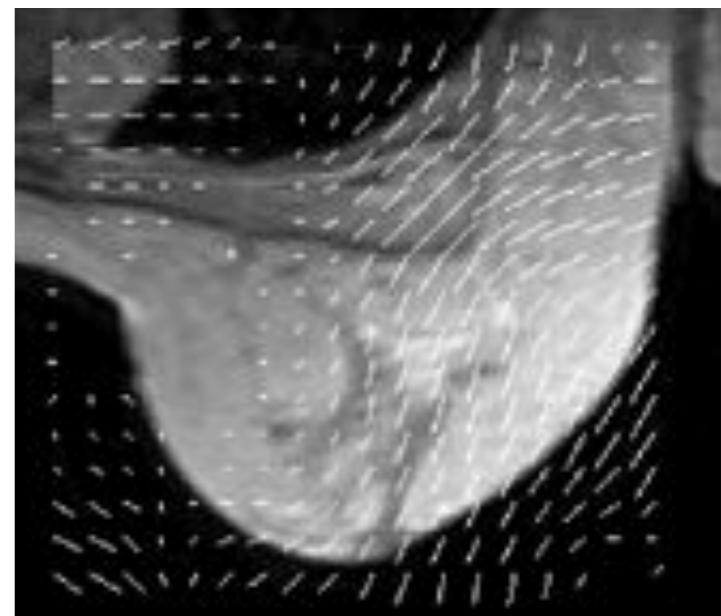
$$T(\mathbf{x}) = A\mathbf{x} + t + \sum_{p=1}^P \mathbf{c}_p G(\mathbf{x} - \mathbf{x}_p)$$

- Les  $x_p$  sont des points de contrôles
- $G$  : produit tensoriel de fonctions  $B$ -splines ou autres fonctions à base radiale telle
- Nombre de degrés de liberté contrôlable ( $x_p$ ), trans. définie explicitement sur des points de contrôle et interpolation entre ces points de contrôle



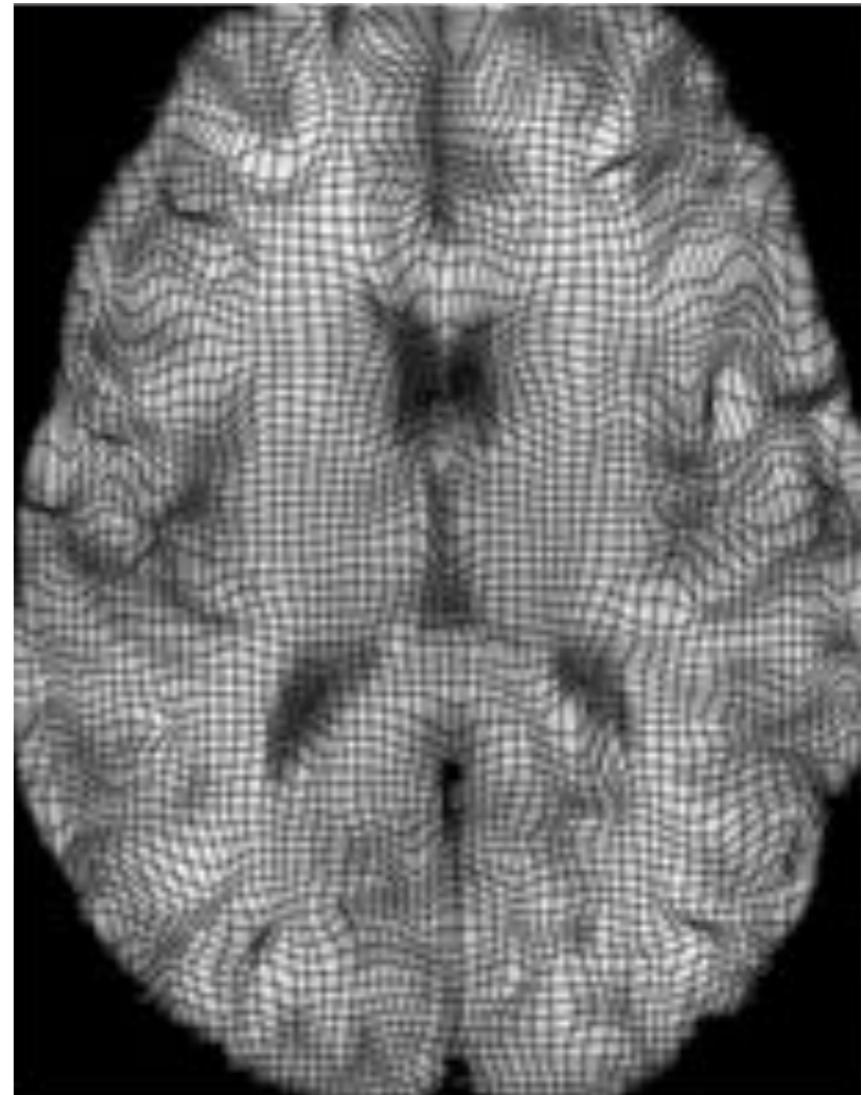
# Transformations locales paramétriques

- Comment choisir des bons points de contrôle
- À la main
- Points régulièrement espacés. Hayton et al 1999 (mammographies)
- Paramètres additionnels de la mesure de similarité qui sont repositionnés itérativement. Meyer et al 1998.
- Gradients, formes, autres.
  - Points SIFT (détailé plus tard)



# Transformations denses

- Principe
  - Un vecteur de déplacement par pixel/voxel
  - $\mathbf{x}' = \mathbf{T}(\mathbf{x}) = \mathbf{x} + \mathbf{u}(\mathbf{x})$
- Nombre de paramètres?
  - $3N$ ,  $N$  est le nombre de pixels/voxels
- Doit restreindre le choix de transformation
  - Inversible (difféomorphisme)
  - Lisse (régularisation)



# Transformation dense

- On suppose qu'on a choisi un critère de similarité,  $S$ , à *minimiser*
- On ajoute à cette mesure un terme indépendant des images dont le rôle est de pénaliser les trans. trop irrégulières
- Comment régulariser?
  - Théorie de l'approximation de Tikhonov
- L'énergie à minimiser fait intervenir deux termes:

$$\hat{T} = \arg \min_T [S(T) + \lambda U(T)]$$

lambda contrôle la régularisation et  $U(T)$  est souvent appelé le terme “stabilisateur”

# Transformations denses

- Autres contraintes?
- Inversibilité
  - Imposer le calcul d'un difféomorphisme
  - Limiter l'amplitude des déplacements
- Symétrie : s'assurer que l'algorithme donne les mêmes résultats si on envoie I sur J ou le contraire, J sur I
- Prise en compte de points d'intérêts dans les images
  - Contours, lignes sulcales (sillons), amers connus, etc.

# Techniques d'optimisation non linéaires

- Approche géométrique : plutôt en linéaire (moindre carré)
- Approche iconique avec petit nombre de paramètres : transformation rigide (descente du gradient à pas non-fixe)
- En non-linéaire (beaucoup d'inconnues), besoin de techniques d'optimisation plus complexes:
  - **Démons difféomorphes - ANTS. L'approche qui semble, en 2014, donner les meilleurs résultats**
  - Free form deformations
  - Recalage localement affine
  - ... Domaine de recherche actif

# ANTS : un outil puissant

- Lisez la doc ants.pdf en-ligne

Category	Transformation, $\phi$	Similarity Measures	Brief Description
Linear	Rigid <sup>†</sup>	MI, MSQ	Rigid registration.
	Affine <sup>†</sup>	MI, MSQ	Affine registration.
Elastic	Deformable	CC, PR, MI, MSQ, PSE	Demons-like algorithm.
	DMFFD	CC, PR, MI, MSQ, PSE	FFD variant.
Diffeo.	Exponential <sup>†</sup>	CC, PR, MI, MSQ, PSE	$\min v(\mathbf{x})$
	Greedy SyN <sup>†</sup>	CC, PR, MI, MSQ, PSE	locally in time $\min v(\mathbf{x}, t)$
	Geodesic SyN <sup>†</sup>	CC, PR, MI, MSQ, PSE	$\min v(\mathbf{x}, t)$ over all time

Table 1: Transformations and a subset of the similarity metrics available in ANTS. Similarity metric acronyms: CC = fast cross correlation (the preferred metric), PR = cross correlation (deprecated), MSQ = mean squared difference, MI = mutual information, PSE = point-set expectation [25]. ANTS also provides the inverse of those transformations denoted by the ‘ $\dagger$ ’ symbol. The brief descriptions of the diffeomorphic algorithms contrast the way in which the velocity field is optimized and used to parameterize  $\phi$ , the mapping. All ANTS Diff algorithms generate  $\phi(\mathbf{x}, t)$  over  $t \in [0, 1]$  through gradient descent.

## Transformation Model

$$\int_0^1 \langle Lv(x, t), v(x, t) \rangle dt$$

## Appearance/Similarity Metrics

$$+ w_1 SSD(I, J) + w_2 MI(I, J) + w_3 \sum_i LM_i(I, J)$$

Diffeomorphic Regularization

Intensity Difference

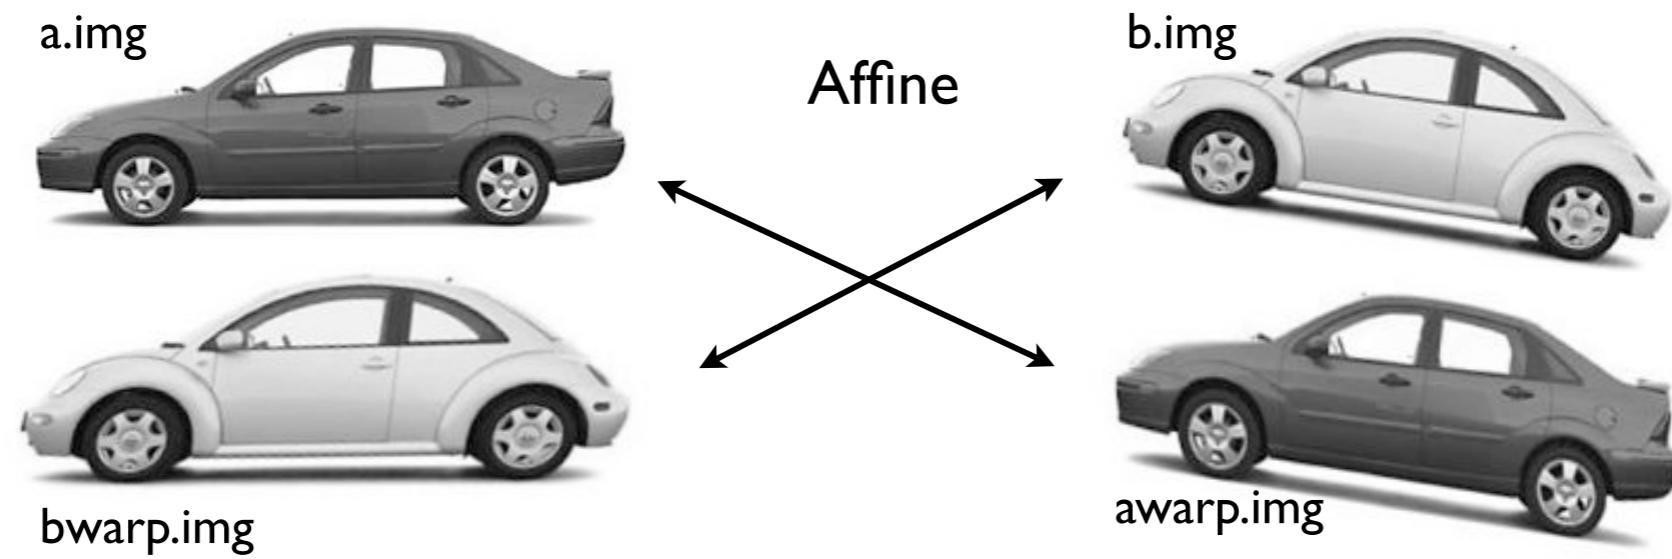
Mutual information

Landmark Guidance

ANTs -t Syn[0.5] -m MSQ(I,J,w1,0) -m MI(I,J,w2,#bins) -m PSE(I,J,w3)

Note: the choice of  $L$  above relates to the  $-r$  (regularization) parameter in ANTS, which would be part of the blue above.

## Affine Registration with ANTS



“fixed” image

“moving” image

ANTS 2 -m MI[a.img,b.img,1,32] -i 0 -o ab.nii

WarplImageMultiTransform 2 b.img b warp.img abAffine.txt -R a.img

WarplImageMultiTransform 2 a.img a warp.img -R b.img -i abAffine.txt

**Outputs:** abAffine.txt

Note: the inverse affine map transforms “fixed” to “moving” space



Affine



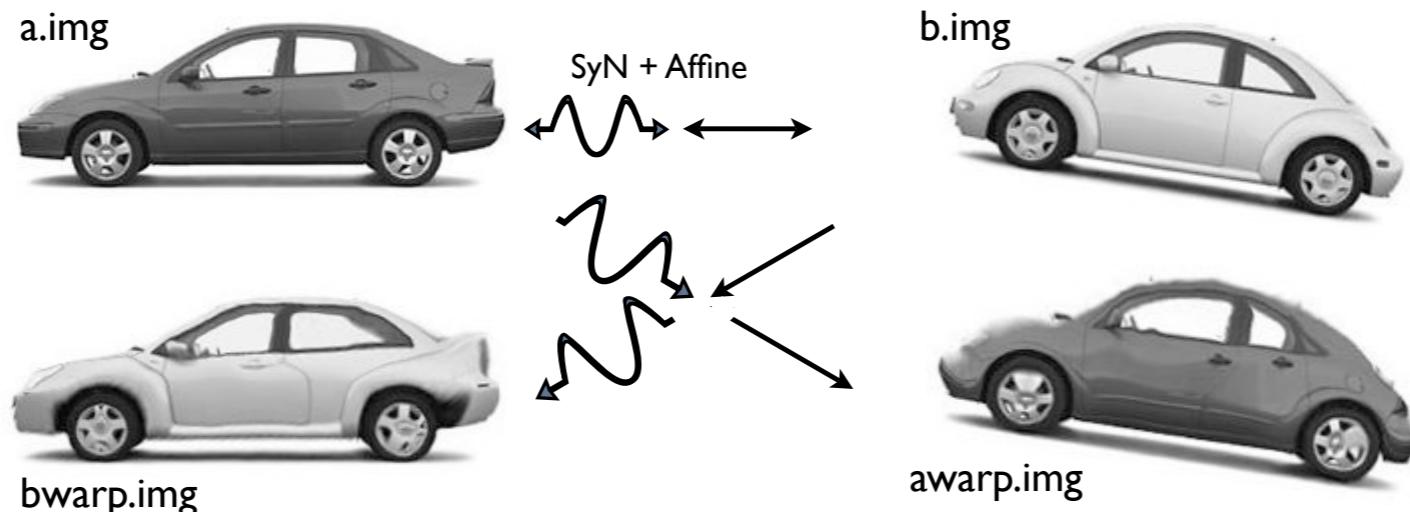
Elastic



Diffeomorphic

### Symmetric Diffeomorphic Mapping with ANTS

Affine+ Diffeomorphic SyN



```
ANTS 2 -m PR[a.img,b.img,l,2] -i 100x100x10 -o ab.nii -t SyN[0.25] -r Gauss[3,0]
```

```
WarplImageMultiTransform 2 b.img bwarp.img -R a.img abWarp.nii abAffine.txt  
WarplImageMultiTransform 2 a.img awarp.img -R b.img -i abAffine.txt abInverseWarp.nii
```

**Outputs:** abAffine.txt (invertible and composable with the warps)

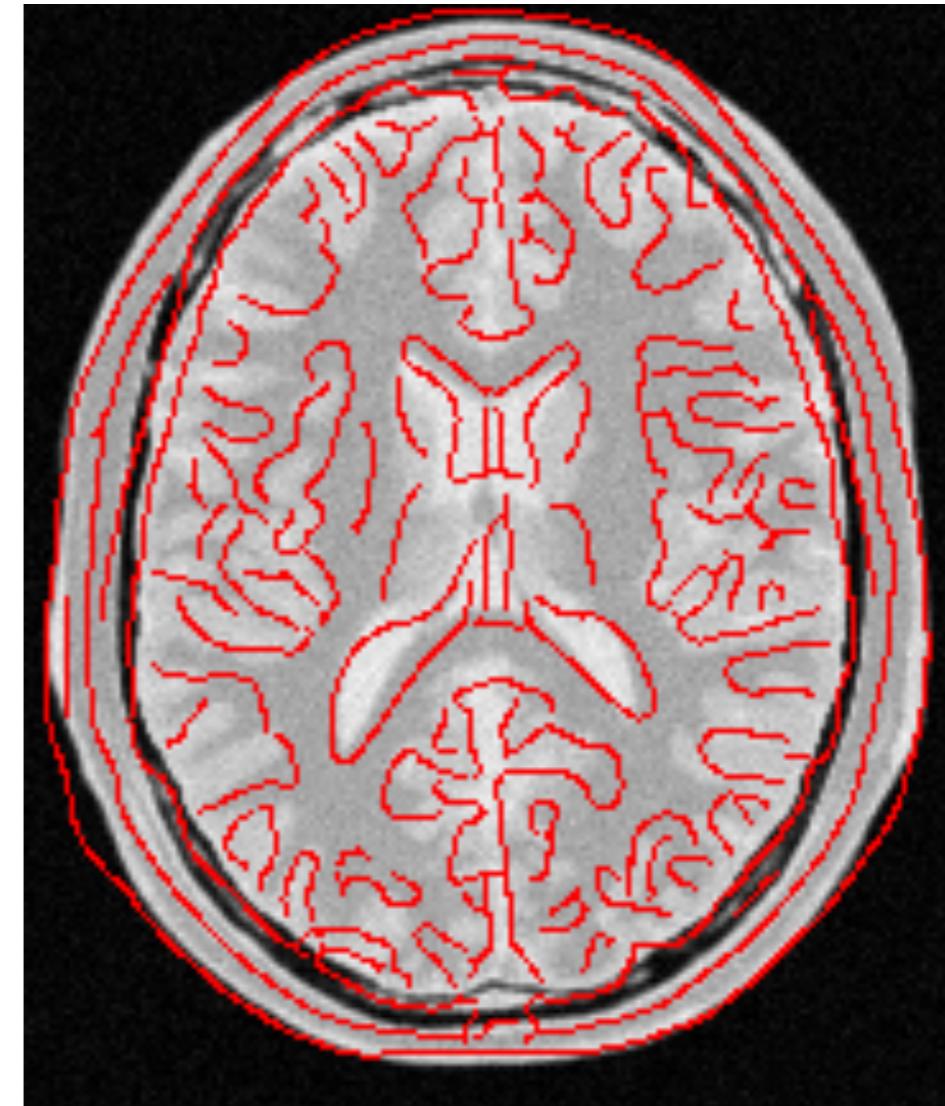
abWarp.nii => abWarpXvec.nii & abWarpYvec.nii

abInverseWarp.nii => abInverseWarpXvec.nii & abInverseWarpYvec.nii

## Exemple: fusion T1/DP inter-sujets

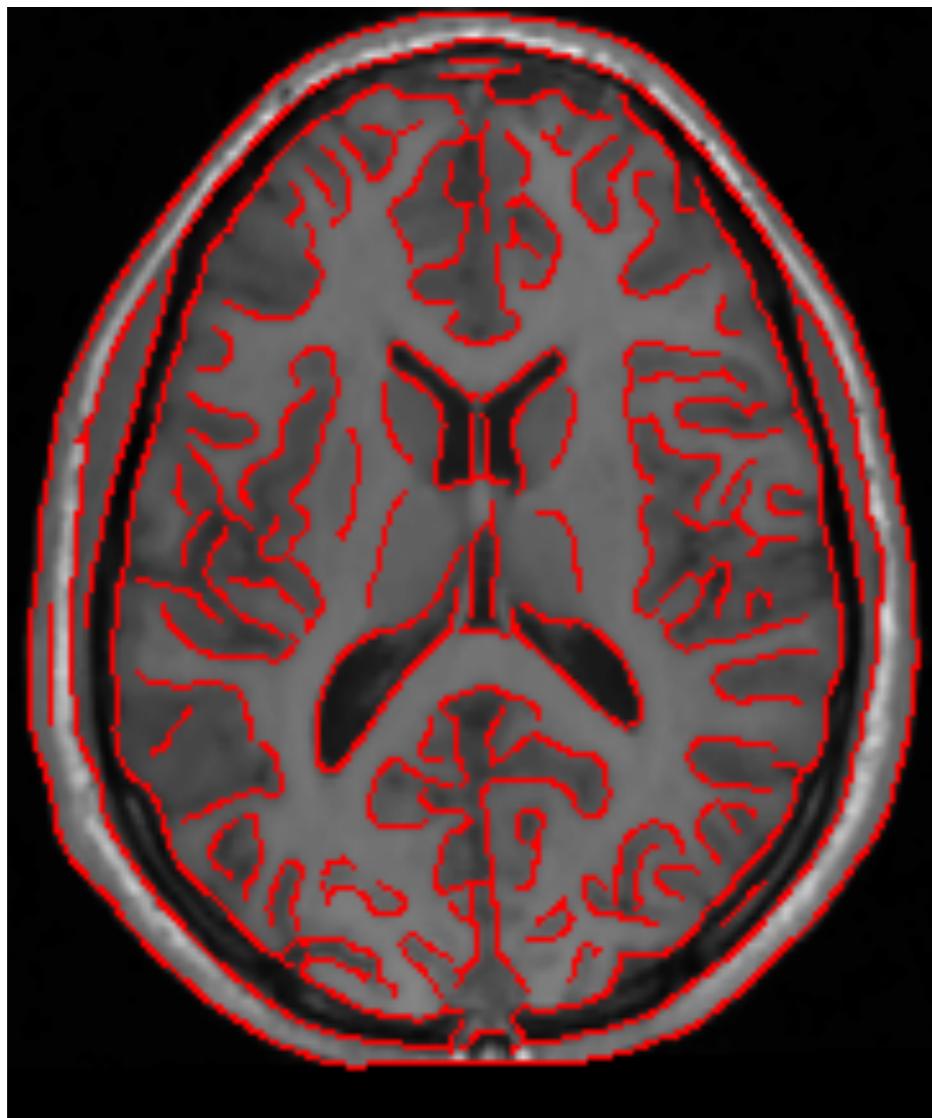


IRM-T1  
(après recalage affine)

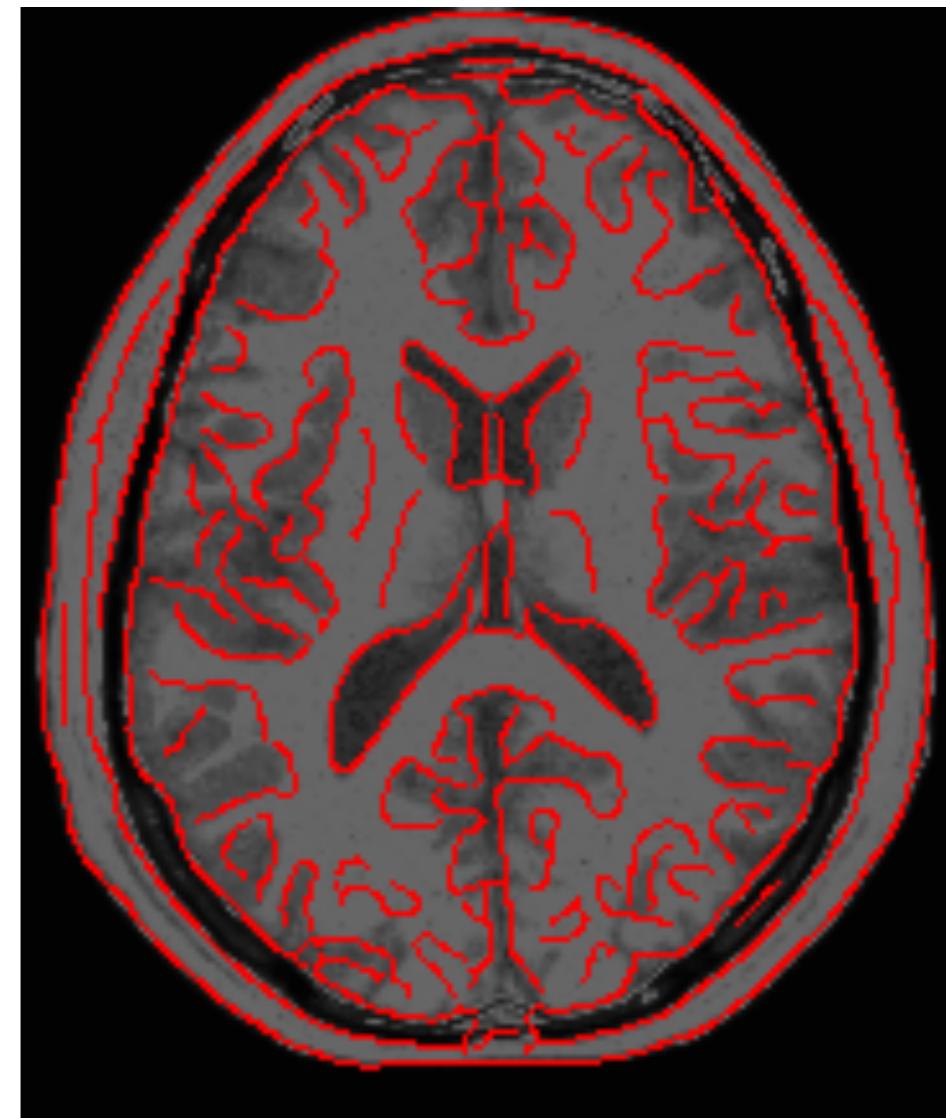


IRM-DP

# Fusion inter-sujets



T1

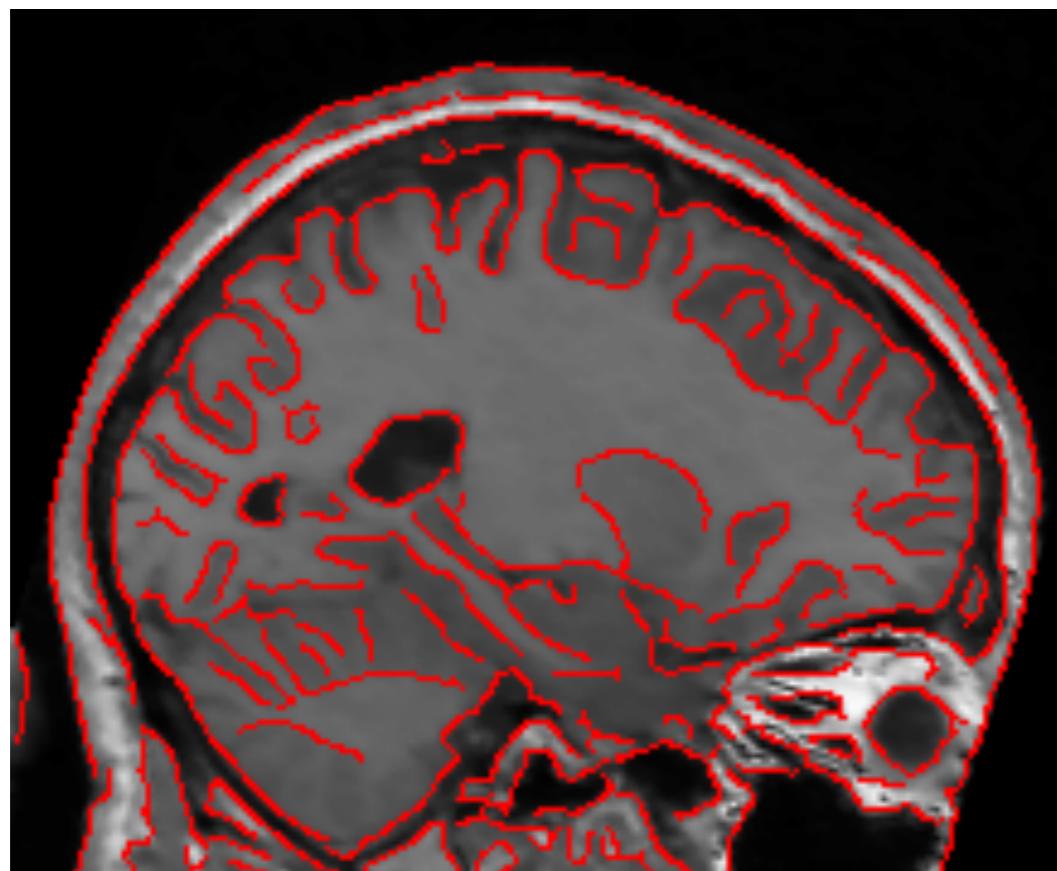


DP

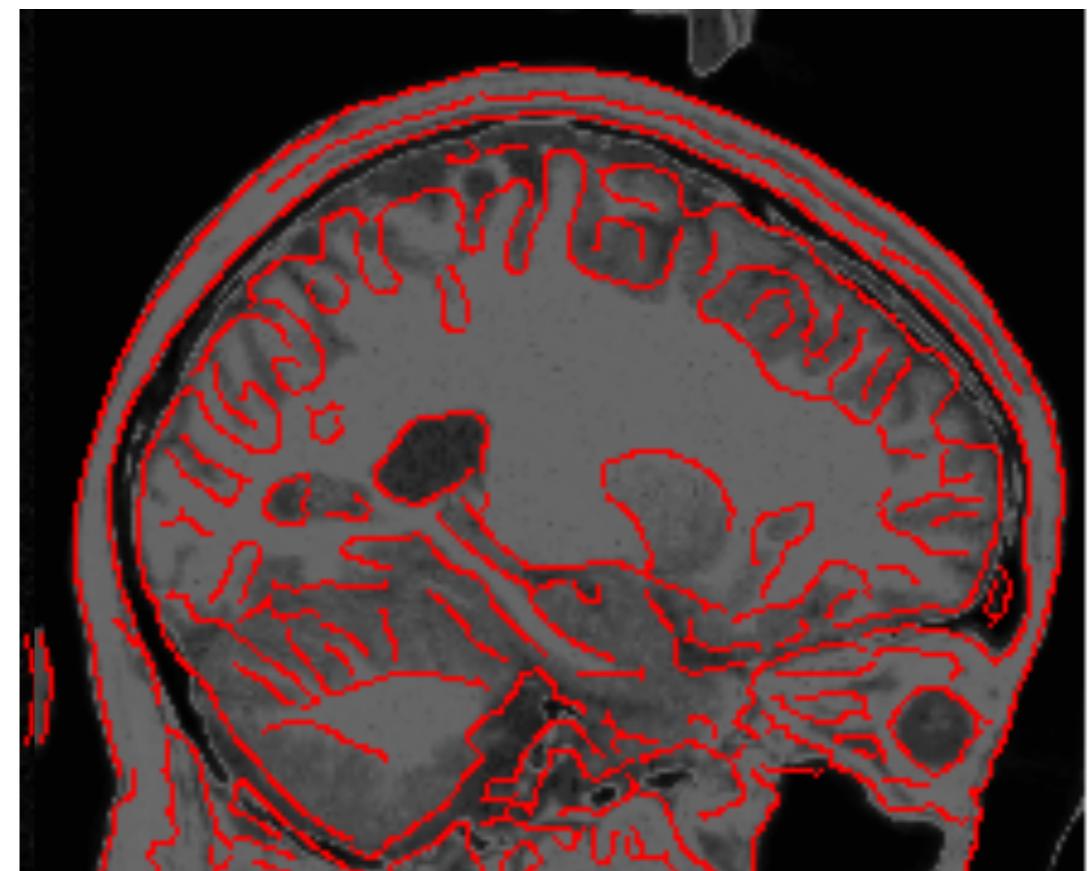
géométrie+ intensité

# Fusion inter-sujets

Vue sagitale



T1



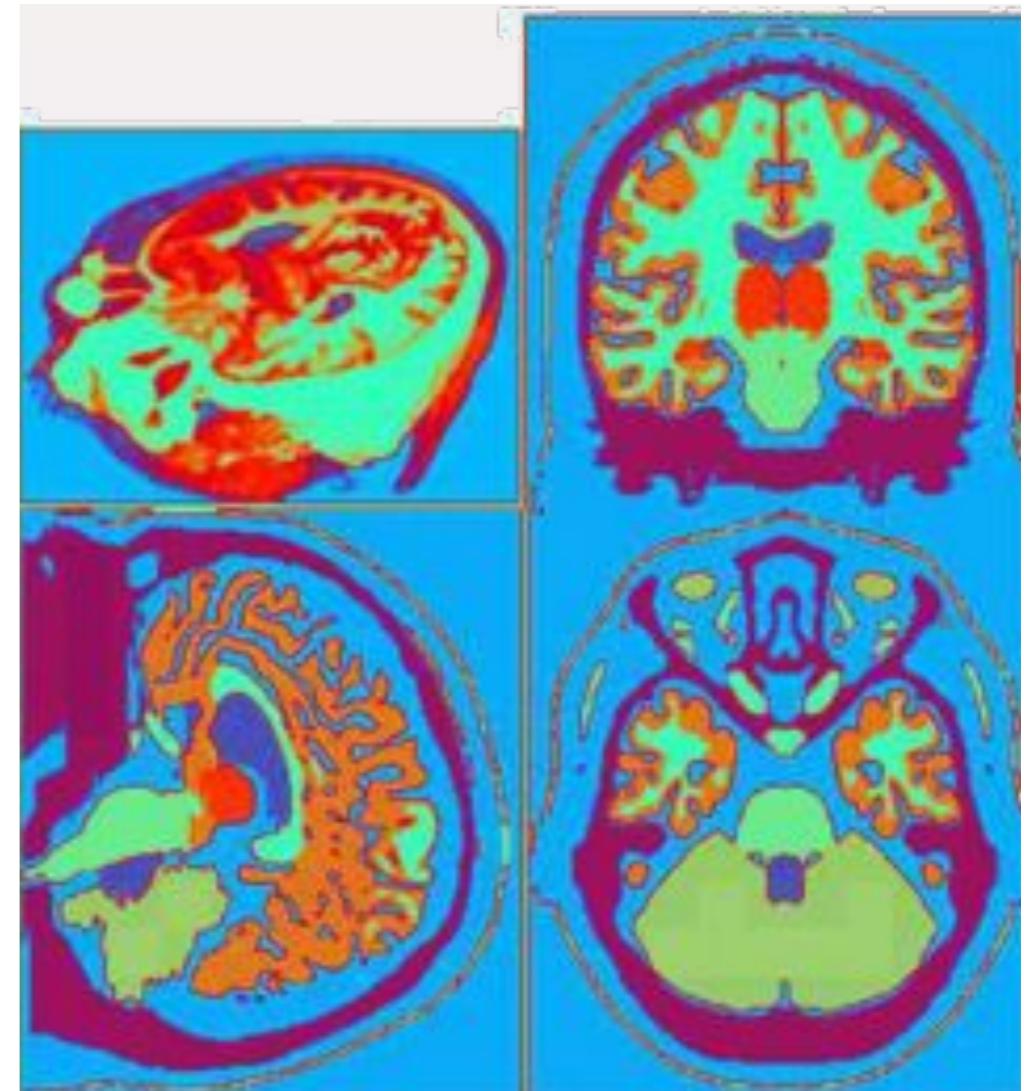
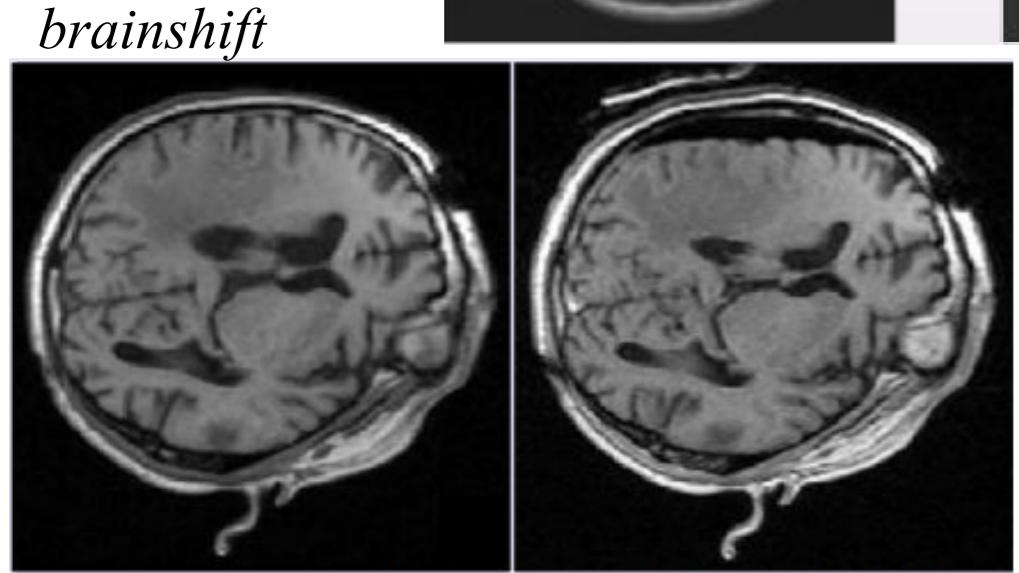
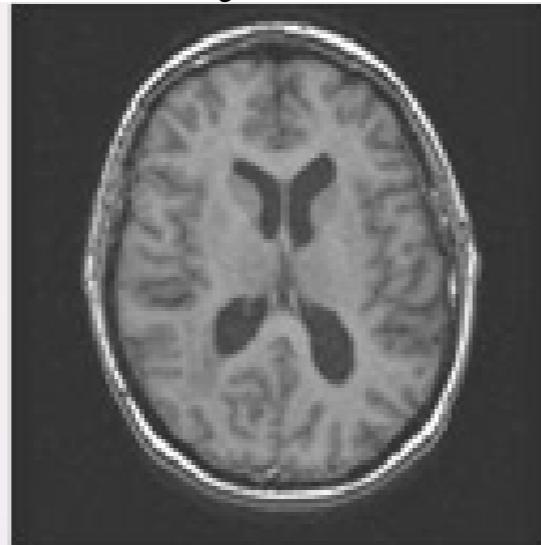
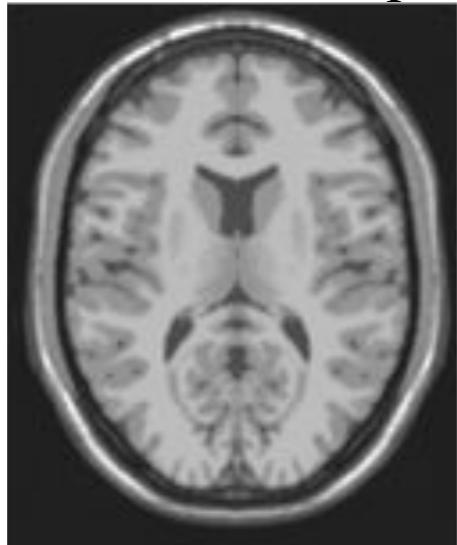
DP

géométrie+ intensité

# Transformations non linéaires - sommaire

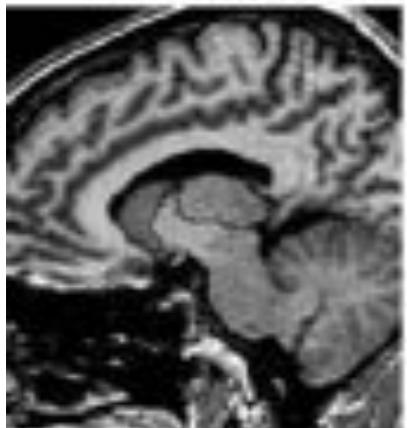
- Suivi longitudinal: tumeur, sclérose en plaque, développement, etc.

Comparaison inter-sujet

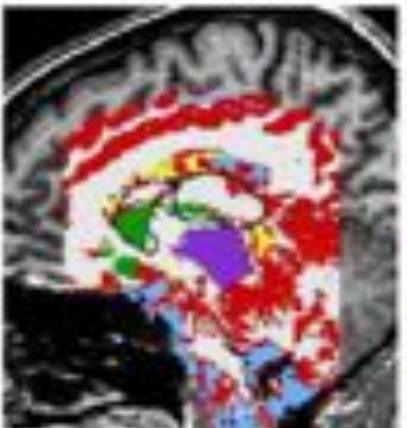


Atlas

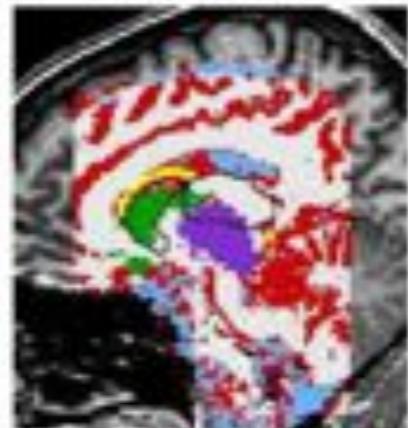
MR Image



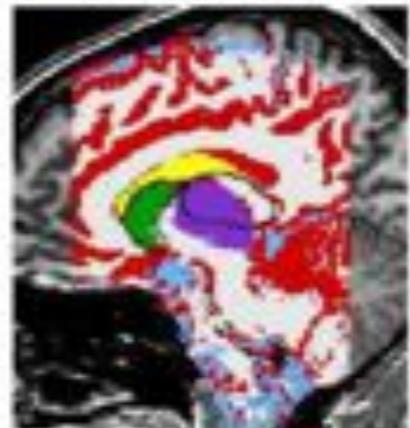
1 Iteration



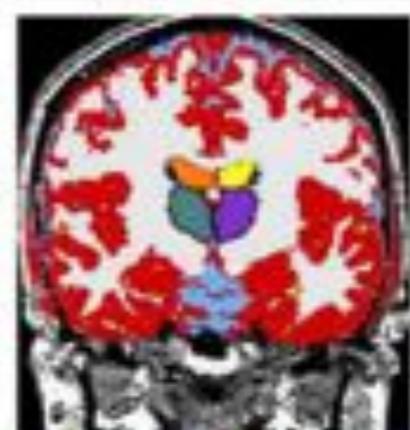
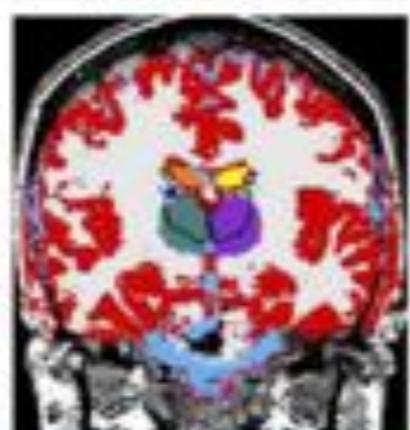
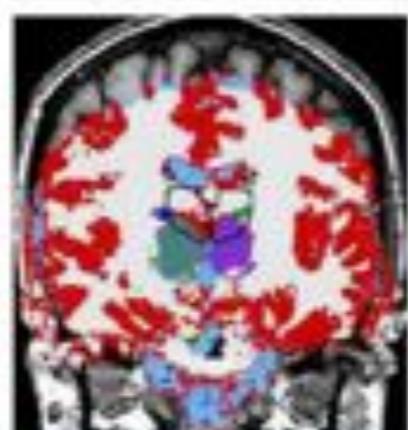
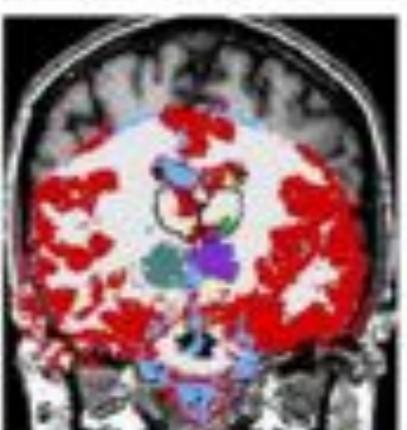
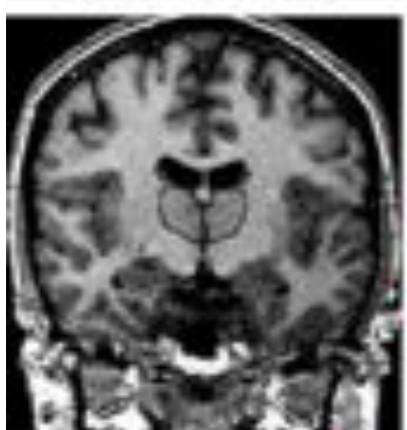
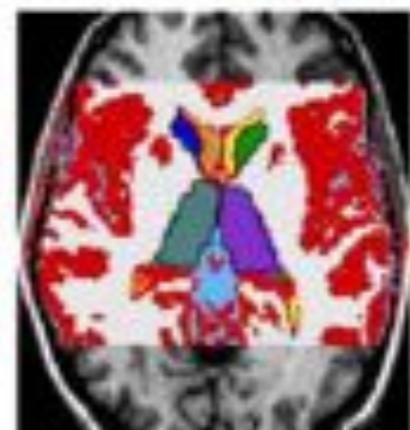
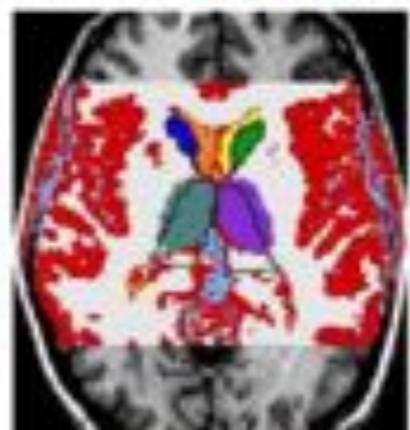
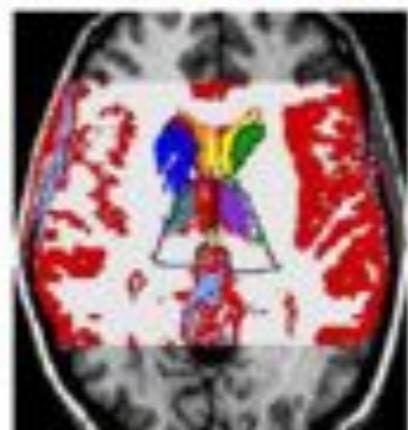
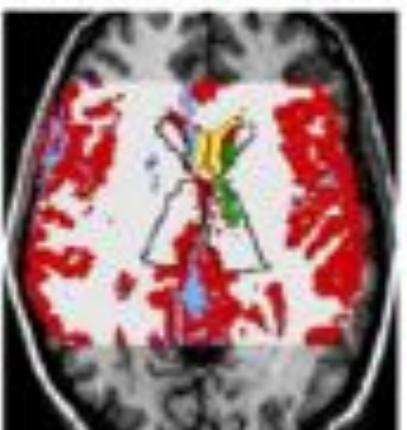
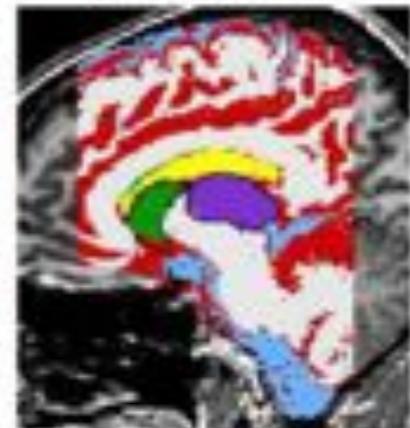
10 Iterations



30 Iterations



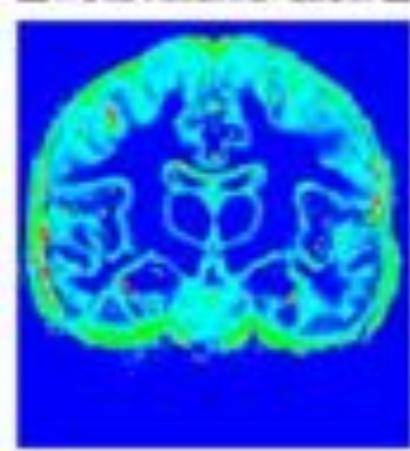
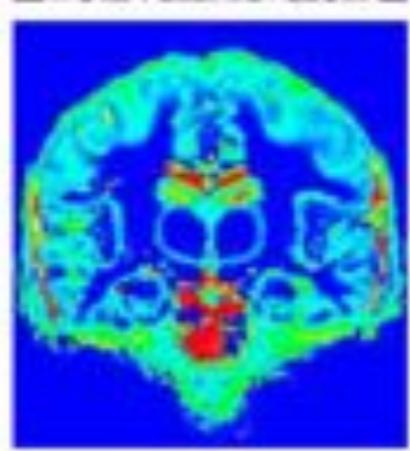
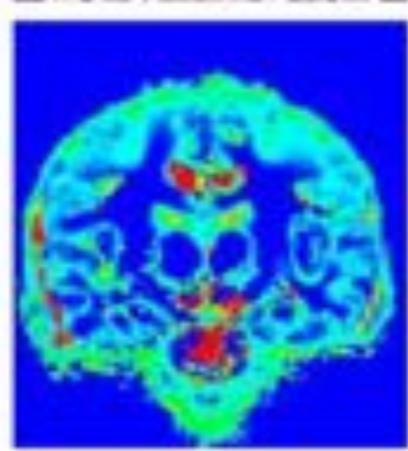
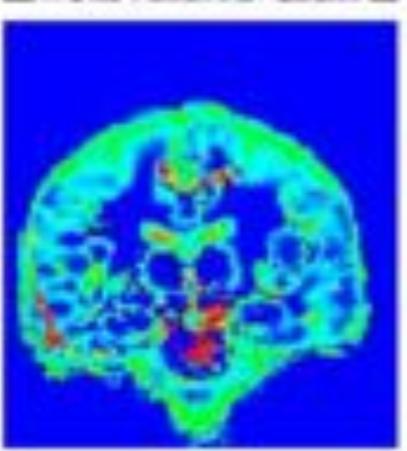
60 Iterations



Disagree

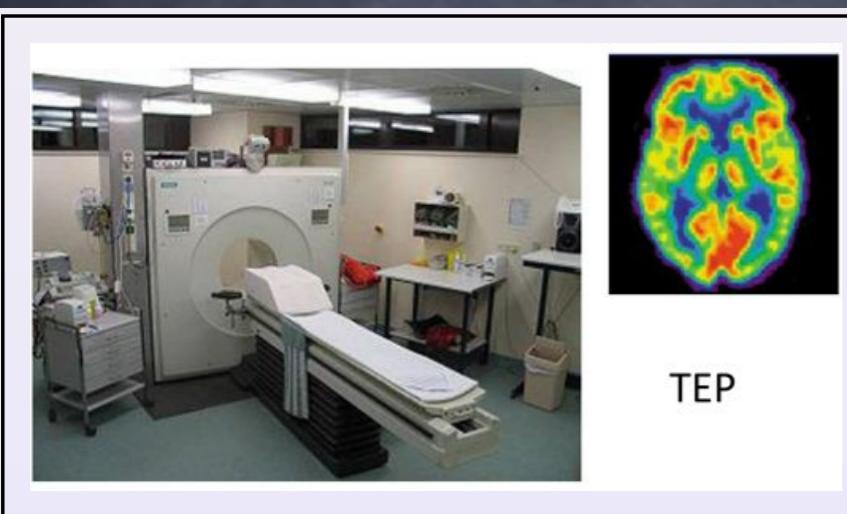


Agree



Iterative atlas-based  
brain segmentation, in  
conjunction with  
nonrigid registration.  
Kilian M. Pohl et al  
A Bayesian model for  
joint segmentation  
and registration  
NeuroImage, 2006

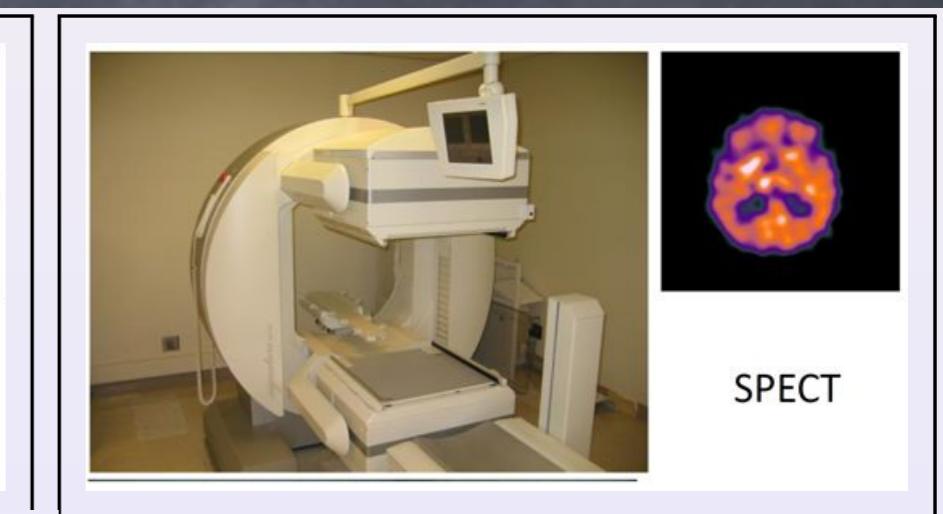
# Quelques exemples



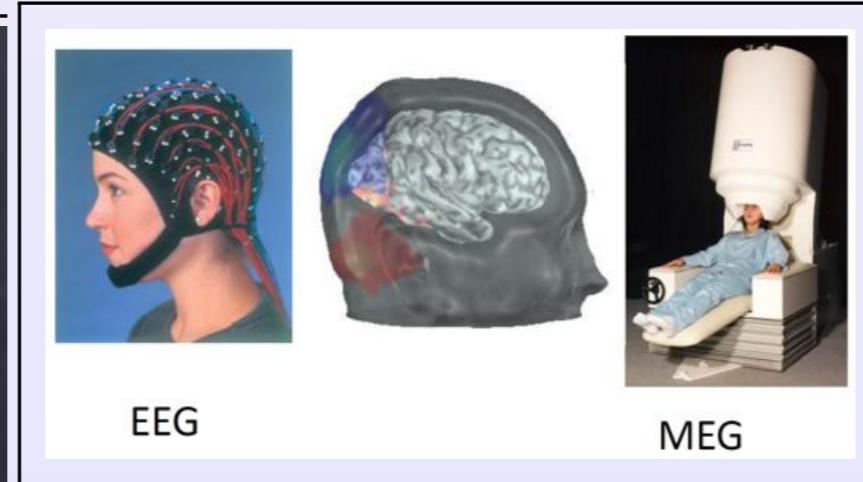
TEP



IRM



SPECT



EEG

MEG

# Quelques exemples

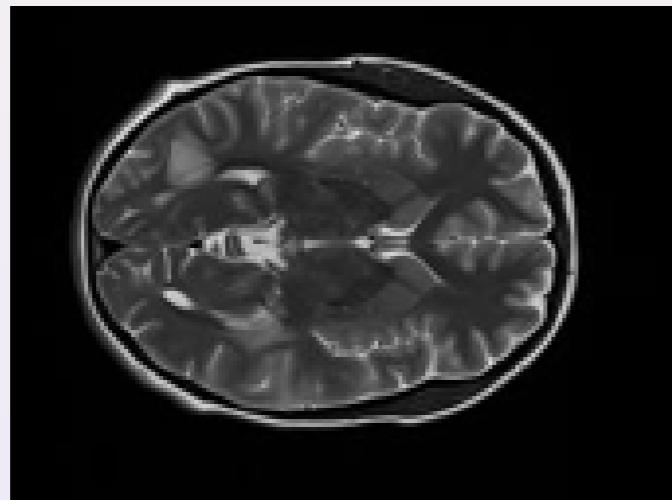
- Suivi longitudinal
- Correction de mouvements
- Multimodalité
  - Fusion IRM et IRM fonctionnelle
  - Fusion IRM et IRM de diffusion
- Recalage sur des atlas

# Intra-patient, intra-modalité

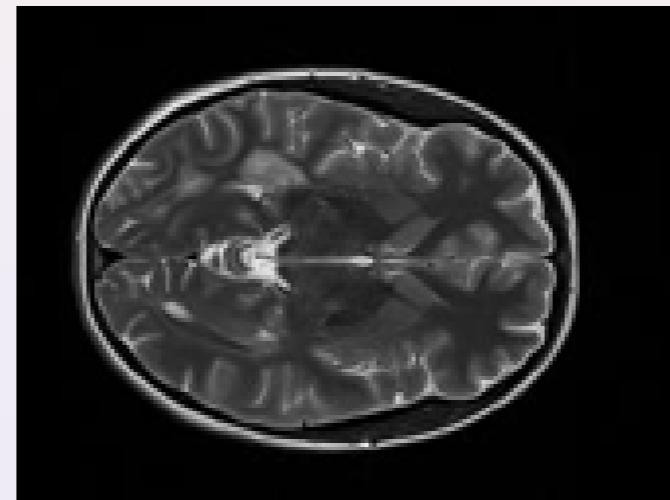
## Suivi longitudinal

- Exemple : évolution de lésions (images IRM-T2 d'un SEP à quelques mois d'intervalle)

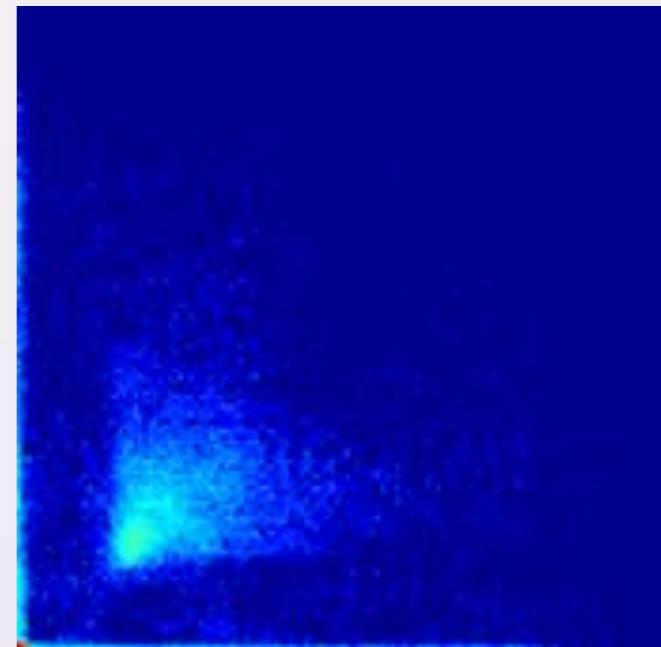
Cible  $T = 0$



Source  $T = 3$  mois



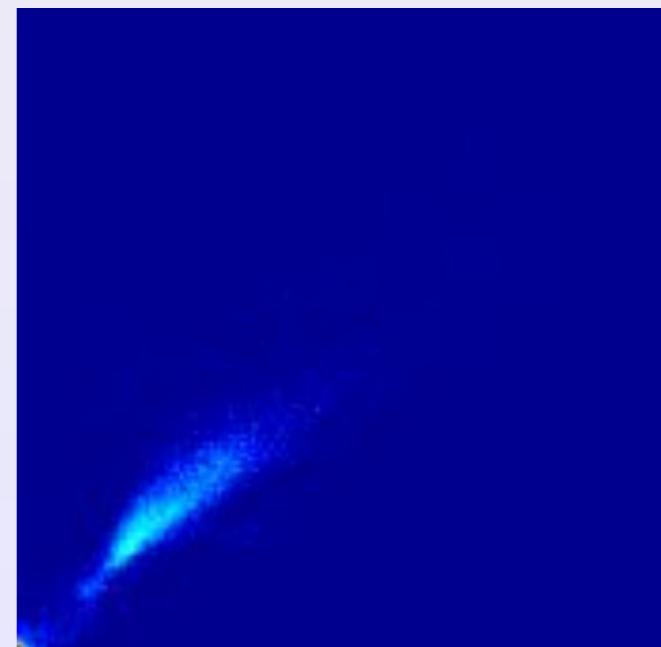
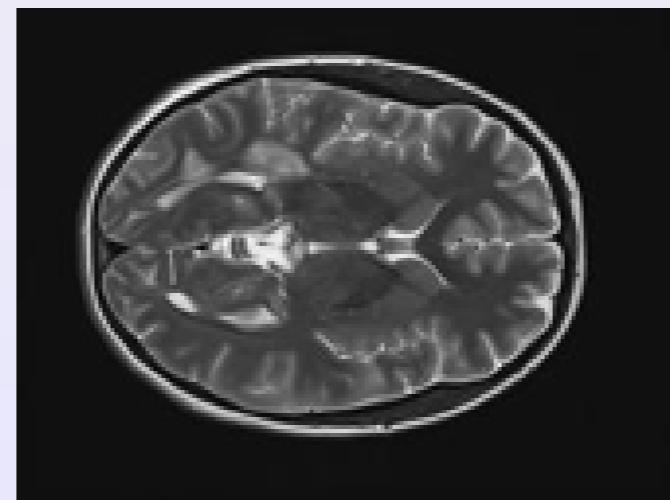
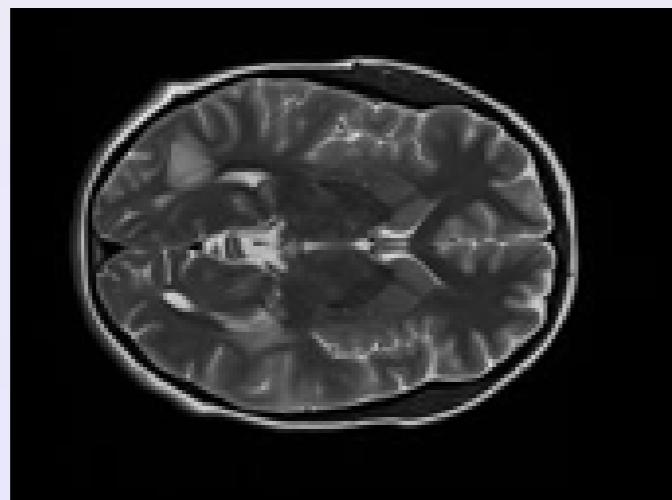
Histo joint



Init

Recalé

SSD , recalage rigide (3D)



# Correction du mouvement

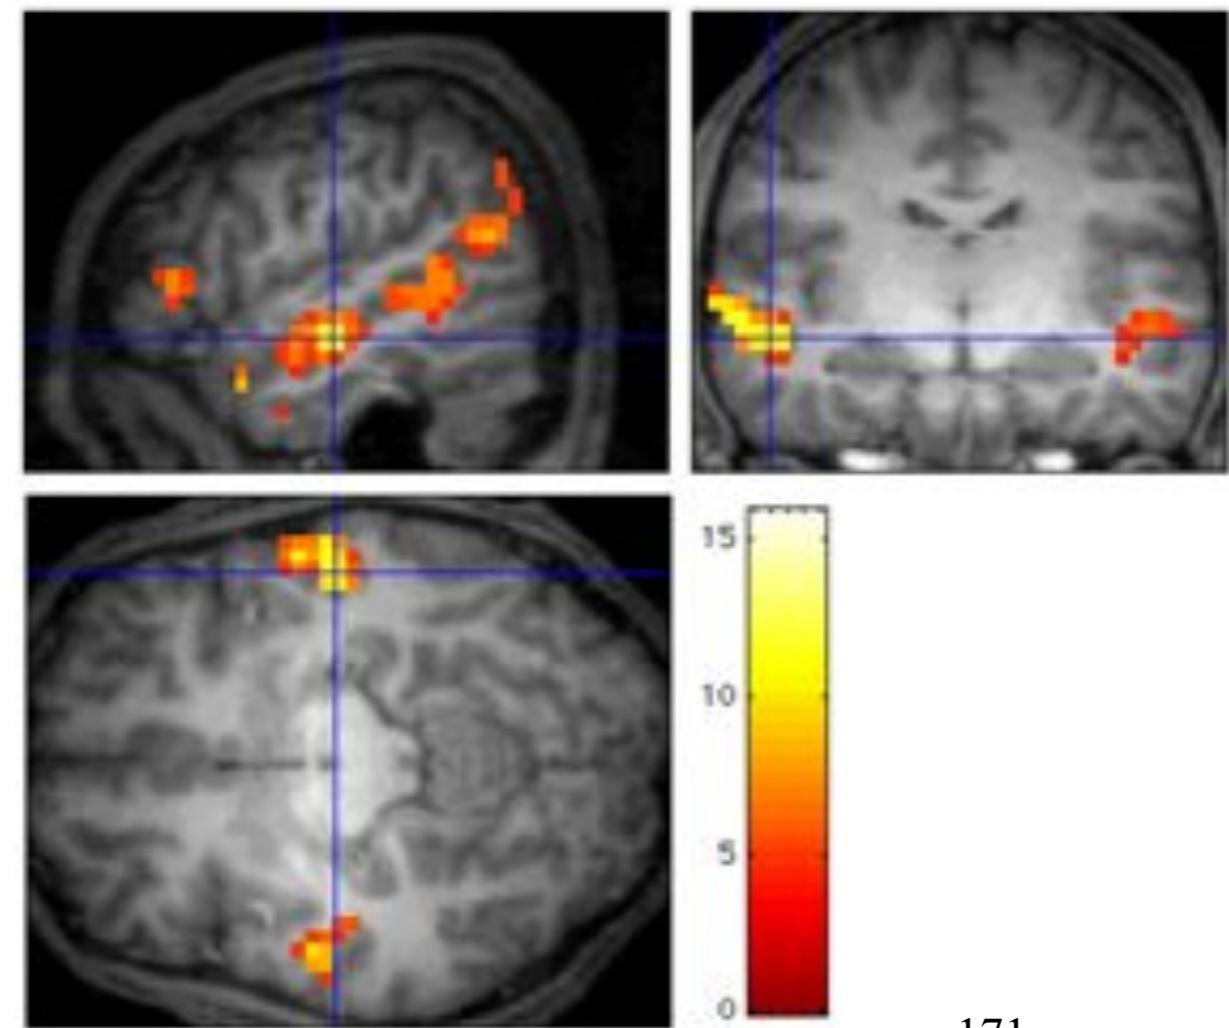
- Imagerie de diffusion. Intra-patient. Intra-modalité
- Comparer des images pour obtenir l'information souhaitée
- SSD, recalage rigide (*flirt* de FSL)

# IRM/IRM fonctionnelle

- Intra-patient. Multi-modalité.
- rapport de corrélation ou information mutuelle. (*flirt*)

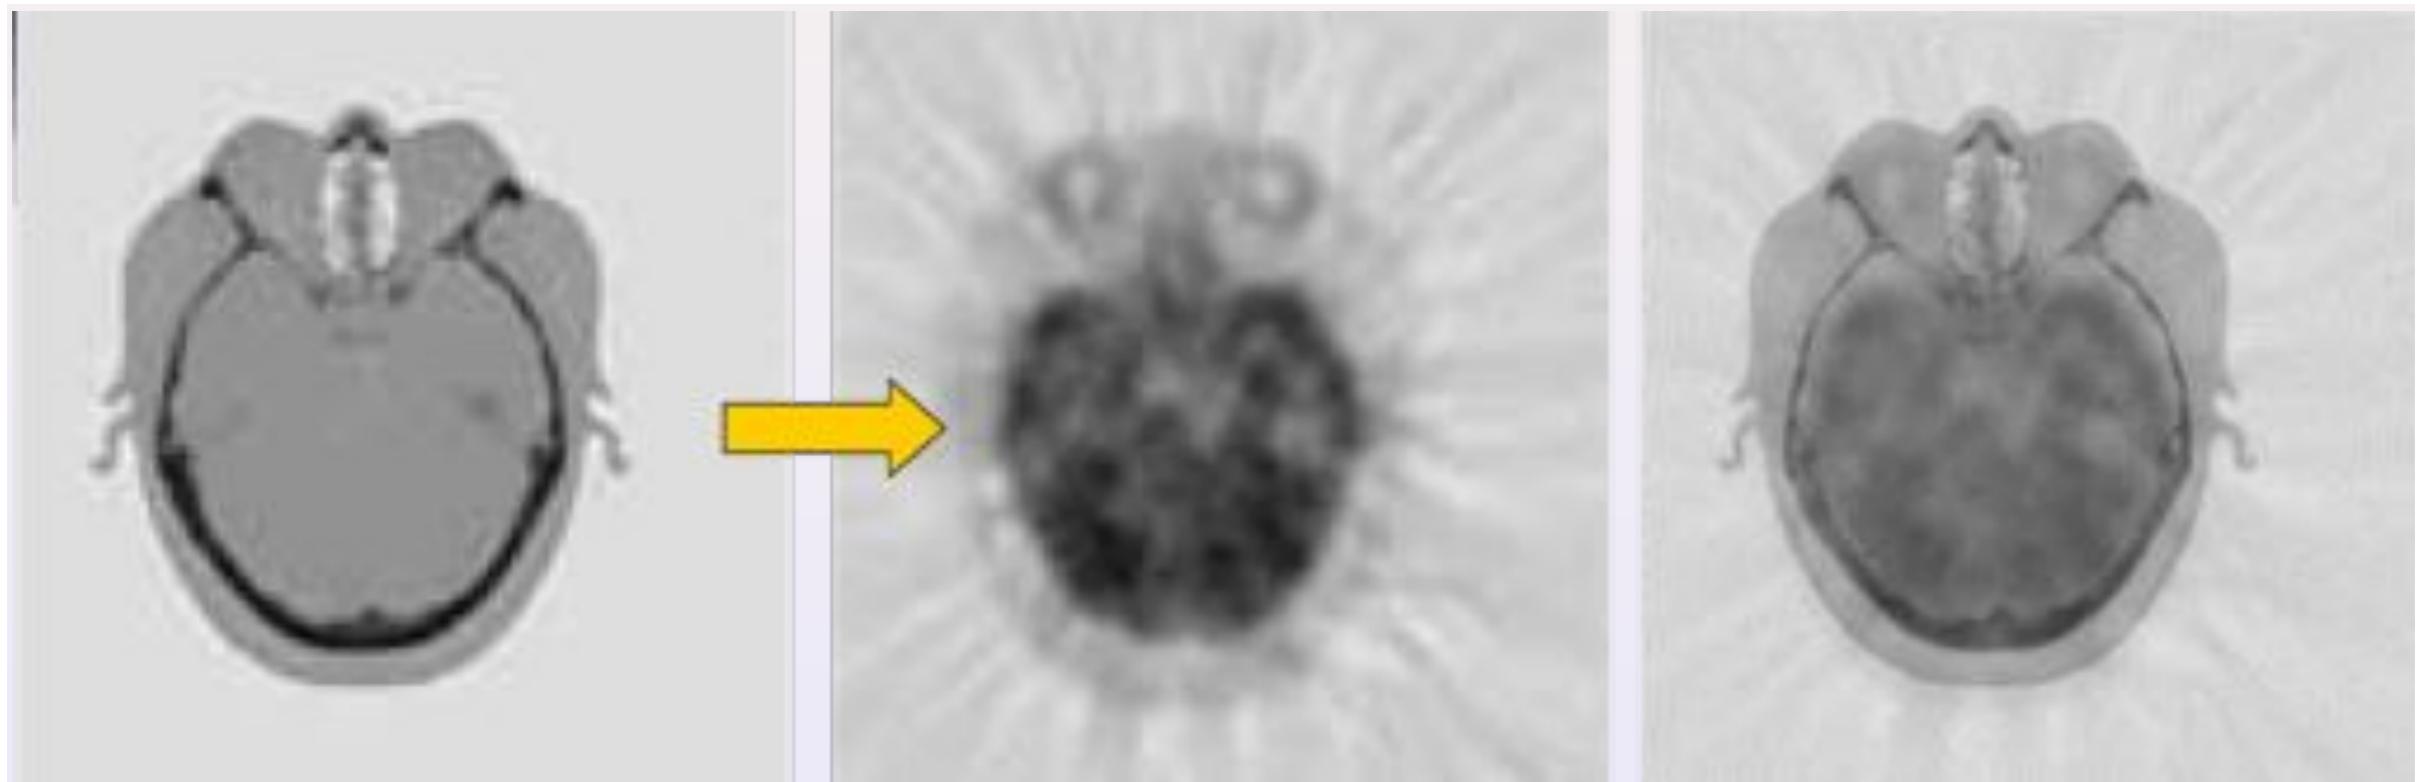
Aires plus activées par des phrases en langue française que par des phrases en langue étrangère

Pallier et al, Cerebral Cortex, 2003



# TEP/IRM

- Intra-patient. Multimodalité.



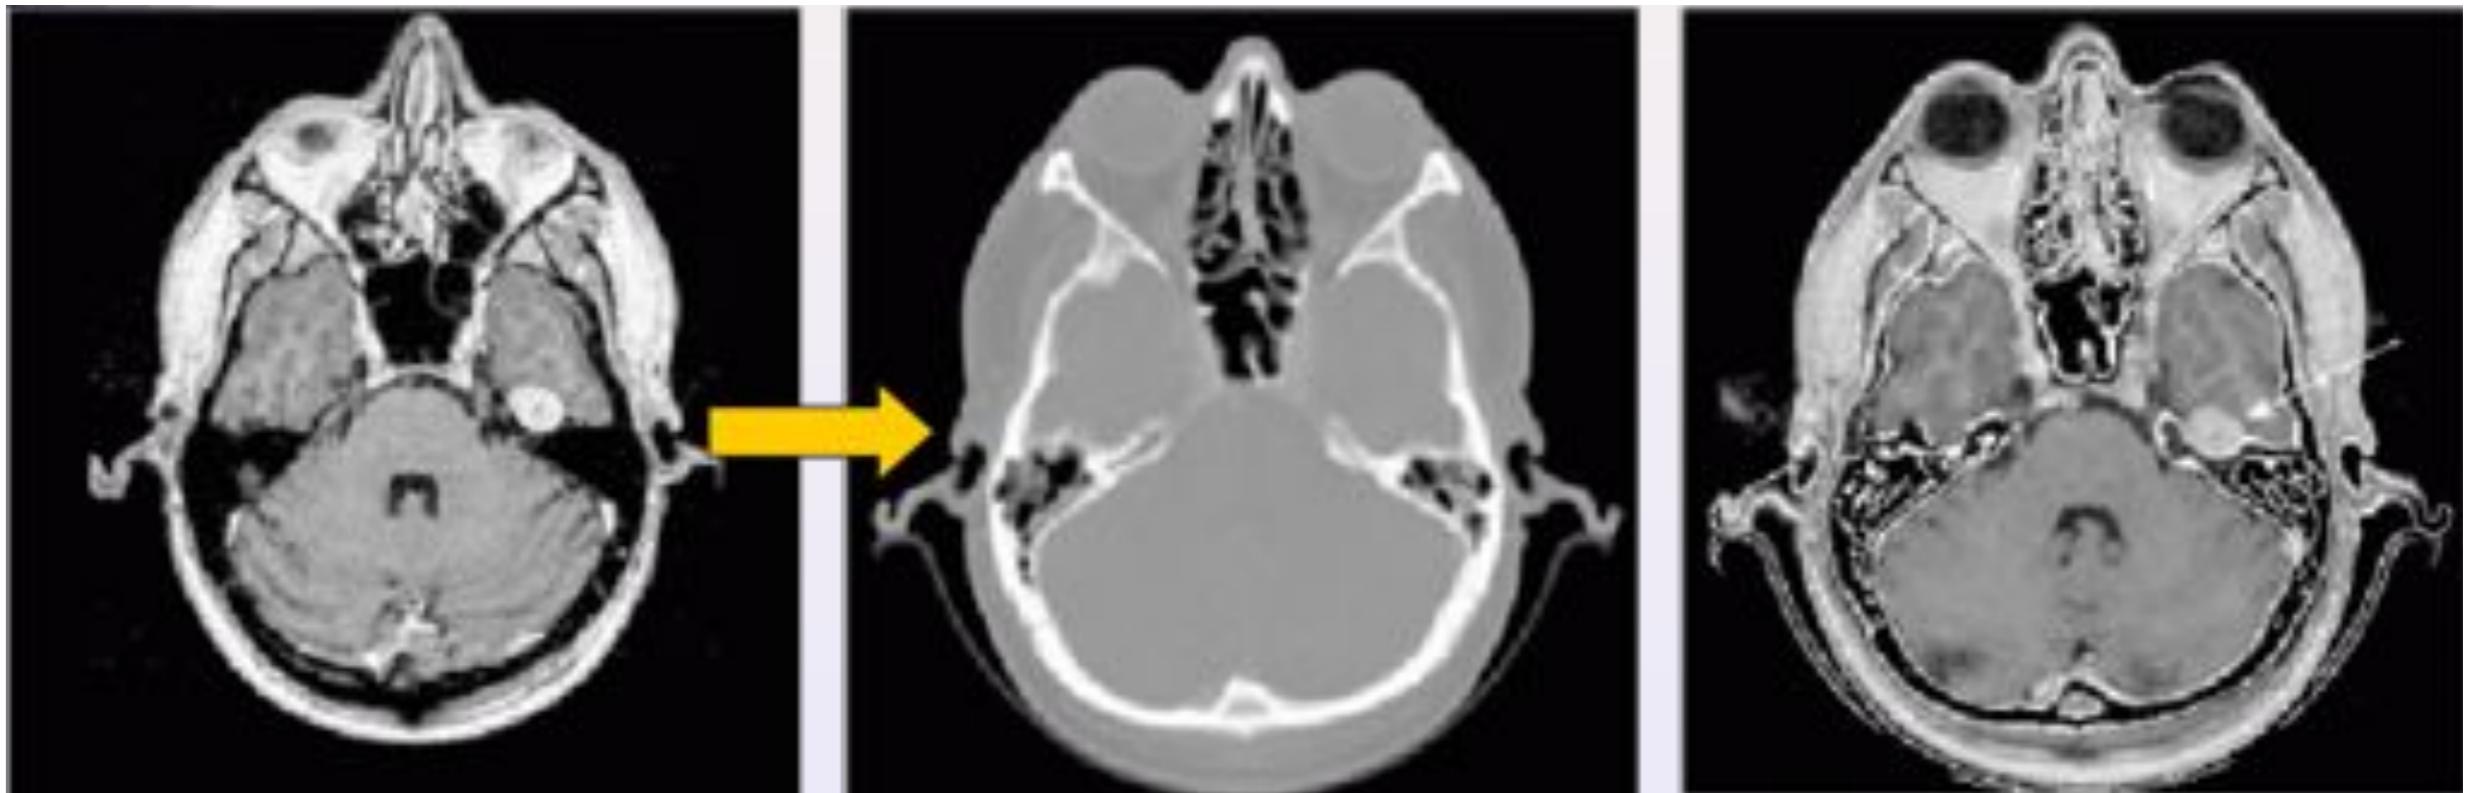
Source (Scanner)

Cible (TEP)

Fusion

Information mutuelle, similitude

# IRM/TDM



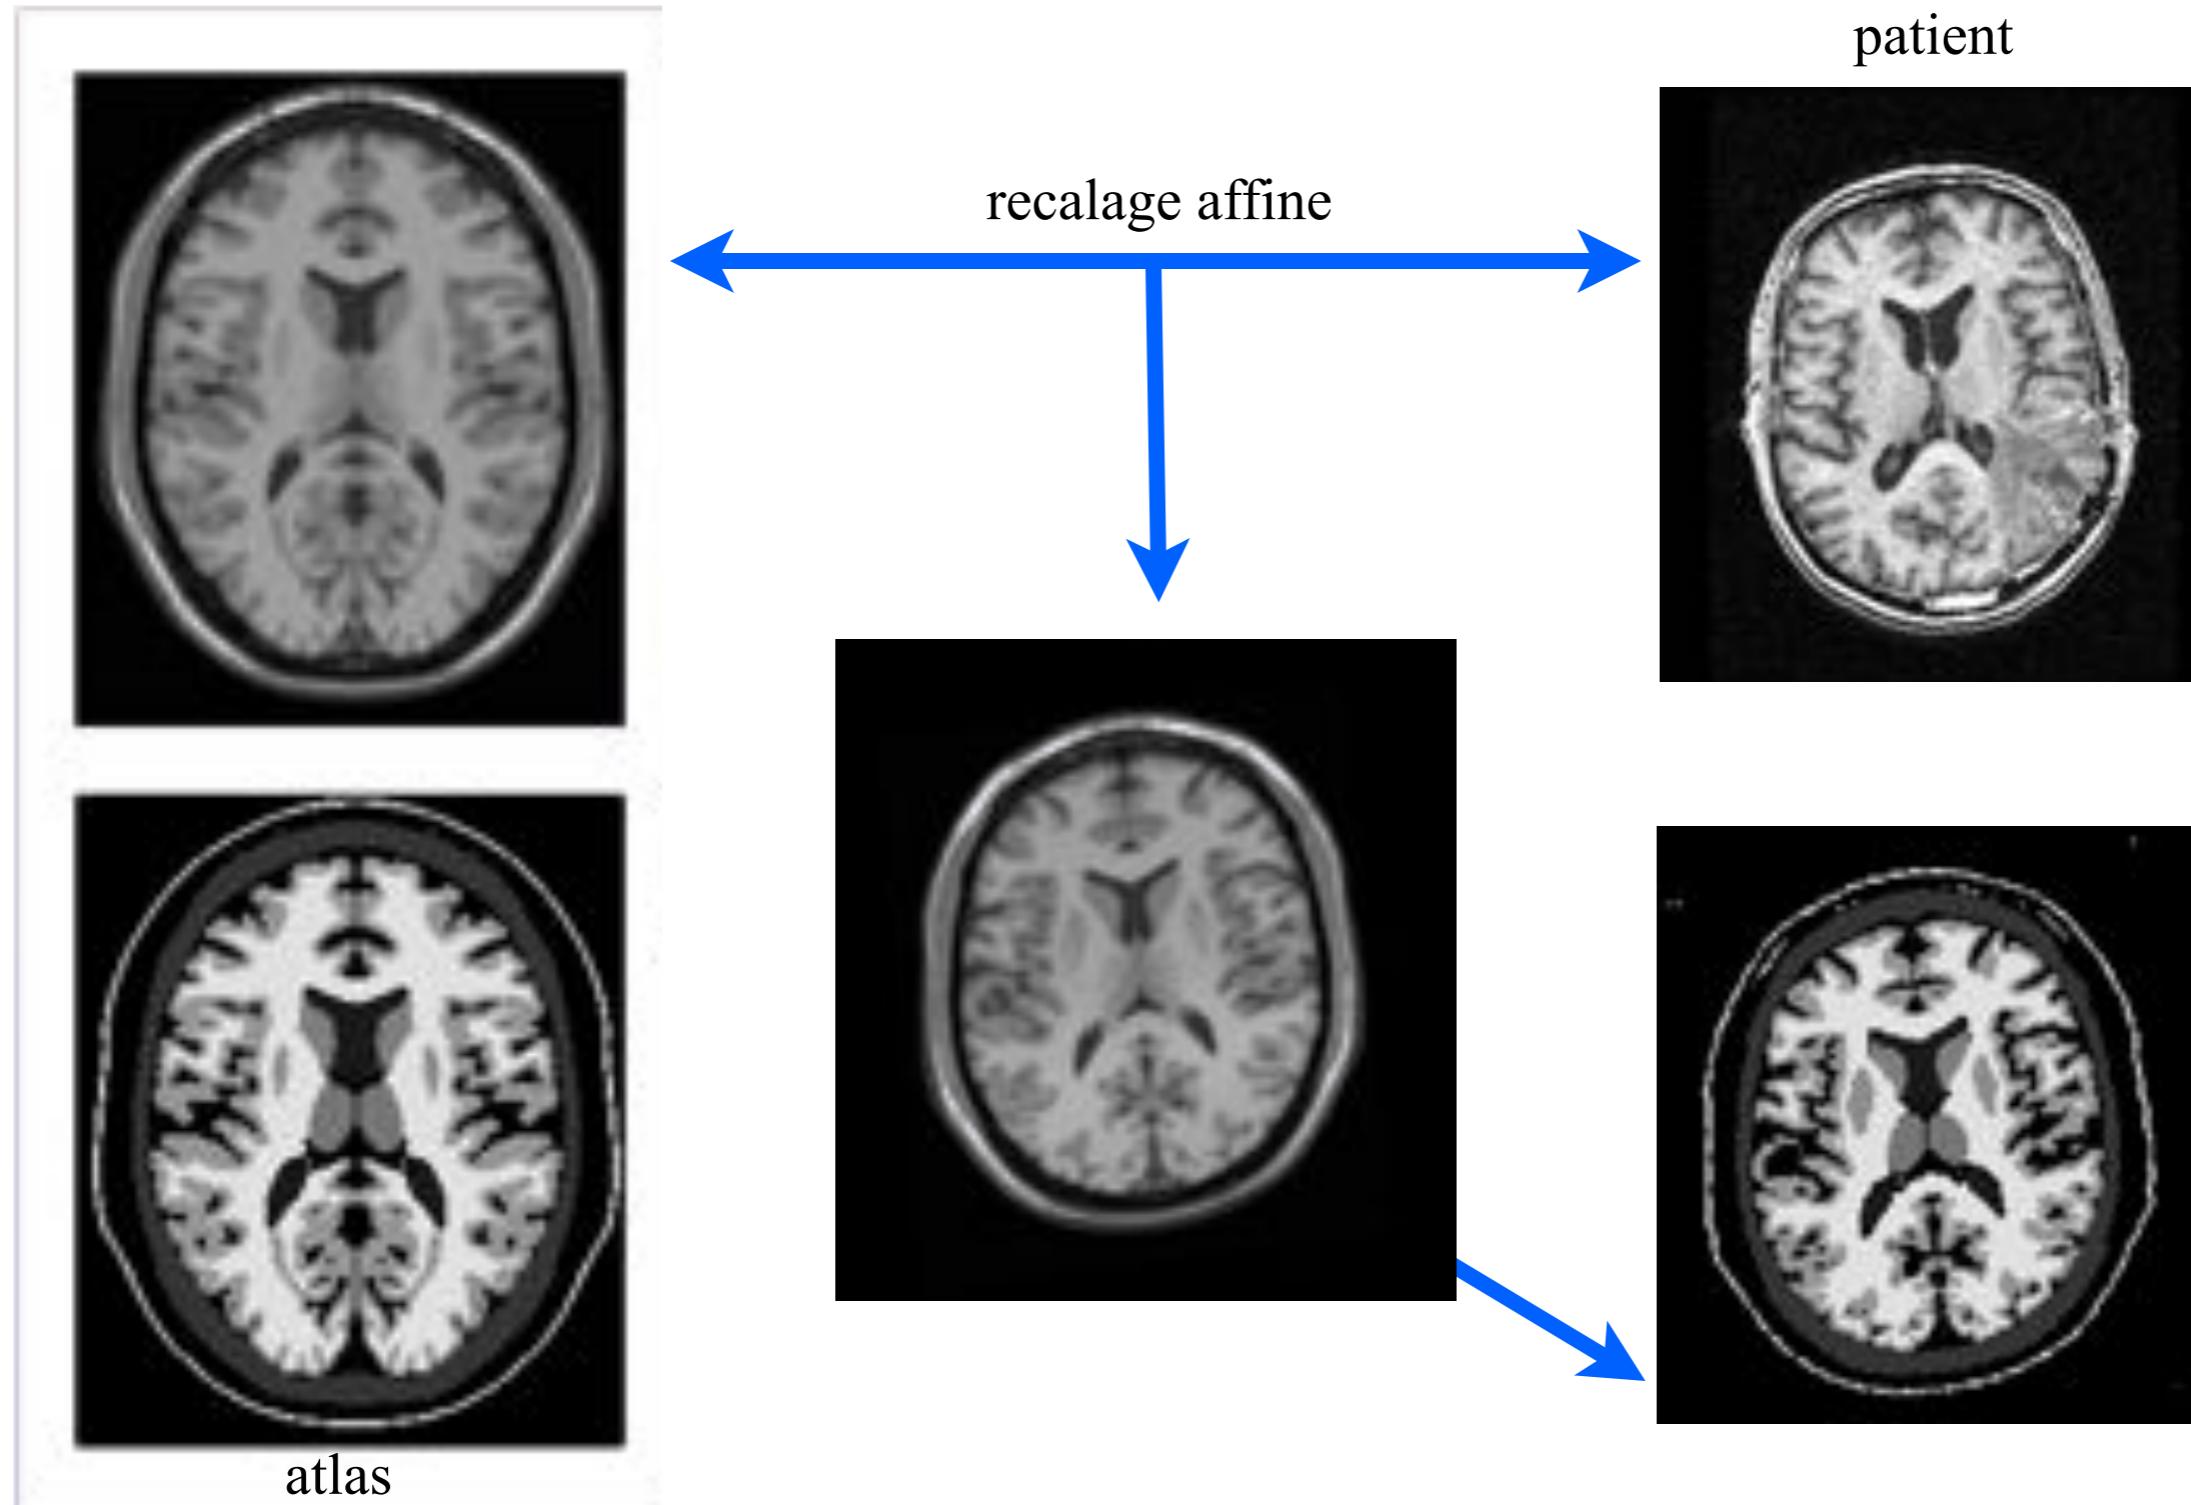
Source (IRM)

Cible (Scanner)

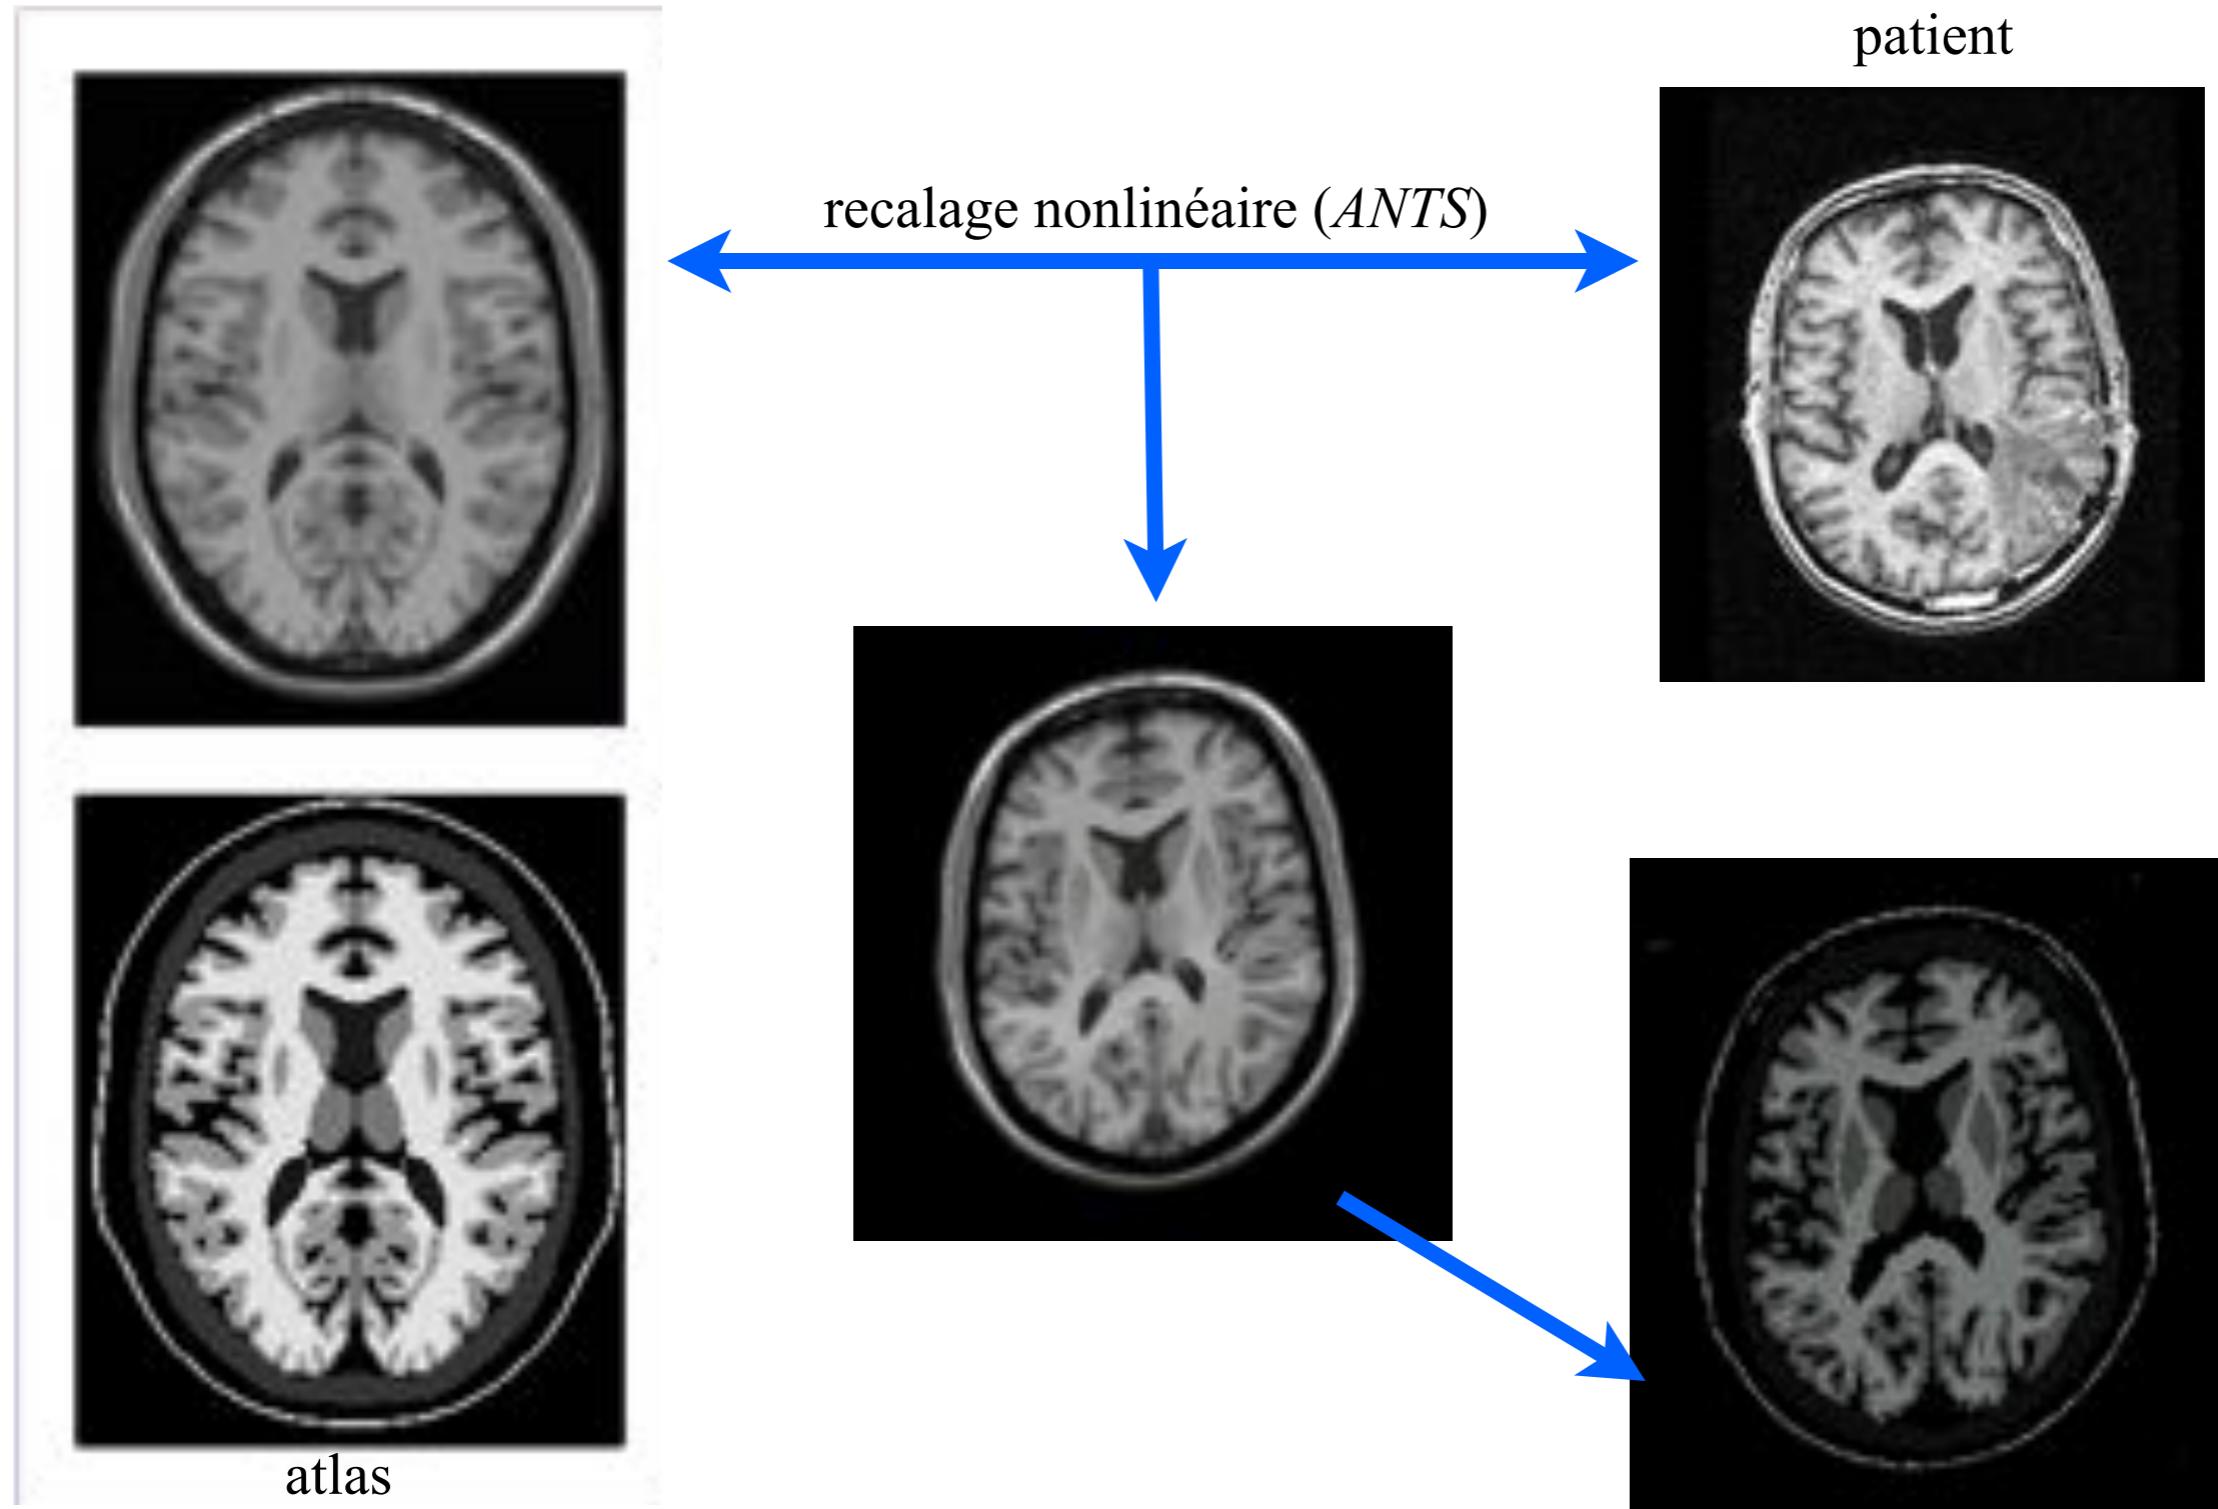
Fusion

Information mutuelle, similitude

# Atlas: inter-patient, intra-modalité



# Atlas: inter-patient, intra-modalité



# Affine vs non linéaire



Affine

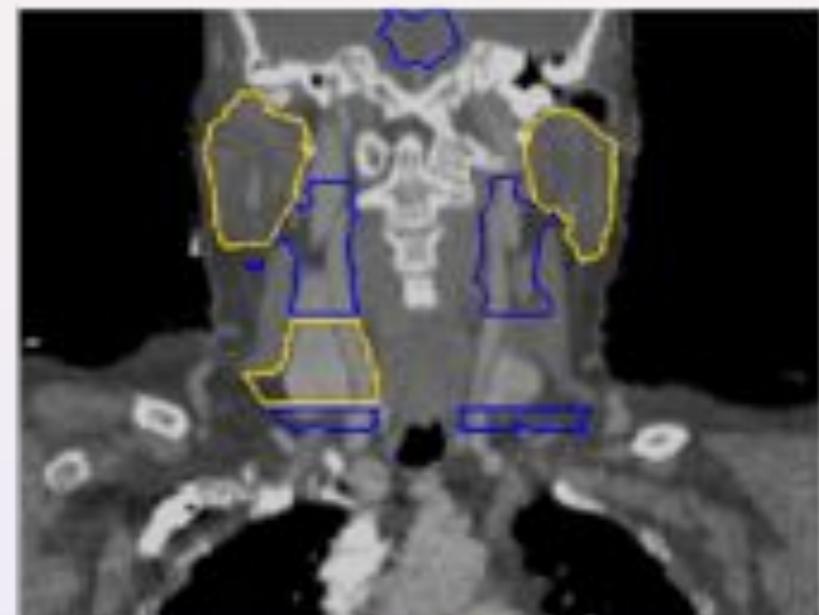


non linéaire

# Inter-patient, Intra-modalité

Segmentation par atlas, exemple : Tête et nuque

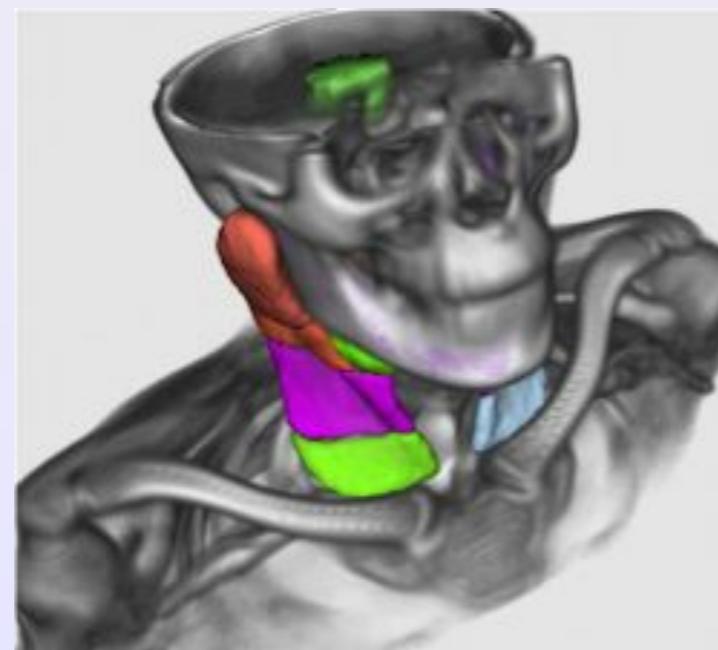
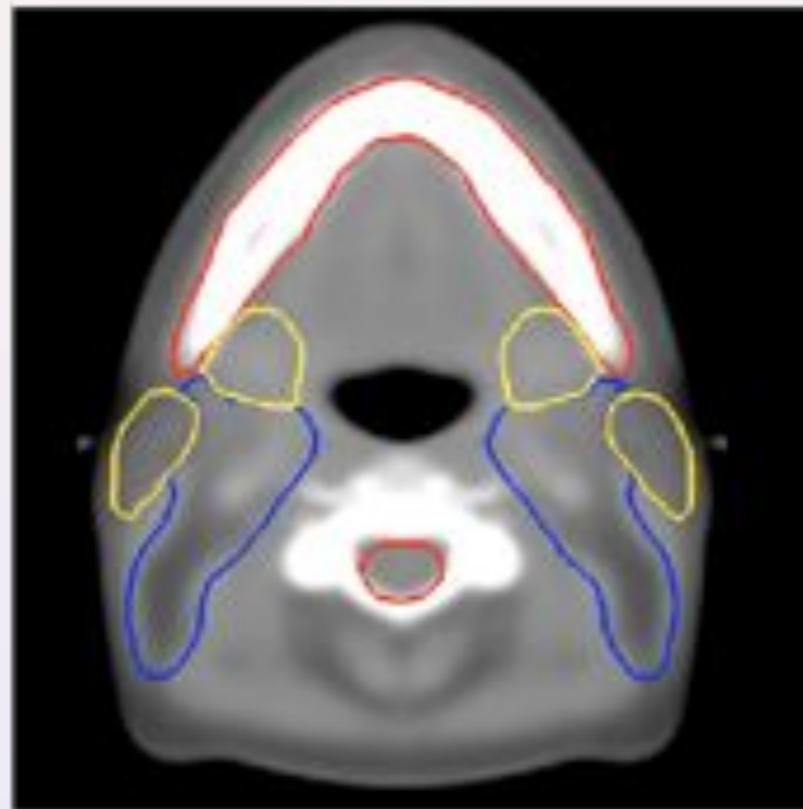
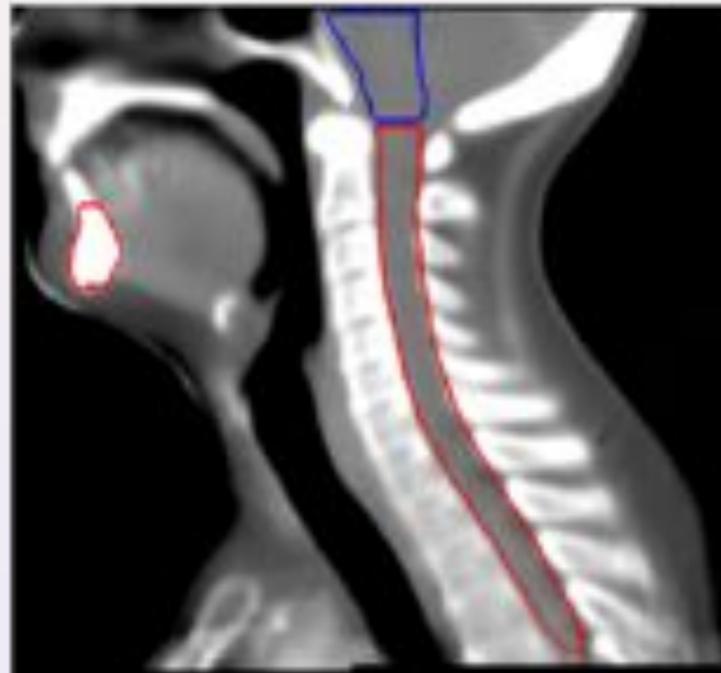
- Exemples de données



# Inter-patient, Intra-modalité

Segmentation par atlas, exemple : Tête et nuque

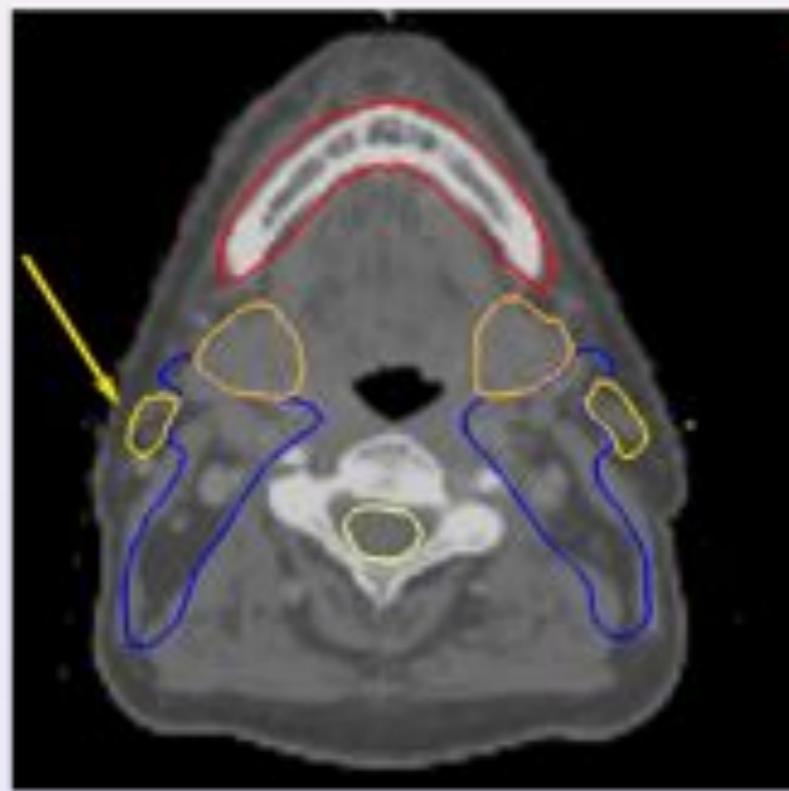
- Atlas obtenu



# Inter-patient, Intra-modalité

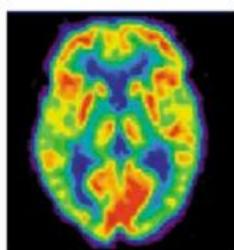
Segmentation par atlas, exemple : Tête et nuque

- Résultats (qualitatifs)

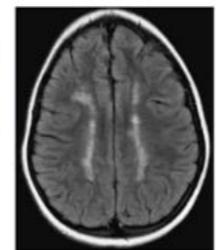


Segmentation par atlas

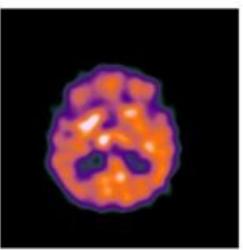
# Évaluation du recalage



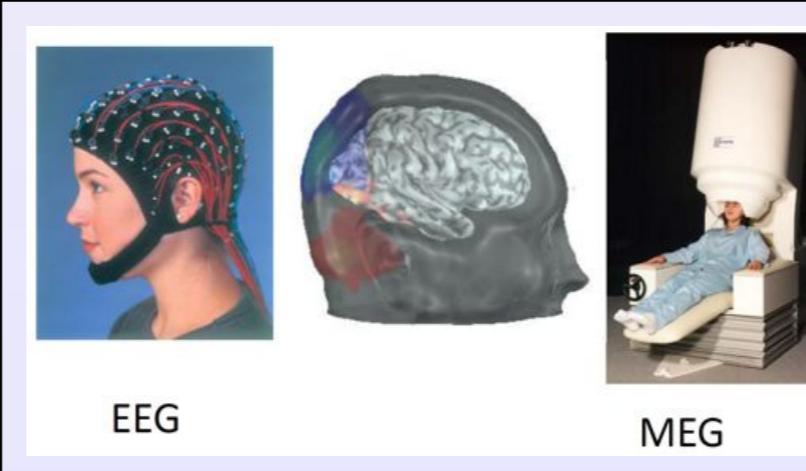
TEP



IRM



SPECT



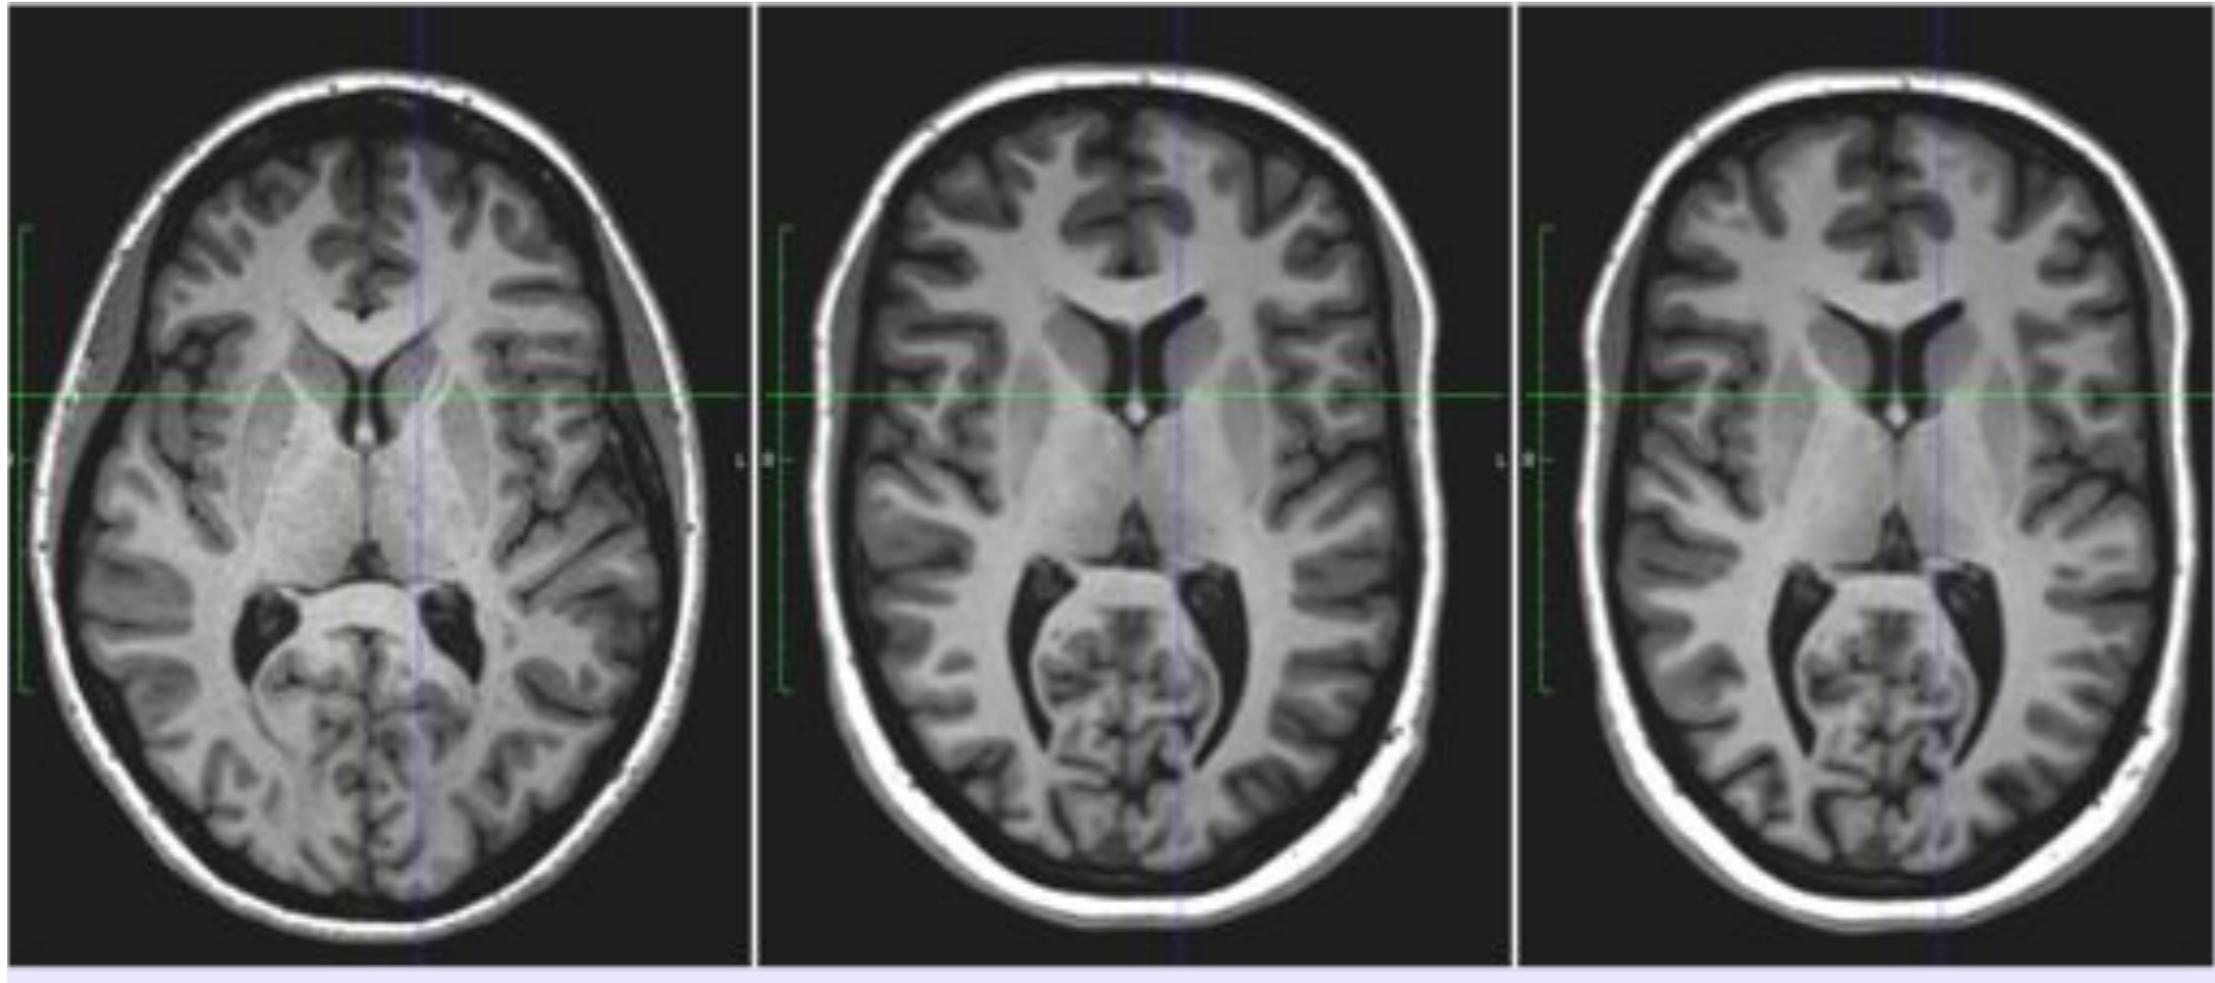
EEG



MEG

# Évaluation de recalage

- Comment évaluer quelle méthode fonctionne mieux?



# Différentes méthodes d'évaluation

- Visuelle (qualitatif)
- Semi-quantitatif
- Quantitative
- En fonction de l'application
  - Comparaison des images recalées
  - Comparaison des transformations (référence?)
  - Comparaison des segmentations obtenues (atlas)

# Évaluation qualitative

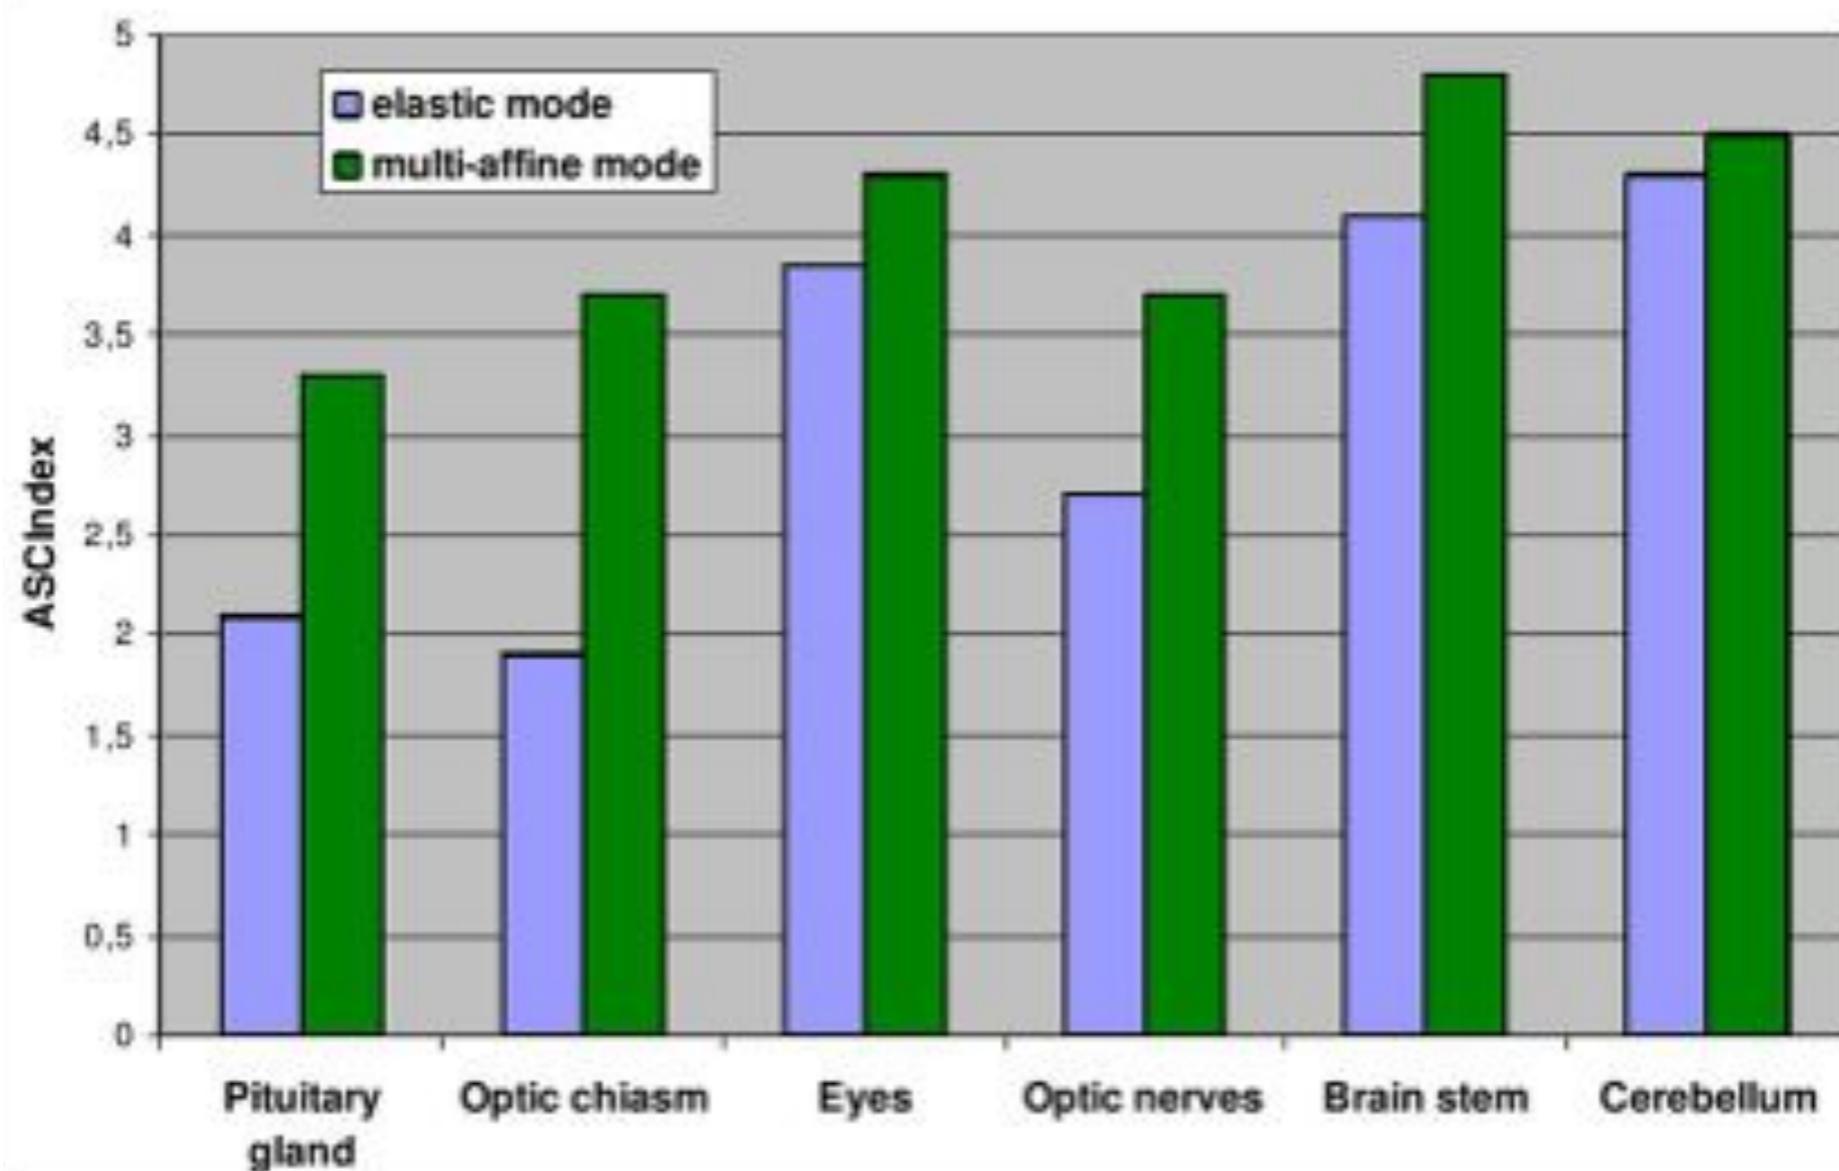
- Inspection visuelle par un clinicien ou un expert
- Souvent la première étape
- Avantages:
  - Inspection selon de multiples critères et connaissances *a priori*
  - Aucun développement nécessaire. Juste de la visu.
- Inconvénients:
  - Varie selon l'expert ou la personne (STAPLE)
  - Long: difficile à effectuer sur une grosse banque de données
  - Clinicien dure à attraper...

# Évaluation semi-quantitative

- Objectif: réduction de la subjectivité de l'évaluation qualitative
- Définition d'une échelle de notation
  - Basé sur des critères bien définis et identifiables (échelle CHIPS, European Task pour le vieillissement)
- Exemple
  - Évaluation de segmentation par recalage d'atlas
  - Score entre 0 et 5
  - 0 = aucun recouvrement
  - 5 = recouvrement parfait

# Évaluation semi-quantitative

- Comparaison entre deux méthodes de segmentation/recalage d'atlas



# Évaluation semi-quantitative

- Avantages:
  - Permet de prendre en compte des attentes précises
  - Moins subjectif, plus reproductible
- Inconvénients:
  - Reste subjectif
  - Difficulté d'une bonne définition de critères de notation
  - Difficile à utiliser pour des comparaisons de recalage pure

# Évaluation quantitative

- Objectif: produire des scores normalisés
- Avantages:
  - Critères objectifs, reproductibles, automatisés
- Inconvénients:
  - Critères plus simplistes
- Différents critères disponibles:
  - Comparaison d'intensité des images
  - Comparaison de transformations
  - Comparaison de landmarks
  - Comparaison de segmentations obtenues